

题目 1

解答

- 第一部分：先别急着看涨跌，把逻辑框架立起来
- 第二部分：为什么 VV 涨了，时长没涨？（拆解业务场景）
- 第三部分：我会直接建议“推全”吗？
- 第四部分：要深挖什么数据，才能做最终决定？
- 第五部分：高阶视角——能不能换个角度看收益？
- 总结与收束
- 本题复盘：知识点归纳

题目2

解答

- 第一部分：先把数字算清楚，别被“提纯”忽悠了
- 第二部分：业务视角，为什么“先浏览后登录”可能是个坑？
- 第三部分：关于“体验”的真相
- 第四部分：总结与建议
- 知识点复盘
- 面试官追问环节

题目 3

解答

- 第一部分：先把运营的那个“账”复盘一下
- 第二部分：活跃是「流量」，卸载是「存量」
- 第三部分：看不见的冰山——“关闭通知率”
- 第四部分：到底是“谁”在卸载？
- 第五部分：饮鸩止渴还是策略性牺牲？
- 第六部分：我的最终建议

题目4

解答

- 第一部分：别急着背锅，先看“归因”有没有问题
- 第二部分：拿出计算器，现场算这笔“糊涂账”
- 第三部分：京东特有的业务死角——自营 vs POP 的博弈
- 第四部分：功能本身的“劝退”嫌疑
- 第五部分：终极验证——AB 测试（不要猜，要测）
- 第六部分：战略视角——是“劝退”还是“良心”？
- 知识点归纳
- 面试官视角：

题目 5

解答

- 第一部分：先看量级，这不仅仅是“下跌”，这是“事故”
- 第二部分：拆解“效率陷阱”，运营没算错，但他想错了
- 第三部分：深挖商业模式，这笔帐真的划算吗？
- 第四部分：还原业务场景，到底发生了什么？
- 第五部分：数据验证，怎么用数据把运营怼回去？
- 第六部分：解决方案，不能只说不行，要说怎么做
- 总结本次解答的知识点：
(切换至面试官视角，发起新一轮追问)

题目 6

解答

- 第一部分：别被“效率”两个字忽悠了，先搞清业务本质
- 第二部分：深度拆解，数据哪里“不对劲”？
- 第三部分：别忘了，美团还要靠广告赚钱
- 第四部分：总结与行动建议

本题知识点归纳

题目 7

解答

- 第一部分：先把“感觉”放一边，建立分析框架
- 第二部分：验证 PM 的“体验提升论”
- 第三部分：CTR 下跌 10%，这可能是生态的“慢性毒药”
- 第四部分：别只说不行，得给解法
- 第五部分：决策结论
- 本次解答用到的知识点总结

题目 8

解答

- 第一部分：先把题目里的“坑”挖出来
- 第二部分：拆解“虚荣指标”，用 AB 测试思维反击
- 第三部分：深挖“0 播放”背后的生态危机
- 第四部分：给出你的判断与解法
- 第五部分：总结一下知识点

题目 9

解答

- 第一部分：先把账算清楚（别被忽悠了）
- 第二部分：为什么我不认可？
- 第三部分：那些你没想到的隐形伤害
- 第四部分：应该怎么看？怎么救？
- 第五部分：总结与行动建议

知识点复盘

追问解答

- 策略一：引入「智能摩擦」机制
- 策略二：千人千面的「上下文文案」
- 策略三：后端算法的「分层曝光」
- 第四部分：实验观测指标（一定要全）
- 第五部分：给老板的汇报话术

知识点复盘

题目 10

解答

- 第一部分：先把账算死，看看“赚了”是不是假象
- 第二部分：信任崩塌——用户的“心理账户”没有余额了
- 第三部分：生态灾难——供给侧的“负向螺旋”
- 第四部分：我的结论与分析师的建议
- 知识点总结归纳

追问解答

- 第一部分：搭建「三角制衡」的指标体系
- 第二部分：那个「唯一的决定性指标」是什么？
- 第三部分：分析师的延伸思考（加分项）
- 知识点总结归纳

题目 11

解答

- 第一部分：别看平均值，平均值是最大的骗子（辛普森悖论实战）
- 第二部分：时长的“含金量”——APP内停留时长 $\neq$ 内容消费时长
- 第三部分：这不仅仅是运营活动，这是在做“资金风控”
- 第四部分：更隐蔽的风险，是把算法给「喂傻」了
- 总结一下我的分析逻辑
- 本题复盘：知识点归纳
- 最后的面试官视角

追问解答

第一步策略：精准分层，建立「老用户保护区」

第二步策略：把「签到」改成「任务」，从“发钱”变成“买时间”

第三步策略：把「落地页」做成「种草机」

总结我的建议

本题复盘：知识点归纳（最后一次总结）

题目 12

解答

第一部分：先把基调定准——我们到底在卖什么？

第二部分：深度数据拆解——这 15% 和 30% 到底意味着什么？

第三部分：逻辑归谬——为什么我不信「优胜劣汰」？

第四部分：生态推演——全量上线后的结局

第五部分：作为分析师的最终建议

知识点总结

面试官视角：追问环节

追问解答

第一步：区分「完成任务」还是「内容太烂」？（意图识别）

第二步：建立动态评分模型

第三步：设计“挽留式”插入，而不是“阻断式”插入

第四步：AB 测试的验证方案

知识点复盘

题目 13

解答

第一部分：先排查数据，这“准时率”是不是在骗人？

第二部分：把账算死，12% 的成本真的值吗？

第三部分：被忽略的“骑手侧”风险

第四部分：既然不能全切，那该怎么办？

总结

面试官视角的反思与总结

追问解答

一、可能发生的负面情况

1. 收益侧：严重的“消费降级”

2. 履约侧：“极速达”变“欺诈达”

3. 供给侧：骑手挑单与博弈

二、监控指标体系

1. 核心护栏指标 —— 只要这几个跌了，马上回滚

2. 策略健康度指标 —— 判断功能是否良性

3. 诊断与风控指标 —— 谁在薅羊毛？

三、既然有风险，该如何应对？

总结给面试官的话：

题目 14

解答

第一层：为什么会跌？因为 30 分钟就是「满足阈值」

第二层：被忽略的致命伤——版权成本倒挂

第三层：PM 说的「养鱼」，逻辑通吗？

第四层：算一笔账，看看我们要「赢」得有多难

第五层：如果不一刀切，我们该怎么救？

总结一下

💡 知识点归纳

👤 面试官追问

追问解答

第一部分：思维转换——从「看净利」到「看资产保值」

第二部分：设计新的「防御 ROI 公式」
第三部分：具体的业务推演（怎么说服老板）
第四部分：防御战也不能「傻大方」
总结
💡 本题知识点归纳（最后复盘）

题目 15

解答

第一部分：先别被 ROI 蒙蔽，理清“增长”的真伪
第二部分：拆穿“唤醒”的文字游戏与平台算法的“共谋”
第三部分：算一笔残酷的账，揭示“利润双杀”
第四部分：如何用数据去“锤”这个结论？
第五部分：这事儿怎么收场？给业务方的建议
总结归纳
面试官视角

追问解答

第一部分：破题——既然看不清“人”，那就看“时间”和“规律”
第二部分：三个低成本的“代理指标”估算模型
第三部分：综合推演与业务修正
第四部分：知识点总结

面试 16

解答

第一部分：先算一笔精准的经济账（含物流与折损）
第二部分：流量成本与算法的“连坐”惩罚
第三部分：重新定义“虚假需求”
第四部分：分析师的破局建议
知识点小结

面试 17

解答

第一部分：先看一眼大盘，这事儿到底多严重？
第二部分：拆解毛利下跌（钱到底去哪了？）
第三部分：深挖复购下降（人为什么跑了？）
第四部分：必须做的数据推演（不算账就是耍流氓）
第五部分：策略调整与自救方案
总结归纳

追问解答

第一步：算清楚“肚子是不是撑着了”？（验证囤货假设）
第二步：建立“理论回购时间表”（精准定义流失）
第三步：看“谁”没回来？（人群结构归因）
总结一下
知识点归纳

面试 18

解答

第一步：永远先质疑数据
第二步：核心逻辑——辛普森悖论与用户结构变化
第三步：深挖业务场景，到底发生了什么？
第四步：给出针对性的建议
总结一下知识点
（切换至面试官视角）

面试 19

解答

第一步：拆解 ROI 公式，把“矛盾”量化
第二步：分析“虚假繁荣”的三个核心原因

第三步：深度验证，怎么用数据说话

第四步：给业务方的建议

知识点总结

面试 20

解答

第一部分：先把数字算清楚，逻辑就能自洽

第二部分：为什么流量会变“水”？

第三部分：怎么验证你的猜想？

第四部分：给业务方的建议

总结一下用到的知识点

知识点归纳（Coach Note）

面试 21

解答

第一部分：先别急着高兴，先把数字算清楚

第二部分：为什么次留涨了？（短期刺激的真相）

第三部分：为什么七留没变？（核心问题的暴露）

第四部分：怎么用数据实锤这些猜想？

第五部分：下一步建议怎么做？

知识点归纳总结

面试 22

解答

第一部分：先别急着找原因，先把那个“消失的数字”算出来

第二部分：业务维度的深度拆解（人、货、场）

第三部分：作为分析师，你的建议是什么？

总结归纳：分析中的知识点

（切换至面试官视角）

面试 23

解答

第一部分：需求侧，这 50% 的暴涨正常吗？

第二部分：供给侧，运力为什么成了瓶颈？

第三部分：匹配效率，中间商有没有赚差价？

第四部分：策略建议，怎么救？

解答中使用到的知识点总结：

（切换至面试官视角）

面试 24

解答

第一部分：把账算清楚，千万别被 0.2% 骗了

第二部分：除了卸载，还有一个更可怕的“隐形杀手”

第三部分：分层看问题，别搞“一刀切”

第四部分：我的最终决策建议

总结一下知识点

题目 25

解答

第一部分：排查思路——先把「价格」定义清楚

第二部分：现状分析——这算不算「杀熟」？合理吗？

第三部分：优化策略——如何既赚钱又不挨骂？

知识点归纳

好，这道题的完整逻辑大概就是这样。

面试 26

解答

第一部分：先把账算清楚，数字具有极强的欺骗性

第二部分：深度反驳“心智占领论”

第三部分：供给侧的崩塌——司机的“套利”行为

第四部分：如果是分析师，该怎么救场？

方案一：价格歧视与分层调度

方案二：平台侧的补贴转移（烧钱换心智）

方案三：动态的分时策略

第五部分：复盘总结

面试 27

解答

第一部分：先把数字算清楚，效率已经崩了

第二部分：滑动速度变快，是用户在通过“物理抵抗”

第三部分：留存率的欺骗性与生态的“慢性失血”

第四部分：我的策略建议

总结

附：面试官可能的追问

题目 28

解答

第一部分：先把大方向捋一下

第二部分：怎么用数据去验证这个「危险」？

第三部分：如何反驳「不要教育用户」这个观点？

第四部分：具体的解决策略（Next Step）

最后总结一下知识点

【面试官追问环节】

题目 29

解答

第一部分：先把数字算清楚，这里藏着一个“幸存者偏差”

第二部分：硬核拆解“业务负责人的自信”

第三部分：用数据验证，拒绝“我觉得”

第四部分：分析师的最终建议

知识点总结

现在，我切换回面试官视角。

题目 30

解答

第一部分：先别急着下结论，建立“生态健康度模型”

第二部分：拆解那个诱人的“暴涨 40%”

第三部分：深挖“举报率翻 3 倍”背后的财务账

第四部分：致命一击——供给侧的“格雷欣法则”

第五部分：我的结论与挽救方案

知识点总结

面试官视角（现在轮到我追问你了）

题目 31

解答

第一部分：别被“平稳”的留存率骗了，它是带毒的安慰剂

第二部分：算一笔账，用数字反推业务的脆弱性

第三部分：舆论爆炸与合规红线的“黑天鹅”

第四部分：不用“杀熟”，怎么赚到这 20%？

总结与建议

题目 32

解答

第一部分：先把“虚胖”的 GMV 还原成真实的资金流（数值推导）

第二部分：像侦探一样去抓“假人”的特征

第三部分：流量侧的猫腻，那是源头

第四部分：业务动机分析，为什么是现在？

第五部分：总结一下我是怎么得出结论的

解答中用到的知识点总结

面试官视角（追问环节）：

题目 33

解答

第一部分：先别急着反驳，要看懂为什么数据会涨

第二部分：拆穿繁荣的假象，你需要这两组数据

第三部分：用钱说话，把“时长增长”折算成“公司亏损”

第四部分：致命一击，关于留存与 LTV 的终极账本

第五部分：无法忽视的现实风险

第六部分：解决方案与话术建议

总结一下知识点

题目 34

解答

第一部分：把“糊涂账”拆成“明白账”

第二部分：带入数字，做一次“生死推演”

第三部分：拆解“用户第一”的陷阱与商家分层

知识点总结

题目 35

解答

第一部分：先拆穿“虚荣指标”的假象

第二部分：最难的一步，怎么证明是 AI 的锅，而不是运营不行？

第三部分：算总账，把“怨气”折算成“亏损”

第四部分：给老板的建议

总结一下知识点

面试官视角追问：

题目 36

解答

一、核心逻辑：为什么实验结果不可信？

二、第一坑：进门前的选择偏差（你选错人了）

三、第二坑：进门后的幸存者偏差

五、怎么避坑？（实战对策）

六、知识点总结

好，我的解答结束了。

题目 37

解答

第一部分：先搞清楚那4200个“废品”到底怎么回事

第二部分：给SKU贴标签，做个“大扫除”

第三部分：制定优化策略，别再犯傻了

第四部分：深挖一点，关于“库存成本”的算账

总结一下知识点

面试官视角追问

题目 38

解答

第一部分：核心决策逻辑

第二部分：PSM 倾向得分匹配，给用户找个“克隆人”

第三部分：DID 双重差分，上帝视角的“减法”

第四部分：终极组合拳 PSM + DID

总结一下

接下来，我要切换回面试官模式了。

题目 39

解答

- 第一部分：底层逻辑差异，一个是「上帝切蛋糕」，一个是「甚至找不到蛋糕」
- 第二部分：K-means 在会员设计中的三大「致命伤」
- 第三部分：K-means 真的不能用吗？它的正确打开方式
- 第四部分：结合一个具体场景把逻辑落地
- 第五部分：数据标准化的隐形坑

知识点复盘

最后，切换到面试官视角。

题目 40

解答

- 第一部分：别急着看模型，先看“作案现场”
- 第二部分：为什么它总是“高估”？拆解三个核心业务偏差
 - 第一，对“品牌词截流”的极度高估。
 - 第二，对“距离支付更近的渠道”的天然偏袒。
 - 第三，严重忽视“高客单价、长决策周期”的业务特性。
- 第三部分：既然这么坑，为什么大家还都在用？
- 第四部分：用数字证明一切——不同模型的计算推演
- 第五部分：高阶视角——从“分蛋糕”到“做实验”

知识点总结归纳

好，现在我是面试官

题目 41

解答

- 第一部分：先把数字算清楚，量化差距
 - 第二部分：最大的嫌疑人——流量来源与用户动机
 - 第三部分：设备端的隐形杀手——PC 端的占比
 - 第四部分：内容属性的“高冷”与“时效性”
 - 第五部分：产品体验与指标定义的坑
- 怎么验证这些猜想？

总结归纳

(面试官视角切换)

题目 42

解答

- 第一部分：先把数字算清楚，量化差距
 - 第二部分：最大的嫌疑人——流量来源与用户动机
 - 第三部分：设备端的隐形杀手——PC 端的占比
 - 第四部分：内容属性的“高冷”与“时效性”
 - 第五部分：产品体验与指标定义的坑
- 怎么验证这些猜想？

总结归纳

(面试官视角切换)

题目 43

解答

- 第一部分：不要背公式，先搞懂核心逻辑
- 第二部分：从理论到肉疼的现实
- 第三部分：业务视角的深度博弈
- 第四部分：总结一下核心知识点

(面试官视角切换)

题目 44

解答

- 一、先搞清楚咱们在争什么
- 二、带数字的业务场景推演（必考点）
- 三、深度业务决策：到底怎么选？
- 四、现实世界的残酷真相（必杀技）

五、总结归纳

面试官视角：追问环节

题目 45

解答

第一部分：核心逻辑的本质差异

第二回合：实战中的效率与算力推演（iForest 完胜）

第三回合：高维数据的诅咒（iForest 再胜）

第四回合：特殊场景——LBS与团伙挖掘（DBSCAN 的反杀）

第五回合：参数调优的难易度

总结一下实战策略

(切换至面试官视角)

题目 46

解答

第一部分：别被表象骗了，先算一笔账

模型一（预测很准，但排序错了）：

模型二（预测偏差大，但排序对了）：

第二部分：拆解 LTR 的三种进化路线

1. Pointwise（单点法）：披着 LTR 外衣的传统模型

2. Pairwise（配对法）：真正的 LTR 入门

3. Listwise（列表法）：上帝视角，但太贵了

第三部分：深入实战——不可导的痛点与 Lambda 的魔法

第四部分：业务中的隐形杀手——Position Bias（位置偏差）

方案一：将 Position 作为特征。

方案二：COEC（点击超越预期）。

第五部分：总结与知识图谱

面试官追问：

题目 47

解答

第一部分：先看一眼致命的账本（UE模型崩塌）

第二部分：深挖「人效下降30%」的业务真相

第三部分：虚荣指标 NPS 的陷阱

第四部分：如果我是负责人，如何救活这个项目？

第五部分：复盘总结与知识点

面试官追问（Next Question）

题目 48

解答

第一部分：先搞清楚这几个指标到底在说什么

第二部分：这组数据为什么看起来"矛盾"？

第三部分：深挖骑手差评率上升的可能原因

原因一：骑手为了赶时间牺牲了服务细节

原因二：准时宝改变了用户的评价心理

原因三：评价漏斗的变化

原因四：骑手群体结构发生了变化

原因五：订单结构发生了变化

第四部分：用户复购率为什么还能提升？

第五部分：如果我是分析师，怎么进一步拆解这个问题

第六部分：这道题的考察意图和实际业务建议

知识点总结

追问环节

题目 49

解答

第一部分：AB测试为什么会"失灵"？

场景一：已经发生的事情没法随机
场景二：不能做随机分组
场景三：随机分组有伦理问题
场景四：样本量不够做AB
场景五：选择性暴露

第二部分：那PSM到底是个什么东西？

第三部分：举个具体的例子，带数字

第四部分：PSM有哪些匹配方法？

第五部分：PSM的几个大坑

坑一：只能控制观察到的变量

坑二：共同支撑假设

坑三：模型设定的影响

坑四：匹配后样本量大幅缩水

第六部分：PSM在业务中的实际应用

案例一：营销活动归因

案例二：功能使用效果评估

案例三：政策效果评估

案例四：用户分层后的定价策略

案例五：广告渠道归因

第七部分：什么时候用PSM，什么时候用别的方法？

知识点总结

追问环节

题目 50

解答

第一部分：为什么简单比较不靠谱？

第二部分：回归不连续设计的核心思想

第三部分：具体怎么操作？带数字推导

第四部分：用图来理解会更直观

第五部分：回归不连续设计的关键假设

假设一：用户不能精确操控自己是否跨过门槛

假设二：门槛附近的用户特征连续变化

假设三：除了会员等级，没有其他干预在这个门槛上发生变化

第六部分：带宽选择的权衡

第七部分：RDD和其他因果推断方法的比较

第八部分：业务中哪些场景可以用RDD？

第九部分：实际操作中的注意事项

知识点总结

追问环节

题目 51

解答

第一部分：先搞清楚为什么首单转化率可能是个"虚假繁荣"

第二部分：LTV到底是什么？怎么理解？

第三部分：砍一刀用户的LTV该怎么算？带完整推导

第四部分：为什么不能只看首单？用数据说话

第五部分：不同渠道的LTV对比才有战略意义

第六部分：LTV计算中的几个坑

坑一：用户还没流失，怎么算生命周期？

坑二：不同用户差异太大

坑三：利润口径不统一

坑四：没考虑资金的时间价值

第七部分：LTV驱动的业务决策

知识点总结

追问环节

题目 52

解答

第一部分：先理解问题出在哪

第二部分：什么是增量测试？核心概念

第三部分：怎么设计增量测试？

问题一：直播是实时的，怎么做AB？

问题二：如果完全不显示购物车，对照组体验太差

问题三：用户可能有其他购买渠道

第四部分：更实际的增量测试设计方案

方案一：购物车位置/显著程度测试

方案二：时间差分法（上线前后对比）

方案三：地区分层测试

第五部分：用数字说明增量效应

第六部分：增量测试的几个关键概念详解

第七部分：为什么增量测试很重要？业务意义

第八部分：增量测试的局限性和注意事项

知识点总结

追问环节

题目 53

解答

第一部分：先把分享率这个指标拆清楚

第二部分：假设口径确认了，分享率下降的可能原因

可能原因一：用户结构变了

可能原因二：报告内容吸引力下降

可能原因三：分享路径或入口变了

可能原因四：外部环境变了

可能原因五：分享渠道受限或成功率下降

可能原因六：时间节点不对

可能原因七：报告触达方式变了

第三部分：排查的优先级和步骤

第四部分：DAU和用户时长增长，为什么分享率还下降？

第五部分：分析完之后怎么汇报？

知识点总结

追问环节

题目 54

解答

第一部分：为什么不能直接比较试点和非试点城市？

第二部分：双重差分的核心思想

第三部分：用公式更清楚地理解

第四部分：双重差分的关键假设——平行趋势

第五部分：完整的效果评估——算一笔财务账

第六部分：双重差分的几个变体和进阶

第七部分：实际业务中怎么用DID？

知识点总结

追问环节

追问解答

问题在哪？

结论会有什么偏差？

应该怎么处理？

总结

题目 55

解答

第一部分：为什么传统方法不好用？

方法一：直接对比广州和深圳

方法二：对比广州的今年和去年

第二部分：合成控制法的核心思想

第三部分：具体怎么操作？完整流程

第四部分：合成控制法的关键要求和假设

第五部分：怎么判断结论是否可信？

第六部分：合成控制法 vs 双重差分

第七部分：业务中还有哪些场景可以用？

知识点总结

追问环节

追问解答

问题在哪？

结论会有什么偏差？

应该怎么处理？

总结

题目 56

解答

第一部分：传统AB测试的问题在哪？

第二部分：多臂老虎机的核心思想

第三部分：几种常见的MAB算法

算法一：Epsilon-Greedy (ϵ -贪婪)

算法二：UCB (Upper Confidence Bound, 置信上界)

算法三：Thompson Sampling (汤普森采样)

第四部分：用Thompson Sampling跑一遍B站的场景

第五部分：实际业务中怎么落地？

落地步骤一：确定要优化的指标

落地步骤二：确定候选项和流量规模

落地步骤三：选择算法

落地步骤四：设置安全机制

落地步骤五：设置结束条件

第六部分：MAB vs 传统AB测试，什么时候用哪个？

第七部分：MAB的几个坑和注意事项

知识点总结

追问环节

追问解答

问题在哪？

应该怎么处理？

会不会影响之前的结论？

实际操作建议

题目 57

解答

第一部分：先搞清楚ROI是怎么算的

第二部分：完整拆解漏斗，带数据

第三部分：逐层对比找问题

问题一：下单率为什么从50%掉到30%？

问题二：客单价为什么从65元掉到55元？

问题三：补贴效率怎么样？

第四部分：根据分析给出建议

第五部分：漏斗分析的标准方法论

知识点总结

追问环节

追问解答

怎么优化？有几个方向可以考虑。

综合建议

题目 58

解答

第一部分：为什么归因这么难？

第二部分：常见的归因模型有哪些？

模型一：末次触点归因（Last Touch Attribution）

模型二：首次触点归因（First Touch Attribution）

模型三：线性归因（Linear Attribution）

模型四：时间衰减归因（Time Decay Attribution）

模型五：位置归因/U形归因（Position-Based/U-Shaped）

模型六：数据驱动归因（Data-Driven Attribution）

第三部分：用数据说明不同模型的结论差异

第四部分：哪个模型是对的？怎么选？

第五部分：数据驱动归因的核心思路

知识点总结

追问环节

追问解答

问题在哪？

怎么区分真实效果？

总结

题目 59

解答

第一部分：先确认问题的口径

第二部分：可能的原因假设

第三部分：排查的优先级和步骤

第四部分：可能的结论和建议

知识点总结

追问环节

追问解答

怎么解读这个现象？

对平台有什么影响？

平台应该怎么应对？

总结

题目 60

解答

第一部分：用一个干净的例子把道理讲透

第二部分：辛普森悖论的本质是什么

第三部分：这道题到底在考什么

第四部分：如果你是瑞幸的分析师，看到这数据该干嘛

第五部分：现实中辛普森悖论还会在哪儿出现

知识点总结：

追问：

【追问回答】

首先说说这两个指标各自反映的是什么。

我的回答是：两个都要看，而且要交叉分析。

题目 61

解答

第一部分：同期群分析到底是个啥

第二部分：整体留存率怎么就会骗人了

第三部分：同期群分析能帮你发现啥

第四部分：同期群分析怎么做

第四步，找规律找异常

第五部分：几个实战中的坑

知识点总结：

追问：

追问解答

第一，先看渠道结构有没有变

第二，看产品最近有没有大改动

第三，看用户画像有没有变化

第四，看外部环境

第五，做用户调研

第六，分层去看

第七，建立归因模型

题目 62

解答

第一部分：RFM是啥

第二部分：用RFM定位盒马的问题用户

第三部分：找到问题群体之后怎么干

第四部分：RFM的几个坑

第五部分：RFM的进阶玩法

知识点总结：

追问：

追问解答

题目 63

解答

第一部分：先把账算明白

第二部分：为什么折扣效果这么差

第三部分：这道题考什么

第四部分：如果你是海底捞的分析师该怎么做

第五部分：这活动到底值不值得做

知识点总结：

追问：

【追问回答】

第一，先把账算清楚：活动的真实ROI是多少

第二，看短期ROI之外的价值

第三，看那40%转移用户的后续行为

第四，我的建议：不是简单地继续或停止，而是优化规则

第五，如何向业务部门汇报这个结论

题目 64

解答

第一部分："没有显著差异"到底是什么意思

第二部分：为什么样本不够就看不出效果

第三部分：怎么在实验前算清楚需要多少样本

第四部分：实战里常踩的坑

第五部分：跑完了还是没显著性怎么办

知识点总结：

追问：

【追问回答】

第一，接受检测更大的效应

第二，换一个方差更小的指标

第三，用更高效的实验方法

- 第四，考虑是否真的需要AB实验
- 第五，接受更高的风险
- 第六，做定性验证而不是定量验证
- 第七，如何向业务方沟通这个问题

题目 65

解答

- 第一部分：先把问题拆开
- 第二部分：按渠道拆开看
- 第三部分：深挖各渠道的问题
- 第四部分：从用户画像维度看
- 第五部分：从产品体验维度看
- 第六部分：给出建议

知识点总结：

追问：

【追问回答】

- 第一步：理解业务部门的真实诉求
 - 第二步：用数据说话，但不是指责
 - 第三步：承认双方的诉求都有道理
 - 第四步：提出折中方案
 - 第五步：如果还有分歧，建议做测试
 - 第六步：把问题升级到更高层面讨论
- 关键心法总结

题目 66

解答

- 第一部分：幸存者偏差到底是啥
- 第二部分：工作中常见的幸存者偏差陷阱
- 第三部分：怎么避免踩坑
- 第四部分：几个真实场景的深度拆解

知识点总结：

追问：

【追问回答】

- 第一种方法：加上失败者做对比分析
 - 第二种方法：控制其他变量，做多因素分析
 - 第三种方法：做时序分析，检查因果方向
 - 第四种方法：设计AB实验验证因果
- 总结一下验证流程

题目 67

解答

- 第一部分：先把指标关系捋清楚
- 第二部分：频次下降的几种可能原因
- 第三部分：怎么判断频次下降是好事还是坏事
- 第四部分：如果是我会怎么具体分析
- 第五部分：频次下降到底是好事还是坏事

知识点总结：

追问：

【追问回答】

- 第一个方向：先排除"正常"的可能性
- 第二个方向：看竞品动态
- 第三个方向：看叮咚自己有没有变化
- 第四个方向：按品类拆分看频次变化
- 第五个方向：做用户调研
- 第六个方向：做留存和流失分析

第七个方向：做同比和环比分析
总结一下排查框架

题目 68

解答

第一部分：别被“3 倍转化率”冲昏头脑
第二部分：寻找那只“上帝之手”——工具变量 Z
第三部分：用 Wald 估计量算出真实 ROI
第四部分：深度业务解读与决策建议
总结知识点

追问

追问解答

候选一：用户手机型号 (是否是旗舰机)
候选二：用户所在区域的瞬时网络速度 (4G/5G/WiFi 信号强度)
最佳实践建议：寻找更纯粹的“技术故障”

题目 69

解答

第一部分：一个价值上亿的统计学陷阱
第二部分：为什么普通 t 检验会失效？
第三部分：正确的打开方式——Delta Method
第四部分：另一种武器——Bootstrap (自助法)
第五部分：总结与建议
总结知识点

追问

追问解答

1. 定义区别
2. 为什么它们不相等？（辛普森悖论的影子）
3. 业务影响：你到底想要什么？
4. 统计学上的坑：User CTR 的噪声极大
结论

题目 70

解答

第一部分：不仅是“浪费”，更是“亏损”
第二部分：营销四象限策略
第三部分：如何训练这个“读心术”模型？
第四部分：评估与实战坑点
总结知识点

追问

追问解答

1. 既然没有个体 Label, Loss Function 怎么算？
2. 树模型 (Uplift Trees) 的处理方式
3. 怎么验证模型准不准？
结论

题目 71

解答

第一步：回归指标定义，寻找数学上的“稀释效应”
第二步：用户分层拆解，还原真实业务场景
第三步：结合新版本须弥版本的特殊性进行“归因排查”
第四步：给出结论与建议

这时候，作为面试官，我会接着追问你一个问题：

追问解答

一、替代“时长”的黄金指标：分层后的“内容消耗率”
二、衡量“粘性”的进阶指标：DAU/MAU 并不够

三、总结

题目 72

解答

第一步：什么是 A/A 测试？它在测什么？

第二步：深度解析 $P < 0.05$ 的灾难性含义

第三步：业务场景推演（带数字）

第四步：怎么救？

这时候，作为面试官，我会追问你一个更刁钻的实战问题：

追问解答

一、什么是 SRM？为什么它比你想象的严重？

二、消失的用户通常是谁？（业务侦探环节）

三、为什么这会导致结果不可信？

四、总结与补救

题目 1

【字节跳动 | 数据分析师 | 二面真题】

为了提升 Feed 流的内容消费效率，你们调整了分发策略，略微提升了短视频的曝光占比。

实验结果显示：人均视频播放量（VV）显著提升了 15%。

但尴尬的一个点是：

人均总使用时长（Duration）完全持平，没有任何增长。

产品经理非常兴奋，认为：「VV 涨了说明用户互动更频繁、更活跃了，策略有效。」

如果你是分析师，

你会直接给这个实验「推全」的建议吗？你会倾向于认为这是体验变好了，还是体验变差了？

解答

它看着像是一个简单的 A/B 测试判定，其实是在考你对**指标体系的理解深度**以及对**用户体验的敏锐度**。

咱们今天就把这道题像剥橘子一样，一瓣一瓣拆得干干净净。这不仅仅是为了面试，更是为了以后你在工作中遇到这种“盲目乐观”的产品经理时，能有理有据地按住他。

第一部分：先别急着看涨跌，把逻辑框架立起来

拿到这道题，很多人的第一反应是去纠结 15% 到底是多还是少。不对，第一步应该是**还原业务过程**。

你要先建立一个最基础的公式，把这两个指标关联起来。这一步不做，后面的分析全是扯淡。

在 Feed 流（信息流）业务里，有一个恒定的公式：

人均总时长 = 人均 VV（播放量）× 单次播放平均时长

现在题目告诉我们：

1. 人均 VV 涨了 15%（变成了原来的 1.15 倍）。
2. 人均总时长 没变（维持在 1.0 倍）。

那么，根据小学数学我们也知道，**单次播放平均时长**一定发生了变化。

我们算一下：

$1.0 \text{ (总时长)} \div 1.15 \text{ (VV)} \approx 0.87$

也就是说，**用户的“单次播放时长”下降了约 13%**。

这意味着什么？意味着用户虽然刷的视频变多了，但每一个视频看的时间变短了。

好，框架立住了：**这是一个“以牺牲单均时长为代价，换取播放次数增长”的实验**。

在这个框架下，我们再去回答“体验变好还是变坏”，就不再是拍脑袋，而是基于场景的推理了。

第二部分：为什么 VV 涨了，时长没涨？（拆解业务场景）

产品经理觉得 VV 涨了是“互动更频繁”，这个结论下得太草率了。我们需要把这个数据结果，还原成真实的用户行为场景。通常有三种可能性，结局完全不同。

场景一：内容结构的被动变化（中性偏负面）

你们调整了策略，“提升了短视频的曝光占比”。这可能意味着，你们把原本推荐流里 3-5 分钟的“中长视频”，替换成了 15-60 秒的“短视频”。

用户原本花 5 分钟看 1 个长视频；现在花 5 分钟看了 5 个短视频。

- VV 从 1 变成了 5（大涨）。
- 总时长 还是 5 分钟（持平）。

如果是这种情况，VV 的增长仅仅是因为**内容载体变短了**，而不是用户更爱看了。这叫“虚假繁荣”。用户并没有因为这次调整多停留哪怕一秒钟，平台对于用户的粘性并没有真正提升。

场景二：快刷与跳过（明显的体验恶化）

这是最危险的情况。

策略调整后，可能推出来的短视频虽然多了，但**质量很差或者很标题党**。

用户点进去，看了 3 秒觉得不好看，划走；下一个，看了 5 秒，划走；再下一个……

- VV 蹭蹭往上涨（划走也算一次播放）。

- 总时长没涨，甚至可能因为频繁切换的疲劳感，用户提前退出了。

在这种场景下，VV 的提升代表的不是“活跃”，而是“筛选成本的增加”。用户在垃圾堆里找金子，不得不频繁滑动手势。这时候产品经理还在那高兴，简直就是灾难。

场景三：碎片化消费满足（唯一的正面可能）

除非，这个实验针对的是那些“碎片化时间”很强的场景（比如早高峰地铁、蹲坑）。用户本来就没耐心看长视频，你推短的，他刚好能完整看完几个。

但如果是这样，逻辑上总时长应该会有微涨才对，因为体验变好通常会带来“不知不觉多看了一会儿”。现在时长完全持平，我更倾向于前两种判断。

第三部分：我会直接建议“推全”吗？

结论是：绝对不会。

甚至我会比较悲观，我认为大概率是**体验变差了**，或者至多是**无效改动**。

现在的证据（VV+15%, Duration+0%）完全不足以支撑“推全”这个决策。产品经理看到的 VV 只是一个**过程指标**，而时长（Duration）才是内容消费产品的**北极星指标**（或者至少是核心护栏指标）。

拿过程指标的上涨来掩盖核心指标的停滞，这是数据分析里最大的坑。

第四部分：要深挖什么数据，才能做最终决定？

既然不能马上推全，作为分析师，你需要告诉面试官（或者业务方），我们还需要看哪些“**二阶指标**”来验证刚才的假设。

这一步是体现你专业度的时候，别只盯着那两个数看了。

1. 必须看“完播率”或“长播率”

既然单均时长下降了（变短了），那是因为视频本身变短了，还是因为用户没看完？

- **如果完播率维持稳定**：那说明这只是单纯的内容结构切换（场景一），用户还是把短视频看完了。这属于“无功无过”，可以考虑为了广告库存（如果你是靠展示广告赚钱的）推全，但别指望提升留存。
- **如果完播率显著下降**：实锤了，这就是场景二。用户在频繁跳过，体验变差，坚决回滚实验。

2. 必须看“次日留存”（Retention）

这才是检验体验的唯一真理。

如果这组用户今天刷得挺欢（VV 高），但因为全是水货短视频，觉得没意思，明天不来了。那今天的 VV 涨得再高也是透支未来。

如果 VV +15%，时长持平，但次日留存跌了 0.5%，这实验必须马上停掉。

3. 看看“负向反馈率”

去查一下这组用户点击“不感兴趣”、点击“举报”或者直接快速关闭 App 的比例有没有上升。VV 涨了 15%，如果“不感兴趣”的点击率涨了 50%，那这策略就是给用户喂垃圾。

第五部分：高阶视角——能不能换个角度看收益？

分析到这儿，基本分已经拿到了。但如果你想惊艳面试官，你需要跳出“用户体验”这个单一视角，结合**商业化**聊两句。

有些时候，哪怕用户体验（时长）没涨，这个策略依然**可能被推全**。为什么？

为了钱。

如果是信息流广告模式（Feed Ads）：

- 广告通常是插在视频流里的（比如每刷 5 个视频出一个广告）。
- VV 涨了 15%，意味着**广告库存（Ad Inventory）可能也涨了 15%**。
- 如果总时长没变，说明用户的**广告加载率（Ad Load）**其实变相提升了。

这时候的决策就变成了博弈：

我们愿不愿意用“用户体验的持平（甚至略微下降）”以及“单均时长的缩短”，来换取“广告位增加 15%”的短期商业收入？

这是一个战略选择题，不是简单的对错题。

但作为分析师，你必须把这个账算清楚告诉老板：“老板，用户没爽，但我们广告位多了。如果留存没跌，这事儿也许能干。”

总结与收束

回到题目，我的最终回答逻辑是：

1. **直观判断**：VV 涨但时长平，说明单次消费时长显著下降，大概率是用户在快速切换，体验存在风险。
2. **否定建议**：在没有更多数据前，**反对推全**。PM 的理由站不住脚。
3. **核心归因**：需要拆解是“视频本身变短了”还是“用户不耐烦跳过了”。
4. **关键验证**：必须补看**完播率、次日留存和负向反馈**。
5. **商业视角**：如果留存无显著负向，且 VV 提升能带来显著的广告收入增长，可以在监控长期留存的前提下，谨慎小流量尝试，但不能为了“活跃”而推全。

做数据分析，最怕的就是看着一个孤立的数字兴奋。VV 是面子，时长是里子，留存才是底子。别为了面子丢了底子。

本题复盘：知识点归纳

在刚才的拆解里，我们其实用到了好几个非常硬核的分析概念，我给你列一下，下次遇到别的题直接往上套：

- 1. **公式拆解法**：遇到复合指标（如总时长），先拆解成 $A \times B$ （VV $\times$ 单均时长）。这是寻找问题根源的最快路径。
- 2. **北极星指标 vs. 过程指标**：Duration（时长）/ Retention（留存）是北极星，代表价值；VV 是过程，代表动作。过程指标涨不代表价值涨，这叫“虚荣指标陷阱”。
- 3. **辛普森悖论的变体**：整体数据的表现（VV 涨）掩盖了内部结构的变化（单片时长跌）。
- 4. **护栏指标（Guardrail Metric）**：做实验不仅要看想提升的指标（VV），必须盯着不能跌的指标（留存、完播率）。
- 5. **商业化与体验的 Trade-off**：分析师不仅要懂用户体验，还要懂流量变现。VV 和广告库存的强相关性是很多面试的加分点。

OK，这道题的逻辑咱们已经彻底盘透了。

现在，我要切换回面试官的模式了。请听题：

（面试官面无表情地看着你，记了两笔笔记，然后抬头）

“分析得挺有道理。那你刚才提到了‘完播率’这个指标。

我想追问一下，在短视频业务里，5 秒的视频和 5 分钟的视频，天然的完播率差异非常大。

如果我们这次混排策略里，不仅增加了短视频，还引入了不同长度的视频混着推。

你如何设计一个‘标准化的完播率指标’，让我们能公平地对比不同长度视频的完播表现？或者说，怎么去衡量长短视频混合后的真实完播质量？”

题目2

【快手 | 用户增长 | 二面】

为了优化新用户体验，你们把「强制登录」改为「先浏览内容，触发互动后再登录」。实验数据显示：新用户的注册转化率下跌了 15%。

但出现了一个明显的利好：注册用户的次日留存反而提升了 10%。

业务同学的结论是：「虽然注册的人少了，但留下来的都是高意向用户，这波我们是在『提纯』用户，整体是赚的。」如果你是分析师，你会认可这个「提纯」的逻辑吗？你会判定这个改动是成功的，还是大概率是有问题的？

解答

这题要是答不好，基本就告别“增长分析师”这个岗位了。因为它暴露了你是不是只看率值（Ratio），而不看绝对值（Volume）。

咱们今天不整虚的，直接把这道题的分析框架给你，下次遇到类似的“率值打架”问题，直接套用。

第一部分：先把数字算清楚，别被“提纯”忽悠了

这道题最大的误导，就是那个好听的词——“提纯”。

听起来好像我们去掉了杂质，留下的都是金子。但做增长的核心公式是什么？是**DAU（日活跃用户）**的增量。

我们来做个最简单的数学推导。

假设在这个改动之前，进来的新流量是 1000 人。

场景 A（改版前）：

- 注册率我们假设是 50%（强制登录通常注册率较高）。
- 那么注册用户数 = $1000 * 50\% = 500$ 人。
- 次日留存率我们假设是 40%（随便设一个基准）。
- 最终留下来的活跃用户（留存用户）** = $500 * 40\% = 200$ 人。

场景 B（改版后）：

- 注册转化率下跌了 15%。这里的下跌通常指相对下跌（即原先的 85%）。
- 新的注册用户数 = $500 * (1 - 15\%) = 500 * 0.85 = 425$ 人。
- 注意看，这里我们已经直接流失了 75 个注册用户。

接下来看留存。题目说留存提升了 10%。这里有个常见的坑，是绝对值提升（+10%）还是相对提升（ $\times 1.1$ ）？在严谨的分析中，如果没有特指，我们通常先按**相对提升**来估算最保守的情况，或者我们需要算一个“盈亏平衡点”。

- 如果是相对提升 10%：
- 新的留存率 = $40\% * (1 + 10\%) = 44\%$ 。

- **最终留下来的活跃用户** = 425（新注册数） * 44%（新留存率） = **187 人**。

算账结果出来了：改版前留下 200 人，改版后留下 187 人。结论：总的留存用户数反而下降了 **6.5%**。

哪怕我们乐观一点，假设那个“提升 10%”是绝对值提升（也就是留存率从 40% 变成了 50%）：

- 最终留下来的活跃用户 = 425 * 50% = 212.5 人。
- 这种情况才刚刚回本，略有盈余。

但在实际业务中，仅仅因为把登录后置，留存率很难直接发生“绝对值暴涨 10 个点”这种质变。通常留存的提升，仅仅是因为分母变小了（分母里去掉了那些本来就会流失的人），这是“**幸存者偏差**”，而不是产品价值真的变高了。

所以，作为分析师，你的第一个判断必须是：从数学期望上看，大概率是亏的。因为漏斗上层（注册）的 **15% 跌幅**，通常很难被漏斗下层（留存）的 **10% 涨幅** 完全对冲掉。

这就是数学上的“乘法效应”： $0.85 * 1.1 = 0.935$ 。两个因子一乘，整体还是小于 1 的。

第二部分：业务视角，为什么“先浏览后登录”可能是个坑？

算完了数，我们再来聊聊业务逻辑。为什么我说业务同学觉得“提纯是好事”这个观点很危险？

这里涉及到一个核心概念：**用户资产化**。

在快手、抖音这种平台，一个“游客”和一个“注册用户”，对于平台的价值是天壤之别。

1. 触达能力的丢失

只要用户注册了（哪怕是被强制的），我就拿到了他的 ID、手机号或者设备指纹。他明天不来？我可以发 Push、发短信召回他。但他如果不注册只是逛一逛就走了？他就成了一个“**幽灵用户**”。他走了就是走了，挥一挥衣袖，我不带走一片云彩，你也别想再找到我。放弃 15% 的注册用户，意味着我们放弃了对这 15% 人群的“**后续召回权**”。这在买量成本极高的今天，是巨大的资产浪费。

2. 算法冷启动的困境

“先浏览”意味着用户在非登录状态下看视频。这时候算法很难精准构建用户画像（特别是跨设备时）。如果你没法在第一时间给新用户推他爱看的东西，他的体验不仅不会变好，反而可能因为推荐太泛化而流失。所谓的“优化体验”，可能只是我们的一厢情愿。

3. 商业化的损失

不登录，很难做精准广告变现，也很难做直播打赏。一个非登录用户的 LTV（全生命周期价值），通常远低于登录用户。所以，为了所谓的“体验”牺牲掉“账号体系的完备性”，这笔账在 LTV 层面大概率也是算不过来的。

第三部分：关于“体验”的真相

咱们再深挖一层。业务同学说把登录放在“触发互动”后，是优化体验。真的吗？

想象一下这个场景：你正看得起劲，想给个视频点个赞，或者想看一眼评论区。啪！弹出一个登录框：“请先登录”。这种“中断式”的打断，往往比一开始这就让你登录（预期管理）更让人烦躁。

这叫“阻断心流”。我们在用户最想交互的时候泼一盆冷水，这大概率会造成互动率的暴跌。而互动（点赞、评论）又是留存的魔法指标。所以，把登录后置，不仅可能丢了注册，还可能连带着把“互动率”也搞崩了。

第四部分：总结与建议

回到面试题，如果我是分析师，我会这样回答：

我不认可业务同学“提纯是赚的”这个结论，大概率是亏的。

我的判断逻辑是：

- 数学账算不过来：**注册跌 15% 带来的量级损失，很难被留存涨 10% 补回来 ($0.85 * 1.1 < 1$)。活跃用户绝对值在缩水。
- 资产流失风险：**未注册用户的召回能力和 LTV 远低于注册用户，我们在人为制造“幽灵流量”。
- 幸存者偏差误导：**留存率的提升是因为分母（低意向用户）变小了，而不是产品体验真的变好了。

我的建议是：不要看“率”，要看“量”。立刻拉出“次日留存用户绝对值”和“LTV（生命周期总价值）”这两个指标。如果绝对值跌了，建议立刻回滚版本，或者采用折中方案（比如浏览 3 个视频后强制登录，而不是完全放开）。

知识点复盘

解答这道题，我们用到了以下几个关键分析思维，大家可以拿小本本记一下：

- 绝对值 vs 比率 (Volume vs Ratio)：**这是最常见的面试坑。当面试官告诉你两个比率一涨一跌时，必须第一时间去算绝对值的变化（盈亏平衡公式）。永远记住：公司是靠赚“绝对值的钱”活着的，不是靠“高转化率”活着的。
- 幸存者偏差 (Survivorship Bias)：**当筛选门槛变高（或者变低）时，留存率的波动往往是因为样本结构变了，而不是产品变了。这时候看比率没有意义。
- 流量资产化 (Traffic vs Asset)：**在用户增长 (UG) 领域，注册 ID 是核心资产。没有 ID 的流量只是过客。放弃注册率就是放弃资产沉淀，这个战略定性比数据计算更显你的业务 Level。
- 阻断点分析 (Friction Point)：**体验优化不是简单的“减少步骤”，而是要看步骤出现在哪里。心流中的阻断比启动时的阻断更伤人。

面试官追问环节

（现在我是你的面试官，听完你刚才精彩的分析，我点了点头，然后在笔记本上记了几笔。我抬起头，看着你的眼睛，抛出了下一个问题）：

“这笔账你算得很清楚，逻辑我也认同。0.85 乘以 1.1 确实小于 1。

但是，如果我们发现，虽然整体留存用户数少了，但这批留下来的用户，他们的人均时长和人均广告变现效率（ARPU）都比以前高了 20%。

也就是说，用户确实变少了，但剩下的这批人真的更值钱了，总盘子的收入反而是微涨的。

在这种情况下，作为快手的分析师，你会建议保留这个‘先逛后登’的策略吗？还是依然坚持回滚？这就涉及到我们现阶段战略取舍了，你怎么看？”

题目 3

【拼多多 | 经营分析 | 二面】

为了冲刺年底 KPI，你们针对「沉默用户」加大了 Push 推送的频率（从每天 1 条增加到 3 条）。效果立竿见影：当天的 DAU（日活）直接拉升了 8%，这是很久没见过的涨幅。

但你发现了一个危险信号：当天的「APP 卸载率」同时也翻了一倍。

运营负责人的态度是：「怕什么？算一下账就知道，拉回来的用户量级 远远大于 卸载走的那一点点人，整体肯定是赚的。」如果你是分析师，你会认可这种「加减法」算账的逻辑吗？你会判定这次策略是成功的，还是属于「饮鸩止渴」？

解答

这道题很有意思，它是典型的「拼多多风格」——既要凶猛的增长，又要极致的效率，但往往伴随着巨大的争议。

这不仅仅是一道算术题，更是一道「业务价值观」的判断题。那个运营负责人的话听起来是不是特别有道理？“赚的大于亏的，为什么不干？”

如果你在面试里点头说“对啊，赚了就是赚了”，那大概率就挂了。因为你只看到了今天的报表，没看到明天的坟墓。

咱今儿就把这道题拆开了揉碎了讲讲，怎么用数据去反驳这种“看似正确”的短视逻辑。

第一部分：先把运营的那个“账”复盘一下

我们得先承认，运营负责人的逻辑在数学上可能暂时是成立的。为了让大家更有体感，咱们假设一组数据（面试的时候如果没给数，你就这样假设，面试官会很喜欢这种具象化的能力）。

假设这个沉默用户池子里有 100 万人。

平时的日活（DAU）转化率可能是 5%，也就是 5 万人。

平时的卸载率是 0.1%，也就是 1000 人。

现在 Push 加大了，变成一天 3 条：

DAU 涨了 8%。原来的 5 万人变成了 5.4 万人，多了 4000 个活跃用户。

卸载率翻倍了，变成 0.2%。原来的 1000 人变成了 2000 人，多走了 1000 人。

运营一看：

“你看！我找回了 4000 个活人，只牺牲了 1000 个卸载的。净赚 3000 人！这买卖太划算了，必须搞！”

听起来是不是无懈可击？

这就是这道题最大的陷阱。这个逻辑把「活跃」和「卸载」看成了同等权重的加减法。

但它们根本不是一种东西。

第二部分：活跃是「流量」，卸载是「存量」

这里的核心反驳点在于：**时间维度不对等**。

今天的 DAU 只是「今天的」状态。那个被拉回来的沉默用户，他今天点开了 APP，不代表他明天还会来，更不代表他下个月还在。他可能只是误触，或者被标题党骗进来瞄了一眼又走了。这 4000 个增量，大部分可能是「一次性」的。

但是，那 1000 个卸载用户，却是「永久性」的损失。

用户一旦卸载，召回的成本是极其高昂的。你要重新投广告、重新让他下载、重新登录.....这个链路长得可怕。

所以运营的那个公式：收益 = 新增 DAU - 新增卸载 是完全错误的。

正确的公式应该是：

收益 = (新增 DAU * 这些人留存下来的概率 * 他们的 LTV) - (新增卸载 * 重新召回他们的成本)

哪怕不做复杂的 LTV（生命周期价值）计算，光从用户心理上讲，卸载用户往往带着极强的负面情绪。这种情绪是会传染的，而且卸载往往意味着我们失去了唯一的触达渠道。

用流失一个「永久触达机会」去换取一次「大概率是一次性」的活跃，这在战略上大概率是亏的。

第三部分：看不见的冰山——“关闭通知率”

这还没完。比卸载更可怕的，是那些「没卸载但关了通知」的人。

你想啊，面对一天 3 条的狂轰滥炸，性格刚烈的直接卸载了（那翻倍的 0.2%）。但还有一大批人，他们懒得卸载，或者偶尔还得用拼多多砍一刀，他们会做什么？

他们会去系统设置里，把 APP 的推送权限给关了。

这个数据，通常比卸载率要高出一个数量级。

如果卸载率翻倍了，我有理由怀疑，「关闭通知率」可能涨了 3 倍甚至 5 倍。

这部分人虽然今天还在 DAU 里（因为被点进来了），甚至没卸载，但他们变成了「死户」。

因为你再也 Push 不到他们了。

拼多多这种电商模式，极其依赖 Push 来做低成本的促活。如果你把用户的 Push 开关给“作”没了，这就是把未来的路给堵死了。

所以，我绝对不会只看「卸载率」，我一定会要求看当天的**「系统通知权限关闭率」。这才是真正的隐形杀手。

第四部分：到底是“谁”在卸载？

再往下深挖一层，我们得看用户分层。

运营说“赚了”，是把所有用户当成一样的“人头”来算的。但用户价值是有天壤之别的。

如果被拉回来的那 8% DAU，全都是一分钱不花的「羊毛党」，只是进来看看有没有红包领；

而被骚扰到卸载的那 0.1% 的新增流失用户，全是每个月买几千块钱的高净值用户，或者刚下完第一单正准备复购的新客.....

那这波策略就是毁灭性的。

高价值用户通常对打扰的容忍度更低。他们时间宝贵，更注重体验。

低价值用户可能对红点没那么敏感，或者为了几分钱愿意忍受骚扰。

所以，必须把这 8% 的增量和那翻倍的卸载量做 User Profile（用户画像）对比。

看他们的 R 值（最近一次购买时间）、F 值（购买频率）、M 值（消费金额）。

如果流失掉的 M 值总和 > 拉回来的 M 值总和 × 转化率，那运营负责人的“算账逻辑”就在直接亏钱，连反驳的余地都没有。

第五部分：饮鸩止渴还是策略性牺牲？

回到你的问题：我会判定这是「饮鸩止渴」吗？

大概率是。

但我作为分析师，话不能说得太死，要给业务留个口子（这也是面试的高分点，体现你的思维灵活性）。

有没有可能这个策略是“对”的？

只有一种极端情况：存量见顶，只争朝夕。

比如，公司下周就要上市了，或者正在谈一轮非常关键的融资。投资人现在只看 DAU，不看留存，不看卸载。那为了这几天的报表好看，别说一天发 3 条，发 10 条我也干。

这时候，卸载率的长期损失被“融资成功”的巨大短期收益覆盖了。

但在正常的经营周期里，这种策略就是典型的「杀鸡取卵」。

第六部分：我的最终建议

如果我是分析师，面对这个局面，我会给老板和运营负责人这样的建议：

1. **立刻叫停全量暴推**：虽然 DAU 涨了，但长期的资产（用户触达能力）在流失，风险太大。
2. **改“大水漫灌”为“精细化滴灌”**：
 - 不要对所有人一天 3 条。
 - **分层测试**：对那些「对 Push 高响应、低反感」的用户，可以维持一天 2-3 条。
 - 对那些「一旦多发就关通知/卸载」的敏感用户，严格控制在一天 1 条甚至隔天 1 条。
 - 利用算法预测用户的「卸载概率」，在 P(uninstall) 较高的用户群里坚决不发多余的 Push。
3. **监控核心护城河指标**：把「通知权限开启率」和「高价值用户留存率」列为这次 KPI 冲刺的一级红线指标。只要这两个跌了，DAU 涨再多也得停。

总结一下这道题用到的知识点：

- **北极星指标的陷阱**：DAU 是虚荣指标，健康度指标（留存、卸载、权限关闭）才是根本。
- **Stock vs Flow（存量与流量）**：活跃是流量，用户数是存量。不能用消耗存量的方式换流量。
- **LTV 与 召回成本**：流失一个用户的代价远大于获取一个活跃的收益。
- **隐性指标挖掘**：从卸载率联想到「通知权限关闭率」。
- **用户分层价值（RFM）**：不同用户的流失代价不同，不能简单数人头。

面试官视角：

（好，我看你刚才提到了「精细化滴灌」和「分层测试」。这确实是解决矛盾的方向。）

那么我的下一个问题是：

假设我们现在决定要做这个分层策略，我想找出那些“最容易因为多发 Push 而卸载”的高危用户，把他们排除在 3 条策略之外。你现在手头有用户的行为日志（点击、浏览、下单、退货等），你打算选取哪些具体的特征来构建这个「卸载风险预测模型」？请列举你认为最重要的 3-5 个特征，并解释为什么。

题目4

【京东 | 电商数据 | 二面】

为了方便用户决策，你们在商品详情页加了一个「同款比价」的功能入口。

上线一周后发现：

这个功能的点击率非常高，说明用户确实有强烈的比价需求。

但出现了一个非常反直觉的数据：

「点击过比价」的用户，最终下单转化率反而比「没点击过」的用户低了 30%。

产品经理认为：

「这很正常，爱点比价的人本来就是价格敏感型，容易犹豫，转化率低是用户属性决定的，跟功能本身无关。」

如果你是分析师，你会直接接受这个「用户属性」的解释吗？

你会更倾向于认为这个功能是「帮助用户」，还是把原本可能成交的用户「劝退」了？

解答

这道题太经典了。它表面考的是数据异动分析，底子里考的是你对「流量分发逻辑」和「用户心理博弈」的理解。

产品经理说：“点击比价的人本来就是犹豫客，转化率低是用户属性决定的。”

我的第一反应：**这话听着顺耳，但经不起推敲。**

作为数据分析师，如果你直接点头认了，那你就被 PM 的“逻辑闭环”给忽悠了。面对这个“反直觉”的数据，我们要分四步走，一步步把真相撕开。

第一部分：别急着背锅，先看“归因”有没有问题

PM 的逻辑叫「**自选择偏差**」。他认为行为筛选了人群。确实，点比价的人可能更纠结价格。但这里有一个巨大的逻辑漏洞：

他用「**相关性**」解释了「**因果性**」。

如果是功能本身设计得太反人类，导致用户看了比价页面后一脸懵逼，直接关掉 App 走人了呢？

如果我不验证就信了 PM 的话，万一真是功能有 Bug 或者体验极差，那这 30% 的转化下跌就是实打实的业务事故，而不是什么“用户属性”。

所以，我的态度是：**我不接受这个解释，除非数据能证明“没点比价”和“点了比价”的人，在看到这个功能之前是两类完全不同的人。**否则，这就是在掩盖产品缺陷。

第二部分：拿出计算器，现场算这笔“糊涂账”

题目里给了具体的数字：**低了 30%**。咱们必须得做一次带入计算，看看这 30% 到底是怎么跌没的。这里经常出现一个数学陷阱，叫做「**分母的错位**」。

假设有 1000 个用户进来了。

场景一（PM 认为的情况）：500 个人没点比价，直接买了 50 单，转化率 10%。500 个人点了比价，这帮人确实抠门，只买了 35 单，转化率 7%。 $(10\% - 7\%) / 10\% = 30\%$ 。这是 PM 的逻辑：“**人不行**”。

场景二（更符合现实的电商逻辑）： 这才是分析师该看到的视角——**流量流转**。假设用户在看一款“京东自营”的 500 元跑鞋（SKU A）。他点击了“同款比价”，发现了一个 300 元的同款（SKU B），虽然是第三方商家的，但他觉得便宜，去买 SKU B 了。

此时的数据表现是：对 SKU A（原商品）：转化率确实跌了，可能跌得妈都不认。对 SKU B（竞品）：转化率暴涨。对「**用户本次会话**」：他最终还是下单了！

所以，如果我看数据发现：虽然点击用户的「**当前商品转化率**」跌了 30%；但是他们的「**会话下单率**」或者「**人均 GMV**」并没有跌，甚至还涨了。

那这就不是“劝退”，这是「**成功的流量分发**」。说明我们帮用户找到了更想要的东西，挽回了原本可能流失的订单。

第三部分：京东特有的业务死角——自营 vs POP 的博弈

这一点是很多面试者容易忽略的，但在京东面试里必杀。

京东的商品分两类：**自营（亲儿子，物流快，体验好，毛利高）** 和 **POP（第三方商家，物流参差不齐）**。

如果这个“同款比价”功能，逻辑写得太死板，单纯按「**价格低**」排序，会发生什么？

用户正在看 100 块的京东自营抽纸（明日达），手一抖点了比价，系统给他推了 80 块的第三方商家抽纸（三天后发货）。用户一看便宜 20 块，跳过去买了第三方。

结果分析： 用户侧：等了五天才收到货，体验变差，过几天退货了。平台侧：虽然成交了，但自营的高毛利丢了，还赔了物流口碑。

在这种情况下，**转化率低 30%** 可能还不是最可怕的，最可怕的是 **GMV 和 用户满意度（NPS）** 的双杀。

所以我要去查：**点击比价后，流量是不是大规模从“优质品”流向了“低质低价品”**？如果是，那这个功能就是在大动脉上插管子放血，必须改算法权重（比如把物流时效也算进比价权重里）。

第四部分：功能本身的“劝退”嫌疑

排除了流量流转的问题，如果发现连“整体下单率”都跌了，那多半是功能做得烂。

我有几个具体的怀疑点，需要去验证数据：

1. 价格诚意度： 用户点了比价，结果弹出来一堆“比现在还贵”或者“价格一样”的商品。用户心理：“你要我呢？”——直接关掉 App。**数据验证：** 统计点击后展示结果中，「有更低价商品」的占比是多少？

2. 视觉干扰与中断： 比价页面是不是遮挡了“立即购买”按钮？比价页面是不是加载很慢？是不是看完比价后，回不到原来的页面了？**数据验证：** 看一下点击比价后的「**跳出率**」和「**页面停留时长**」。如果跳出率异常高，那就是交互设计在劝退。

第五部分：终极验证——AB 测试（不要猜，要测）

分析了这么多，最稳的办法还是做实验。不能拿“点过的人”和“没点过的人”比，这两拨人天生不一样。

实验设计： 对照组（A组）：50% 流量，**不展示** 比价入口。实验组（B组）：50% 流量，**展示** 比价入口。

核心观测指标： **1. 人均 GMV（最重要）：** 有功能的这波人，到底是不是买得更多了？ **2. 订单转化率（UV 价值）：** 不是看单个商品，是看用户进来到离开有没有花钱。 **3. 留存率/复购率：** 这是一个看长期的功能。

推演结论： 如果 **实验组** 的人均 GMV < **对照组**：那别洗了，这功能就是垃圾，要么逻辑改，要么下线。如果 **实验组** 的人均 GMV >= **对照组**，但 **点击人群** 的当前商品转化率低：那 PM 赢了，确实是用户属性问题，而且我们还通过比价挽救了订单，属于良性循环。

第六部分：战略视角——是“劝退”还是“良心”？

回答完技术层面，必须升华一下。

我会倾向于认为这个功能是「**帮助用户**」，哪怕短期数据不好看。

因为电商的竞争终局是「**信任**」。如果我不提供比价，利用信息差赚了用户 500 块。用户回头发现隔壁才卖 300 块。他会觉得“京东杀熟”，下次买东西先去拼多多搜一圈。

“同款比价”本质上是在「**消除站内信息差**」。它可能会导致 **高客单价向低客单价流转**（导致 GMV 短期微跌），或者让用户犹豫时间变长（导致转化率分母变大）。

但只要它能提升 **用户复购率** 和 **信任感**，把用户留在京东 App 内部完成比价，而不是跳出去比价，那这个功能的战略价值就远大于那 30% 的转化率波动。

所以，我的建议往往是：**优化比价体验，而不是下线功能**。比如，在比价结果里不仅比价格，还比服务、比物流，告诉用户“虽然我贵 10 块，但我明天早上就能送到”，这才是京东该干的事。

知识点归纳

这一通分析下来，我们用到了以下核心能力：

- **归因分析的陷阱：** 识别自选择偏差（Self-selection Bias），区分相关性与因果性。
- **辛普森悖论思维：** 拆解整体与局部，细分 SKU 转化与 Session 转化。
- **电商业务逻辑：** 1P（自营）与 3P（POP）的利益冲突，流量分发的价值判断。
- **AB Testing 实战：** 真正科学的验证方法是控制变量，而不是观察性统计。
- **LTV（全生命周期价值）思维：** 短期转化率 vs 长期用户信任的权衡。

面试官视角：

（面试官微微点头，显然对你考虑到自营和 POP 的冲突感到满意）

“分析得很全面。确实，我们上线后发现，点击比价的用户经常被低价的第三方商家吸引走，导致我们自营商品的销量受到了冲击，虽然整体盘子没跌，但自营部门的利润率下降了。

现在的局面是：自营部门的老大非常不满意，要求下线这个功能；但平台用户体验部门觉得这个功能必须保留。如果你是数据分析负责人，你要出一个什么样的‘流量分配策略’或‘排序算法规则’，既能保留比价功能平息用户体验部门的怒火，又能保护自营部门的利润不至于跌得太难看？请说出你的算法逻辑。”

题目 5

【抖音电商 | 策略分析 | 二面】

为了提升直播间的变现效率，你们调整了流量分发逻辑，给「高转化直播间」更多的流量倾斜。

实验数据显示：

大盘 GMV（成交总额）确实上涨了 12%。

但同时伴随一个明显的下跌：

用户在直播间的「平均停留时长」下降了 20%。

运营同学非常乐观，认为：

「这说明由于推荐精准，用户进来了直接就买，决策效率变高了，不用看半天废话，这是大好事。」

如果你是分析师，

你会认可这个「决策效率变高」的解释吗？

你会判定这次改动是「优质的增长」，还是在「透支用户耐心」？

解答

它表面上是在考数据异动分析，实际上是在考你对「流量货币化」这笔账算不算得清楚。

如果面试时你顺着运营的话说：“效率确实高了，这是好事”，那你基本上就挂了。

第一部分：先看量级，这不仅仅是“下跌”，这是“事故”

首先，作为分析师，我们要对数字有绝对的敏感度。

题目中给的数据是：大盘 GMV 涨 12%，用户平均停留时长跌 20%。

我们要先建立一个基准认知：对于一个日活数亿的内容平台，时长（Duration）是生命线。

平时算法调整，时长波动 0.5% 都要写复盘报告；波动 1% 已经是重大事故。

现在跌了 20%？

这意味着用户的粘性正在**断崖式崩塌**。如果这个实验全量上线，意味着平台可能会流失五分之一的活跃度。

所以在深入分析之前，我的第一反应不是“分析一下”，而是“**建议立刻回滚实验，或者将流量切片缩得非常小，止损优先**”。

这就好比：你开了一家商场，为了让大家多买东西，把商场里的椅子全撤了，空调关了，逼大家“买完赶紧走”。结果销售额确实涨了，但顾客逛商场的时间少了一大截。长此以往，这家商场离倒闭就不远了。

第二部分：拆解“效率陷阱”，运营没算错，但他想错了

运营同学非常兴奋，说：“这是决策效率变高了，大好事。”

我们要理性地帮他拆解这个逻辑。从数学公式上看，运营同学其实**没算错**。

我们定义一个指标叫「单位时间产出（GPM per Minute）」： $\text{效率} = \text{总 GMV} / \text{总时长}$ 。

分子（GMV）变成了 1.12。分母（时长）变成了 0.8。新的效率 = $1.12 / 0.8 = 1.4$ 。

也就是说，单位时间的变现效率确实暴涨了 40%。

但是，分析师的价值在于指出：追求“效率”在这个阶段可能是错的。

我们做生意的最终目的是为了「**总利润最大化**」，而不是「**效率比率最大化**」。

如果为了把效率提上去，导致整个“流量池子”（总时长）枯竭了，那是典型的“**杀鸡取卵**”。

我们宁愿要一个“庞大但稍微低效”的生态（总时长 100亿分钟 * 效率 1.0），也不要一个“极度高效但小而美”的生态（总时长 10亿分钟 * 效率 5.0）。

第三部分：深挖商业模式，这笔帐真的划算吗？

这部分是整个面试的杀手锏，我们要算一笔“大账”。

流量在抖音这种平台，主要有两种变现方式：

1. **卖给广告主（信息流广告）**：依赖于总时长和总展现量（PV）。
2. **做电商（直播带货）**：依赖于 GMV 和佣金。

现在的情况是：**时长跌 20%**。

这意味着广告库存（Ad Inventory）直接少了 20%。

假设广告收入占大盘的 60%，电商收入占 40%（这是一个假设比例，实际广告占比可能更高）。

广告侧损失：20% 的库存消失，直接导致广告收入大跌。 **电商侧收益**：GMV 涨 12%，电商收入涨 12%。

我们做一个简单的推演：假设原本广告赚 100 块，电商赚 50 块。总收入 150 块。改版后：广告收入变成了 80 块（跌 20%）。电商收入变成了 56 块（涨 12%）。总收入 = $80 + 56 = 136$ 块。

结论：哪怕电商涨了，公司整体其实亏了 **14 块钱**。

这就是为什么我说运营同学“只看局部，没看全局”。为了电商部门的 KPI，牺牲了公司最核心的广告变现基石，这是典型的**部门利益冲突**，也是分析师必须指出的**“负向外部性”**。

第四部分：还原业务场景，到底发生了什么？

数据是冰冷的，我们要结合业务 Sense 还原出用户到底经历了什么。

为什么 GMV 涨了，人却跑了？

极有可能是算法把原本属于“优质内容”的流量，强行灌给了“强营销直播间”。

原本的体验：用户刷抖音，看几个搞笑段子，看几个美妆教程，偶尔刷到一个带货的，觉得很有趣，看了一会儿买了。这种体验是**“逛街”**，轻松愉悦。

改版后的体验：为了追求高转化，算法疯狂推荐那种“3、2、1 上链接！”、“破价清仓！”、“不买就是亏！”的直播间。这种直播间转化率极高（因为都在逼单），但内容极度枯燥、吵闹、甚至低俗。

用户进来了，被话术一激，确实下单了（GMV 涨了）。但下完单之后，用户觉得脑瓜子嗡嗡的，心里想：“这 APP 现在怎么全是广告？没意思。”然后手一滑，关掉了 APP，去看 B 站或小红书了（时长跌了）。

这种**“透支用户耐心”**的增长，是不可持续的。

第五部分：数据验证，怎么用数据把运营怼回去？

为了让结论铁板钉钉，我们需要看几个关键的“打脸指标”。

- 1. 负向反馈率：**去查一下，用户对这些“高转化直播间”点击“不感兴趣/拉黑/举报”的比例是不是飙升了？如果点击“不感兴趣”的比例上涨，说明用户在用脚投票。
- 2. 关播后流失率：**这是个非常细的指标。看用户从这些高转化直播间退出来之后，是继续刷下一个视频，还是直接杀掉了 APP 进程？如果“直接关掉 APP”的比例变高，说明这个直播间是用户的“体验终结者”。
- 3. T+14 退款率：**靠“逼单”催出来的 GMV，往往伴随着极高的退款率。我们要看这 12% 的 GMV 增长里，有多少在两周后变成了退款？如果退款率也涨了，那这 12% 就是彻头彻尾的虚假繁荣。
- 4. 活跃用户 DAU 渗透率：**时长跌了 20%，不仅意味着单人看得少了，很可能意味着有一部分轻度用户（Low Active Users）直接流失了。如果 DAU 也开始微跌，那问题就更严重了。

第六部分：解决方案，不能只说不行，要说怎么做

最后，作为金牌陪练，我们要给出一个建设性的结尾。

我的建议是：

- 1. 短期策略：**立刻停止全量实验。如果非要跑，把流量切片缩减到 1% 的用户群，并且严密监控次日留存率。
- 2. 算法优化：**目前的算法显然是 $\text{Rank Score} = \text{CVR} * \text{Price}$ （只看转化）。我们要把公式修正为**多目标优化（Multi-objective Optimization）**。

$$\text{Rank Score} = \alpha * (\text{GMV预估}) + \beta * (\text{停留时长预估}) + \gamma * (\text{互动率预估}) - \delta * (\text{负反馈概率})$$

我们不能只奖励“卖得快”的直播间，我们要奖励那些“**卖得好，且用户愿意看很久**”的直播间。

对于那些“转化高但时长极短”的直播间（比如粗暴叫卖），要进行**降权处理**。

3. 业务共识：拉上运营老大和商业化老大开会，达成一个共识：“**任何 GMV 的增长，都不能以牺牲 DAU 和时长为代价。**”这是一条不可逾越的红线。

总结本次解答的知识点：

- 流量货币化的互斥性：**意识到 Ads 收入和 E-com 收入在抢夺“时长”这个原材料，必须算总账（LTV 模型），不能只看单业务 KPI。
- 效率与规模的博弈：**效率提升不代表总量提升，警惕分母缩减带来的虚高效率。
- 多目标优化：**推荐算法的核心不是单一指标，而是 GMV、Time、Retention 的加权平衡。
- 负向外外部性：**识别一个业务动作对整个生态造成的隐性伤害（如用户体验受损导致的流失）。
- 数据敏感度：**对 20% 这种量级的异常要有极高的警觉性，这在互联网大厂属于事故级别。

（切换至面试官视角，发起下一轮追问）

面试官：分析得非常到位，尤其是关于“广告收入和电商收入互斥”的那笔账，很有高度。

那我顺着这个话题深挖一下。

你说要进行“多目标优化”，把「**停留时长**」也加到推荐公式里。但是，我们发现确实有一类直播间，它们也不叫卖，也不逼单，主播就在那儿发呆、或者做一些很无聊但很猎奇的事情（比如睡觉直播、数米粒），**用户的停留时长非常长，但 GMV 几乎为零**。

如果我们将“时长”权重调高，算法可能会推一堆这种“叫好不叫座”的直播间出来，导致 GMV 大跌，老板也不满意。

请问：作为一个分析师，你会设计一个什么样的复合指标（Metric），来同时平衡“商业转化”和“内容消费时长”？能不能给出一个具体的指标定义？

题目 6

【美团 | 搜索策略 | 二面】

为了提升用户的搜索体验，你们优化了搜索结果的排序算法，把高分商家排得更靠前。

数据反馈看起来很不错：

搜索结果页的点击率明显提升了 10%。

但同时伴随一个“下跌”：

人均搜索次数却下降了 15%。

算法同学非常自信，认为：

「这说明排序变准了！用户搜一次就能找到想要的商家，不用反复换词搜了，这是典型的效率提升。」

如果你是分析师，

你会直接买单这个「效率提升」的逻辑吗？

你会倾向于认为这是成功的优化，还是可能存在严重的“坏味道”？

解答

算法同学非常自信：“这说明排序变准了！用户搜一次就点，不用反复换词搜了，这是典型的效率提升。”

作为分析师，你会买单吗？我的答案是：**绝对不买单。如果不马上排查，这个改动可能正在“杀死”业务。**

为什么？因为这背后可能藏着一个巨大的“**幸存者偏差**”和“**生态灾难**”。

第一部分：别被“效率”两个字忽悠了，先搞清业务本质

首先，我们得建立一个大框架。听到“效率提升”，你脑子里要立刻崩出一根弦：**对于这个 APP，什么才是真正的效率？**

如果是百度、Google，用户搜“感冒怎么办”，点开第一个链接看完关掉，这是好的。这叫“获取信息，用完即走”。但在美团、淘宝、抖音电商，搜索的终极目的不是“点击”，而是“交易”。

算法同学的逻辑漏洞在于：他默认了 **“搜索次数变少 + 点击变多 = 用户满意并下单了”**。

但在现实业务中，存在另一种完全相反的恐怖剧本——**“劝退式点击”**：用户搜了“火锅”，看到排在前面的全是 4.9 分的店（往往伴随着高客单价或过度营销）。出于从众心理，或者是封面图太好看，他点了进去（CTR 提升）。进去一看，人均 500 块，或者离我 10 公里，太贵太远了。他退出来，心想“美团现在怎么推荐的都这么贵”，然后**直接关掉了 APP**，去打开了饿了么或者抖音。

在这个剧本里：CTR 确实涨了（被头部商家吸引）。搜索次数确实跌了（用户失望流失了，不再进行第二次搜索）。但这叫效率提升吗？这叫**“用户劝退”**。

第二部分：深度拆解，数据哪里“不对劲”？

我们不能空口反驳，必须用数据推演来证明风险。

1. 核心验证：UV 转化率（CVR）与 Session Success Rate

这是裁判员指标。如果像算法同学说的那样，用户是因为“爽了”才少搜，那么“搜索到下单”的整个链路应该是通畅的。

我们必须引入 **Session Success Rate（会话成功率）**。定义：在一次完整的搜索会话（Session）中，用户最终是否有产生有效交易行为。

推演逻辑：如果 SPU（搜索次数）下降是好事（一搜即中），那么 SPU 下降的同时，**成交人数** 应该持平甚至上涨。如果 **Orders per User**（人均订单量）或者 **Search CVR**（搜索转化率）跟着搜索次数一起暴跌，那这就不是效率提升，而是 **GMV 的直接损失**。

举个简单的算数例子：**改版前：**我搜 5 次，点 3 次，最后下 1 单。SPU = 5，下单 = 1。**改版后（算法觉得好的情况）：**我搜 2 次，点 2 次，最后下 1 单。SPU = 2（降了），CTR 涨了，下单还是 1。→ **这是真效率提升**。

改版后（实际可能的情况）：我搜 1 次，点 1 次（被高分吸引），没下单，走了。SPU = 1（降幅巨大），CTR 100%（爆表），下单 = 0。→ **这是业务事故**。

2. 隐形杀手：价格敏感度与“价格心智”崩塌

题目说“高评分排前面”。在业务常识里，高评分往往和“高客单价”、“精致堂食”强相关。而搜索场景下，大量用户（特别是工作日午餐场景）要的是“快”和“便宜”。

如果这次改动，导致搜索结果页（SRP）的前三屏全是人均 100+ 的店，把那些评分 4.2 但性价比极高的小店挤到了后面：对于价格敏感型用户（这是美团的基本盘），这就是一场灾难。他们点进去 → 嫌贵 → 退出来 → 觉得没东西吃 → 离开。

我们需要把数据切片（Segmentation）来看：把用户按历史客单价分成：**高消用户、低消用户**。看看是不是高消用户很开心，但低消用户的转化率直接崩盘了？如果低消用户占了大头，那你总体数据的“好看”就是一种“**虚假繁荣**”。

3. 生态危机：马太效应与商户流失（非常重要！）

这一点是高级分析师必须看到的。如果算法强行倾斜流量给“高评分商家”，会发生什么？**马太效应（The Matthew Effect）：强者愈强，弱者愈弱**。

原本那些评分 4.0-4.5 的腰部商家，可能饭很好吃，只是不擅长运营评分。现在他们突然没了流量（曝光暴跌）。结果是：头部商家接单接到手软，服务质量下降，导致评分最终也下降。腰部商家因为没有流量，没生意做，最终**流失（Churn）**，离开平台。一旦供给侧变少，用户的选择就变少，平台生态就死水一潭了。

所以我们必须看：**曝光商户数的基尼系数**，或者**腰部商户的动销率**是否在恶化。

第三部分：别忘了，美团还要靠广告赚钱

这一点非常现实，直接关系到公司的钱袋子。

美团的收入结构里，商家广告费（竞价排名）是很重要的一块。商家的广告展示机会（Inventory），通常是混在搜索结果里的。

现在的局面是：**人均搜索次数下降了 15%**。这意味着什么？意味着 **广告的库存（PV）直接少了 15%**！

我们简单算一笔账： $Revenue = PV * CTR * CPC$ 虽然 CTR 涨了 10%，但 PV 跌了 15%。我们带入数字推演一下： $0.85 (PV) * 1.10 (CTR) = 0.935$ 。整体的广告点击量（Clicks）反而下降了 **6.5%**！

除非商家的 CPC（单次点击出价）能暴涨，否则这次改动直接导致了广告收入的下滑。一个好的排序策略，不能只看用户爽不爽，还要看会不会把平台的营收搞崩了。如果用户效率提升带来的 GMV 增量，覆盖不了广告收入的损失，这个策略在商业上依然是不合格的。

第四部分：总结与行动建议

回到面试现场，我会这样收尾：

“所以，我不会直接买单‘效率提升’这个结论。目前的 CTR 提升和 SPU 下降，呈现出一种非常典型的‘漏斗收窄’风险，甚至有‘杀鸡取卵’破坏生态的嫌疑。

我会建议立刻做四件事：

1. **看北极星指标**：拉出改版前后的 **UV 转化率** 和 **人均 GMV**。如果这两者下跌，立刻回滚。
2. **区分‘好S’与‘坏S’**：拆解搜索行为。是因为 Query Reformulation（改词率）下降导致的 SPU 下降（这是好事），还是因为 Session 深度变浅、用户直接跳出导致的 SPU 下降（这是坏事）？
3. **人群切片**：重点看‘低频用户’和‘低客单价用户’，看他们的跳出率是不是变高了。我怀疑算法是在用牺牲长尾用户的体验，来换取头部数据的‘好看’。
4. **算账**：评估搜索 PV 下降带来的广告库存损失，和 CTR 提升带来的收益相比，整体变现效率（RPM）到底是赚了还是赔了。”

只有这四个维度都验证过了，我们要么开香槟庆祝效率提升，要么就得赶紧去修 Bug 了。

本题知识点归纳

解答这道题，我们用到了以下几个关键的数据分析与商业思维：

1. **北极星指标（North Star Metric）**：明白业务的最终目的是交易（Order/GMV），而不是过程指标（CTR/PV）。
2. **会话成功率（Session Success Rate）**：衡量搜索质量的核心指标，专门用来反驳单纯的 SPU 下降/上升。
3. **辛普森悖论/细分分析（Segmentation）**：总体好不代表每个人都好，必须按价格/用户分群看，防止头部效应掩盖长尾问题。
4. **双边市场生态（Marketplace Ecosystem）**：考虑到供给侧（商家）的存活与流量分配的公平性（马太效应风险）。
5. **商业变现模型（Business Model）**：考虑到流量库存（Inventory）与广告收入的线性关系。

（面试官视角切换）

（此时面试官点点头，眼神里流露出一丝欣赏，但也带着一点狡黠）

好，刚才你的分析逻辑很严密，尤其是关于“高评分可能意味着高价格，从而劝退低价用户”以及“广告库存下降”的推测非常有道理。

那我现在提出下一个问题，这可能是一个更痛的业务取舍：

假设我们深入分析后发现，情况确实很复杂：1. 高客单价用户的转化率大幅提升，低客单价用户转化率下跌。2. 最终算下来，平台的总 GMV（交易额）微涨了 1%，但是总订单量却跌了 5%。

老板现在问你：作为分析师，从公司未来 3 年的发展角度看，你会建议保留这个“涨 GMV 但跌订单”的策略，还是回滚？为什么？

题目 7

【小某书 | 社区增长 | 二面】

为了提升 Feed 流的互动氛围，你们尝试把「神评论」直接外透展示在笔记封面上（用户不用点进去就能看到）。实验数据显示：大盘互动率（点赞 + 评论）显著提升了 15%。

但带来了一个很痛的副作用：笔记的点击率（CTR）直接下跌了 10%，意味着真正点进详情页看内容的人变少了。

产品经理的观点是：「用户在外层看神评论就爽到了，需求已经被满足了，虽然没点进去，但用户体验其实是提升的。」如果你是分析师，你会认可这种「体验提升」的说法吗？你会更看重「互动的上涨」，还是会判定 CTR 的下跌会「毁了创作者生态」？

解答

很多同学一看到数据有升有降，立马就开始慌，或者凭感觉选一个“我觉得点击率更重要”。但在面试官眼里，你选 A 还是选 B 其实不重要，重要的是你「怎么拆解这个利益冲突」，以及你能不能跳出单一指标，站在整个社区生态的角度看问题。

第一部分：先把“感觉”放一边，建立分析框架

遇到这种“一个涨、一个跌”的题目，千万别急着站队。PM 说“用户体验提升了”，这只是他的假设。作为分析师，我们要把这个感性的假设拆解成可量化的逻辑。

咱们可以把这个问题拆成三个视角来看：

- 1. **用户视角**：是否真的“爽到了”？这种爽是可持续的吗？
- 2. **创作者视角**：CTR 下跌对他们意味着什么？
- 3. **平台视角**：长期来看，这种流量分发机制会让社区变成什么样？

先把这三个桩子打稳，后面的分析就不会飘。

第二部分：验证 PM 的“体验提升论”

PM 觉得用户在外层看到神评论，笑一笑就划过去了，需求被满足了。这个逻辑看似通顺，但我们要看数据是不是真的支持。

如果“体验提升”是真的，那么理论上：

用户在 App 里的总时长应该是涨的。用户的留存率或者次日回访应该是稳中有升的。

但是，这里有个很隐蔽的坑。

大盘互动率（点赞+评论）涨了 15%，这个数看着很漂亮，但我们要问：**用户点赞的对象是谁？**

大概率，用户是在给那条“神评论”点赞，而不是给这篇笔记的内容点赞。

这就导致了一个严重的信号错位：笔记本身可能质量一般，但因为评论区有个段子手，这篇笔记就被算法误判为“优质内容”疯狂加权。

这叫什么？这叫“买椟还珠”。

如果是这种情况，用户其实是在消费“段子”，而不是消费“笔记”。长此以往，用户会养成一种“只刷封面不看内容”的快餐习惯。这种习惯一旦养成，用户会变得越来越浮躁，对深度内容的耐心会急剧下降。

所以，我会反驳 PM：**短期的爽不等于长期的体验提升**。我们可能是在透支用户对深度内容的耐心，用“段子消费”替代了“内容消费”。

第三部分：CTR 下跌 10%，这可能是生态的“慢性毒药”

这一块是分析的重头戏，也是最能体现你业务 Sense 的地方。

CTR 跌 10%，这个数其实挺吓人的。咱们得替创作者算笔账。

对于小红书的博主（尤其是中长尾博主）来说，“涨粉”的核心路径通常是：用户点击进入详情页 -> 阅读完整内容 -> 觉得有价值 -> 浏览主页 -> 关注。

如果用户连详情页都不进了，直接在外层把神评论看完划走，那么：

1. **笔记详情页的曝光暴跌。**
2. **路人转粉的转化率暴跌**（因为在 Feed 流直接关注的概率远低于进主页关注）。
3. **博主的商业价值受损**（很多商单是看阅读量的，不是看外层曝光的）。

这时候会出现一种很可怕的现象：**劣币驱逐良币**。

那些认真写长文、做深度测评、拍精美图片的博主，因为“神评论”不够炸裂，或者因为内容需要沉浸阅读，CTR 哪怕正常，也竞争不过那些“标题党+神评论段子”的内容。

慢慢地，创作者发现“认真写内容不如去评论区编个段子”，或者“把封面做得像个段子集锦”。

整个社区的内容生态就会从“有用、美好”滑向“抖机灵、段子手”。小红书如果变成了微博段子区，那它的核心护城河也就塌了。

所以，对于你的第二个问题：我会判定 CTR 的下跌会严重伤害创作者生态，这个风险远大于互动率上涨带来的收益。

第四部分：别只说不行，得给解法

分析到这里，如果你直接说“这功能砍了吧”，那也就刚及格。高级的分析师会想：既要互动，又要保护 CTR，有没有中间态？

既然神评论确实能提升互动，说明用户喜欢看，那我们能不能优化展示策略？

我有几个具体的策略建议，你可以拿去怼 PM（开玩笑，是建议）：

1. 分品类差异化策略 不是所有垂类都适合外透评论。

- 搞笑、娱乐、吐槽类：神评论往往是灵魂，外透没问题，用户本来就是来图一乐的。
- 穿搭、美妆、干货类：这些需要看细节、看教程。如果外透评论导致用户不点进去，博主的价值就被埋没了。这类内容，坚决不透，或者只透“半句”吸引点击。

2. 修改交互样式 现在的外透是不是把神评论全展示了？能不能只展示前 10 个字？或者展示“xx 人热议中”？利用“信息缺口”原理，把神评论作为诱饵（Hook），诱导用户点进去看完整版，而不是作为替代品让用户在外层直接消费完。这样既利用了神评论的热度，又保住了 CTR。

3. 调整推荐算法的归因 如果用户在外层对外透评论点了赞，这个正向反馈，权重必须降级。不能把它等同于“用户看完了笔记并点赞”。算法模型里，要区分“对评论的互动”和“对笔记的互动”，防止那些纯靠神评论的低质笔记抢占了过多的流量池。

第五部分：决策结论

最后，咱们来个掷地有声的总结。

如果我是分析师，面对这组数据：

第一，我不认可 PM 简单的“体验提升”说法。现在的提升大概率是“浮层消费”带来的虚假繁荣，且伴随着巨大的生态风险。

第二，在当前 15% 互动提升 vs 10% CTR 下跌的局面下，我站 CTR。因为 CTR 链接着创作者的生存命脉和深度内容的消费场景，这是社区的根基。

第三，下一步行动（Next Step）。暂停全量上线。将实验继续拆解，看不同品类下的 CTR 变化。如果是全品类 CTR 普跌，那这个功能设计就是失败的，必须改版（比如改成点击展开神评论）再测。

本次解答用到的知识点总结

为了帮你更好地消化，我把刚才分析里用到的核心概念整理了一下：

1. 北极星指标与虚荣指标：互动率（Like+Comment）有时候是虚荣指标，如果不产生深度消费，它可能没

有商业价值。CTR 和 留存 往往更反映业务健康度。

2. **流量分发机制与生态健康 (Ecosystem Health)**： 分析师不能只看单次实验的涨跌，要看这个变动会对“供需关系”产生什么长期影响。CTR 下跌会打断创作者的“正反馈循环”，属于生态损伤。
3. **信息缺口理论 (Curiosity Gap)**： 在产品设计上，内容不能在外层透得太“满”。太满则无点击。好的设计是给一点甜头，引诱用户进去吃正餐。
4. **辛普森悖论 (Simpson's Paradox) 的变体应用**： 我们要警惕大盘数据掩盖了分品类 (Segment) 的问题。可能某些品类 CTR 没跌，但核心品类跌得很惨，平均一下看不出来，必须下钻分析。

面试官视角：追问环节

好了，现在把我的分析师帽子摘下来，换上高冷面试官的面具。

刚才你的回答逻辑很清晰，尤其是在生态保护这一块。那么我想基于你的回答，追问一个更实际的问题：

“如果老板（比如公司VP）非常看重这次互动率的 15% 提升，强行要求上线这个功能。作为数据分析师，你需要设计一套什么样的「监控指标体系」或者「补救策略」，来确保半年后，我们的创作者生态不会因为 CTR 下跌而崩盘？请具体说出你会监控哪两三个最关键的预警指标。”

题目 8

【快手 | 内容生态 | 二面】

为了降低普通用户的发布门槛，你们上线了「一键成片」功能，让用户能快速生成视频并发布。上线后数据非常漂亮：每天发布视频的用户数（UGC 生产人数）激增了 25%。

但你查到一个很尴尬的数据：这批通过新功能发布的视频，「0 播放率」高达 40%，意味着几乎没有任何分发，全是自嗨。

产品经理反驳说：「没关系，数据证明：只要用户发了视频，他的次周留存率就会显著变高。我们现在的目标是让用户养成『发』的习惯，没人看也无所谓。」如果你是分析师，你会认可这种「用垃圾内容换留存」的打法吗？你会判定这是社区繁荣的开始，还是生态崩坏的前兆？

解答

第一部分：先把题目里的“坑”挖出来

这道题最有意思的地方在于，它给了两个看似矛盾的数据，还附赠了一个非常有迷惑性的观点。

先看数据：

1. **发布人数涨了 25%**：听起来很棒，供给侧繁荣。
2. **新视频 0 播放率 40%**：这不仅仅是“没人看”，这在算法分发逻辑里意味着“系统连试都不想试”，或者“试了第一波由于质量太差直接被截断”。

再看 PM 的逻辑链条：用户发布视频 -> 用户次周留存变高 -> 结论：发布行为带来了留存，所以内容烂点没关系。

这里面最大的坑就在于：**归因错误**。

如果我是你，我在面试现场会先肯定 PM 看到的数据（毕竟数据本身不会撒谎），然后立刻指出逻辑漏洞。

我会这么说：“这个数据表现确实很有欺骗性。表面上看是发布带来了留存，但我们必须先搞清楚一个核心问题：**到底是发布行为让用户留下来，还是本来就忠诚度高的用户才更愿意去试用这个新功能？**”

第二部分：拆解“虚荣指标”，用 AB 测试思维反击

这里咱们得动点真格的，用数据思维去验证那个 PM 的假设。

1. 幸存者偏差与筛选效应

PM 说“发了视频的人留存高”。但这很可能是一个筛选过程。愿意去点击“一键成片”、愿意去选素材、愿意等待生成并点击发布的人，大概率本身就是平台的**核心活跃用户**。

这就好比说“买健身房年卡的人身体更健康”，不是因为买卡让他们健康，而是本来就在意健康的人才会去买卡。

怎么验证？（考察你的分析落地能力） 我会建议把这批使用了“一键成片”的用户，拉出他们**使用功能前 30 天**的活跃数据。如果这批人本来就是高活用户，那 PM 的“发布带来留存”的论点直接就被推翻——留存是由于人的属性，而不是功能的功劳。

2. 只有正反馈才能带来真正的习惯

PM 说要“养成发的习惯”。这里有个业务常识：在内容社区，**没有任何反馈的发布是不可持续的**。

用户不是机器。用户发视频是为了什么？为了被看到，为了点赞，为了评论。如果 40% 的视频是 0 播放，意味着这 40% 的用户发完之后，把手机扔一边，过几个小时回来一看：0 赞，0 评，0 播放。

你觉得他会有“成就感”吗？他会有“爽感”吗？不会。他只会觉得“这平台没人理我”或者“我发的这玩意儿真没意思”。这种挫败感，大概率会导致他下周直接流失，或者再也不发了。

所以 PM 看到的“次周留存高”，可能只是**短期的新鲜感红利**。如果不解决 0 播放的问题，拉长到 T+30 或者 T+60 看留存，数据大概率会崩盘。

第三部分：深挖“0 播放”背后的生态危机

这一段我们要把视角拔高，聊聊“生态崩坏”。

1. 0 播放 = 无效供给 + 算力浪费

40% 的 0 播放，说明这批内容在算法看来是**“绝对劣质”**的。可能是画质模糊、可能是毫无信息量、可能是纯粹的拼凑。

对于平台来说，存储这些垃圾内容要钱，审核这些内容要人力，计算这些内容的特征要算力。如果这些成本换不回任何消费时长，那就是纯纯的负资产。

2. 消费侧的“信噪比”灾难

虽然现在这 40% 是 0 播放（说明没分发出去），但剩下的 60% 呢？如果“一键成片”本身就是低门槛、模板化的工具，那么生产出来的内容大概率是**同质化严重**的。

想象一下，用户刷快手，刷 10 条视频，有 3 条是长得一模一样的“一键成片”模板视频。用户会怎么想？“快手怎么全是这种注水内容？”消费者的体验一旦下降，消费时长就会跌，大盘就会受损。为了保全一小撮生产者的“发布虚荣心”，牺牲广大消费者的体验，这是典型的**捡了芝麻丢西瓜**。

3. 劣币驱逐良币

当“一键成片”的垃圾内容泛滥，那些认真拍视频、剪辑了 2 小时的创作者会怎么想？他们会发现流量池里充斥着工业废料，竞争变得更加无序。长此以往，优质创作者会心寒离开。

第四部分：给出你的判断与解法

分析到这儿，态度已经很鲜明了。

我的判断： 我不认可 PM 的打法。这绝对不是繁荣的开始，而是**虚假繁荣下的生态隐患**。如果不加干预，这就是崩坏的前兆。我们不能用“垃圾内容的堆积”来换取“短期的数据好看”。

我的建议： 作为分析师，我不能只说“不行”，我得告诉大家“怎么行”。

1. **调整北极星指标 (Metric)：** 废除单纯的“UGC 生产人数”作为核心指标。改为**“有效生产人数”**，定义为：发布视频后，至少获得 10 次播放或 1 个互动的用户。这样能倒逼产品去优化“一键成片”的质量，而不是只追求数量。
2. **优化分发策略 (保底机制)：** 对于那 40% 的 0 播放，我们要拆解原因。如果是内容太烂，直接在生产端提示用户“素材清晰度不足，建议更换”。如果是冷启动分发没覆盖到，能不能给每条新内容 **50-100 次的保底曝光**？如果给了曝光还是没人看，那说明内容确实不行，这时候再判定为劣质也不迟。让用户“死个明白”，而不是“死于 0 播放”。
3. **产品侧的归因验证 (Causal Inference)：** 正如前面说的，立刻跑一个倾向性得分匹配 (PSM) *或者简单的*双重差分 (DID) *模型。算清楚：去掉了用户本身的活跃属性后，这个“一键成片”功能到底给留存带来了多少*增量 (Lift)？如果增量接近于 0，那就拿着数据去打 PM 的脸（啊不，去说服 PM）。

第五部分：总结一下知识点

这道题解答完，咱们复盘一下用到了哪些硬核知识点：

- **虚荣指标 (Vanity Metric) vs 实效指标：** UGC 数量 vs 有效 UGC。
- **相关性不等于因果性：** 这是数据分析最大的坑，千万别被表面趋势骗了。
- **选择性偏差 (Selection Bias)：** 活跃用户才用新功能，而不是新功能导致用户活跃。

- **幸存者偏差**：只看到了留存下来的人，没看到因为 0 播放而流失的人。
 - **生态健康度**：供给侧（生产者）和消费侧（消费者）的动态平衡，信噪比的概念。
-

好了，这道题的分析逻辑就是这样。

最后，回答完这个问题，我要切换到面试官视角了。

（面试官此时身体前倾，推了推眼镜，看着你）

“既然你提到了要把指标改为‘有效生产人数’，并且要给新视频保底流量。那么问题来了：

如果你给这批质量一般的‘一键成片’视频开了保底流量，势必会挤占原本属于优质内容的流量池，导致大盘的人均消费时长下跌 2%。老板问你：用消费侧 2% 的下跌，换取供给侧 10% 的有效产能增长，这个置换到底值不值？你怎么量化评估这个 Trade-off？”

题目 9

【某陌生人社交 | 用户增长 | 二面】

为了降低陌生人社交的破冰门槛，你们在推荐列表页加了一个「一键打招呼」的功能（点击自动发送一句开场白）。上线后数据非常猛：每日「发起聊天」的用户数和消息量直接翻了一倍，社区看起来热闹极了。

但与此同时，有一个指标很难看：这些发出去的消息，「回复率」却暴跌了 40%。

运营同学坚持认为：「回复率跌是因为分母变大了，这是数学必然。只要最终『成功匹配的绝对对数』微涨，就说明我们促进了社交，不必在意回复率。」如果你是分析师，你会认可这个「只看绝对值」的逻辑吗？你会认为这是「社交效率提升」，还是在制造「社区噪音」骚扰用户？

解答

面试陌生人社交（Tinder/Soul/探探类）岗位时，这道题出现的概率极高。它表面考数学，实际考的是你对「**双边市场生态**」的理解深度。

题目很简单：上线了个「一键打招呼」（比如点击卡片自动发一句“Hi”），上线后发送量翻倍，社区看起来热火朝天。但尴尬的是，回复率暴跌了 40%。运营说：「别慌，只要最终『成功匹配的绝对对数』微涨，哪怕回复率跌了，也是我们促进了社交效率。」

作为分析师，你怎么看？

如果这时候你点头同意，那你离「挂掉面试」也就差这一哆嗦了。因为这个「涨幅」极有可能是透支未来三个月生态换来的「带血的增长」。

第一部分：先把账算清楚（别被忽悠了）

运营同学的逻辑乍一听是无懈可击的。我们先来做一个简单的数学推演，还原一下他的底气从哪来。

我们假设改版前的基数是这样的：

- 每天发送消息：100 条
- 回复率：10%
- **成功匹配数** = $100 * 10\% = 10$ 对

改版后（根据题目描述）：

- 发送量翻倍：变成 200 条（因为门槛低了，手滑都能发）。
- 回复率暴跌 40%：也就是变成了原来的 60%。即 $10\% * 60\% = 6\%$ 。
- **成功匹配数** = $200 * 6\% = 12$ 对

你看，运营同学没撒谎。从绝对值来看，成功的匹配确实从 10 变成了 12，涨了 20%。如果你的 KPI 只考核「当天新增匹配对数」，那你确实可以给技术团队发奖金了。

但是，作为分析师，我们必须看到数字背后的代价。为了多换来这 **2 对** 匹配，整个平台多产生了 **100 条** 垃圾消息。以前每产生 1 个匹配需要消耗 10 条消息，现在每产生 1 个匹配需要消耗 **16.6 条** 消息。

这不仅仅是效率下降，这叫「**社交通货膨胀**」。

第二部分：为什么我不认可？

我不认可运营的逻辑，核心原因在于他只看到了「数量」，忽略了陌生人社交最致命的三个隐患：**信噪比**、**社交货币贬值**、**算法中毒**。

1. 接收方（供给侧）：灾难级的红点疲劳

陌生人社交里，女性用户（通常是稀缺资源）的体验决定了平台的生死。以前我收到 10 条消息，虽然不多，但可能都是对方看了我的主页、找了共同话题才发来的，这叫「Signal（信号）」。我回了 1 条，感觉还行。

现在好了，因为「一键打招呼」成本极低，我手机突然嗡嗡响了 20 次。我打开一看，全是千篇一律的系统自动文案：「Hi」「你好」「认识一下」。

我的第一反应是什么？不是「哇，我好受欢迎」，而是「这软件全是机器人吧？」或者「这些人好烦，看都不看就群发」。

这就是「信噪比」的崩塌。当噪音淹没了信号，用户的防御机制会升级。高质量的接收方会因为不堪其扰，直接关闭通知，甚至卸载 APP。一旦供给侧的用户流失，那些发消息的男性用户也会随之流失，整个大盘就会崩盘。这叫「**双边市场的负向螺旋**」。

2. 发送方（需求侧）：虚假的繁荣与更深的挫败

对于发送方来说，以前通过「一键打招呼」确实爽，手指点一点，几十个人打招呼。但他马上会发现一个问题：怎么没人理我？

回复率从 10% 跌到了 6%（甚至现实中会更低，因为接收方麻木了）。这意味着他发出去的消息，94% 都是石沉大海。

刚开始他会觉得「我发了好多」，有成就感；但只要过个两三天，他就会意识到这个功能是骗人的，全是无效社交。这种「明明付出了（虽然成本很低）但得不到反馈」的挫败感，比「不知道跟谁聊」还要强。最终他会觉得「这个平台的人都很高冷」，然后离开。

3. 劣币驱逐良币（格雷欣法则）

这才是最危险的，也是运营容易忽略的。当「一键打招呼」这类低成本的交互占据主流，那些真正愿意花时间看资料、认真写开场白的用户会被淹没。

想象一下，一个真心交友的人写了 50 个字的开场白，混在 20 个「Hi」里面。接收方已经被那些「一键 Hi」搞得不耐烦了，她可能连那个认真写的开场白都懒得点开看，或者直接点击「全部已读」。

最后结果就是：真心想交友的人走了，留下的全是想碰运气的「点击党」和「约炮党」。社区氛围彻底庸俗化。

第三部分：那些你没想到的隐形伤害

这一部分是加分项，能体现你对业务的深度思考。

1. 算法模型的「中毒」

现在的推荐算法通常依赖用户的显性行为（点击、喜欢、打招呼）来学习用户的偏好。以前，用户「发起聊天」是一个高权重的正向信号——代表我真的对这个人感兴趣。

现在有了「一键打招呼」，用户可能会为了「广撒网」，对列表里的 10 个人全都点了一遍。这对算法来说是灾难性的：用户的真实偏好被稀释了。算法分辨不出你是真的喜欢这 10 个人，还是只是手滑？这会导致后续的推荐越来越不准，进一步降低匹配效率。

2. 黑产与风控的噩梦

「一键打招呼」是黑产（灰产、杀猪盘、引流微商）最喜欢的功能。以前发广告还得写脚本模拟输入，现在官方直接送了个「群发按钮」。如果不加限制，这多出来的消息量里，可能混杂了大量的垃圾引流信息，这会极大地增加风控审核的成本和漏放的风险。

第四部分：应该怎么看？怎么救？

既然运营说「绝对值涨了」，我们不能光怼人，分析师的价值在于解决问题。我会建议把指标拆得更细，并设计分层策略。

1. 别只看「匹配」，看「有效对话」

现在的「匹配」定义太水了，双方发一句话就算匹配吗？我们要看**匹配后的会话深度**。比如：**双向回复超过 3 轮的用户比例是多少？**

我敢打赌，虽然那个「匹配绝对值」涨了 20%，但「超过 3 轮对话」的深度社交大概率是跌的。因为「一键」带来的匹配，往往是「Hi」→「Hi」→ 沉默。这不叫社交，这叫打卡。如果 **Total Value (总有效对话数)** 是跌的，那这个功能就是失败的。

2. 拆解「留存率」，特别是「高价值女性用户」的留存

把那天收到超过 50 条「一键打招呼」的用户单独拎出来。看她们接下来 3 天的打开率是不是降了？看她们关闭「消息推送」的比例是不是高了？如果平台的核心资产（活跃女性用户）感到不适，必须马上叫停。

3. 分层看回复率（归因分析）

看看是所有人的回复率都跌了，还是只是「一键打招呼」的回复率低？**如果连「手动输入」消息的回复率也被拖累下降了**（因为接收方即使看到手写的也以为是机器发的），那就实锤了——这个功能正在污染社区环境。

第五部分：总结与行动建议

总结一下我的观点：

我坚决不认可「只看绝对值」的逻辑。运营同学犯了两个错误：

1. **偷换概念**：把「连接（Connect）」当成了「社交（Social）」。
2. **短视**：用生态的长期健康（信噪比、用户耐心）换取了短期数据的虚假繁荣。

这就像是为了提高 GDP 而去砸碎窗户（破窗谬论），虽然修窗户产生了交易额，但社会财富并没有增加。

我的建议：

1. **增加门槛**：如果要保留「一键打招呼」，必须加 CD（冷却时间）或者加成本（比如消耗金币），不能让用户无脑连点。
2. **差异化展示**：让接收方能明显区分「系统招呼」和「手写招呼」，保护用心社交的用户。
3. **算法降权**：在推荐逻辑里，降低那些频繁使用一键打招呼用户的权重，倒逼他们去认真聊天。

知识点复盘

解答完这道题，咱们梳理一下用到的分析思维：

1. **信噪比（Signal-to-Noise Ratio）**：做内容、做社交，永远要关注有效信息和干扰信息的比例。单纯追求「活跃度」而忽视「质量」，是社区死亡的前兆。
2. **辛普森悖论的变体**：总量涨了不代表真的好了，可能是因为低质量的基数变大了，掩盖了高质量行为的衰退。
3. **双边市场效应（Two-Sided Market）**：必须同时考虑供给端（接收方）的承载能力和需求端（发送方）的满足感。单边优化往往会导致双边崩盘。

4. **格雷欣法则 (Gresham's Law)**：劣币驱逐良币。低成本的社交行为如果不加限制，一定会挤出高成本的优质社交行为。
5. **社交通胀**：当打招呼变得太容易，打招呼这个行为本身就变得不值钱了。

（切换至面试官视角）

你的回答非常深刻，特别是关于「算法中毒」和「社交通胀」的观点，说明你不仅看数，还懂产品。

现在的局面是：功能已经全量上线了，下线是不可能下线的（老板好面子，运营也要背 KPI）。

作为分析师，请你设计一个 **A/B Test 实验** 或 **具体的策略调整方案**。目标是：在**不直接下线**功能的前提下，把「回复率」拉回来，同时尽量保住那个增长的「匹配绝对值」。你会怎么设计这个实验？变量怎么控？重点看哪几个指标？

追问解答

面对「功能不能下线，但数据很难看」的死局，分析师的价值就体现出来了。我们不是来吵架的，我们是来解决 Trade-off（权衡）问题的。

我们的目标非常明确：在保持「绝对匹配数」不跌（甚至微涨）的前提下，大幅拉升「回复率」。

公式是这样的：**成功匹配数 = 发送量 × 回复率**

现在的情况是「发送量」极大，「回复率」极低。我们要做的调整方向是：**适度控制「发送量」（减少噪音），同时通过策略大幅提升「回复率」（提升精准度）。**

只要「回复率」提升的幅度 > 「发送量」减少的幅度，总匹配数就能保住，而生态会健康得多。

以下是我设计的三个实验方向，按推荐程度排序：

策略一：引入「智能摩擦」机制

这是最快见效的手段。我们要给「一键打招呼」加一点点门槛，让用户不那么容易手滑。

实验设计：

- **对照组 (Control)**：维持现状，无限次点击，文案是通用的「Hi」。
- **实验组 A (每日限额)**：普通用户每天只能用「一键打招呼」**10 次**。超过次数后，引导用户「手动输入」或「消耗金币解锁」。
 - **逻辑**：稀缺产生价值。当用户知道这玩意儿每天只有 10 次，他会挑好看的、匹配度高的人点，而不是瞎点。这能直接剔除低意向的点击。
- **实验组 B (强制差异化)**：点击按钮时，弹出一个气泡选项，必须选一个话题（如「聊聊电影」「夸夸照片」「打个招呼」）。
 - **逻辑**：多一步操作，拦截掉机器人和纯手滑党，同时让接收方看到是有具体意图的，而不是机器群发。

预期结果：实验组的发送量（分母）会下降，但因为筛选了意向，回复率（分子）会大幅提升。只要回复率能翻倍，哪怕发送量腰斩，总匹配数也是持平的，且用户体验大涨。

策略二：千人千面的「上下文文案」

现在的核心痛点是接收方看到「Hi」就想吐。我们要把「一键」变得不像机器发的。

实验设计：

- **策略逻辑：**利用 NLP（自然语言处理）或简单的标签匹配。
 - 如果接收方标签里有「猫」，按钮文案自动变成「想看你的猫」。
 - 如果接收方标签是「旅行」，文案自动变成「最近去哪玩了？」。
 - 如果没标签，才显示兜底的「Hi」。
- **实验组：**对 50% 的流量上线「动态文案」功能。

预期结果：这一招可以在**不降低发送量**的前提下，直接提升回复率。接收方会觉得「这个人懂我」或者「这个人看了我资料」，从而愿意回复。这是解决「信噪比」问题的技术解法。

策略三：后端算法的「分层曝光」

这是治本之策。既然「一键打招呼」是把双刃剑，那我们就只把剑给「会用剑的人」，只砍「该砍的人」。

实验设计：

- **供给侧控制（保护女神）：**
 - 对于**高热度女性用户**（每天收到 >50 条消息）：在推荐列表中，**隐藏**对她们的「一键打招呼」按钮。想聊？必须手动打字。
 - **逻辑：**高分用户不缺消息，缺真心。保护她们免受骚扰。
- **需求侧控制（限制屌丝）：**
 - 对于**回复率极低的用户**（发 100 条回 0 条的）：系统判定为「低质量发送者」或「潜在骚扰者」，对其隐藏该功能，或将其打招呼的消息折叠进「垃圾箱」。
 - **逻辑：**把有限的曝光机会留给信用好的用户。

第四部分：实验观测指标（一定要全）

在做 A/B Test 时，我不会只看一个数，我会看一套指标：

1. **核心指标：双向对话 > 3 轮的匹配数。**
 - 注意，我不再看单纯的「匹配数」，我要看「聊起来的数」。这才是老板真正应该关心的 KPI。
2. **约束指标：**
 - **接收方 D1 留存率：**不能跌。

- 接收方拉黑/举报率：必须显著下降。

3. 过程指标：

- 人均发送次数（预期下降）。
- 单条消息回复率（预期上升）。

第五部分：给老板的汇报话术

最后，作为分析师，不管是分析还是实验，最后都要去说服老板。我会这么说：

“老板，完全下线确实可惜。但我发现现在的增长有点‘虚胖’，很多匹配根本没聊起来，反而增加了举报率。

我建议做一个‘优选打招呼’的升级。通过加一点点策略（比如每日限量、智能文案），我们的测算显示：虽然发送量会跌 30%，但因为更精准了，回复率能涨 80%。这样算下来，**有效匹配数其实能涨 20%**，而且用户也不骂了。我们先切 10% 的流量跑个 A/B 测试看看？”

这样，你既保住了老板的面子（功能没下线，只是升级了），又保住了社区的里子（生态健康了）。

知识点复盘

在这个追问中，我们用到了几个高阶的数据/产品思维：

1. **Trade-off（权衡）思维**：在商业分析中，很少有「既要又要」的好事。通常是在「数量 vs 质量」或「短期 vs 长期」中做平衡。你的方案必须体现这种平衡术。
2. **Friction（摩擦力）设计**：在增长黑客理论中，通常我们要减少摩擦。但在生态治理中，**增加合理的摩擦**（如限制次数、增加输入成本）是筛选高价值行为的最有效手段。
3. **Contextualization（场景化/上下文）**：提升转化率（这里是回复率）的万金油就是「相关性」。让自动化看起来像个性化，是产品经理和算法的功力。
4. **A/B Test 的 OEC（Overall Evaluation Criterion）选取**：不能只看单一指标，要设计「核心指标+护栏指标」的组合，防止局部优化导致全局崩盘。

题目 10

【滴滴 / 高德 | 业务分析 | 二面】

为了提高用户在估价页的下单意愿，你们调整了预估接驾时间（ETA）的展示策略，展示得比以前更“乐观”了（比如实际预计 5 分钟，展示为 3 分钟）。效果很明显：估价页到下单的转化率提升了 8%。

但随之而来的是一个坏消息：用户下单后的「取消率」也上涨了 12%，很多用户因为等得不耐烦取消了。

业务方认为：「不用太纠结取消率，只要最终算下来，【成交订单总量】是涨的，那这个策略就是赚的，取消的那部分只是合理的损耗。」如果你是分析师，你会认可这种「透支预期」带来的增长吗？你会判定这是策略的胜利，还是在制造「信任危机」？

解答

业务方的逻辑非常诱人：「虽然取消率高了，但只要最后成交的单子变多了（GMV 涨了），那咱们就是赚的。」如果你在面试里点头同意，那你不仅是不懂用户，你甚至是不懂财务。

因为这不仅是一个关于体验的道德题，更是一个关于 **Unit Economics（单体经济模型）** 的算术题。我们分四个层面来把这个逻辑彻底拆解。

第一部分：先把账算死，看看“赚了”是不是假象

业务方说「成交订单总量是涨的」，这个结论我们先验证一下，但更重要的是，我们要算算**每一单赚的钱是不是跌了**。

先看流量漏斗的基本公式：

最终成交订单 = 流量 × 下单转化率 × (1 - 取消率)

已知条件： 下单转化率（CVR）涨了 8%。取消率（Cancel Rate）涨了 12%。

1. 订单量的账（业务方的逻辑）： 我们做个具体的数字推演。假设日均流量 10,000 人。原策略：转化率 20%，取消率 15%。新策略：转化率变为 $20\% \times 1.08 = 21.6\%$ 。取消率变为 $15\% \times 1.12 = 16.8\%$ 。

原成交量： $10,000 \times 20\% \times (1 - 15\%) = 1,700$ 单。

新成交量： $10,000 \times 21.6\% \times (1 - 16.8\%) \approx 1,797$ 单。

你看，订单量确实涨了，涨了约 5.7%。到这里，业务方是开心的，觉得策略生效了。

2. 利润的账（分析师必须看到的逻辑）： 但是，**取消订单是有成本的！** 在现实业务中，用户下单后取消，平台可能面临以下直接亏损：

- **支付通道费：** 用户支付后退款，部分第三方支付通道依然会收手续费。
- **技术成本：** 地图路径规划 API 的调用费（这是按次收费的，很贵）、短信通知费、服务器资源。
- **司机端补偿（关键）：** 如果司机已经空驶了一段距离用户才取消，平台往往需要给司机发放“空驶补偿”以安抚运力，这笔钱是平台纯贴的。

我们假设每单毛利是 5 元，但每发生一单取消，平台的综合隐性成本是 2 元。

原利润： $(1,700 \text{单} \times 5 \text{元}) - (2,000 \text{个下单} \times 15\% \text{取消} \times 2 \text{元成本}) = 8,500 - 600 = 7,900$ 元。

新利润： $(1,797 \text{单} \times 5 \text{元}) - (2,160 \text{个下单} \times 16.8\% \text{取消} \times 2 \text{元成本}) = 8,985 - 726 = 8,259$ 元。

在这个假设下，利润虽然还是涨了一点点，但你会发现**利润的涨幅（4.5%）明显低于订单的涨幅（5.7%）**。这说明什么？说明这个策略导致**每一单的质量在下降，边际收益在递减**。而且，一旦“取消成本”稍微再高一点（比如你需要发券挽留愤怒的用户），这个策略在财务上立马就是亏的。

第二部分：信任崩塌——用户的“心理账户”没有余额了

算完钱，咱们得算算人心。这也是业务方最容易忽略的**隐性负债**。

地图和打车软件的核心壁垒是什么？不是便宜，是**确定性**。用户为什么用你的 App？因为他相信你能让他准时到。

现在策略把预计 5 分钟展示为 3 分钟。这就构成了**预期违约**。根据心理学的“峰终定律”，用户在寒风中多等的那 2 分钟，体感时长会无限放大。

这会带来两个长期的恶性后果：

1. **LTV（生命周期价值）断崖式下跌**：今天的转化率提升，透支的是明天的留存。用户这次没取消，忍了，但他下次会直接打开竞品比价。现在的打车市场（滴滴、高德、Uber等）切换成本几乎为 0。一次欺骗，可能就是永久流失。哪怕他下周还来，他也会在心里自动给你的时间加 Buffer，你的“转化率优势”荡然无存。
2. **客诉成本爆炸**：取消率上涨 12%，通常意味着进线咨询量（Ticket）可能上涨 20%。客服中心的人力成本是非常昂贵的。为了赚那几单的钱，导致客服被打爆，赔付支出激增，这在公司整体损益表（P&L）上绝对是得不偿失。

第三部分：生态灾难——供给侧的“负向螺旋”

我们必须看**供给侧（司机）**。业务方认为“取消只是合理的损耗”，但对司机来说，取消是实打实的**收入损失和情绪打击**。

这里有一个可怕的**死循环**：

1. 平台虚报时间骗用户下单。
2. 司机接单，赶往起点。
3. 用户发现车怎么还没来（因为真实距离其实很远），不耐烦取消。
4. 司机白跑一趟，产生怨气，且空驶率上升。
5. **关键点来了**：司机为了止损，会开始**挑单**，或者对该平台的订单响应速度变慢（不愿意接）。
6. 平台的**真实运力响应效率下降**，真实 ETA 变得更长（比如原来 5 分钟，现在变成 7 分钟）。
7. 为了维持转化率，平台不得不**撒更大的谎**（把 7 分钟显示成 3 分钟）。
8. 取消率继续飙升，生态崩盘。

这就是为什么说“虚假 ETA”是平台的毒品。它在短期内让数据好看，但会从根基上腐蚀掉平台的运力调度效率。

第四部分：我的结论与分析员的建议

所以，我的结论非常明确：**我坚决不认可这种通过透支预期带来的增长。这不是策略的胜利，这是在饮鸩止渴。**

作为分析师，我给出的建议方案如下：

- 1. 叫停全量欺骗，转向“分层预期管理”：**不要对所有人都撒谎。对于**价格敏感型用户**（如拼车、一口价），他们对时间宽容度高，可以展示一个范围（如 3-6 分钟），用价格留住他们。对于**商务、急单用户**，必须展示绝对真实的 ETA，甚至要略微保守（Buffer），给他们“提前到达”的惊喜。信任才是高端用户的留存密码。
- 2. 引入“坏体验”监控指标：**不能只看 GMV 和 成交单量。必须把 **PPO (Percentage of Perfect Orders)** 作为北极星指标。如果一单虽然成交了，但用户等待时间超过预期 50%，或者用户给了差评，这单在分析师眼里应该归为“失败订单”。
- 3. 根治问题：优化调度算法：**用户嫌时间长，正确的做法是优化派单逻辑、增加运力密度，让车真的来得快一点，而不是在屏幕上改个数字自欺欺人。

知识点总结归纳

这道题非常综合，我们用到了以下关键分析框架：

- 流量漏斗与财务模型结合：**不能只看漏斗转化，必须引入 Unit Economics（单体经济模型），把隐性成本（Cancel Cost）算进账里。
- 短期 ROI vs 长期 LTV：**识别“虚荣指标”，任何牺牲用户信任的短期增长，最终都会由 LTV 的下降来买单。
- 双边市场效应（Two-sided Marketplace）：**在平台型业务中，分析必须同时覆盖 C 端（用户）和 B 端（司机）。伤害供给侧，最终会反噬需求侧。
- 系统动力学（System Dynamics）：**看到策略背后的“反馈回路”。虚假 ETA 会导致“司机挑单 -> 真实运力下降 -> 需要撒更大的谎”的恶性循环。

好了，这道题的坑算是填平了。

现在，切换回面试官视角。你刚才的表现很犀利，甚至考虑到了司机端的负反馈，这很好。

“那我想接着你的思路追问一个更实操的问题：

你说要引入‘坏体验监控’。如果我们现在要上线一个新的 ETA 算法，目标是降低用户的‘心理落差’。除了‘取消率’，请你设计一套核心指标体系来衡量这个新算法在‘体验’和‘效率’上的平衡。如果让你只看一个数来决定是否回滚，你会看哪个数？”

追问解答

这道题有两个坑：

- 1. 指标体系太散：**很多人会报菜名一样列出十几个指标（点击率、转化率、时长、好评率……），没有逻辑分层。
- 2. 核心指标选错：**选 GMV？太迟钝。选转化率？又回去了。选好评率？那是 T+1 的事，黄花菜都凉了。

下面我来拆解这个「监控仪表盘」该怎么搭，以及那个「唯一的按钮」到底是什么。

第一部分：搭建「三角制衡」的指标体系

要平衡体验与效率，我们不能是一笔糊涂账。在地图/打车业务中，我建议建立一个「**准确度 - 业务量 - 体验感知**」的三角模型。

你的回答可以这样构建：

“针对 ETA（预估到达时间）算法的评估，我认为必须建立一套互相对抗的指标体系，主要分为三个维度：”

1. 准确度指标 (The Truth)：监控算法准不准 这是基础。如果不准，一切免谈。

- **MAPE (平均绝对百分比误差)**：这是一个统计学指标，用来衡量预测值和真实值的整体偏差幅度。
- **Bad Case Rate (坏案例率)**：这一点更关键。比如，「**预测偏差 > 3分钟的订单占比**」。MAPE 看的是平均，Bad Case 看的是下限。用户不会因为你平均准而夸你，但会因为一次迟到 10 分钟而骂死你。

2. 业务效率指标 (The Business)：监控单子有没有少 这是底线。算法再准，如果导致没人下单也不行。

- **TCR (Total Conversion Rate, 全链路转化率)**：从估价到成交的转化。
- **Fulfillment Rate (完单率)**：派出去的单子，最后真的完成履约了吗？
- **ATP (Arrival to Pickup, 接驾时长)**：司机实际用了多久接到人。这个指标反映了真实的运力供给压力。

3. 体验感知指标 (The Experience)：监控用户痛不痛 这是护栏。

- **取消率 (按原因细分)**：特别是选择“等待时间过长”或“司机位置不准”的取消占比。
- **低星差评率**：打分低于 3 星且标签为“迟到/不准”的订单占比。

第二部分：那个「唯一的决定性指标」是什么？

这是面试的高潮。面试官让你选一个数做“回滚”依据。

千万别选 **GMV 或 转化率**。因为短期内，一个极其激进（骗人）的算法，GMV 和转化率一定是涨的。等你发现 GMV 跌的时候，口碑已经崩盘了。

也别选 **NPS (净推荐值) 或 客诉量**。因为这些是**滞后指标 (Lagging Indicator)**。等用户投诉打爆客服电话，或者 NPS 调研报告出来，已经是几天甚至几周后了，这时候再回滚，损失已经造成了。

我的答案是：

我会选择「**严重预估偏差率 (Severe ETA Breach Rate)**」。

定义：**(实际接驾时间 - 预估接驾时间) > X 分钟 的订单占比**。（这个 X 分钟，通常取决于业务容忍度，比如 3 分钟或 5 分钟）。

为什么选它？

1. 它是最灵敏的「**即时指标**」：只要订单一结束，数据立马就能算出来，不需要等用户评价，也不需要等第二天看留存。它是实时的。
2. 它直接代表了「**信任危机**」的程度：如果用户比预估时间晚到了 1 分钟，他可能没感觉。但如果晚了 5 分钟，这就是一次严重的“预期违约”。如果这个指标飙升，说明我们的新算法虽然可能让更多人下单了（因为

展示的时间短)，但实际上根本做不到。我们在大规模撒谎。

3. 它是一票否决权：转化率跌一点，我们可以通过运营活动补；但如果「严重偏差率」从 5% 飙升到 15%，意味着每 100 个人里有 15 个人被狠狠欺骗了。这 15 个人是不可挽回的流失。所以，只要这个数超过阈值（比如 10%），必须立刻回滚，没有任何商量余地。

第三部分：分析师的延伸思考（加分项）

回答完上面两点，如果你想惊艳面试官，可以再补一句关于「AB 实验设计」的思考。

“另外，在做这个实验时，还有一个非常重要的细节：**样本隔离**。由于打车是双边市场，如果你在同一个区域切 50% 用户做实验组，50% 做对照组，会导致**实验组抢占对照组的运力**（因为实验组展示的时间更短，吸引了更多司机或用户），导致对照组数据变差，从而得出错误的‘新算法完胜’的结论。所以，评估这个指标时，必须采用**时间片轮转（Time-slice）**或者**蜂窝隔离（Geo-switch）**的方式来进行实验，这样看到的‘严重偏差率’才是真实的。”

知识点总结归纳

这道追问考察了三个核心能力：

- **指标体系的分层（Metric Hierarchy）**：输入（准确性）-> 过程（效率）-> 输出（体验）。
- **先导指标 vs 滞后指标（Leading vs Lagging）**：回滚决策必须依赖先导指标（实时发生的数据），不能依赖滞后指标（如投诉、留存）。
- **北极星指标的陷阱**：在风控或体验场景下，核心指标往往不是“涨了多少”，而是“坏了多少”（护栏指标）。**Severe Breach Rate** 就是典型的护栏指标。
- **实验设计的干扰项**：双边市场的 AB Test 存在**网络效应（Network Effect）**干扰，不能简单随机分流。

题目 11

【B站 | 用户运营 | 二面】

为了拉动日活，你们上线了一个强利益刺激的「每日签到领现金」活动。效果立竿见影：大盘 DAU（日活跃用户数）迅速上涨了 15%。

但数据日报里出现了一个很刺眼的“绿字”（下跌）：人均每日使用时长竟然下跌了 8%。

运营同学非常淡定，解释说：「这完全是数学问题：新来的『签到党』只停留 1 分钟，把平均值拉低了而已。只要看『总时长』是涨的，就说明大盘是健康的。」如果你是分析师，你会认可这个「平均值被稀释」的解释，并判定活动成功吗？你会担心这种「来完即走」的用户量，会对平台产生什么隐患？

解答

首先，我们要建立一个最基础的分析框架：**先验证数学逻辑，再验证业务价值，最后看长远隐患。**

运营同学的核心论点是：虽然人均时长跌了，但总时长是涨的，池子里的水变多了，所以大盘是健康的。

这话对不对？我们来现场做一次“带入数字”的推演。

假设活动前（基准值）：DAU = 100 人 人均时长 = 100 分钟 那活动前的总时长 = $100 \times 100 = 10000$ 分钟。

活动后（根据题目给出的涨跌幅）：DAU 涨了 15% -> 变成 115 人 人均每日使用时长跌了 8% -> 变成 92 分钟 那活动后的总时长 = $115 \times 92 = 10580$ 分钟。

$10580 / 10000 = 1.058$ ，也就是说，总时长确实涨了 **5.8%**。

看到这里，你大概就能意识到运营为什么这么淡定了。从「总时长」这个单一指标来看，他是对的，池子里的总水量的确变多了。如果公司的北极星指标（North Star Metric）仅仅是「总时长」，那他确实完成了 KPI，甚至可以说是个还不错的成绩。

但是——注意哦，这里有个巨大的「但是」——作为分析师，如果你这时候点头说「确实没问题」，那你基本上就挂了。

因为长视频平台（爱优腾芒）的商业模式，根本不是靠堆砌“无效时长”来赚钱的。运营同学的这个解释，其实利用了统计学里的盲区，掩盖了三个致命的业务陷阱。

下面我们就一层一层把这个「虚假繁荣」给扒开。

第一部分：别看平均值，平均值是最大的骗子（辛普森悖论实战）

运营说的「稀释」理论，其实就是统计学里经典的辛普森悖论（Simpson's Paradox）的变种。他说新来的「签到党」只停留 1 分钟，拉低了均值。

这听起来非常符合直觉，对吧？但我们不能只听他说，我们得用数学去验证这个“假设”是否成立。

我们必须马上把用户分成两波人：

1. **老用户（存量用户）**：那些本来就每天来看剧的核心用户。
2. **新用户（增量用户）**：那些被「领现金」吸引进来的羊毛党。

我们来做个极限假设：假设运营说的是真的，这 15 个新用户（15%的增量）真的是纯粹的“签到党”，每人每天只来 1 分钟。

那我们倒推一下，为了维持“大盘人均 92 分钟”这个结果，老用户的表现应该是多少？

公式是这样的： **$(\text{老用户数} \times \text{老用户时长} + \text{新用户数} \times \text{新用户时长}) / \text{总用户数} = \text{大盘人均时长}$**

带入数字： $(100 \times \text{老用户时长} + 15 \times 1) / 115 = 92$
 $100 \times \text{老用户时长} + 15 = 10580$
 $100 \times \text{老用户时长} = 10565$
老用户时长 = 105.65 分钟

发现问题了吗？

如果新用户真的像运营说的那样“只停留 1 分钟”，那么数学告诉我们：**老用户的人均时长必须从 100 分钟上涨到 105.6 分钟，才能把大盘平均值托在 92 分钟这个水平！**

如果数据跑出来，老用户时长真的涨了，那确实皆大欢喜。

但现实中，最可怕的情况往往是这样的：拆包后发现，新用户并不是只待 1 分钟，他们可能为了做任务挂机挂了 20 分钟（无效时长）。而老用户的人均时长，**其实从 100 分钟跌到了 95 分钟**。

这就不是「稀释」的问题了，这是「**存量被侵蚀**」。

为什么老用户时长会跌？因为你的「领现金」活动肯定占用了 APP 的黄金资源位。首页全是弹窗、红点、悬浮球，老用户想看剧，结果误触了三次广告，体验极差。于是他们关掉了 APP。

为了拉来这 15% 的羊毛党，你牺牲了核心用户的体验，导致核心基本盘在松动。这笔账，怎么算都是亏的。

所以，面对运营的解释，你的第一反应不是认可，而是要求：“**请把新老用户的留存和时长拆开给我看，我要确认老用户的数据一根毛都没有掉，我才敢信你。**”

第二部分：时长的“含金量”——APP内停留时长 ≠ 内容消费时长

好，退一万步说，假设老用户没受影响，真的纯粹是新用户带来的「总时长上涨」。我们有了 5.8% 的总时长增量。

作为分析师，必须具备极强的业务敏感度：**这 5.8% 的增量，到底发生在哪个页面？**

这就涉及到了长视频业务的核心逻辑。

长视频平台的 1 分钟，和抖音快手的 1 分钟，甚至和新闻资讯的 1 分钟，商业价值都是不一样的。长视频靠什么赚钱？

1. **会员收入 (Subscription)**：用户为了看好剧买会员。
2. **广告收入 (Ads)**：贴片广告（前贴）、中插广告。

这帮「签到党」的用户行为特征是什么？来了 -> 点击签到页 -> 浏览活动规则 -> 做任务（比如“浏览满15秒得金币”） -> 提现操作 -> 关掉 APP。

注意了！他们在 APP 里可能确实停留了 5 分钟。**但这 5 分钟，全部消耗在了「H5 活动页」或「任务中心页」。**

请问这 5 分钟里，平台能卖钱吗？

- **贴片广告？** 没机会展示，因为他们根本没点开正片（Video Play）。
- **会员转化？** 更是天方夜谭，他们是来赚钱的，不是来花钱的。
- **信息流广告？** 也许能展示一两个，但这种为了完成任务而进行的“被动浏览”，转化率（CVR）几乎为 0。

所以，结论很扎心：**那涨出来的 5.8% 的总时长，极大可能是「无效时长」或「垃圾时长」。**

它既没有广告库存价值，也没有会员转化价值。它只是让服务器的负载更高了而已。

如果是短视频平台，用户为了领金币刷视频，起码还贡献了 VV（播放量）和广告展现。但在长视频平台，**不看剧的时长，就是废时长**。

你需要去查一个更细的指标：**「视频内容消费时长」**。我敢打赌，虽然 APP 总时长涨了，但「视频内容消费时长」很可能是跌的。

第三部分：这不仅仅是运营活动，这是在做“资金风控”

这点是很多初级分析师容易忽略的——“领现金”不仅仅是一个运营活动，它本质上是一次资金分发。

题目中说了，这是一个“强利益刺激”的活动。既然涉及现金，就一定会招来互联网上最黑暗的一群人：**黑产和羊毛党**。

DAU 迅速上涨 15%？如果是自然增长，那简直是神迹。但如果是发钱带来的，这 15% 里有多少是真人？

如果是分析师，我会非常担心以下几点：

1. **设备指纹异常**：这 15% 的新增用户，是不是很多都来自同一个 IP 段？是不是用了模拟器？
2. **提现行为**：他们是不是一到提现门槛就秒提？提现之后留存率是不是直接归零？
3. **资金安全**：公司的预算是不是被这群人用脚本薅走了？

这已经不是“用户体验”的问题了，这是“**国有资产流失**”（如果是国企背景）或者“**营销费用被欺诈**”的问题。

如果运营同学还在沾沾自喜“DAU 涨了”，而没意识到他的预算可能全发给了机器人，那这个后果是灾难性的。你需要计算 **CAC（获客成本）**，但更要计算 **有效获客成本**。如果剔除掉秒提现流失的用户，真实的获客成本可能高到老板想杀人。

第四部分：更隐蔽的风险，是把算法给「喂傻」了

很多人分析到 ROI 这一层就停了，觉得已经很深刻了。但如果你想在面试里拿 S 卡，你得再往深想一层：**这波人对平台的长期生态有什么破坏？**

现在的长视频平台，全是靠**推荐算法（RecSys）**来分发内容的。首页的“猜你喜欢”，是流量分发的核心。

算法是怎么学习的？它是根据用户的点击、观看时长、完播率来判断内容好不好。

现在突然涌进来一大波「签到党」，他们的行为模式非常畸形：

- 只点签到页，不点内容页。
- 或者为了完成任务（比如“观看视频5秒领红包”），随便点开一个视频，放个 5 秒钟就关掉。

这会造成什么后果？这会产生大量的**噪音数据（Noise）**。

1. **全局点击率（CTR）被稀释**：首页展示了无数次海报，但没人点，算法会误以为今天推的内容都很烂。
2. **完播率暴跌**：视频刚开始就被关掉，算法会觉得这视频质量不行，从而降权（Down-weight），导致优质内容没法被分发给真正想看的人。

这种「数据污染」，修起来是非常麻烦的。你可能为了这几天的 DAU 暴涨，导致接下来一个月的推荐系统都变得「弱智」，让真正的老用户觉得「最近推的东西都不好看」，进而导致真正的用户流失。

这就是典型的「**饮鸩止渴**」。

总结一下我的分析逻辑

回到你的问题，我绝对不会认可运营那个「仅仅是平均值被稀释」的简单解释，我也不会判定这个活动是成功的。

相反，我会立刻做三件事：

1. **做分群 (Segmentation)**：只要老用户的「视频内容消费时长」有哪怕 1% 的下滑，立刻叫停活动，或者优化弹窗打扰策略。
2. **算 ROI 和反作弊 (Financials & Security)**：严查这 15% 新增用户的设备指纹和行为路径。如果发现大量脚本号，立刻封禁并停止发钱。计算这波用户的真实 LTV（生命周期价值），如果 LTV 覆盖不了发出去的现金，那就是亏本买卖。
3. **看生态 (Ecosystem)**：排查推荐算法的各项指标（如内容 CTR、完播率）是否出现异常波动，必要时要在算法模型里把这波「签到党」的数据剔除掉（加白名单或黑名单），别让脏数据把模型喂傻了。

数据分析师的职责，不是帮运营圆谎，而是帮公司避坑。当所有人都在为 DAU 欢呼的时候，我们得是那个看着财务报表和用户留存说「这事儿不对劲」的人。

本题复盘：知识点归纳

咱们把刚才用到的技能点，快速打包一下：

- **辛普森悖论 (Simpson's Paradox)**：在分组比较中都占优势的一方，在总评中有时反而是失势的一方。这里引申为：总体的平均值（人均时长）下降，掩盖了不同分群（老用户 vs 新用户）的真实表现差异。
- **北极星指标陷阱 (North Star Metric Trap)**：指标如果定得不够纯粹（比如只看总时长不看内容时长），很容易被动作变形地完成。
- **群组分析 (Cohort Analysis)**：这是破解平均值陷阱的唯一解法。必须把用户按「新老」「渠道」「行为」切片。
- **同类相食 (Cannibalization)**：指新业务或新活动不仅没带来增量，反而吃掉了原有的存量（比如打扰了老用户）。
- **数据污染 (Data Poisoning)**：异常用户行为对推荐算法模型的长远破坏。

最后的面试官视角

（好了，现在我切换回面试官的状态。看着你的回答，我点了点头。你的回答不仅涵盖了统计学陷阱，还涉及了长视频的商业模式、资金风控和算法生态，这比我预期的要深得多。）

面试官追问：

「你的分析非常全面，风险提示也很到位。但现在情况是，活动必须要搞，老板背着 DAU 的年度指标压力，停是不能停的。」

作为分析师，如果让你给运营同学提出一个『修正后的活动策略』，既能保住 DAU 的增长，又能解决你刚才提到的『时长下跌』和『老用户打扰』问题。你会建议他们怎么改？」

追问解答

面对这个追问，你的心态要立刻切换：老板的 KPI 是天条，DAU 必须保。所以我们不能再建议“砍掉活动”，而是要“置换流量的质量”。

我的建议方案，核心逻辑只有六个字：分人群，转任务。

第一步策略：精准分层，建立「老用户保护区」

既然我们最大的痛点是“老用户时长被侵蚀”，那解决办法很简单：别让老用户看见这个活动，或者别让他们以这种形式看见。

我会建议运营同学立刻上线「黑白名单策略」：

1. **高活/会员用户（白名单）**：对于那些本来每天就来看剧 30 分钟以上的用户，或者是尊贵的 VIP 会员，彻底屏蔽「领现金」的强弹窗。
 - **理由**：他们已经是核心资产，不需要用几毛钱来刺激，弹窗只会打扰他们。他们的留存靠的是好剧，不是红包。
 - **预期效果**：既然他们看不见弹窗，干扰就消失了，老用户的人均时长会立刻回升到正常水平。
2. **低活/流失边缘用户（目标人群）**：这个活动只针对这部分人开放。他们本来就不怎么来了，或者快流失了，这时候用强利益刺激把他们拉回来，才是真正的“增量”。

这一招叫「物理隔离」，保住基本盘，只用药救病患。

第二步策略：把「签到」改成「任务」，从“发钱”变成“买时间”

原来的逻辑是：来了 -> 点一下 -> 给钱。这太亏了。既然我们要发钱，就要让用户付出劳动。在长视频平台，用户的劳动就是“看视频”。

我会建议运营修改活动规则，把“一键签到”改成「阶梯式观影任务」：

- **原来的规则**：登录即送 0.5 元。
- **修改后的规则**：
 - 登录 APP：不给钱，但给一个红包待解锁状态。
 - **任务一**：观看任意正片满 3 分钟，解锁 0.2 元。（强制拉时长）
 - **任务二**：观看「每日推荐」里的精彩片段满 3 个，再解锁 0.3 元。（强制做内容种草）

这背后的逻辑是：既然这些羊毛党是为了钱来的，那我们就利用他们的贪欲。想拿钱？可以，把你的时间留下来。这样一来，原本 1 分钟的“垃圾时长”，就被强制转化为了 5-10 分钟的“有效时长”。虽然这依然不是主动消费，但起码数据好看了，而且有了 5 分钟的缓冲，用户很有可能被某个精彩片段吸引，真的转变为追剧用户。

第三步策略：把「落地页」做成「种草机」

刚才我们分析了，新用户来了只停留在活动页，不进内容页。

那我们就把活动页改造成内容页。

建议运营把“领现金”的那个 H5 页面进行改版：不要只放一个大大的“点我领钱”按钮。要把这个页面做成「短视频流」形式。页面上全是当下最热电视剧的「高光切片」（比如《狂飙》最燃的片段）。

用户在领钱的过程中，必须滑动浏览这些切片。

- **策略意图：**利用短视频的高刺激感，完成对长视频内容的「种草」。
- **转化路径：**用户为了领钱看切片 -> 觉得这剧有点意思 -> 点击下方“看正片”链接 -> 进入长视频播放页。

这样，我们把“外部流量”通过“金钱诱饵”，成功导流到了“核心内容池”。

总结我的建议

针对老板的 KPI 和现状，我的修正方案总结如下：

1. **做减法：**对高活老用户隐藏入口，消除干扰，稳住基本盘时长。
2. **做加法：**对羊毛党设置“观影门槛”，想拿钱必须贡献 5 分钟时长，拉升平均值。
3. **做转化：**改造活动页，用精彩切片做内容种草，把“领钱动机”转化为“看剧动机”。

这样一来，DAU 依然是涨的（因为钱还在发），但人均时长止跌回升，且转化率会有质的飞跃。这就是一个不仅保住了面子（KPI），也保住了里子（生态健康）的双赢方案。

本题复盘：知识点归纳（最后一次总结）

你看，通过这个追问，我们其实用到了更高阶的业务策略：

- **价格歧视与分层运营（Price Discrimination）：**同样的激励，给不同的人。不需要激励的人不给，需要激励的人给重药。
- **沉没成本与行为设计（Sunk Cost）：**让用户付出时间成本（看3分钟），他们为了拿钱不得不看，看了之后流失成本就变高了。
- **漏斗优化（Funnel Optimization）：**从“活动页”到“正片页”的转化，中间加一个“短视频种草”的桥梁。这也是现在爱奇艺、腾讯视频都在做的事情（用短带长）。

题目 12

为了提升「关注页」的可消费性，你们尝试在用户的关注流里，混入了 20% 的「系统推荐优质内容」（原本全是用户关注的人）。实验数据显示：关注页的人均消费时长提升了 15%。

但出现了一个异常指标：用户对已关注作者的「取关率」同时也上涨了 30%。

策略产品非常兴奋，认为：「这是好事！说明推荐的内容太好了，用户一对比，发现以前关注的人很水，就取关了。我们这是在帮用户『优胜劣汰』，净化关注列表。」如果你是分析师，你会认可这个「优胜劣汰」的解释吗？你会认为这是在优化生态，还是在破坏「关注」这个核心心智？

解答

面试官这道题非常经典，考的不是 SQL，而是你对「流量分发机制」和「用户心理账户」的深刻理解。如果只盯着消费时长涨了 15% 就点头叫好，这道题基本就挂了。

第一部分：先把基调定准——我们到底在卖什么？

在看数据之前，必须先对齐「关注页」的产品定义。这决定了我们怎么判断“好坏”。

长视频平台的双核驱动通常是：推荐页（公域）+ 关注页（私域）。

推荐页：核心逻辑是「发现」和「杀时间」。用户心理是“我不知道看什么，你给我推最爽的”。这里的核心指标确实是消费时长和点击率（CTR）。

关注页：核心逻辑是「订阅」和「信任」。用户心理是“我要看我选的人，不要给我塞杂质”。这里的核心契约是「确定性」——我关注了谁，我就应该看到谁。

策略 PM 的做法，本质上是在用户的“私人订阅箱”里，强行塞入了 20% 的“系统传单”。

虽然传单可能设计得很漂亮（推荐内容质量高），用户忍不住多看了两眼（时长 +15%），但用户发现自己的箱子不纯粹了，于是开始退订报纸（取关率 +30%）。

这时候 PM 说这是“优胜劣汰”，这在逻辑上非常牵强。这更像是违背了契约后的用户应激反应。

第二部分：深度数据拆解——这 15% 和 30% 到底意味着什么？

咱们来算一笔账，用数据教做人。

关于「时长 +15%」的含金量：

你要知道，推荐算法的效率天生就是碾压人工订阅的。推荐系统是从全站亿级内容池里，选出最热、最吸睛的内容。而关注流受限于用户关注的那几十个作者，内容供给是有限的。

你拿全站 Top 1% 的高热内容，去降维打击用户关注的普通内容。掺入 20% 的推荐内容，时长才涨了 15%？

说实话，作为分析师，我觉得这个 ROI（投入产出比）其实并不高。这意味着你用了极高密度的“强刺激”内容，只换来了常规的增长。这说明用户在关注页的心智很顽固，他们可能并不是来找“刺激”的，而是来找“熟悉感”的。

关于「取关率 +30%」的灾难性：

这是最可怕的数字。大家要注意，面试题里的“取关率上涨 30%”通常指的是相对值（比如从 0.1% 涨到 0.13%），但即便如此，这也是核心护栏指标的“穿透级”事故。

复利效应的恐怖： 关注关系是平台的护城河。今天的取关率涨 30%，意味着用户在这个 App 里的社交链接在加速断裂。一个月后，用户的关注列表变短了，Feed 流变空了。

Feed 流变空的恶性循环： 因为用户取关了，关注页的内容更少了 -> 平台为了填满屏幕，只能塞入更多推荐内容 -> 关注页彻底变成推荐页 -> 用户觉得“关注”这个功能没用了 -> 彻底不再点击关注页。

这是一个典型的“饮鸩止渴”模型：用破坏关系的代价，换取了一时的时长。

第三部分：逻辑归谬——为什么我不信「优胜劣汰」？

PM 的解释是：用户对比了优质推荐内容，发现原关注太水，所以取关。这叫净化。

这个解释最大的漏洞在于：**忽略了“信息噪音”带来的焦虑感。**

我举个更真实的业务场景：

用户打开关注页，原本想看“老番茄”或者“罗翔老师”有没有更新。

结果屏幕里混入了 20% 的美女热舞或者土味短剧（推荐内容）。

用户可能确实看完了短剧（时长增加了），但当他划过去之后，发现找不到“老番茄”了。因为推荐内容打断了原本的时间序，或者抢占了视觉焦点。

这时候，用户产生了一种“失控感”。

为了找回控制权，用户下意识的动作不是“对比质量”，而是“清理门户”。他会觉得“是不是我关注的人太多了，导致我看不到想看的人？”

于是他开始取关。他取关的可能并不是“水”的作者，而是那些“更新频率低、但在心里地位高”的作者，或者仅仅是因为列表太乱了，他在做一种**防御性的清理**。

如果真是这样，这不叫“优胜劣汰”，这叫**“劣币驱逐良币”**。你把用户的“老朋友”挤走了，换来了“陌生人”。

第四部分：生态推演——全量上线后的结局

如果这个实验全量上线，结合当下的行业背景，会发生什么？

1. 创作者（UP主）的集体出逃

这是目前内容平台最敏感的话题。创作者为什么要辛苦做号？是为了沉淀私域流量。

“我有 100 万粉丝，我就应该能触达这 100 万人。”这是创作者的安全感来源。

现在你告诉他，你的粉丝列表里 20% 被系统截胡了，而且因为系统瞎塞内容，导致粉丝开始取关我了。

创作者会认为平台在“公域化”他的私域资产。一旦头部创作者觉得“在这个平台涨粉没用，反正粉丝也看不到我”，他们就会停更，或者把重心转移到微信公众号、私域社群等更安全的地方。供给端一崩，平台就完了。

2. 关注页的“抖音化”与同质化

如果关注页里全是推荐内容，那它和推荐页还有什么区别？

当两个 Tab 的功能趋同，用户的心理账户会合并。最终结果是，用户不再点开关注页。

一旦用户习惯了只看推荐，那么“关注”这个动作就没有意义了。平台就失去了一个最核心的**留存抓手**。

推荐是用**内容**留人（今天没好内容我就走了），关注是用**关系**留人（内容不好但我喜欢这个人，我也会留下来）。废掉关注页，等于平台自断一臂，从“社区”退化成“播放器”。

第五部分：作为分析师的最终建议

骂归骂，活儿还得干。作为分析师，我不能只说“不行”，我得告诉 PM 怎么做才“行”。

我会给出以下建议：

1. 立即止血，细分归因：

不要只看总数。我要看**被取关的作者到底是谁？**

Scenario A（PM 赢了）： 被取关的全是 3 个月未更新的“死号”，或者搬运号。那说明确实是“净化”。

Scenario B（PM 输了）： 被取关的包含活跃的中腰部作者，甚至头部作者。那必须立刻回滚实验，因为你在杀伤生态。

2. 优化“混入”的策略——不要硬塞：

现在的策略太粗暴了（20% 混排）。建议改为：

Gap Filling 策略： 只有当用户的关注内容**全部刷完**（或者当天更新不足 X 条）时，才出现推荐内容。这叫“补充供给”，是帮忙。

End of Feed 推荐： 在关注流的底部，提示“你关注的人都看完了，猜你还喜欢……”，这时候再推，用户不会反感，反而感激。

3. 建立“信任折损”监控体系：

以后做类似实验，不能只看时长。必须把「取关率」、「关注页渗透率」、「人均关注数变化」作为**一票否决指标**。

知识点总结

好，这道题咱们算是拆透了。最后总结一下这里面用到的分析思维，全是干货：

北极星指标 vs 护栏指标： 时长是北极星，但取关率是护栏。车开得再快，撞栏杆也是死。面试时一定要提到“护栏指标”这个词，非常加分。

短期刺激 vs 长期留存：推荐内容是多巴胺（短期爽），关注关系是催产素（长期信任）。用长期资产换短期数据，通常是分析师要警惕的。

双边市场效应：做平台分析，永远不要只看消费者，必须回头看供给者。伤害创作者利益的增长，都是假增长。

归因的逻辑陷阱：两个指标同时上涨（时长涨、取关涨），不代表它们之间互为因果。可能是同一个干扰因素（推荐内容干扰）导致了两个不同的结果。

面试官视角：追问环节

（分析完这一大通，面试官通常会两眼放光，觉得你很懂业务。这时候他会抛出终极一问）

“刚才你提到了‘Gap Filling’策略，也就是在关注内容不足时再补充推荐内容。那么问题来了：**你怎么定义‘关注内容不足’**？如果一个用户关注了 100 个人，每天更新 50 条视频，但他只看 5 分钟就走了。这时候，我们应不应该判定他‘没看爽’，从而给他插入推荐内容来提升这 5 分钟的密度？这个判断的临界点你会怎么用数据去定？”

追问解答

面试官这个问题非常犀利，直接切中了策略的核心痛点。

针对那个“关注了 100 人，有 50 条更新，但只看了 5 分钟”的场景，我的核心观点是：

我们不能用「物理库存」来定义不足，而要用「消费效率」来定义不足。

哪怕库存还有 1000 条，只要用户觉得“不好看”或者“看累了”想走，对他来说就是“有效内容不足”。

我会有层次地通过三个步骤来搭建这个**阈值模型**：

第一步：区分「完成任务」还是「内容太烂」？（意图识别）

用户看了 5 分钟就走，有两种可能：

- 场景 A（任务完成）：**他只是在等地铁，或者只想看看有没有核心关注的人更新。看完满意的就走了。
- 场景 B（败兴而归）：**他想看很久，但滑了 10 下发现全是广告或水贴，失望离开。

作为分析师，我需要找到区分这两者的**特征指标**：

- **滑动速率：**
 - 如果这 5 分钟里，他是**匀速慢滑**，且有点赞、评论互动，说明他在认真消费。这时候他走，是“吃饱了”，**坚决不能插推荐**，否则是画蛇添足。
 - 如果他是**加速快滑**（比如 1 秒滑过 3 条），且几乎没有点击进入详情页。这说明他在“找”东西但没找到。这时候，才是我们要干预的时机。
- **历史习惯比对：**
 - 看该用户过去 30 天在关注页的平均停留时长。
 - 如果他平时都看 30 分钟，今天只看了 5 分钟就加速退出 -> **判定为“内容不足/质量差”，触发插入策**

略。

- 如果他平时就是看 3 分钟的“快枪手” -> 判定为“正常访问”，不打扰。

第二步：建立动态评分模型

我不建议用一个固定的数字（比如“剩下少于 5 条就插入”）作为阈值。我建议建立一个实时的「库存吸引力分数」。

对于那剩下的 40+ 条未读更新，系统其实是知道它们质量的（基于其他用户的后验数据）。

公式逻辑（非数学，讲逻辑）： $\text{剩余库存吸引力} = \Sigma (\text{剩余每条内容的预测点击率 pCTR})$

- **情况 1：** 虽然用户还有 45 条没看，但这 45 条全是用户平时不爱看的“低质搬运号”或者“营销号”，累加起来的 pCTR 极低。
 - **策略：** 系统判定“有效库存枯竭”，立刻插入高热推荐内容来救场。
- **情况 2：** 剩下 45 条里，有 3 条是他最爱看的“老番茄”和“老师好我叫何同学”。
 - **策略：** 系统判定“有效库存充足”，绝对不插，赶紧把这 3 条好内容提权（Re-rank）到最前面让他看到，而不是用推荐内容把他挤走。

所以我的回答是：不看条数，看分值。当剩余未读内容的总预测消费时长低于某个阈值（比如低于 2 分钟）时，触发 Gap Filling。

第三步：设计“挽留式”插入，而不是“阻断式”插入

面试官刚才问的是“应不应该插入”，其实怎么插更重要。

针对这种“有库存但只看 5 分钟”的用户，硬插大概率会激怒他。我建议采用 End-of-Session（会话结束前）的软性策略：

- **不要混排（Don't Mix）：** 既然他还有 50 条更新，别在中间插队，这会让他觉得乱。
- **负向反馈触发（Trigger by Exit）：** 当捕捉到用户有“连续快速上滑”或者“点击返回顶部/退出”的手势时：
 - 弹出一个 Toast 提示或底栏横幅：“今天大家都在看《黑神话：悟空》的通关视频，点这里看看？”
 - 这给了用户选择权。如果他是因为没东西看才走的，他会点；如果他赶时间，他不点也没损失。

第四步：AB 测试的验证方案

最后，为了保险起见，这套策略必须跑 AB 测试。

- **对照组：** 纯时间序展示，不干预。
- **实验组 A（激进）：** 只要剩余 pCTR 总分低于 X，就在第 5 条后混入推荐。
- **实验组 B（保守）：** 仅在监测到“快速跳过”行为时，在流的末尾追加推荐。

我们要观察的**核心指标**不是“单次时长”，而是“**次日留存**”和“**关注页打开频次**”。如果实验组导致用户第二天不来关注页了，说明我们打扰到了他的“私人领地”，策略必须下线。

知识点复盘

解答到这里，其实你已经展示了非常成熟的分析师思维：

- 1. **用户分层 (User Segmentation)**：没有“平均用户”，只有“赶时间的用户”和“无聊的用户”。
- 2. **动态阈值 (Dynamic Threshold)**：拒绝死板的数字（比如“剩 5 条”），使用概率累加（pCTR sum）来定义库存质量。
- 3. **负向体验防御**：始终把“不打扰用户”作为底线，通过重排（Re-rank）优于混排（Insert）的思路来解决问题。
- 4. **意图判断 (Intent Detection)**：这是一个高级考点，利用行为特征（滑动速度）来推测心理状态。

这样回答，既解决了“能不能插”的问题，又给出了“怎么插才科学”的方案，直接把产品经理可能没想细的地方都补全了。

题目 13

【美团 / 饿了么 | 履约策略 | 二面】

为了降低每单的配送成本，你们调整了调度算法，提高了「拼单率」（让骑手一次多带顺路的单子）。数据表现很亮眼：单均配送成本下降了 12%，这直接全是纯利润。

但你发现了一个很微妙的“矛盾”：虽然「准时送达率」并没有下降（说明骑手确实赶上了），但用户的「五星好评率」却下跌了 8%。

业务负责人的判断是：「只要饭没送晚，用户就不会流失。好评率跌一点只是因为用户看到骑手绕路心里不爽，属于『情绪价值』受损，不影响核心留存，成本省下来才是真金白银。」如果你是分析师，你会敢于支持这个「牺牲好评换利润」的决策吗？你会认为「准时率」是底线，还是「好评率」的下跌预示着更大的危机？

解答

遇到这种“既要利润又要体验”的策略题，千万别上来就凭感觉站队。这题看着是在问你选利润还是选体验，其实是在考察你是否具备“**拆解数据谎言**”的能力，以及是否拥有“**全链路的业务视角**”。

很多分析师看到“省了 12% 成本”就觉得是天大的功劳，甚至想帮着洗地。别急，我们把这个“矛盾”彻底撕开来看，你会发现事情没那么简单。

第一部分：先排查数据，这“准时率”是不是在骗人？

题目里说：“准时送达率没有下降，但好评率跌了 8%。”

这在逻辑上非常反直觉。如果骑手真的都在承诺时间内送到了，用户为什么会大幅度不爽？

这里有一个极其隐蔽的“**数据障眼法**”，你必须第一时间向面试官指出来：

是否存在“拉长 ETA（预计送达时间）”的情况？

这是平台常用的策略。为了提高拼单成功率，算法可能把原本承诺用户的“30 分钟必达”，悄悄调整成了“40 分钟预计送达”。

只要骑手在 39 分钟送到，指标上依然统计为“准时”。

但在用户眼里：

- 以前点这家店，一局王者荣耀没打完饭就到了（25 分钟）。
- 现在点这家店，两局打完了饭还没到（39 分钟）。
- 虽然系统显示“准时”，但用户的体感是“**显著变慢**”。

这解释了为什么好评率会暴跌——**因为用户的预期被强行降低了，而不是服务质量真的达标了**。这种通过调整分母（承诺时间）来维持分子（准时单量）的做法，是在透支用户的信任。

另外，还有一个致命体验叫“**看得见的绕路**”。

用户看着地图上骑手明明离自己只有 500 米了，突然掉头往反方向跑 2 公里去送顺路的拼单。这种“近在咫尺却吃不到”的愤怒值，远高于单纯的等待。这 8% 的好评下跌，大概率是这种“**确定性丧失**”带来的。

第二部分：把账算死，12% 的成本真的值吗？

业务负责人说：“只要不晚，好评下跌只是情绪价值，省下来的成本是真金白银。”

这个观点非常危险。我们需要做一个“**带数字的推演**”，用财务逻辑反驳他。

假设：单均配送成本是 7 元，日均 1000 万单。

- **成本端**：下降 12%，意味着每单省了 **0.84 元**。一天省下 840 万元，确实很诱人。

但是，我们来看**损失端**：

- **收益模型**：一个活跃用户的年 GMV 贡献约为 3000 元，平台抽成+广告假设赚 15%，即 **450 元 LTV（年生命周期价值）**。
- **流失推演**：仅仅为了在这一单上省下 **0.84 元**，我们得罪了用户。如果这 8% 的好评下跌，最终转化成了 **1% 的核心用户流失**。
- **算账**：失去 1 个用户，意味着未来一年 **450 元的毛利蒸发**。
- **对比**：为了赚眼前的 0.84 元，冒着损失 450 元的风险。你需要送 **535 单** 省下的钱，才能弥补 **1 个用户** 流失带来的损失。

结论：在目前的存量竞争时代（获客成本极高），用“极高风险的 LTV 损失”去换取“微薄的单均成本节省”，这笔账在长期绝对是亏的。

而且，**好评率下跌是前置指标，GMV 下跌是滞后指标。**等你发现 GMV 真的掉了再想改，用户早就卸载跑去竞对平台了。

第三部分：被忽略的“骑手侧”风险

除了用户和利润，这个策略还漏掉了最重要的一环：**骑手（供给侧）**。

拼单率提高，意味着骑手车上的箱子更满，脑子里规划的路线更复杂。

- **安全风险：**骑手为了赶多个单子的时间窗，逆行、闯红灯的概率会指数级上升。一旦发生一起恶性舆情事故，省下来的那点配送费都不够赔公关费的。
- **运力流失：**以前送 1 单爬 6 楼，现在送 3 单可能要爬 3 次 6 楼。如果每单的单价因为“拼单”被压低，骑手单位时间的收入没有显著提升，但劳动强度大了，骑手会流失。
- **供需反噬：**骑手一走，高峰期没人接单，平台又得花钱发“高额补贴”把骑手拉回来。这一进一出，之前的 12% 成本节约又被吐回去了。

第四部分：既然不能全切，那该怎么办？

作为分析师，直接否定业务是不够的，我们要给出“既要又要”的解法。我的建议是“**精细化分层策略**”。

1. 场景分层：谁能拼，谁不能拼？

- **绝对不能拼的单：**新用户首单（第一印象定生死）、高客单价订单（付了 200 块还在乎几块钱运费？）、商务楼午高峰（时间就是生命）。这些单子必须锁死“专送”，保好评。
- **可以激进拼的单：**下午茶时段、非饭点、校园单、客单价 < 20 元的订单。这些场景用户对时效不敏感，对价格敏感，可以加大拼单力度。

2. 产品化解决“情绪问题”

- **预期管理：**在下单页直接给用户选。
 - 选项 A：**极速达（专送）**，30 分钟，配送费 5 元。
 - 选项 B：**集单送（拼单）**，45 分钟，配送费 0 元。
- 把选择权交给用户。选了 B 的用户，心里有了“为了省钱愿意等”的预期，就算看到骑手绕路，他也不会给差评。这样既筛选出了价格敏感型用户帮我们降本，又保护了高价值用户的体验。

3. 动态补贴机制

- 系统如果检测到这单已经拼了 3 单，且预计送达时间接近临界值，立刻在骑手端触发“压单预警”，或者在用户端弹窗“**准时红包**”。
- 在用户发火之前，先用一张 3 元的优惠券把嘴堵上。这 3 元成本比流失一个用户便宜得多，而且比全量发券更精准。

总结

我不支持当前这种“掩耳盗铃”式的激进降本策略。

数据表现出的“利润”是短期的、显性的；但“体验”的受损是长期的、隐性的。好评率跌 8% 是一个非常严重的熔断信号。

建议立刻回滚策略至灰度状态，只在“低敏感场景”开放高拼单率，严控核心用户的履约体验。

面试官视角的反思与总结

这个回答之所以能拿高分，是因为它没有停留在“好评率重要”这种正确的废话上，而是：

1. **揭穿了数据：** 指出了“准时率”背后可能存在的 ETA 操纵。
2. **量化了风险：** 用“0.84 元省钱”对比“450 元 LTV”，让风险变得肉眼可见。
3. **覆盖了全链路：** 不仅看了用户端，还看了骑手端的隐患。
4. **给出了策略：** 用分层和产品化手段，解决了“既要又要”的难题。

本次解答用到的核心知识点：

- **北极星指标的局限性：** 单一看“单均成本”或“准时率”都会骗人，必须看“指标对撞”。
- **LTV（生命周期价值） vs CAC（获客成本）：** 算账的底层逻辑，永远是用长期价值决策当下投入。
- **供需模型：** O2O 业务不仅有需求侧（用户），还有供给侧（骑手），两边都要稳住。
- **用户分层运营（Segmentation）：** 没有任何一个策略适合 100% 的用户，分层是万能钥匙。

OK，这道题的逻辑我们挖得足够深了。

现在，我切换回面试官视角。你刚才提到了“产品化解决”，让用户自己选“极速达”还是“集单送”。

那么我的问题是：如果上线了这个功能，你预计会发生什么负面情况？（比如大家都选便宜的，导致营收暴跌？）你会设计哪些指标来监控这个新功能的健康度？

追问解答

这是一个非常敏锐的追问。你指出的“大家都选便宜的，导致营收暴跌”，正是「价格歧视」策略中最核心的风险点——收益蚕食。

如果在面试中被问到这一层，说明面试官已经认可了你的大方向，现在正在考察你落地执行的细腻程度和风控意识。

以下是针对“分层履约”上线后可能出现的负面情况推演，以及配套的监控指标体系。

一、可能发生的负面情况

除了你提到的“营收暴跌”，其实还有更隐蔽的运营风险：

1. 收益侧：严重的“消费降级”

- **现象：**原本对时间不敏感、愿意支付标准运费的用户，发现有个“减免运费”的选项，虽然慢15分钟，但他们觉得无所谓，纷纷倒戈。
- **后果：**订单量没变，但“配送费收入”断崖式下跌。如果省下的配送成本（B端）无法覆盖掉损失的配送费收入（C端），平台就是“做慈善”，亏损反而扩大。

2. 履约侧：“极速达”变“欺诈达”

- **现象：**假如晚高峰运力本身就不足，而此时一部分用户付了高价买了“极速达”。但系统发现根本调不出“专送”骑手，或者路况实在太堵。
- **后果：**付费用户没享受到承诺的特权（依然超时了）。这种“花了钱买罪受”的愤怒值是普通超时的10倍，会导致高端用户永久流失，甚至引发监管投诉（虚假宣传）。

3. 供给侧：骑手挑单与博弈

- **现象：**骑手知道“集单送”的单子单价低、时效宽，可能在心理上产生懈怠（反正还有40分钟，我先去送那个极速达，或者先去抽根烟）。
- **后果：**“集单送”的订单虽然时效长，但如果骑手过度拖延，导致实际送达时间超过了那个本来就延长的承诺时间（比如承诺45分钟，结果送了60分钟），那低价策略也就失效了，好评率依然会崩盘。

二、监控指标体系

为了监控上述风险，我们需要建立一套包含“财务健康”、“履约质量”和“用户迁徙”的指标看板。

1. 核心护栏指标——只要这几个跌了，马上回滚

- **履约差异化兑现率（极速达准时率）：**
 - 定义：购买“极速达”的用户，实际在承诺时间内送达的比例。
 - **阈值：**必须死保 **99.5%** 以上。既然收了溢价，就必须是确定性服务。
- **Unit Economics (UE) 变化值：**
 - 定义：上线后（每单平均配送收入 - 每单平均配送成本）vs 上线前。
 - **目的：**监控是不是“省下的成本 < 损失的收入”。如果该值为负，说明策略亏钱。

2. 策略健康度指标——判断功能是否良性

- **功能渗透率分布：**
 - 定义：选择“极速达” vs “标准送” vs “集单送”的订单比例。
 - **预期：**我们希望呈现纺锤形或金字塔形。如果90%的人都选了“集单送”，说明定价出了问题（极速

达太贵或集单送太香）。

- 分层好评率：

- 定义：分别看“极速达”用户和“集单送”用户的五星率。
- 目的：验证假设——选了集单送的用户，是否真的因为有了心理预期而不再给差评？如果集单送用户依然大量差评，说明“预期管理”策略失败。

3. 诊断与风控指标——谁在薅羊毛？

- 高价值用户降级率：

- 定义：历史月均消费 > 1000 元的用户，在新功能上线后，选择“集单送”的比例。
- 目的：监控核心金主是否在被“逆向转化”。如果高净值人群都在降级，需要立刻干预（例如对这部分人隐藏低价选项，或只给他们发极速达优惠券）。

三、既然有风险，该如何应对？

作为分析师，提出监控指标只是及格，能给出**动态调控策略**才是高分。针对你担心的“营收暴跌”，我有两个“后手”：

1. 动态定价：

- 不要把“极速达”和“集单送”的价差做死。
- 策略：当系统检测到某个区域闲置运力很多时，缩小价差（鼓励大家选极速达，增加收入）；当运力紧缺爆单时，拉大价差（通过高价劝退非急需用户，通过低价引导用户去集单，以此削峰填谷）。

2. 库存控制：

- 不要让所有用户在所有时间都能看到“集单送”。
- 策略：只在预测的“顺路拼单成功率”高于 80% 的时候才放出这个选项。如果系统算出来这单没法拼，必须专送，那就直接隐藏“集单送”入口，避免用户选了便宜的但我们还得亏本去送。

总结给面试官的话：

“所以，上线这个功能的最大风险确实是**利润模型的崩塌**。我会重点监控 **UE 模型的变化** 和 **高价值用户的选择倾向**。

这个功能的本质不应该是简单的‘降价’，而是一种**运力的动态定价工具**。我们要用价格杠杆，把此时此刻最稀缺的运力，分配给最愿意付费的用户，而不是单纯地为了省钱而降级服务。”

题目 14

为了挖掘潜在的付费用户，你们针对非会员上线了「VIP 内容每日免费试听 30 分钟」的福利策略（原本完全听不了）。实验结果非常喜人：非会员的人均收听时长暴涨了 40%，用户黏性明显变强。

但直接的商业结果很惨：实验组当周的「会员新增付费人数」反而下跌了 15%。

产品经理非常笃定，认为：「别慌，这很正常。现在是『养鱼』阶段，用户习惯了优质内容后，下个月我们再收紧权限，付费率绝对会报复性反弹，现在的跌是为了将来赚更多。」

如果你是分析师，你会敢赌这个「报复性反弹」的未来吗？你会倾向于认为这是高明的「放长线」，还是认为门槛太低导致原本该付费的人「正在白嫖」？

解答

如果我是负责这块业务的分析师，我的第一反应绝对不是「相信未来」，而是——**警报拉满，立即止损。**

说实话，跌 15% 是一个非常惊悚的数字。在成熟的商业化业务里，这种幅度的下跌通常意味着你的策略击穿了底线，而不是在「蓄力」。

我们分五个层次来把这件事彻底拆透，看看为什么我不敢赌这个「报复性反弹」。

第一层：为什么会跌？因为 30 分钟就是「满足阈值」

先别谈什么长线短线，我们要先搞清楚为什么付费会掉。

这里得引入一个核心概念：**「核心需求覆盖率」**。

音频产品的使用场景其实非常集中且固定：

1. 通勤：大部分在一二线城市打工的人，单程地铁/公交的时间就在 30-45 分钟左右。
2. 睡前：很多人听个 20-30 分钟助眠，听着听着就睡着了。
3. 午休/摸鱼：碎片化的 15-20 分钟。

发现问题了吗？**「每天免费 30 分钟」这个额度给得太大了。**

它不仅仅是「试听」，它实际上**完整覆盖**了大概 60%-70% 轻度用户的全天候核心听歌/听书需求。

原本这批用户里，有一部分人因为想听某首 VIP 歌或者某个相声，发现听不了，通勤路上又无聊，一咬牙就充了会员（这是刚性转化）。

现在呢？你告诉他：「别急，你每天都能免费白嫖 30 分钟哦。」用户心想：「太好了，我坐地铁刚好半小时，听完下车，完全不用买会员了。」

所以，这 15% 的下跌，不是因为用户还在犹豫，而是因为**你的免费策略完美替代了他们的付费动机**。这在经济学上叫「蚕食效应」。你原本想用免费策略去勾引那些「完全不付费的人」，结果你先把那些「本来准备付费的人」给喂饱了。

第二层：被忽略的致命伤——版权成本倒挂

之前的分析只看了「收入端」，还没看「成本端」。在内容行业，这是要命的。

网易云或喜马拉雅的VIP内容（比如XXX的歌、大制作的有声书），平台是需要给版权方结算版税的。结算方式通常有两种：

1. 买断制：先付一大笔钱。
2. 分成制：按播放次数或会员收入分成。

注意了，如果是非会员听了VIP内容，平台不仅没收到会员费，往往还需要为这30分钟的播放量向版权方支付成本（或者消耗保底金额）。

现在的账模型是这样的：原本：用户不付费 -> 听不了VIP -> 平台没收入也没版权成本 -> 净利为0。原本：用户付费15元 -> 听VIP -> 平台收入15元，支付版权成本 -> 净利为正。

现在的策略下：用户不付费 -> 免费听30分钟VIP -> 平台收入为0（或者极低的广告收入），但产生了30分钟的高昂版权成本 -> 净利为负！

所以，PM看到的「时长暴涨40%」，在财务眼里可能全是「无效且昂贵的流量」。这些时长不仅没有转化成钱，反而在疯狂消耗公司的版权预算。这不仅仅是「少赚」，这是在「失血」。

第三层：PM说的「养鱼」，逻辑通吗？

PM的逻辑是：用户听了30分钟，就会想听第31分钟，然后就会付费。这个逻辑听起来很顺，但在实际业务中，这取决于**内容类型**。

如果你的产品是**强连续性的长篇有声书（悬疑/言情）**：PM的逻辑**可能成立**。用户听到第30分钟正是剧情高潮，凶手刚要拿刀，突然断了，抓心挠肝，这时候付费意愿极强。这种场景下，30分钟是「钩子」。

但如果你的产品是**音乐或者单元剧/相声**：PM的逻辑**基本不成立**。音乐是碎片化的。我今天听周杰伦听爽了30分钟，明天再听也是一样的。我没有必须听到「第31分钟」的强迫性。单曲循环30分钟早就够了。这种场景下，30分钟不是钩子，是「福利餐」。

从数据表现来看，「时长暴涨40%」恰恰证明了用户听得很爽。用户越爽，且没有触发行付费墙，说明这30分钟对他们来说**完全够用了**。

这时候你指望下个月「收紧权限」后会有报复性反弹？大概率不会。一旦用户习惯了「免费听」，当你下个月取消这个福利时，他们产生的不是「购买欲」，而是「被剥夺感」和「愤怒」。他们更可能流失，或者去转战其他盗版/竞品平台，而不是乖乖掏钱。

第四层：算一笔账，看看我们要「赢」得有多难

我们来做个简单的数学推演，看看所谓的「未来反弹」需要达到什么量级，才能弥补现在的亏空。

假设实验组原本每天有1000个潜在付费用户，日ARPU（每用户平均收入）是10元。**原本收入：** $1000 \text{ 人} \times 10 \text{ 元} = 10,000 \text{ 元}$ 。

现在的情况（跌 15%）： 付费人数变成了 850 人。**现在收入：** 850 人 * 10 元 = 8,500 元。每天直接营收亏损 1,500 元。**额外隐性亏损：** 假设那 150 人每人每天免费听的版权成本是 0.5 元，这又是 75 元的净亏损。

PM 说这是「投资」。好，那我们看看回本模型。假设这个策略跑了 1 个月，我们仅营收就亏了 $1500 * 30 = 45,000$ 元。

下个月我们收紧权限，开始「杀猪」。为了填平上个月 4.5 万的坑，并且还要在此基础上实现增长（否则为什么要折腾？），下个月的新增付费人数得暴涨多少？

这里有个致命的漏斗问题：这一个月里，确实有很多「白嫖党」进来了（因为时长涨了 40%），假设活跃用户池子扩大了 20%。但是，把一个「习惯了免费」的用户转化为「付费」用户，难度远高于把一个「本来就有需求」的用户直接转化。

你需要下个月的转化率做到非常夸张的程度，才能把这 15% 的缺口、时间成本、以及额外支付的版权成本全部追回来。在互联网红利见顶的今天，用「确定的营收下跌」去赌「不确定的未来转化暴涨」，这在 ROI（投资回报率）计算上是极度危险的。

第五层：如果不一刀切，我们该怎么救？

作为一个分析师，光会怼 PM 是没用的，我们得给出解法。既然「时长暴涨」说明用户确实对 VIP 内容感兴趣，那个方向没错，只是手段太粗糙。

我不建议赌那个遥远的「下个月」，我建议立刻调整策略，做精细化分层：

1. 从「固定时长」改为「动态权益」

不要给所有人 30 分钟。对于从未付费的纯新用户：给 30 分钟，甚至 60 分钟，培养习惯（养鱼）。对于曾经付费但过期的用户，或者高频访问的用户：只给 5 分钟，或者完全不给。这部分人离付费很近，不能惯着。

2. 改变限制方式：用「集数」卡，别用「时间」卡

对于有声书：不要限制「分钟数」，要限制「关键节点」。比如前 3 集免费，第 4 集（高潮点）必须付费。利用内容的连贯性来转化，而不是靠时间。对于音乐：不要全库免费。可以搞「每周 VIP 限免歌单」，只能听特定的一些歌（版权成本相对低的），而不是想听什么听什么。或者限制音质：免费试听只能听标准音质，想听无损/杜比全景声，请付费。

3. 监测「阻断率」与「完播率」

去后台跑一个数：有多少用户是正好听满 28-32 分钟然后离开 App 的？如果这个比例很高，说明 30 分钟就是他们的生理阈值。我们必须把免费时长砍到 **10 分钟** 或者 **15 分钟**，去测试那个「让他意犹未尽但又没吃饱」的临界点。

总结一下

回到最初的问题。我会敢赌这个「报复性反弹」吗？绝对不敢。

我认为这是高明的放长线吗？不是，这是典型的「门槛过低导致的收益吞噬」，并且伴随着高昂的版权成本泄漏。

数据分析不仅是看涨跌，更是看人性和商业模式。当时长涨了、收入跌了，通常意味着我们的产品太好用了——好用到用户觉得没必要付钱了。

商业的本质是交换。如果我免费就能给你提供 90% 的爽感，那你永远不会为了剩下 10% 掏出钱包。

💡 知识点归纳

在解答这个 Case 时，我们用到了以下几个关键的分析逻辑和商业概念，面试时可以重点提及：

1. **蚕食效应 (Cannibalization)**：指新推出的低价/免费策略抢占了原本高价/付费策略的份额，导致整体收益下降。这是定价策略中最需要防范的风险。
2. **核心需求阈值 (Threshold of Satisfaction)**：用户对于特定服务（如听歌）的满足感是有上限的。一旦免费额度覆盖了这个阈值（如通勤时长），付费意愿就会断崖式下跌。
3. **边际成本 (Marginal Cost)**：在内容行业，每增加一个免费用户的播放，可能都对应着版权成本的增加。忽略成本只看用户增长是互联网早期的玩法，现在行不通。
4. **损失厌恶 (Loss Aversion)**：行为经济学概念。用户对「失去」的敏感度远高于「获得」。先把免费时长给出去再收回来，极易引发用户反感和流失，而不是 PM 预想的付费转化。
5. **虚荣指标 (Vanity Metrics)**：题目中的「时长 (Duration) 暴涨」在缺乏营收支撑的情况下，很容易成为虚荣指标，因为它增加了服务器和版权成本，却没带来现金流。

👤 面试官追问

“非常精彩的分析，特别是关于版权成本那一点，很多初级分析师容易忽略。

现在我们换个角度。假设我们现在的战略目标暂时不是盈利，而是为了应对竞争对手（比如字节跳动出了一款新的免费听书 App）的进攻，老板要求必须先把市场占有率和用户时长锁住，防止用户流失。

在这种‘防御战’的背景下，如果你发现这 15% 的付费下跌，换来的是我们对竞品用户的成功回流，你还会建议叫停这个策略吗？

你要怎么设计一个新的 ROI 公式，来向老板证明这 15% 的亏损是‘值得的防御成本’？”

追问解答

刚才我们聊了，如果单纯为了赚钱，给非会员「每日免费 30 分钟」简直是自杀行为，直接导致营收跌了 15%。

但面试官突然加了一个致命的设定：「如果现在的目标是打仗，是为了防御竞品（比如字节跳动出了个免费听书 App），不让用户流失，你还建议叫停吗？你会怎么设计新的 ROI？」

这一下子就把题目从「财务视角」拔高到了「战略视角」。

这时候，如果你回答「哦，那就不叫停了」，太浅。如果你回答「只要用户没跑就行」，太虚。

我们需要给老板一套全新的「战争数学模型」。

第一部分：思维转换——从「看净利」到「看资产保值」

在和平年代，我们追求 GMV（交易总额）和 Margin（利润率）。但在战争年代（竞品进攻期），我们的北极星指标变成了 **Market Share（市场份额）** 和 **Retention（留存率）**。

为什么？因为音频类产品的 **迁移成本** 其实没有那么高。如果竞品完全免费，用户一旦跑了，想再把他们买回来（Recall），那个 CAC（获客成本）通常是现在维护成本的 5-10 倍。

所以，我们要告诉老板：**这跌掉的 15% 营收，不是「亏损」，而是我们支付给用户的「留存保险费」。**

关键在于：这笔保险费，买回来的东西，值不值？

第二部分：设计新的「防御 ROI 公式」

传统的 ROI 公式是： $ROI = (当期收入 - 当期成本) / 当期成本$ 这就导致现在的策略是负的。

在防御战中，我建议引入 **LTV（用户生命周期价值）** 和 **Churn Reduction（流失挽回）**，重构公式：

防御 ROI = (当期收入 + [挽回用户数 * 单用户 LTV]) / (当期成本 + 版权成本)

我们来拆解一下这个公式的核心逻辑（高分点）：

1. 挽回用户数 (Saved Users) 这需要通过 A/B 实验得出。

- **对照组（无福利）**：面对竞品进攻，流失率可能是 10%。
- **实验组（给 30 分钟）**：面对竞品进攻，流失率降到了 4%。
- **挽回率 (Delta Churn)**：6%。这 6% 的用户，就是我们花钱「买」下来的。

2. 单用户 LTV (Life-Time Value) 这 6% 的人值多少钱？如果他们只是纯白嫖党，LTV 极低，那我们亏大了。但如果这 6% 里包含了很多未来的潜在付费用户，或者高活跃用户（能贡献广告库存），那他们的 LTV 很高。

结论：只要 **(挽回用户数 * LTV)** 的价值，大于 **(15% 的营收跌幅 + 版权支出)**，这个策略在战略上就是 **正收益** 的。

第三部分：具体的业务推演（怎么说服老板）

我会拿着这个新公式，这样跟老板汇报：

“老板，上周数据确实跌了 15%，大概亏了 20 万。但我算了一笔账，这 20 万可能花得很值。

因为我们监测到，竞品上周在大规模投放广告。在没有该策略的对照组里，我们的日活用户（DAU）流失了 8%。但在给了 30 分钟福利的实验组，流失率只有 2%，我们成功**截断了 6% 的用户流失**。

如果我们现在停掉策略，为了省这 20 万，我们将直接流失这 6% 的核心用户。根据过往数据，这批用户的平均生命周期价值（LTV）是 150 元。**挽回价值 = 100,000 人（假设盘子） * 6% * 150 元 = 90 万元。**

我们是用 **20 万的现金流损失**，保住了 **90 万的未来资产**。所以，如果是为了打防御战，这个策略不仅不能停，还得优化。”

第四部分：防御战也不能「傻大方」

虽然我们在打仗，但也不能无脑烧钱。既然是为了防御竞品，策略就要针对竞品的弱点修补。

- 1. **针对性防御** 竞品是主打有声书免费？还是音乐免费？我们只在竞品强势的品类开放 30 分钟，不要全站开放。如果竞品只搞小说，我没必要把周杰伦也免费了，那是浪费子弹。
- 2. **防御的「软着陆」** 如果哪天仗打完了，要收回权限，怎么防止用户暴动？现在就要埋伏笔。把「每日免费 30 分钟」包装成「限时活动」或者「防御战特别津贴」（比如叫“听书节福利”），明确告知用户这是有期限的。这样未来下线时，用户的心理预期是可以接受的，而不是觉得被剥夺了。

总结

在防御战的背景下，怎么判断 15% 的亏损值不值？

答案不在当月的财务报表里，而在「用户资产负债表」里。

如果这 15% 的代价，换取的是 高于代价总额的「存量用户 LTV」，那就是一次成功的战略防御。

作为分析师，我们的价值就在于：把看不见的「未来损失」（流失风险），量化成看得见的「当前价值」，以此来辅助决策。

💡 本题知识点归纳（最后复盘）

- 1. **LTV (Life-Time Value)**: 用户生命周期价值。在做烧钱决策时，必须看 LTV，否则就是盲目亏损。
- 2. **CAC (Customer Acquisition Cost) vs. CRC (Customer Retention Cost)**: 获客成本 vs. 留存成本。通常 CRC 远低于 CAC，所以防御战在算账上往往是划算的。
- 3. **Delta Churn (流失率差值)**: 评估防御策略是否有效的核心指标，即（自然流失率 - 干预后流失率）。
- 4. **沉没成本 (Sunk Cost) vs. 机会成本 (Opportunity Cost)**: 在这里，流失掉用户后的「再获取成本」是巨大的机会成本风险。

题目 15

【欧莱雅 / 雅诗兰黛 | 消费者洞察 | 二面】

为了推广一款高单价的「抗老面霜」，你们砸重金在小红书投了几个头部博主进行种草。活动复盘时数据很好看：活动期间，该单品在天猫的日均销量（GMV）翻了 2 倍，ROI 远超预期。

但你做完人群拆解后，发现了一个极度尴尬的事实：这批下单的用户里，85% 都是过去一年内买过该品牌产品的「高粘性老客」，纯新客占比极低。

市场部的解释非常自信：「这正是策略的成功！说明博主的内容非常有煽动性，成功『唤醒』了沉睡老客，促成了复购，否则这些人早就被竞品抢走了。」如果你是分析师，你会认可这个「成功唤醒」的归因逻辑吗？你会觉得这笔钱花得值，还是会怀疑这群老客其实「不看广告原本也会买」？

解答

第一部分：先别被 ROI 蒙蔽，理清“增长”的真伪

面对市场部那个“唤醒沉睡老客”的解释，如果我是你，我第一反应肯定不是直接反驳，而是先在心里敲响警钟。这道题的核心矛盾在于一个经典的商业谎言：把「存量搬运」包装成了「增量增长」。

我们要判断这笔钱花得值不值，必须先建立一个结构化的判断标准，主要看三点：

1. “沉睡”的定义是否诚实？
2. “购买动机”是被种草，还是图便宜？
3. “不花这笔钱”，这群人到底会不会买？

这不仅是数据问题，更是业务逻辑问题。

第二部分：拆穿“唤醒”的文字游戏与平台算法的“共谋”

市场部的解释里有一个非常具有迷惑性的词——「唤醒」。但我们结合题目中的数据细节和当下的平台算法机制，会发现这里面有两个巨大的漏洞。

漏洞一：用户生命周期的常识性误判

题目说这 85% 是「过去一年内买过」且「高粘性」的老客。对于「抗老面霜」这种高单价品类，一瓶 50ml 面霜的使用周期通常是 3 到 4 个月。如果一个用户被定义为“高粘性”，意味着她可能有囤货习惯或者规律回购。如果她在 3 个月前刚买过，现在又买，这不叫唤醒，这叫「提前囤货」。

你只是把她下个月原本要下的单，提前到了今天。如果她在 10 个月前买过，现在买，这大概率是「自然回购周期」。她家里的面霜刚好快用完了，她本来这几天就要打开天猫去补货的。就在她准备补货的这个节骨眼上，你们花大价钱投的博主发视频了，她刷到了，顺手点了链接。

这不叫“唤醒”，这叫“收割自然流量”。就像一个本来就要进店吃饭的客人，已经走到门口了，服务员突然冲上去塞给她一张优惠券说“快进来吃”。客人拿着券进去了，服务员转头跟老板说：“老板你看，这是我拉来的客人，ROI 很高吧！”

漏洞二：平台算法的“杀熟”逻辑（这一层必须想到）

为什么老客占比高达 85%？这往往不是巧合，而是算法的「偷懒」。现在的广告投放系统（OCPM）非常智能。当你要求“高 ROI”时，小红书和天猫的数据打通（通过 DataBank 等工具）会让算法优先把广告推给「最容易转化的人」。

谁最容易转化？当然是你的老客。所以，这笔钱花出去，实际上是平台算法为了帮你凑那个漂亮的 ROI 数字，拼命把广告塞给了你的老粉丝。这在业务上叫「广告人群圈选的内卷」。你以为你在做拉新，其实你在做昂贵的私域触达。

第三部分：算一笔残酷的账，揭示“利润双杀”

你说这笔钱花得值不值？我觉得极大概率是亏的，而且是亏在两个维度。

我们做个详细的财务推演（带入真实业务数字）：

假设这瓶面霜售价 1000 元，毛利 600 元。假设这 85% 的老客里，有 80% 的人本身就在复购周期内。

场景 A（不投广告，自然回购）： 用户习惯性搜索品牌词进店购买。成本：天猫扣点（约 5%）。**净赚毛利：约 550 元。**

场景 B（投了广告，通过 KOL 购买）： 这里有一个非常现实的问题题目没说，但通常都存在：**头部博主带货通常要有「独家机制」或「赠品」**。假设为了配合博主，你们多送了价值 100 元的小样（或者打了 9 折），且博主坑位费+佣金折算下来每单成本 200 元（20% 的综合费率）。用户通过博主链接下单。**净赚毛利：600 - 100 (多送的成本) - 200 (广告费) - 50 (平台扣点) = 250 元。**

结论： 每成交一单，你少赚了 **300 元**（550 - 250）。如果这单是新客，这 300 元叫“获客成本（CAC）”，值得。但既然是老客，这 300 元就是「纯粹的利润损耗」。所以，这不仅是归因逻辑错误，更是一次「**利润双杀**」——你不仅支付了昂贵的广告费，还可能因为博主的低价机制，让本来愿意原价购买的老客学会了“不打折不买”。

第四部分：如何用数据去“锤”这个结论？

面试官或者业务方肯定会反驳：“你怎么知道她们本来就会买？万一没这个广告她们就被隔壁竞品抢走了呢？”这时候，不能靠吵架，要靠**增量分析**的三个大杀器。

1. 建立「自然基线」与断崖监控

别只看活动期间的 GMV 翻倍。把时间轴拉长，看活动结束后两周。如果平时的自然日均销量是 100 单，这次活动做到了 300 单（看似 +200）。但如果活动结束后，日均销量立刻掉到了 50 单（低于平时的 100），且持续了两周。这就实锤了：**你只是透支了未来的销量**。你把下周要买的人，忽悠到今天买了。总盘子根本没变，只是把波峰挪了个位置。

2. 搜广联动分析

这是判断“种草”是否有效的关键指标。如果博主真的具有“煽动性”并带来了新客，那么在小红书笔记发布的当天及随后几天，天猫站内的「**品牌词搜索量**」应该同步暴涨。如果 GMV 翻倍了，但「品牌词搜索量」几乎没动，或者涨幅很小。这就说明：成交的人根本不是通过“搜索-了解”进来的新人，而是原本就关注店铺、或者被站内推荐顺手转化的老客。**没有搜索增量，通常意味着没有人群破圈。**

3. 增量测试

这是最科学的手段。如果你想精准证明这笔钱白花了，下次投放建议做「**地理隔离测试**」。选两个消费水平相似的城市，A 城投放，B 城不投。计算公式：**真实增量 = (A城转化率 - A城历史基线) - (B城自然波动 - B城历史基线)** 如果算出来增量极低，那就是实锤。

第五部分：这事儿怎么收场？给业务方的建议

咱们做分析的，目的是解决问题，不是为了把市场部怼死。既然钱已经花了，我们要给出建设性的优化方案。

1. 修正考核指标：从 ROI 转向 CAC

既然 ROI 容易被老客粉饰，下次投放头部博主时，建议直接考核「新客获客成本」或「新客流转率」。我们要逼着算法和代理商去挖新流量，哪怕 ROI 难看一点（比如从 5 降到 1.5），只要全是新客，这对品牌长远价值才是真的。

2. 内容策略调整：从“收割”转向“种草”

85% 的老客占比说明博主的内容可能太“垂直”或太“自嗨”了，只有懂行的人才看。下次是不是该找一点泛生活类、跨界的博主？虽然转化率会低，但触达的都是真正的“生面孔”。

3. 私域承接老客

对于这群高粘性老客，请把她们引导到微信私域或天猫会员群。老客的唤醒应该靠几毛钱的短信、公众号推文或者专属客服，而不是靠几万块一条的广告视频。不要用昂贵的公域流量去洗自己的私域用户。

总结归纳

1. **渠道互斥/吞噬**：指付费渠道抢占了本该属于自然流量的转化，导致表观 ROI 虚高，实际利润下降。
2. **销量透支/提前消费**：促销活动往往只是将未来的需求提前释放，而非创造新需求，常表现为活动后销量的断崖下跌。
3. **增量/增效**：衡量广告真正带来的“额外”价值。计算公式核心思想是：(有广告时的转化 - 假如没有广告时的转化)。
4. **利润侵蚀**：在计算 ROI 时，不能只看 GMV，要扣除营销费用和因促销机制（赠品/折扣）导致的毛利损失。
5. **算法归因偏差**：广告平台算法为了优化数据表现，倾向于将广告展示给高概率转化人群（通常是老客），造成“拉新”假象。

面试官视角

（此时我切换回面试官，眼神变得锐利，因为你刚才提到了一个很难解决的痛点）

“这一波分析非常透彻，特别是关于算法‘杀熟’和利润双杀的点。那么我想追问一个非常实际的操作问题：你也知道，小红书（种草）和天猫（拔草）之间存在巨大的**数据黑盒**（Data Silo）。

在现实中，我们很难精准追踪一个用户是不是看了小红书才去天猫买的，因为两边 User ID 不打通。在这种**无法做精准链路归因**，且业务部门坚持说‘全网种草就是会有溢出效应’的情况下，如果不做昂贵的地理实验，你有什么**低成本的、基于现有数据**的方法或代理指标，能帮我快速估算出这 85% 的老客里，到底有多少比例是‘看了广告才买的’，又有多少是‘纯属凑巧’？”

追问解答

第一部分：破题——既然看不清“人”，那就看“时间”和“规律”

面对数据黑盒，我的核心逻辑是：利用“反常”来锁定增量。

既然我们无法追踪每一个 User ID 的跨平台路径，那我们就通过分析这群老客的“**购买时间**”是否违背了她们平时的“**生理生物钟**”，来判断是不是广告在起作用。

如果一个人的行为符合她的一贯规律，那就是「**自然存量**」； 如果一个人的行为突然打破了规律，那大概率就是外力（广告）带来的「**被唤醒增量**」。

我有三个具体的“**侦探指标**”来做这个估算。

第二部分：三个低成本的“**代理指标**”估算模型

方法一：R值偏移测试 ——最硬核的逻辑

这是针对“抗老面霜”这种易耗品最准确的估算方法。

逻辑原理：老客的复购是有周期的。通过历史数据，我们可以算出每个高粘性老客的平均复购间隔（**Inter-Purchase Time, IPT**）。假设用户 A，过去 3 次购买面霜的间隔分别是 90 天、92 天、88 天。这意味着，她的“**自然回购点**”就在第 90 天左右。

怎么算：我们把这次活动中下单的所有老客拉出来，看她们下单的这一天，距离上一次购买过了多久。

- **情况 A（存量）：** 如果她这次下单的时间，刚好卡在她历史平均复购周期的 $\pm 10\%$ 范围内（比如第 85-95 天）。
 - **判定：** 这就是**自然回购**。不管她有没有看广告，她家里的面霜都用完了，她本来就要买。广告只是碰巧出现在她想买的时候。
- **情况 B（增量）：** 如果她这次下单的时间，远远小于她的平均周期（比如第 30 天就买了）。
 - **判定：** 这就是**囤货/被唤醒**。她的面霜肯定没用完，是博主的内容让她产生了冲动，提前透支了预算。这就是广告的功劳。

结论输出：统计一下，这 85% 的老客里，有多少人的购买时间发生了显著的“**左移**”（**提前购买**）。如果只有 10% 的人属于“**严重提前购买**”，那说明剩下的 90% 都是自然单。

方法二：搜索词的“**纯度**”分析

虽然我们拿不到用户链路，但天猫后台有「**搜索来源**」数据。这是判断用户意图的直接证据。

逻辑原理：看广告进来的人，和自然回购的人，搜的词是不一样的。

怎么算：我们观察活动爆发的那几天，进店成交的老客主要搜了什么词？

- **自然回购特征：** 搜索“**品牌名**”或“**产品通用名**”（如“XX面霜”）。老客习惯直接搜牌子，或者直接去“我的订单”里点再来一单。
- **被广告种草特征：** 搜索“**博主提到的特定暗号**”或“**具体痛点词**”。
 - 比如博主在视频里强调这面霜是“**熬夜脸救星**”或者提到了一个具体的昵称“**极光瓶**”。
 - 如果发现大量成交来自于搜索“**极光瓶**”或“**熬夜急救**”，而不是标准的“**抗老面霜**”。
 - **判定：** 这些搜索量的激增，就是小红书外溢过来的**真实增量**。

结论输出：计算「**特定营销词搜索成交**」在「**总成交**」里的占比。这个占比越高，说明种草的引导性越强。

方法三：购物车/连带率分析

看她们买的东西，也能推测动机。

逻辑原理： 自然回购的老客，通常目的性很强，买完就走，或者搭配常用的水乳。被博主种草的老客，往往是为了“占便宜”或者“试新品”。

怎么算： 看订单结构。

- 如果博主推的是一个特定的“买一送一”或者“赠品组合”。
- **判定：** 只要是买了“**博主专属组合**”的，我们可以宽容地算作是广告带来的转化（因为没有这个优惠她可能就不买了）。
- **判定：** 如果她买的依然是普通的单品，且没领专属券，那大概率是自己摸进来的自然流量。

第三部分：综合推演与业务修正

有了上面三个维度，你就可以在 Excel 里搭一个简单的模型：

真实增量（估算） = 严重提前购买的用户 + 搜索特定营销词的用户 + 购买专属KOL组合的用户 （注意去重）

比如，虽然老客占了 85%，但经过这三层过滤，你可能发现：

- 只有 15% 的人是“严重提前购买”（囤货）。
- 只有 5% 的人搜了“博主暗号”。
- 只有 10% 的人是为了“专属赠品”下单。

加起来（去重后），可能这 85% 的老客里，只有 **20%** 是真正的“广告唤醒”，剩下的 **65%** 全是“自然回购的冤大头”。

这时候，你拿着这个估算的数据（比如 20% vs 65%）去找市场部，比单纯的质疑要有力得多。

第四部分：知识点总结

1. **Inter-Purchase Time (IPT) Analysis：** 购买间隔分析。利用用户历史复购习惯作为基线，判断当次购买是“自然需求”还是“受激需求”。这是区分存量与增量的核心逻辑。
2. **Search Interest Correlation：** 搜索热度相关性。在没有链路追踪时，站外投放时间点与站内特定关键词搜索量的协方差，是判断种草效果的最佳“影子指标”。
3. **Proxy Metric（代理指标）：** 当核心指标（如精准归因 ROI）无法获取时，使用逻辑强相关的间接指标（如复购时间偏移、搜索词占比）来进行估算。
4. **Attribution Window（归因窗口）：** 在分析时，要严格限定时间窗口。种草带来的搜索激增通常只维持 24-48 小时，超过这个时间窗口的自然回购不应归功于广告。

面试 16

【SHEIN / 淘宝头部女装 | 供应链分析 | 二面】

为了彻底解决服装行业「库存积压」这个核心痛点，你们将店铺的经营模式从「现货模式」全面改为「7 天预售模式」（先卖再做）。供应链端的数据非常惊艳：库存周转天数从 40 天直接降到了 10 天，几乎实现了零库存风险。

但交易端出现了一个明显的“恶化”：用户的「发货前退款率」（未发货就取消订单）飙升到了 35%。

供应链负责人的态度非常强硬：「这 35% 的退款根本不用心疼，那是虚假需求。以前为了满足这些人备货，最后都变成了库存垃圾。现在我们虽然单子少了，但每一单都是实打实的利润，这才是健康的生意。」

如果你是分析师，你会认可这种「牺牲规模换利润」的判断吗？你会认为这是供应链的进化，还是在透支品牌的「寿命」？

解答

供应链负责人的话听着很有道理，甚至有点“断舍离”的爽感，但如果我们真信了他的话，这牌子可能撑不过明年双十一。

我们要判断这事儿对不对，不能光看“省了多少库存钱”，得把账算全了。这事儿得拆成三层来看：

1. **算总账（P&L 损益视角）**：加上物流和折损，省下的成本，到底能不能覆盖掉跑掉的 35% 订单带来的利润损失？
2. **看流量（平台算法视角）**：这 35% 的退款，对店铺权重和流量分发的打击有多大？
3. **看人性（用户视角）**：所谓“虚假需求”，是真的虚假，还是被我们硬生生把热情给拖凉了？

接下来我们一层层剥开看，中间我会带几个假设的数字进去，你一听就明白了。

第一部分：先算一笔精准的经济账（含物流与折损）

供应链负责人的逻辑是：少卖点没关系，只要不压货，不仅省了库存钱，还省了发货又退货的冤枉钱。

这个逻辑在理论上成立，但我们必须用数字来验证。我们来假设一组符合女装行业现状的数据：

假设客单价 200 元，毛利率 50%（成本 100，毛利 100）。假设发货运费 5 元/单，退货整理+包材+保险成本 10 元/单（这是隐形大头）。假设原本每天能获得 100 个订单。

场景 A：以前的现货模式（高库存，高退货）

接到 100 单，全部发货。假设女装行业常态退货率 40%（收到货后退），最终成交 60 单。**收入端**：60 单 × 100 元毛利 = 6000 元。**成本端（物流磨损）**：发货 100 单：100 × 5 = 500 元。退货 40 单：40 × 10 = 400 元（运费险+衣服折旧+人工）。**最终净贡献 = 6000 - 500 - 400 = 5100 元**。**风险**：库存周转 40 天，意味着资金有 40 天压在货里，且有滞销贬值风险。

场景 B：现在的预售模式（低库存，高取消）

接到 100 单，发货前直接跑了 35 单（发货前退款率 35%）。剩下 65 单发货。**注意一个关键点**：这 65 单收到货后，依然会有退货！哪怕预售筛掉了冲动消费，我们乐观估计收货后退货率降到 20%。最终成交 = 65 单 × (1 - 20%) = 52 单。**收入端**：52 单 × 100 元毛利 = 5200 元。**成本端（物流磨损）**：发货 65 单：65 × 5 = 325 元（你看，运费省了）。退货 13 单：13 × 10 = 130 元（退货处理费也省了）。**最终净贡献 = 5200 - 325 - 130 = 4745 元**。

账算清楚了：现货模式净赚 5100 元 vs 预售模式净赚 4745 元。**结论**：哪怕算上了供应链引以为傲的“物流节省”和“退货磨损节省”，我们每天的净利依然亏损了 355 元（约 7% 的利润跌幅）。这还没算上因为规模缩小而导致的固定成本（房租、人力）分摊变高的问题。

所以，供应链负责人所谓的“每一单都是实打实的利润”，其实是以**利润总额缩水**为代价的。

第二部分：流量成本与算法的“连坐”惩罚

这部分是供应链负责人最容易忽略，但也是最致命的隐患。

现在的电商环境（无论是淘系还是抖音），流量非常贵。那 35% 申请退款的用户，不是天上掉下来的，是我们花真金白银买来的。

假设我们的 **CAC（获客成本）** 是 50 元一个下单用户。这 100 个下单用户，我们花了 5000 元的营销费。

1. 营销费用的直接打水漂 在预售模式下，针对那退款的 35 个人，我们的 1750 元（35人×50元）营销费直接归零。这比发货后退货更伤，因为发货后退货至少用户还摸到了衣服，还有可能因为质量好而留下，或者产生品牌形象。发货前取消，就是纯粹的浪费。

2. 平台算法的“死刑判决” 这点非常关键。平台的算法不仅看 GMV，更看**履约能力**。当你的店铺出现高达 35% 的“下单后发货前取消”，算法会捕捉到两个信号：信号一：这家店“货不对板”或“服务极差”，用户后悔极快。信号二：这家店的流量承接能力弱，给它流量它也转化不了。

结果就是：**DSR 评分下降，自然流量降权**。下个月你会发现，你不仅要面对利润下滑，还要面对流量变少、付费推广变得死贵死贵的局面。这就是在透支品牌的“寿命”。

第三部分：重新定义“虚假需求”

供应链负责人说：“那是虚假需求，以前为了满足这些人备货，最后都变成了库存垃圾。”

这个观点，在心理学和消费行为学上是完全错误的。在快时尚女装领域，**所有的需求本质上都是“冲动需求”**。女孩子买衣服，买的就是那一瞬间的“心动”和“想象”。

现货模式下：我下单了，过两天收到了，开心穿上了。这个“冲动”就固化成了“交易”。哪怕我有 40% 的概率退货，至少还有 60% 的概率留下了。

预售模式下：我下单了，等了 5 天还没发货，那股劲儿过了。这时候，我可能路过商场，可能刷到了另一家有现货的店，或者仅仅是冷静下来觉得不需要了。于是我点了退款。

这 35% 的流失，不是因为她们本来就不想买（虚假需求），而是因为**我们的服务时效配不上她们的冲动**。把“由于等待而流失的客户”强行定义为“垃圾流量”，这是一种为了掩盖供应链能力不足的极其傲慢的自我安慰。

更可怕的是**心智损伤**：一次预售等 7 天，两次预售等 10 天，第三次用户就不会再点了。她会给你的品牌贴上一个标签：“这家店很磨叽，买它等于给自己找罪受”。一旦这个心智形成，以后就算你全场现货，她可能也懒得点进来看了。

第四部分：分析师的破局建议

既然不管是“全现货死于库存”还是“全预售死于退款”都有坑，那我们该怎么办？作为分析师，我们不能只怼人，得给方案。

- 1. 建立 SKU 分级制（拒绝一刀切）：**
 - A类款（爆款/引流款）：**必须备现货，或者做“滚动现货”（备 3 天量）。这部分款流量大，一旦出现 35% 退款，对全店权重伤害最大。
 - B类款（常青款）：**维持小库存 + 快速返单。
 - C类款（测款/高价款）：**可以维持 7 天预售。用这部分款来做真正的“按需生产”。
- 2. 倒逼供应链提速（别躺在 10 天周转上睡大觉）：**为什么非要是 7 天？SHEIN 的小单快反可以做到 3-5 天出货。供应链负责人的 KPI 不应该是单纯的“库存周转天数”，而应该是“**缺货率**”和“**周转天数**”的平衡指标。只考核库存低，他当然恨不得一件都不备，全部空手套白狼。
- 3. 运营侧的“安抚战术”：**如果非要预售，那在这 7 天里，能不能做点什么挽留那 35% 的人？比如：下单后第 2 天发个短信告知“面料已裁剪”，第 4 天告知“正在缝制”，增加用户的沉没成本和期待感。或者：只要等满 7 天，随包裹附赠一个精致的发圈或袜子。用小成本把“等待的痛苦”转化为“收礼的惊喜”。

知识点小结

这道题解答完了，咱们复盘一下用到了哪些数据分析和业务分析的知识点：

- P&L 分析（损益表思维）：**计算利润时，必须包含显性成本（进货价）和隐性成本（物流、退货折损、包装费）。
- 机会成本与流量 ROI：**退款订单不仅是收入的损失，更是营销费用（CAC）的直接浪费。
- 平台算法逻辑：**理解“发货前退款”对店铺权重（DSR、流量分发）的致命影响，这是业务 Sense 的体现。
- 用户心理账户：**理解“冲动消费”在时间维度上的衰减曲线。

面试官视角追问：

- （这时候面试官点了点头，眼神里多了几分认可，他在笔记本上记了几笔，然后突然抬头）
- “你的分析很全面。但如果我现在告诉你一个反直觉的数据：虽然发货前退款率飙升到了 35%，但是我们要考核的最终指标——**‘净利润额’**实际上比上个季度反而增长了 **10%**。”

既然利润涨了，那就说明供应链负责人的策略在结果上是‘赢’的。那你刚才担心的那些‘品牌透支’、‘流量浪费’，是不是其实都被‘降本’覆盖掉了？面对这个‘利润增长’的结果，你又要怎么去修正你刚才的结论？”

面试 17

2025年冬季，某美妆企业，调整积分规则后核销率+30%，但券后毛利下降5pp、次月复购下降4%。

请问：你会如何评估积分策略收益与副作用，并提出调整方向？

解答

这组数据非常凶险。核销率暴涨看似繁荣，但毛利和复购双降，说明我们在“赔本赚吆喝”，而且吆喝完，客人还走了。

我们要怎么像剥洋葱一样把问题拆解清楚？按这四个步骤来。

第一部分：先看一眼大盘，这事儿到底多严重？

面试官给了三个关键数，我们先建立基本的判断框架。

核销率 +30%：这说明新的积分规则非常有吸引力，门槛一定降了，或者兑换价值极高。用户活跃度确实被激活了。

券后毛利 -5个百分点：注意，美妆行业的毛利虽然高（通常 60%-70%），但营销费用巨高。直接掉 5个百分点的毛利是非常痛的。这意味着每卖出一单，公司的利润空间就被大幅压缩。如果这 5个点是直接让利给消费者的，那我们在财务上必须要求销量有大幅增长才能打平（后面我会算这笔账）。

次月复购 -4%：这是最要命的指标。做积分体系的核心目的是锁客，是为了拉长 LTV（生命周期价值）。现在大家把分花完了，下个月反而不来了。结合“**2025年冬季**”这个时间点，问题更复杂。冬季通常紧接着双11或年货节，本身就是囤货季。如果在这个节点复购率还在同比下降，说明这次策略不仅透支了购买力，可能还打乱了用户的自然消费节奏。

初步结论：这是一个典型的“透支型策略”。用高额成本换取了短期活跃，但牺牲了利润和未来的留存。

第二部分：拆解毛利下跌（钱到底去哪了？）

毛利掉了 5个百分点，绝不是“打折”两个字能概括的。我们需要推演两种具体的业务场景：

场景一：积分货币化程度过高

如果你把积分规则改成了“积分直接抵扣现金”，且比例过高，那这 5 个点就是实打实的折扣成本。比如，原本面霜 300 元，毛利 200 元（66%）。现在允许积分抵扣 30 元，实收 270 元，成本还是 100 元，毛利变成 170 元（63%）。毛利率直接掉了 3 个百分点。如果叠加其他成本，很容易掉到 5 个点。

场景二：兑换品选品失误（高成本商品被击穿）

这是更隐蔽的风险。如果积分原本只能兑换小样（低成本），现在开放兑换正装（高成本）。一旦规则有漏洞，被羊毛党发现“用低成本动作攒分，兑换高成本硬通货”，就会出现结构性的毛利崩塌。比如用户只做签到、转发任务，不花钱就攒够了换口红的分。这种兑换，每发生一笔，公司的毛利就在失血。

第三部分：深挖复购下降（人为什么跑了？）

这一块是核心得分点。为什么给了优惠，用户反而跑了？结合美妆业务，有三个核心推论：

推论 1：消费透支（囤货效应）

这是美妆行业最核心的逻辑。冬季本身皮肤干燥，用户需求强，加上积分活动刺激，用户可能一次性买了两瓶面霜或者是大容量装。面霜的使用周期是 3-4 个月。既然这个月买够了，下个月他当然不需要买了。所以，**复购率下降，可能是因为“提频囤货”导致的自然回落**。如果是这种情况，复购下降不全是坏事，我们需要拉长看 3-6 个月的总销售额。

推论 2：低质量用户稀释了大盘

核销率+30%，说明涌进来了很多“为了占便宜”的人。这部分新增的核销用户，可能本来就是价格敏感型（羊毛党）。他们本身就没有忠诚度，兑换完走人是必然的。当分母（参与活动的总人数）变大了，但分子（会持续购买的忠诚用户）没变甚至被挤出去了，整体的复购率数据自然会被拉低。

推论 3：价值感崩塌

这是最危险的。如果我们为了刺激核销，让积分兑换变得太廉价，或者像地摊甩卖一样。高净值用户会觉得品牌调性掉了，觉得“原来你们家东西只值这个价”，从而产生离心力。这叫品牌资产的流失。

第四部分：必须做的数据推演（不算账就是耍流氓）

既然毛利掉了 5 个百分点，我们必须算一下，这波活动到底值不值。

我们做一个盈亏平衡分析。假设策略调整前：毛利率 65%。假设策略调整后：毛利率 60%（掉了 5 个点）。

我们要保证赚到的**绝对毛利额**不亏，销量需要涨多少？

公式逻辑： 原毛利率 * 原销售额 = 新毛利率 * 新销售额 $0.65 * 100 = 0.60 * X$ $X = 108.3$

这意味着，在毛利掉 5 个点的情况下，我们的销售额（GMV）必须至少增长 8.3%，才能勉强打平。

如果题目中没提 GMV 大幅增长，或者 GMV 涨幅低于 8%，那这次积分调整在财务上就是**彻底的失败**。你不仅亏了利润率，连绝对值都没赚回来。

第五部分：策略调整与自救方案

病因找到了，现在开药方。针对“毛利跌”和“复购跌”，我有三招：

第一招：调整兑换结构，从“硬通货”转为“强关联小样” 不要再直接让积分抵现或兑换正装了，这太伤毛利。把积分引导去兑换**新品小样**或者**同系列的互补品**（比如买精华兑换同系列面霜小样）。小样成本极低（通常只有正装的5%-10%），不会拉低5个点的毛利。更重要的是，小样是**“种草”**，是为了培养他下一次购买正装的习惯，这能直接救回那个跌掉的复购率。

第二招：把“即时满足”改成“延时满足” 针对复购下降，我们要设计钩子。用户核销积分后，不要只给他现在的货。要送他一张**“下个月生效的8折券”**，或者**“春季新品的优先购买资格”**。把积分变成一个**锁客工具**，强行把用户的使用场景拖到下个月，对冲掉囤货带来的流失风险。

第三招：做人群隔离 既然怕羊毛党击穿毛利，那就设门槛。积分规则分层：普通用户：积分只能换周边、换优惠券（低成本）。金卡/黑卡用户：积分才能抵现或换正装（高权益）。保护高复购人群的权益，把低价值用户的成本控制住。

总结归纳

这个案例复盘下来，核心知识点有这么几个：

蚕食效应： 积分活动如果没有带来纯增量，只是让原本要全价买的人用了折扣，那就是自己吃自己。

提前购买（透支）： 促销导致的短期销量暴涨，往往伴随着后续周期的销量低谷，分析时要拉长周期。

单体经济模型： 任何策略调整，都要算一笔单客毛利的账，看看需要多大的销量增幅才能覆盖掉牺牲的利润率。

辛普森悖论变种： 整体复购率下降，可能是因为引入了大量低质量用户，掩盖了核心用户的真实表现。

最后，切换到面试官视角：

你刚才的分析中，关于“囤货效应”的假设非常关键。

那么请听下一题：

如果老板现在就要你验证“复购率下降到底是因为用户囤货了，还是用户真的流失了”，在你只有**交易流水数据（订单表）**的情况下，你需要提取哪些特征或指标来进行验证？请列出你的分析逻辑。

追问解答

第一步：算清楚“肚子是不是撑着了”？（验证囤货假设）

如果用户是囤货，那她的特征一定是：**单次购买量变大，导致理论消耗周期变长。**

我们需要从订单表里提取两个核心指标来验证：

1. **客件数 (UPT, Units Per Transaction)**：平均每单买了几个商品。
2. **件单价/规格大小**：是不是买了更大容量的装（比如从 30ml 换成了 50ml）。

分析逻辑：把参加了积分核销的用户单独拎出来，看他们在这次活动中的 **UPT**。

- **如果 UPT 明显上涨**：比如平时平均每单买 1.2 瓶，这次变成了 1.8 瓶。那次月复购率下降是完全正常的。因为她手里的货还没用完，你不能指望她下个月就来。这不是流失，这是「**消费周期平移**」。
- **如果 UPT 没变**：她和平时一样，只买了一瓶。结果下个月也没来。这时候你就要警惕了，这大概率是真的流失，或者是对产品失望了。

怎么算（文本公式）：计算 **囤货系数** = 活动期人均购买件数 / 历史人均购买件数。如果系数 > 1.3，说明囤货效应显著，复购下降是假象。

第二步：建立“理论回购时间表”（精准定义流失）

光看买了多少还不够，还得看她“**该不该回来**”。

我们需要根据订单里的**商品 SKU** 和 **购买数量**，推算出每个用户的「**理论消耗天数**」。

这是一个非常硬核的业务逻辑：假设一瓶 50ml 的面霜，平均用户每天用 1ml，一瓶能用 50 天。

- **场景 A（囤货）**：用户这次买了两瓶（100ml）。理论上她 100 天后才会缺货。现在的观测点是“次月”（第 30 天），她当然不会复购。这时候的“未购买”是健康的。
- **场景 B（流失）**：用户这次买了一瓶（50ml），但距离上次购买已经过了 80 天了（超过了 50 天的理论周期）。这时候她还没来，那说明她大概率在别的地方买了竞品，或者已经弃坑了。

分析动作：我要在订单表里加一列计算字段：**下次预计购买日 = 订单日期 + (购买总量 / 日均消耗量)**

然后统计：**超时未归率**。即：当前时间 > 下次预计购买日，但仍未产生新订单的用户比例。

- 如果“复购率”跌了，但“超时未归率”没涨，说明大家只是还没用完，不用慌。
- 如果“超时未归率”也暴涨，那就是真出事了。

第三步：看“谁”没回来？（人群结构归因）

最后，我们要排除“羊毛党”的干扰。我们要看跌掉的那 4% 的复购，到底是谁跌的。

利用订单表里的历史数据，把用户分成两波：

1. **老客（存量高价值）**：过去一年购买次数 > 3 次。
2. **新客/低频客（潜在羊毛党）**：过去只有 1 次或 0 次购买。

分析逻辑：我们要看这两波人的**复购率变化幅度**。

- **情况一**：新客的复购率雪崩（比如从 10% 掉到 2%），但老客的复购率很稳。
 - **结论**：没大事。这说明积分活动引来了一堆本来就不忠诚的羊毛党，他们拉低了整体数据。核心盘没动，业务是安全的。
- **情况二**：老客的复购率也跟着掉。

- **结论：** 红色警报。说明连忠诚用户都觉得这次体验不好，或者被竞品抢走了。这时候必须马上介入干预。

总结一下

要回答这个问题，千万不要只盯着“复购率”这个单一指标看。

通过订单表，我只需要做这三件事：

1. **看 UPT (客件数)：** 确认她是不是买多了（囤货实锤）。
2. **算消耗周期：** 确认她是不是还没用完（理论回购时间）。
3. **分新老客：** 确认是不是羊毛党在捣乱（结构性下跌）。

只要把这三个维度拆开，是“囤货”还是“流失”，一目了然。

知识点归纳

在回答这个追问时，我们用到了以下 3 个核心分析方法：

1. **UPT (Units Per Transaction, 客件数)：** 衡量单次购买深度的关键指标，判断囤货行为的直接依据。
2. **Consumption Rate Method (消耗率法)：** 基于商品规格和使用习惯，推算用户生命周期节点，比单纯看“自然月”更科学。
3. **Cohort Analysis (同期群分析)：** 把新老客拆开看，避免平均值掩盖了业务真相（避免辛普森悖论）。

面试 18

某短视频平台 DAU（日活用户）创历史新高，但人均使用时长却环比下跌了 15%。作为商业分析师，你会如何拆解原因，并给出针对性的建议？

解答

拿到这种“指标背离”（一个好一个坏）的问题，最忌讳的就是直接瞎猜“是不是内容变差了？”“是不是竞品搞事情？”。

你得先有一个**公式思维**。

在这个场景下，核心公式是：

总使用时长 = DAU * 人均使用时长

虽然题目说的是人均时长跌了，但 DAU 涨了。我们首先要判断的是**总盘子**（总时长）发生了什么变化。如果 DAU 涨了 20%，人均时长跌了 15%，那其实总时长还是涨的（ $1.2 * 0.85 = 1.02$ ）。只要总盘子在涨，这事儿大概率就不是“灾难”，而是“结构性调整”。

确立了这个大前提，心态就稳了。接下来咱们按三个步骤来拆：**数据排查 -> 用户结构拆解（核心） -> 业务场景还原**。

第一步：永远先质疑数据

别笑，这个步骤在实际工作中能救你的命。

面试的时候你必须先提一嘴：“在深入分析之前，我会先快速排查数据口径和采集链路是否正常。”

为什么要这么做？因为 15% 的环比跌幅其实是非常恐怖的。对于一个成熟的短视频平台，用户习惯通常很稳定，除非 APP 崩了或者发版发错了，否则很难一夜之间大家都不爱看了。

你要检查：

1. **DAU 的口径变了吗？** 以前是“打开 APP 算日活”，现在是不是把“后台挂机”或者“推着通知栏点错”也算进去了？
2. **时长统计出 Bug 了吗？** 比如新版本上线，某个核心页面的埋点掉了，导致那部分时长没记上。

如果数据技术侧反馈没问题，OK，那这就是真实的业务表现。我们就进入真正的分析环节。

第二步：核心逻辑——辛普森悖论与用户结构变化

这是这道题的**灵魂**所在。

当 DAU 创历史新高时，通常意味着什么？意味着今天涌入了很多**新用户**，或者很久没来的**回流用户**。

这里你要用到一个非常关键的概念：**用户分层（Segmentation）**。

如果你把所有用户混在一起看“人均”，你就会被平均数骗了。咱们得把用户拆成“老用户”和“新用户/回流用户”两拨来看。

我们就来算一笔账，带入数字感受一下（这就是我常说的，要有数感）：

假设昨天（平时状态）：

- 老用户有 100 人，每个人看 60 分钟。
- DAU = 100，人均时长 = 60 分钟。

今天（DAU 创新高）：

- 老用户还是 100 人，习惯没变，还是看 60 分钟。
- 但是，因为做了个拉新活动，突然进来了 50 个新用户。

- 新用户刚下载 APP，还没建立粘性，或者只是为了领个红包，每个人只看了 10 分钟。

现在我们看看整体数据：

- **DAU**： $100 + 50 = 150$ （涨了 50%！创历史新高！）
- **总时长**： $(100 * 60) + (50 * 10) = 6000 + 500 = 6500$ 分钟。
- **人均时长**： $6500 / 150 = 43.3$ 分钟。

看到没？

从 60 分钟跌到了 43.3 分钟，跌幅甚至超过了 25%。

结论是什么？

老用户的体验可能根本没变，平台的内容质量也没变差。单纯是因为“**低时长的分母（新用户）**”变大了，把平均值给拉下来了。

这就是经典的**辛普森悖论**在业务里的变种。如果你不拆分看，你会以为产品出大问题了；拆分开看，你会发现这是用户规模扩张带来的必然阵痛。

所以，作为分析师，你的第一个核心论点必须是：**DAU 激增导致用户结构被稀释（Dilution Effect）**。

第三步：深挖业务场景，到底发生了什么？

光说个“结构变化”还不够，老板要的是细节。作为商业分析师，你得结合业务 sense 给出具体的场景假设。

1. 渠道质量分析

DAU 创新高，肯定是由于某个动作。是投了信息流广告？还是上了热搜？还是做了裂变活动（比如拼多多那种“砍一刀”）？

如果是裂变活动来的用户，特征就是：**目的性极强（领钱），内容消费意愿极低**。

这种用户进来，DAU 极其好看，但领完红包秒退，人均时长只有 1 分钟。这会剧烈拉低大盘时长。你需要建议运营团队评估：这波拉新的 ROI 到底划不划算？留存率怎么样？如果留存很差，那这种“虚胖”的 DAU 没有意义。

2. 产品功能的引导变化

有没有一种可能，DAU 涨是因为我们把某个“短链路”的功能做强了？

比如，APP 新上线了一个“每日签到”或者“纯文字动态”功能，或者把“查看天气/查快递”这种工具属性的功能放在了首页。

用户打开 APP -> 看了眼天气 -> 关掉。DAU +1，时长 +10 秒。

这种情况下，DAU 的增长是良性的（用户粘性增加了），但时长的下跌是必然的（因为功能本身就用时长短）。这时候你就不能用“时长”这一个指标来考核业务了，得看“频次”。

3. 季节性与特殊节点

是不是因为今天是除夕？或者是周五晚上？或者是某个突发大事件（比如地震、或者某个明星的大瓜）？

如果是突发新闻，用户可能会频繁打开 APP 刷最新进展（DAU 飙升），但确认没新消息就关了（单次时长短），导致全天累计时长不如平时沉浸式刷视频长。

或者，如果是开学第一天，学生党（主力军）只能课间偷偷看两眼，DAU 没掉，但时长肯定掉。

第四步：给出针对性的建议

分析半天，最后得告诉老板怎么办。别只抛问题，要给方案。

1. 别慌，先看分群数据

建议立刻把大盘数据拆解为：核心老用户、新用户、回流用户。

- 如果老用户的人均时长是稳定的（比如还在 58-60 分钟波动），那说明内容生态没崩，底盘很稳。目前的下跌纯粹是数学游戏，不用过度干预，甚至应该庆祝 DAU 的增长。
- 如果老用户时长也跌了，那就要拉响警报了！这说明可能为了迎合新用户，算法推荐了太水的内容，伤了老粉的心。

2. 针对新用户的“软着陆”策略

既然进来了一大波新用户（虽然现在时长短），我们不能看着他们拉低数据不管。

- **建议：**优化新用户的 Onboarding（新手引导）流程。给新用户推的内容，不要直接推那种 5 分钟的长视频，也不要推太小众的梗。要推“爆款”、“高完播率”、“普世性强”的内容，先让他们多看几秒，把时长从 10 分钟拉到 15 分钟。

3. 调整考核口径

如果公司最近的战略就是“不管不顾冲 DAU”，那在这个阶段，建议暂时下调对“人均时长”的考核权重，或者只考核“老用户人均时长”。否则业务团队会很冤，为了保时长而不敢去拉新，这就因噎废食了。

总结一下知识点

回答完这道题，我们用到了以下几个关键的分析思维，赶紧记下来：

1. **公式拆解法：**总数 = 数量 * 平均值。任何平均值的波动，都要先看是不是分母结构变了。
2. **辛普森悖论 (Simpson's Paradox)：**这是数据分析面试的神技。当你发现总体趋势和分组趋势不一致时，大概率就是它在作祟。即：新用户把平均值拉低了，但其实新老用户各自的表现可能都没问题。
3. **Cohort Analysis (群组/分层分析)：**由于用户入APP的时间不同，行为差异巨大，必须分层看，不能看大锅饭数据。
4. **业务归因 (Attribution)：**数据变动背后一定是业务动作（拉新、改版、活动）或外部环境（节日、事

件)。

(切换至面试官视角)

好，这一部分的回答逻辑非常清晰，尤其是对用户结构的拆解，很有 sense。

那我顺着你的思路追问一个问题：

你刚才提到了，新用户的引入稀释了时长，但这可能只是短期的。如果我们要判断这批创新高的 DAU 到底是给平台带来了真实的长期价值，还是一波“虚假繁荣”，你应该重点监测哪个指标？为什么？

面试 19

某次大促发放了大额优惠券，复盘时发现优惠券的核销率同比提升了 20%，但最终活动的 ROI（投入产出比）却下降了。作为商业分析师，你会如何分析？

解答

首先，咱们把解题的思路框架先立起来。

面试官问这个，考察的肯定不是你的计算能力，而是你对「流量效率」和「增量价值」的理解。我们要从 ROI 的定义公式出发，然后顺着公式里的分子（产出）和分母（投入）去找原因，最后再落脚到用户分层和商品结构上。

咱们先别急着猜是因为“羊毛党”还是“门槛低”，先回到最基础的公式，这才是最稳的起手式。

第一步：拆解 ROI 公式，把“矛盾”量化

我们先达成一个共识，通常在大促场景下，ROI 的计算公式大概长这样：

$$ROI = (\text{引导成交金额 GMV}) / (\text{优惠券总成本})$$

或者更严谨一点看利润 ROI：

$$ROI = (\text{引导成交产生的毛利}) / (\text{优惠券总成本})$$

现在题目告诉我们两个事实：

1. 优惠券核销率同比提升了 20%（说明用券的人变多了）。
2. ROI 下降了。

好，我们看分母——优惠券总成本。成本 = 发放张数 × 核销率 × 单张优惠券实际抵扣金额。

既然核销率涨了 20%，假设发放张数没变（或者更多），那分母（成本）肯定是大幅上涨的。这其实是一个很重要的信号：**花的钱变多了，而且是实打实地花出去了。**

再看分子——**GMV（或者毛利）**。既然 ROI 下降了，数学上只有两种可能：要么，分子的增长速度远远没跟上分母的增长速度；要么，分子压根没怎么涨，甚至可能跌了。

所以，这道题的核心矛盾就翻译成了：**为什么我们多花了这么多钱（核销率高），却没有换来等比例的生意增长？**

第二步：分析“虚假繁荣”的三个核心原因

找到痛点后，咱们就可以开始排查嫌疑人了。这里面通常藏着三个最常见的大坑，面试时候你按这个顺序讲，逻辑感会很强。

1. 严重的“自然转化”侵蚀（Cannibalization）

这是最最最常见的原因。说人话就是：**这帮人本来就要买东西，结果你非要塞给他一张大额券，他不光买了，还少付了钱。**

比如，用户 A 本来打算买个 1000 块的耳机，不管你发不发券他都会买。去年你发了 10 块钱券，他买了，你赚爽了。今年你发了 100 块的大额券，他一看“哇太好了”，赶紧核销了。

结果是：

- 核销率：涨了（毕竟 100 块谁不要）。
- 成本：激增（从 10 块变成 100 块）。
- GMV：没变（还是买那个耳机）。
- ROI：直接跳水。

这种情况我们叫“没有带来增量”。大额券如果不设门槛，或者门槛设置在用户本来就要消费的水平线上，那就是纯粹的利润损耗。

2. 门槛设置失误，导致客单价（AOV）被拉低

核销率高，有时候是因为门槛设得太低了，变成了“普惠福利”。

举个例子：假设去年是大促，满 500 减 50，大家得凑单才能用，客单价可能是 600。今年想刺激一下，搞了个“大额券”满 200 减 50。

用户一看，这也太容易达到了！于是大家纷纷把本来想买 600 的单子拆成三单 200 的，或者干脆只买个 200 出头的凑个数。

结果是：大家用券用得很开心（核销率暴涨），但每单实际上只付了 150 块。总的 GMV 增长如果跑不赢成本的 5 倍、10 倍增长，ROI 必然很难看。

3. 用户结构变了，引来了“低质量用户”

大额优惠券对谁的吸引力最大？对价格敏感型用户（羊毛党）。

如果这次发券渠道没控制好，或者算法把券推给了大量非目标用户。这群人可能只盯着“神价”商品买，买完就走，没有任何关联购买。

这会导致一个很隐蔽的问题：**毛利结构恶化**。如果大额券支持全品类，这帮羊毛党会专门挑那些本来就是引流款、没利润甚至负毛利的商品买。券一叠加，公司卖一单亏一单。核销率越高，亏得越惨，ROI 自然就崩了。

第三步：深度验证，怎么用数据说话

光有猜测不行，面试官这时候通常会盯着你问：“那你怎么验证你的想法？”咱们得拿出具体的分析动作。

这时候你要展现出你的业务 Sense，不要只说“我要看数据”，要说“我要看什么数据”。

动作一：做归因分析，看“增量 ROI”

我会把领券并核销的用户单独拎出来，和“未领券但有类似行为”的对照组（如果有 AB Test 最好，没有就找相似人群）进行对比。

重点看 **Uplift（提升值）**。如果用了 100 块的券，但这群人的客单价只比对照组高了 20 块，那这券就是发废了。如果客单价甚至没区别，那就是纯粹的资金浪费。

动作二：拆解客单价（AOV）分布图

我会去拉一下这次活动核销订单的金额分布。

如果发现大量的订单金额都死死地卡在优惠券的使用门槛上（比如满 300 减 100，结果一堆订单全是 301 元、302 元），那就实锤了——门槛设低了，用户在“凑单套利”，而不是在增加消费。

动作三：看商品连带率

去查一下核销订单里，是不是只包含单一爆品？健康的大促应该是：大额券吸引你进店，你买了爆品，顺手带了两件高毛利的配件或衣服。如果不健康的 ROI 场景，通常是：用户拿了券，精准打击低价品，买完即走，连带率为 1.0。

第四步：给业务方的建议

分析完了不能光吐槽，得给老板或者运营一个台阶下，顺便给出解决方案，显着咱们专业。

我会建议：

1. **调整门槛策略**：下次发大额券，门槛必须设在用户平均客单价的 1.2 倍甚至 1.5 倍以上，强行拉升客单价，逼着用户凑单，这样才能用增量 GMV 覆盖掉增加的成本。
2. **差异化发券（杀熟？）**：对高净值、本来就要买的老客，发小额券或者不发券（推品为主）；对那种很久不来的流失边缘用户，才发大额券做挽回。别搞“阳光普照”。
3. **限定品类**：大额券严禁用于低毛利的硬通货（比如 iPhone、金条），必须引导流向高毛利品类（如服饰、美妆），用高毛利来对冲高成本。

知识点总结

好了，这道题咱们复盘一下，其实就用了这几个核心概念，你心里要有个底：

1. **ROI 的构成**：不要只盯着赚了多少钱，要看效率。分子分母的变动比例才是关键。
2. **Cannibalization（蚕食效应/自然转化侵蚀）**：这是营销分析里最高频的词，区分“存量”和“增量”是分析师的入门课。
3. **价格弹性**：大额券对应的是价格敏感人群，核销率高往往意味着价格弹性起作用了，但如果门槛没设计好，弹性带来的量不足以弥补价的损失。
4. **Uplift Analysis（增效分析）**：这是验证活动效果的黄金标准，永远要问“如果不发这张券，我们会损失多少？”

这题其实不难，难在你要把“核销率高”这个看似正向的指标，迅速转化成“成本失控”的预警信号，这个思维转换过来了，你就赢了。

(切换至面试官模式)

分析得很全面，逻辑很清楚。特别是在“蚕食效应”那块讲得很透。

那么我想接着你刚才提到的“增量”继续往下问：

你说要做 A/B Test 或者找对照组来看 Uplift，但在大促这种全站级别的活动里，流量是混杂的，很难完全隔离出一个纯净的“对照组”不给发券（因为用户会投诉杀熟，或者自己换个号就领了）。在这种无法做完美 A/B Test 的情况下，你要怎么计算这次大额券带来的**真实增量 GMV**？

面试 20

App 首页改版后，Banner 位的点击率（CTR）翻倍，但详情页的跳出率飙升，且最终成交单量并没有增长。作为商业分析师，你会如何定位原因并提出建议？

解答

其实没那么复杂，这道题考的就是你对「流量质量」和「转化漏斗」的理解，以及你能不能把这两个东西串起来讲个明白的故事。

咱们先别急着下结论，先把这个分析框架搭起来。这就好比医生看病，不能上来就开药，得先看看化验单。

第一部分：先把数字算清楚，逻辑就能自洽

我们要建立一个最基础的转化公式。无论业务多复杂，电商或者交易类的核心公式就这一个：

成交单量 = 曝光人数 × CTR × 详情页转化率

现在题目告诉我们什么？

1. **曝光人数**：假设没变（题目没说变，通常改版 Banner 不会影响总盘子的曝光）。
2. **CTR（点击率）**：翻倍了，也就是变成了原来的 2 倍。
3. **成交单量**：没涨，也就是保持不变（系数是 1）。

把数字带进去算一下：

1（订单）= 1（曝光）× 2（CTR）× ?（转化率）

这数学题小学生都会算吧.. 想要等式成立，**详情页转化率必须变成原来的 0.5（减半）**。

这就解释了为什么“跳出率飙升”。进来了两倍的人，但这些人“没看上”你的东西，扭头就走了。所以，这道题的核心矛盾并不是“系统出 Bug 了”，而是「引入的流量变多了，但流量变『水』了」。

第二部分：为什么流量会变“水”？

逻辑通了，接下来就是找原因。这时候你要展现你的业务 Sense，不要干巴巴地列点，要结合场景去猜。通常这种情况，我会重点排查三个方向，按可能性从大到小排列。

可能性一：严重的「货不对板」，也就是标题党。

这是最常见的情况。Banner 改版可能换了一张特别吸睛的图，或者文案写得特别夸张。比如 Banner 上写着“戴森吹风机 9.9 元”，用户疯了一样点进来（CTR 翻倍），结果进来一看是“9.9 元抽奖资格”或者“9.9 元买个配件”。

用户会有什么反应？**被欺骗感。**

这时候用户不仅不买，还会立刻关掉页面（跳出率飙升）。这种高 CTR 是虚荣指标，除了浪费服务器资源和消耗用户信任，没半点用处。

可能性二：误导了用户预期，导致受众错位。

这种情况隐蔽一点。也许没骗人，但素材的风格变了。

比如原本你卖的是高端大衣，Banner 很性冷淡风，点进来的都是想买贵衣服的。现在改版把它设计得特别花哨、像清仓大甩卖。结果是一堆想买便宜货的人点进来了（流量大了），发现价格还是 2000 块，买不起走了。而原本想买高端货的人，看到这个 Banner 以为品牌降级了，反而不点了。

这就是典型的“不仅没捞到新客，还把老客得罪了”。

可能性三：详情页本身的技术或体验灾难。

虽然题目说的是首页改版，但万一改版的时候，不小心把详情页的加载逻辑搞坏了呢？

比如流量翻倍了，瞬间并发太高，导致详情页加载变慢了 2 秒。现在的用户哪有耐心等你啊，转个圈的时间就划走了。这个需要去查一下详情页的 **Loading 时间** 和 **报错率**，虽然概率低，但作为严谨的分析师，这个必须要排查，防止是技术锅。

第三部分：怎么验证你的猜想？

光有猜测不行，面试官要看你落地的手段。要验证上面这些想法，其实不用搞太复杂的模型，切几个维度看数就行。

1. 拆分新老客来看。

老用户通常对价格和品牌有认知，如果老用户的转化率没跌太惨，主要是新用户狂跳出，那大概率是 Banner 吸引了非目标人群。

2. 也就是最关键的，去对比 Banner 素材 和 详情页内容。

这一点很多人会漏掉。你要真的去把那个 Banner 找出来看一眼！看看上面的文案、利益点（比如“全场五折”），在详情页里是不是真的有承接。如果没有承接，那就是运营事故，得赶紧改。

3. 看热力图和停留时长。

如果跳出率高，但用户在页面上停留了很久才走，那可能是价格劝退；如果进来看一眼（比如 1 秒内）马上关掉，那绝对是“被骗了”或者“加载慢”。

第四部分：给业务方的建议

分析完原因，最后得给建议。千万别只说“改回去”。

如果我是分析师，我会这么建议：

首先，**短期止血**。如果确认是严重的标题党导致用户反感，立刻下线这个素材，或者修改文案，让 Banner 的预期和详情页的实际情况对齐。

其次，**AB 测试**。现在的 Banner 虽然转化差，但它确实吸引人啊（CTR 高是事实）。我们可以保留这个高点击的设计风格，但是把详情页的头图或者首屏文案优化一下，专门承接这部分流量？

比如，既然大家是冲着“便宜”进来的，我们能不能在详情页最上面放一个“新人专享低价区”？把这部分想薅羊毛的流量接住，而不是让他们直接流失。

最后，**复盘考核指标**。这事儿出的根源，可能是设计团队或者运营团队背的 KPI 只有 CTR。如果只考核点击率，他们肯定会无所不用其极地做标题党。建议把 KPI 改成 **“CTR × 转化率”** 或者直接考核 **“Banner 带来的最终 GMV”**，这样上下游的目标才能统一。

总结一下用到的知识点

回答这题其实就用了几个最基本的东西：

- **漏斗模型**：曝光 -> 点击 -> 转化 -> 成交，哪个环节断了修哪里。
- **流量质量**：点击率高不等于质量高，要看后续承接。

- **用户预期管理**：Banner 是承诺，详情页是兑现，不一致就会崩。
- **假设检验**：先列出可能性（欺骗、错位、技术故障），再用数据验证。

做数据分析其实挺像破案的，数字虽然不会说话，但它们摆在那里的姿势，其实已经把凶手供出来了.. 只要你别被表面的“增长”给忽悠了就行。

知识点归纳 (Coach Note)

为了让你更扎实地掌握这类题目，我把里面用到的核心逻辑再提炼一下：

1. **辛普森悖论的变体**：虽然整体 CTR 涨了，但如果引来的是低质量流量，稀释了整体转化率，最终结果可能是负向的。
2. **虚荣指标 (Vanity Metrics)**：CTR 在没有转化支撑时，就是最典型的虚荣指标。面试中只要看到“某个指标飙升但最终结果不变”，第一反应就要去想这个指标是不是虚荣指标。
3. **前后链路一致性**：这是商业分析中归因的核心。用户点击是因为 Banner 的 Promise（承诺），用户离开是因为 Detail Page 没 deliver（交付）。

(切换至面试官视角)

回答得不错，逻辑挺清晰的。

既然你提到了修改 KPI 考核，那我继续追问你一个问题：

如果按照你的建议，我们把 Banner 换回了之前的版本，转化率回来了，但 CTR 又掉下去了，总订单量还是没涨。现在业务方提出，是因为我们的价格比竞对高导致转化上不去，希望发优惠券来刺激转化。

请问，你如何通过数据分析来判断，“发优惠券”这个策略是否真的能带来正向收益，而不是纯粹的利润损耗？你需要看哪些指标，怎么设计实验？

面试 21

某 App 优化了新用户引导流程 (Onboarding) 后，新用户的次日留存率提升了 10%，但 7 日留存率却几乎没有变化。作为商业分析师，你会如何解释这一现象，并建议下一步怎么做？

解答

这题看似在问数据表现，其实是在考你对**用户生命周期 (Lifecycle)**和**产品价值传递**的理解。

咱们别急着下结论，先稳住心态，搭个架子。面对这种“短期涨、中期平”的诡异现象，我们得像剥洋葱.....不对，得像修车师傅找故障一样，一层一层排查。

整体的分析思路我建议按这三步走：**先查数据口径（是不是算错了），再看用户分层（是不是人变了），最后看价值传递（是不是引导做歪了）。**

第一部分：先别急着高兴，先把数字算清楚

拿到这个数据，第一反应绝对不能是“哇，次留提升了”，而是要怀疑“这数对不对”。

这里有几个必须要核实的口径问题，面试的时候你得把这些假设抛出来，面试官会觉得你这人严谨。

首先，这个“提升了 10%”到底是怎么算的？是绝对值还是相对值？

比如，原来次留是 40%。如果是绝对值提升 10%，那就是变成了 50%，这可是惊天动地的涨幅，基本属于产品改头换面了；如果是相对值提升 10%，那就是 $40\% \times 1.1 = 44\%$ 。

在大多数常规优化的语境下，我们假设这是一个相对涨幅（从 40% 涨到 44%），这比较符合现实。

其次，留存的定义有没有变？

这 App 的“新用户引导”是不是加了一些强制性的动作？比如，以前注册完就算“新用户”，现在是不是必须得点完几个新手任务才算？或者，以前“次日留存”是指用户第二天打开 App，现在是不是只要后台有个推送唤醒了进程就算？

如果有这种定义上的“偷换概念”，那这个分析就没意义了。

好了，假设数据没得造假，口径也一致，那我们面对的就是一个真实的业务问题：**用户第二天确实更爱来了，但第七天该走的还是走了。**

这就尴尬了。

这意味着我们做了一次“成功的短视优化”。

第二部分：为什么次留涨了？（短期刺激的真相）

次日留存（Day 1 Retention）通常反映了什么？它反映的是**第一印象和即时满足感**。

既然次留涨了，说明我们在 Onboarding 阶段做对了一些事情，通常只有两种可能：

1. 门槛降低了（降阻力）

比如我们把注册流程从 5 步砍到了 2 步，或者支持了一键登录。用户觉得“哎，挺顺滑”，第一天没被烦走。或者我们把原本比较难的新手教程简化了，让用户更容易上手。

2. 诱饵加大了（强激励）

很多 App 喜欢搞这种，新手引导里加了个“签到领现金”或者“次日登录送大礼包”。用户第二天回来不是为了你的产品核心价值，而是为了那个“大礼包”。

这一步做好了，确实能把人留到第二天。但问题就出在这里——**留住人和留住心是两码事。**

第三部分：为什么七留没变？（核心问题的暴露）

七日留存（Day 7 Retention）反映的是什么呢？它反映的是一个完整的使用周期后，用户是否认可产品的核心价值，也就是我们常说的 Product-Market Fit (PMF) 在微观层面的验证。

次留涨、七留平，这就形成了一个非常典型的“剪刀差”。

这背后通常有三个非常残酷的业务逻辑，咱们得一个个看。

逻辑一：我们是不是搞丢了“天然筛选器”？

以前那个繁琐的引导流程，虽然体验不好，但它其实是个筛子。能忍受 5 步注册流程走过来的人，通常是强需求用户，他们本来就更有可能留到第 7 天。

现在我们把门槛降得太低，或者用红包把人“骗”进来，把那些本来对产品没啥兴趣、仅仅是凑热闹的“低质量用户”也留到了第二天。

但这帮人是留不住的。

这就是为什么次留涨了，因为分母里的“凑热闹党”第二天还没走；但七留没变，因为这帮人到了第三天、第四天发现没羊毛薅了，或者发现产品并不好用，自然就流失了。

从数据上看，这意味着 **Day 2 到 Day 6 的流失率（Churn Rate）变高了**。这曲线原本是平滑下降，现在变成了第二天那个点很高，然后“咔嚓”一下掉得更陡。

逻辑二：价值传递错位（Aha Moment 的缺失）

这是最可惜的一种情况。

Onboarding 的核心目的不仅仅是让人“把流程走完”，而是要快速把用户带到“**Aha Moment**”（惊喜时刻）。

如果你优化的方向是“让流程更短”，比如直接跳过了核心功能介绍，让用户直接进入首页。用户确实进来了（次留可能因此受益），但他进去之后一脸懵逼，根本不知道这 App 怎么用，或者没体会到好在哪里。

举个具体的例子。假设是个修图 App。原来的引导：强迫你修一张图，虽然烦，但你修完发现“哇，滤镜真好看”。现在的引导：一键跳过，直接进相册。

第二天用户回来（次留涨了），打开相册看了看，不知道点哪，关了。到了第七天，他早就忘了这 App 是干嘛的了。

这就是典型的：为了流程顺畅，牺牲了教育用户的机会。

逻辑三：激励的不可持续性

如果这次优化包含了“次日登录奖励”。那用户第二天回来纯粹是生理性的反射——领奖。领完奖之后呢？如果产品本身不好玩，第三天他就没理由来了。

这就像请人吃饭，第一顿你请客，大家来了；第二顿还得自己掏钱，大家就散了。

第四部分：怎么用数据实锤这些猜想？

光瞎猜不行，作为分析师，我们得拿出证据。

我会建议立刻跑下面这几组数据，基本上能把问题看透：

1. 这里的核心是看“留存曲线的斜率”。

千万不要只看 Day 1 和 Day 7 这两个点。我要看 Day 1, Day 2, Day 3...一直到 Day 7 的完整留存率。

如果我没猜错，数据形态应该是：Day 1 明显高了，但 Day 2 到 Day 3 的跌幅比以前剧烈得多。这就能证明“低质量用户被短期留存掩盖了”的假设。

2. 拆解“核心行为转化率”。

这一步非常关键。

我要看这批新用户在 Onboarding 之后，有没有发生**关键行为（Key Action）**。

比如，还是那个修图 App。A 组（老流程）：100 人进来，次留 40 人，其中 30 人在头七天修了图。B 组（新流程）：100 人进来，次留 50 人（涨了！），但只有 30 人在头七天修了图。

你看，虽然留下来的人多了，但**干正事**的人数没变。这就说明多出来的那 10% 的人，全是“无效活跃”。

3. 用户分层分析（Cohort Analysis）。

把新用户按渠道拆开看看。是不是某个买量渠道（比如刷金币的广告）带来的用户次留涨得特别猛，但七留极差？这能帮我们排除是不是渠道流量质量的问题，而不是产品引导的问题。

第五部分：下一步建议怎么做？

分析完了，咱得给业务方出招。既然次留涨了是事实，说明优化方向有一半是对的（至少门槛低了大家愿意来），我们现在的任务是**把这多出来的 10% 的用户，真正转化为长期用户**。

我有三个具体的建议：

建议一：在“顺畅”和“教育”之间找平衡（加回必要的摩擦）

如果我们为了顺畅删掉了关键教程，现在得加回来。

但不要加在开头，可以加在用户第二次打开 App 的时候。比如用户第二天回来时，引导他去完成那个“Aha Moment”的动作。

建议二：拉长激励周期

如果是靠奖励提升的次留，那就把“次日奖励”改成“七日签到计划”或者“新手成长任务线”。把给用户的糖果碎着给，让他为了领完奖必须体验完核心功能。

这不是为了恶心用户，是为了给他足够的时间去发现产品的真正价值。

建议三：根据用户行为做分层引导

对于那些“第二天来了但没干正事”的用户，进行针对性的 Push 推送或站内引导。

既然他们来了，说明不排斥 App。我们要分析他们在 App 里停留的那几分钟到底看了啥？如果只是在首页瞎逛，那就直接弹窗推荐热门内容；如果是卡在某个功能页，就弹出教程。

知识点归纳总结

这道题解答完了，咱们复盘一下用到的知识点，以后遇到类似的题可以直接套用：

- 1. **虚荣指标 (Vanity Metric) 陷阱**：次日留存有时会骗人，必须结合长期留存 (Day 7 / Day 30) 一起看。
- 2. **留存曲线 (Retention Curve)**：分析留存不能只看单点，要看衰减的速率 (斜率)。
- 3. **魔法数字 / 关键行为 (Aha Moment)**：用户留存的核心不是因为引导做得好看，而是因为他们体验到了核心价值。分析留存必须关联核心行为转化。
- 4. **摩擦力 (Friction) 的双面性**：摩擦力不一定是坏事，好的摩擦力能筛选用户、教育用户。过度平滑的流程可能会导致用户一脸懵逼地流失。

好，关于这道题我就分析到这。

现在，如果你是面试官，听完我这通分析，你大概率会盯着我刚刚提到的“核心行为”继续深挖。

你会问我：

“你刚才提到了 Aha Moment (惊喜时刻)，如果在我们这个业务里，目前还不知道用户的 Aha Moment 到底是什么，作为分析师，你会通过什么样的数据分析手段把它找出来？”

面试 22

某视频平台本月付费会员数环比增长了 30%，但会员总收入却环比下降了 5%。作为商业分析师，你会从哪些维度拆解原因，并给出优化建议？

解答

这道题其实非常有意思，乍一看挺反直觉的，会员多了这么多，钱怎么还能少了呢？咱们不用那些花里胡哨的模型，直接坐下来把这笔账算清楚，你就知道问题出在哪了。

第一部分：先别急着找原因，先把那个“消失的数字”算出来

这道题的核心逻辑其实就一个最简单的等式：

总收入 = 付费会员数 × ARPPU（每付费用户平均收入）

题目给了咱们两个已知条件：

1. 付费会员数（Members）变为了原来的 130%（增长 30%）。
2. 总收入（Revenue）变为了原来的 95%（下降 5%）。

那我们可以反推一下那个没说的指标——ARPPU 变成了多少？

$$0.95 / 1.30 \approx 0.73$$

这意味着什么？意味着本月的 **ARPPU 环比暴跌了 27%**。

这是一个非常惊人的跌幅。你想想，平时如果你卖东西，突然把客单价砍掉快三分之一，这绝对不是正常的市场波动，这通常意味着业务侧有了巨大的动作，或者是统计口径出了大问题。

所以，这道题的本质不是问你“收入为什么跌”，而是问你：“**为什么我们的单用户价值（ARPPU）会突然缩水 27% 这么多？**”

只有把问题定位到这里，你的分析才算入了门。

第二部分：业务维度的深度拆解（人、货、场）

既然锁定了是 ARPPU 出问题，那我们就顺着业务场景去抓“嫌疑人”。通常这种情况，我会从这几个方向去排查。

1. 价格战与促销活动（最常见的嫌疑人）

这是最直接的可能性。业务部门为了冲 KPI（会员数增长），是不是搞了“自杀式”促销？

- **首月极低价**：比如平时 25 元一个月，现在搞“首月 1 元”或者“0.1 元试用 7 天”。如果是大量新用户通过这个渠道进来，会员数确实会暴涨，但这些人的付费金额几乎忽略不计。
- **免费赠送/联合会员**：比如买京东送爱奇艺，或者办信用卡送腾讯视频。这种情况下，虽然用户数算在平台头上，但结算价格可能极低，甚至有账期延迟，导致当月确认收入很少。

如果真的是这样，你要马上看一眼“新老用户结构”。是不是新增的这 30% 会员，全是薅羊毛进来的？

2. 产品结构结构性塌方（货的变化）

视频平台的会员通常分等级，比如：

- **电视端+手机端通用的高级会员（贵，比如 35 元）**
- **仅限手机端的普通会员（便宜，比如 15 元）**
- **学生会员（极便宜，比如 10 元）**

如果本月“高级会员”大量到期流失（Churn），而新增的全部是“学生会会员”或者“手机端基础会员”，就会出现这种“人变多了，但全是低净值人群”的现象。这也就是我们常说的 Mix Change（结构变化）。

3. B端渠道的特殊结算（场的特殊性）

有时候平台会和运营商（移动、联通）做大规模的打包活动。

比如运营商为了推 5G 套餐，一口气采购了 100 万个会员名额发给用户。这 100 万个会员瞬间计入系统，导致会员数暴涨 30%。

但是！B 端的结算价格通常极低（可能是 2 折甚至更低），而且这笔钱可能不是当月立刻到账，或者财务上需要分摊确认。这就导致账面上看人数猛增，但真金白银没进来，甚至因为原来的 C 端散户自然流失，导致总盘子收入还跌了。

4. 统计口径与财务确认（坑特别多）

这里其实有个很隐蔽的点，叫 **“Deferred Revenue”（递延收入）**。

假设本月搞大促，主推“99 元包年卡”（原价 200）。

- 会员数：立刻 +1。
- 现金流：立刻 +99 元。
- **财务确认收入**：注意了，财务记账时，这 99 元是要分摊到未来 12 个月的。所以本月只能确认 $99 / 12 \approx 8.25$ 元。

如果上个月大家买的都是单月卡（25 元），这个月大家买的都是年卡（本月入账仅 8.25 元）。虽然你收到了很多现金，但财务报表上的“本月收入”可能会显得很难看。这也解释了为什么会员涨了，（确认）收入却跌了。

5. 极端的异常情况：退款与欺诈

虽然概率小，但也要看一眼。是不是上个月有一批大额充值在本月集中发生了退款？或者有没有灰产利用系统 Bug 刷会员，导致虚假用户激增但没产生实际收益？

第三部分：作为分析师，你的建议是什么？

光找出原因不够，面试官最想听的是你的 **Actionable Insight（可落地的建议）**。

千万不要上来就说“停止低价促销”，那太初级了。我们要分情况讨论。

如果是“递延收入”导致的（卖了很多年卡）：那其实问题不大，这是虚惊一场。现金流是健康的，只是财务确认滞后。建议在报表中增加“现金收入（Cash Revenue）”或者“订单金额（Bookings）”作为辅助指标，展示真实的业务健康度。

如果是“低价引流”导致的（比如 1 元首月）：这就要警惕了。我们需要计算 **LTV（生命周期价值）**。你要回答这个问题：这批用 1 元钱买进来的用户，下个月的留存率怎么样？

- 如果他们薅完羊毛就跑，那这波操作就是纯亏，必须立刻叫停，优化获客渠道。

- 如果他们虽然首月便宜，但次月续费率很高（哪怕恢复原价后），那从长线看 $LTV > CAC$ （获客成本），这波亏损就是值得的“战略性投入”。

如果是“高价值用户流失”导致的：这是最危险的情况。说明你的核心体验出了问题（比如最近没好剧，或者广告太多）。建议立刻对流失的高级会员做 **Exit Survey（流失调研）**，并发放定向的“召回券”试图挽回，同时去盘一下内容供给端，是不是头部内容断档了。

总结归纳：分析中的知识点

这道题其实串联了几个非常核心的数据与商业概念，咱们复盘一下：

1. **公式拆解思维**：遇到异动，先列公式（ $Revenue = DAU * ARPU$ 或 $Revenue = Members * ARPPU$ ），量化排查方向。
2. **ARPPU（Average Revenue Per Paying User）**：每付费用户平均收益，是衡量用户质量的关键指标。
3. **Mix Change（结构变化）**：总量掩盖了结构问题。不同价格带的用户比例变动，会剧烈影响整体表现。
4. **递延收入（Deferred Revenue）**：理解会计上的“权责发生制”，现金流不等于当期收入，特别是对于订阅制（SaaS/会员）业务。
5. **LTV（Life Time Value）**：即使当期亏损（收入跌），只要 LTV 健康，短期波动是可以接受的。要用发展的眼光看问题。

（切换至面试官视角）

刚才听你提到了如果是低价引流用户，我们要看他们的 LTV 来判断这次策略是否成功。

那么我想追问一下：假设我们现在的业务是刚刚起步阶段，数据基建还不是很完善，没办法精准计算出长周期的 LTV。在这种情况下，如果你要评估这一批“1元首月”用户的质量，你会选取哪几个短期的代理指标（Proxy Metrics）来快速判断这批用户未来是否有价值？为什么？

面试题 23

某打车平台晚高峰期间，用户叫车需求量（呼叫单量）同比暴涨 50%，但最终的订单成交率（应答率）却大幅下降。

作为商业分析师，你会如何分析这一供需失衡问题，并提出策略？

解答

面对这种「一个指标涨，一个指标跌」的倒挂现象，我的第一反应通常不是去翻数据，而是先在脑子里画个公式。

$应答率 = 完单量 / 呼叫单量$

现在题目告诉我们：**分母（呼叫单量）同比暴涨 50%，但是结果（应答率）大幅下降。**

这说明什么？说明分子（完单量）并没有跟上分母的涨幅，甚至可能还是跌的。

所以，分析这道题，我们必须把问题拆解成三个维度来看：

1. **需求侧 (Demand)**：这 50% 的涨幅是真的还是假的？
2. **供给侧 (Supply)**：运力到底去哪了？为什么接不住这泼富贵？
3. **匹配效率 (Match)**：也就是中间那个连接器，是不是坏了？

咱们一步步往下挖。

第一部分：需求侧，这 50% 的暴涨正常吗？

做分析最怕的就是被「虚荣指标」骗了。同比暴涨 50%，听起来业务好得不得了，但你得先打个问号：这真的是有效需求吗？

1. 排查「虚假繁荣」：

晚高峰大家打车都急。如果运力不足，用户叫不到车，由于焦虑，他可能会频繁取消、重新呼叫，或者在同一个 App 里切换不同车型（比如同时呼叫快车、优享、专车）。

在数据统计口径上，如果按「发单次数」统计，这一个人就贡献了 3-5 个 Call Request。

所以，咱们得先看 **UV（下单用户数）** 的涨幅。

- 如果 Call Volume 涨 50%，但 UV 只涨了 10%，那说明这 50% 的暴涨大部分是用户因为打不到车而产生的「无效重试」。这不仅不是好事，反而是用户体验崩塌的前兆，
- 如果是这种情况，那应答率下降就是必然的，因为分母被人工「注水」了。

2. 排查外部归因：

如果 UV 确实也涨了很多，那就要看是不是有偶发事件。

- **天气**：当天是不是下暴雨？下雨天打车需求通常会瞬间翻倍，但司机可能会因为视线不好、不想洗车而收车，供需剪刀差瞬间拉大。
- **活动**：附近是不是有大型演唱会散场、体育赛事或者突发的地铁故障？这种瞬时爆发的局部需求，任何平台的常态运力都是接不住的。

第二部分：供给侧，运力为什么成了瓶颈？

假设需求是真的，那问题核心一定在供给侧。这也是打车平台最头疼的地方。

这时候你要引入一个概念：**有效运力 (Effective Supply)**。

注意哦，不是看「在线司机数」有多少，而是看「能干活的时间」有多少。

1. 晚高峰的致命杀手：拥堵

这是很多人容易忽略的业务常识。晚高峰意味着什么？意味着堵车。

如果不堵车，一个司机 1 小时能跑 3 单；一旦堵车，1 小时可能只能跑 1.5 单。

哪怕在线司机人数没变，受拥堵影响，实际服务能力（Supply Capacity）直接腰斩。

这时候需求涨 50%，供给受拥堵影响跌 30%，这一进一出，缺口就是巨大的，应答率不崩才怪。

2. 司机出车意愿（激励敏感度）：

还需要排查一下，同比去年，我们的司机侧策略有没有变化？

- 去年这个时候是不是有「晚高峰冲单奖」？今年是不是取消了？
- 或者竞对平台是不是在搞事情？比如隔壁平台在这个时段给了 1.5 倍的流水补贴，司机都切到隔壁 App 去听单了？

3. 合规与门槛：

这是一个比较硬的限制。是不是最近城市出台了新的网约车新政？比如清理非本地车牌、清理无证司机？这会导致运力底盘瞬间缩水。

第三部分：匹配效率，中间商有没有赚差价？

如果供需两端看起来都还凑合，那就要看中间的算法和系统了。

- **系统故障：** 50% 的流量冲击，是不是导致派单系统有延迟？或者定位漂移严重，导致司机接单后找不到乘客，大量无责取消？
- **调度逻辑失效：** 比如算法在晚高峰过于追求「长单」，导致短途单大量积压，而这些短途单往往是贡献 Call Volume 的主力军。

第四部分：策略建议，怎么救？

既然病因找到了，开药方就得对症。咱们分短期止血和长期调理来说。

1. 短期策略（立刻生效）：

- **价格杠杆（Surge Pricing）：** 这是最直接的。启动动态调价，一方面抑制一部分对价格敏感的低价值需求（筛选掉那些“可打可不打”的单子），把资源留给刚需用户；另一方面，高价能刺激更多司机上线，或者把在隔壁平台的司机拉回来。
- **疏导拥堵：** 在产品端引导用户走到「推荐上车点」，避开极度拥堵的路段。这能帮司机节省进出拥堵区的时间，变相增加运力周转效率。
- **安抚体验：** 对于叫不到车的用户，发放延迟满足的优惠券，或者在等待界面明确告知「预计等待时间」，降低焦虑，减少重复呼叫。

2. 中长期策略（结构优化）：

- **运力蓄水池：** 针对晚高峰这种由于潮汐效应导致的运力不足，可以招募「兼职运力」，比如鼓励上班族下班顺路接一单（顺风车模式），释放社会闲置运力。
- **拼车业务（Carpooling）：** 这是提升效率的神器。如果两三个顺路的人拼一辆车，相当于把原本需要的 3 辆车的运力需求，压缩到了 1 辆车上。在供给受限的情况下，这是提高应答率（Served Rate）最有效的手

段。

解答中使用到的知识点总结：

1. **供需分析框架**：任何双边市场问题，都要拆解为 Demand（量、真伪）、Supply（数量、效率）、Match（算法、体验）。
2. **指标拆解**：不要只看表面指标（呼叫量），要看过程指标（UV、重复呼叫率）和效率指标（TPS, Trips Per Supplier）。
3. **业务Sense**：理解业务场景（晚高峰=拥堵=周转率下降），单纯的数字计算无法发现这个逻辑。
4. **价格弹性**：利用价格（动态调价）来调节供需平衡，这是经济学的基本原理在商业分析中的应用。

（切换至面试官视角）

刚才你的分析里提到了「动态调价」这个策略。

确实，涨价可以抑制需求并拉动供给。但如果我是业务负责人，我现在告诉你，**我们不仅不能涨价，为了抢占市场份额，晚高峰还得保持低价策略。**

在这种「既要（保低价）又要（保应答率）」的极端约束条件下，你还有什么非价格手段能把应答率提上来？

面试 24

为了提升 DAU，某 App 将消息推送频率从每天 1 条增加到 3 条。实验结果显示：DAU 环比提升了 5%，但同时 App 的卸载率也上升了 0.2%。作为商业分析师，你会如何量化评估这次调整是否“划算”，并决定是否全量上线？

解答

这道题的考察意图其实很贼，它把两个完全不同维度的指标放在了一起：**DAU 是一个「流量」指标（Flow），而卸载率是一个「存量」的毁灭指标。**

简单的说，DAU 涨了是今天的热闹，卸载率涨了是明天的坟墓。

所以，我的分析框架会非常直接：我们要把这两个指标换算成同一种“货币”来进行比较。通常这种货币就是**LTV（用户生命周期价值）**或者更直观一点的——**总活跃天数的净增减**。

我们得搞清楚：这多出来的 3 条推送，到底是用透支用户未来的寿命换来的，还是真的激活了用户的兴趣？

第一部分：把账算清楚，千万别被 0.2% 骗了

很多人第一眼看这题，直觉会觉得：“哇，DAU 涨了 5%，卸载才多了 0.2%，这不是赚翻了吗？”

这其实是个巨大的错觉。因为分母不一样，且后果不一样。

- DAU 的提升通常是基于“活跃用户”这个盘子，或者是基于当天的流量。
- 卸载率的提升，通常分母是“总用户量”或者“活跃用户量”，但它的杀伤力是**永久的**。

我们来做个带数字的推演，这事儿立马就清楚了。

关键假设：

假设你这个 App 的日活（DAU）是 100 万。

假设总用户盘子（包括那些低频活跃的）是 500 万。

假设平时的日均卸载率是 0.1%。

场景 A（调整前）：

- DAU：100 万。
- 自然流失（卸载）：假设按活跃用户算， $100 \text{ 万} \times 0.1\% = 1000$ 人流失（为了简化模型，我们先只看活跃用户的流失）。

场景 B（调整后）：

- DAU 涨了 5%： $100 \text{ 万} \rightarrow 105 \text{ 万}$ 。你今天多赚了 **5 万个 DAU**。
- 卸载率上升了 0.2%：变成了 0.3%。
- 新的流失数： $100 \text{ 万} \times 0.3\% = 3000$ 人流失。

账面计算：

你看，你为了今天多换取这 5 万个活跃人次，你额外“杀死”了 2000 个真实用户（ $3000 - 1000$ ）。

这就变成了一个极其残酷的数学题：**50,000 个当天的活跃人次，是否大于 2,000 个用户剩下的所有生命周期价值？**

我们算一下“盈亏平衡点”：

$$50,000 / 2,000 = 25。$$

这意味着，如果这 2000 个被你气跑的用户，他们平均每个人只要在未来的生命里还能再来 App 访问超过 **25 天**，那你今天就是亏的。

对于绝大多数 App 来说，一个活跃用户的留存寿命远不止 25 天。所以，单纯看这个数，**这笔生意大概率是血亏的**。这还没算那些虽然没卸载、但心里已经很不爽的用户。

第二部分：除了卸载，还有一个更可怕的“隐形杀手”

作为商业分析师，如果只看到“卸载”这一层，那还有点浅。

面试官这时候通常在等你说出另一个关键词：**通知关闭率**。

这是比卸载更隐蔽的损失。

当用户觉得一天 3 条推送很烦的时候，极端的动作是卸载（Uninstall），但更温和且普遍的动作是——**关掉通知权限**。

一旦用户关掉了通知：

1. 你以后再也触达不到他了，他变成了一个“沉默用户”。
2. 这个损失在当天的 DAU 数据里是看不出来的，甚至在卸载率里也看不出来。
3. 但这个用户的 LTV 会断崖式下跌，因为你失去了召回他的手段。

所以，评估这次调整是否划算，我必须要求加上监控 **“通知权限关闭率”** 的变化。哪怕卸载率只涨了 0.1%，如果通知关闭率涨了 5%，那我坚决反对全量上线。

第三部分：分层看问题，别搞“一刀切”

接下来我们聊聊业务策略。现在数据摆在这了，是不是就一定不能推 3 条了？

也不是。这其实是个**精细化运营**的问题。

这里的核心问题在于：**是对“谁”推了 3 条？**

我们得把用户切开看：

1. 高活死忠粉：

这些人本来就会每天打开 App。你推 1 条还是 3 条，对他们贡献 DAU 没啥大帮助（因为他们本身就会来），反而可能因为打扰而产生反感。对这类人，增加推送是纯成本，零收益。

2. 低活/流失边缘用户：

这些人可能本来一个月才来一次。你推 3 条，可能真的把他唤醒了，贡献了增量 DAU。而且他们本身也没啥忠诚度，卸载了也就卸载了，成本较低。

我的分析结论是：

这次实验的整体数据（+5% DAU, +0.2% 卸载）是全量平均后的结果，它掩盖了内部的结构性差异。

很有可能情况是：你恶心了那批最值钱的老用户（导致卸载和关通知），同时唤醒了一批没什么价值的羊毛党（贡献了 DAU）。如果是这样，这就是典型的“饮鸩止渴”。

第四部分：我的最终决策建议

基于上面的分析，我会给出一套非常具体的行动方案，而不是简单的 Yes or No。

1. **立刻停止全量上线计划**：按照目前的推算（25 天的回本周期），风险极大，不能只看 DAU 这一项虚荣指标。
2. **细分实验（分层测试）**：
 - **活跃用户**：保持 1 条/天，甚至不推（免打扰），保护体验。
 - **次活跃/沉睡用户**：尝试维持 3 条/天，观察这部分人的卸载率是否在可控范围内。如果这部分人的卸载率提升不明显，但 DAU 提升显著，那就在这部分人群中保留策略。

3. 引入更全面的评估指标：

不要只看 DAU。要把 $DAU / (\text{新增卸载数} + \text{新增通知关闭数} * \text{权重})$ 做成一个综合监控指标。只有当这个比率健康时，才能扩大推送。

4. 内容质量复盘：

最后多嘴问一句运营团队：这增加的 2 条推送，推的是什么？如果是优质的个性化内容，容忍度会高；如果是纯营销广告，那必须砍掉。

总结一下知识点

回答这道题，其实就是在向面试官展示你懂这几个概念：

1. **存量 vs 流量思维**：懂得把短期收益（DAU）换算成长期的用户价值（LTV）来对比。
2. **隐性成本**：知道除了“卸载”，还有“关闭通知权限”这个更重要的中间态指标。
3. **用户分层（Segmentation）**：知道不能用平均数看世界，高活用户和低活用户的策略必须差异化。
4. **盈亏平衡分析（Break-even Analysis）**：能随手做一个简单的数学估算，把抽象的好坏变成具体的数字门槛（比如上面的 25 天）。

好了，这个题拆解完了。你会发现，只要把账算细了，数据分析其实就是把生活中的“得失权衡”量化出来而已。

（这里你可以停顿一下，消化一下这个逻辑。这道题在大厂的面试里出现率极高，就是因为它考了你有没有“大局观”。）

那么，既然我们要站在面试官的角度，我现在要抛出下一个问题了，请接招：

追问：

“刚才你提到了要对用户进行分层，针对不同活跃度的用户采用不同的推送频率。

那么，如果让你来设计一套‘用户活跃度分层模型’（RFM 或者其他模型都可以），你会选取哪些具体的特征指标来定义‘高潜用户’和‘流失风险用户’？

另外，怎么验证你分的层是准确的？”

题目 25

近期舆情监测发现，大量用户投诉平台存在“大数据杀熟”现象：同一时间、同一商品，老用户看到的价格比新用户贵了 15%。作为商业分析师，你会如何通过数据排查这是否属于“杀熟”？如果现状如此，你认为这种定价策略合理吗？该如何优化？

解答

这一篇关于「大数据杀熟」的面试题解析，我们不仅要聊数据怎么查，更要聊透这背后的业务逻辑和合规红线。这题目在现在的互联网大厂面试里出现率极高，因为它同时考察了你的SQL取数思维、归因分析能力，以及对商业伦理的判断。

第一部分：排查思路——先把「价格」定义清楚

拿到这道题，很多人的第一反应就是去跑 SQL，把新老用户的订单拉出来对比平均值。这其实有点急了。在动手之前，我们得先有个结构化的分析框架，核心在于厘清两个概念：**展示价格（List Price）**和**实付价格（Final Price）**。

用户说的「贵了 15%」，到底是哪里的价格贵了？这直接决定了定性。

如果我是分析师，我会分三步走来排查数据：

首先，确立对比基准，控制变量。

所谓的「杀熟」，必须是在严格控制变量的前提下才能成立。我们不能拿北京的老用户和五线城市的新用户比，也不能拿上午的订单和半夜的订单比。

我需要在数据仓库里拉取这样一个切片：

筛选出「同一SKU」、「同一时间窗口（比如 10 分钟内）」、「同一配送区域」的请求记录。注意哦，这里看的是曝光日志（Impression Log），而不是仅仅看订单表，因为很多用户看了价格觉得贵就没下单，只看订单表会有幸存者偏差。

其次，拆解价格构成，定位差异源头。

我们将价格公式拆解为：实付价格 = 商品原价（Base Price） - 基础折扣 - 优惠券/红包 - 运费 + 溢价（如果有）。

我们要看这 15% 的差异到底出在哪一项上。

通常会有两种情况：

1. **原价不同**：老用户看到的 Base Price 是 100 块，新用户看到的是 85 块。
2. **原价相同，优惠不同**：大家都看到 100 块，但新用户有个「首单立减 15」的券，或者「新客免运费」。

最后，验证「随机性」还是「歧视性」。

如果发现价格差异确实存在，我们还要看这是不是某种 A/B 测试导致的。是不是正好老用户撞进了高价组？我们需要检查实验 ID。如果排除了 A/B 测试，且发现这 15% 的差异在「高频老用户」群体中具有统计学上的显著性，那基本就可以定性了。

这里有个细节大家容易忽略——**机型和渠道**。有时候不是杀熟，而是 iOS 和 Android 的定价策略不同（虽然这也是一种歧视），或者某些渠道（比如小程序 vs App）有特定补贴。这块得单独拎出来看一眼，别冤枉了算法。

第二部分：现状分析——这算不算「杀熟」？合理吗？

假如数据跑出来了，结论是：**原价确实一样，但新用户手里有一张 85 折券，导致最终价格便宜了 15%。**

这种情况，在业务上我们通常不叫它「杀熟」，而叫「新客获取成本（CAC）」。

这合理吗？从商业逻辑上讲，合理。

因为新用户的获取是需要花钱的，商家把广告费变成了补贴发给用户，这是为了拉新。就像你办健身卡，新会员首月打折，老会员续费原价，这在传统行业也很常见。

但是！

如果数据跑出来是：老用户看到的商品原价直接就是 115 块，而新用户看到的是 100 块。

这就叫「大数据杀熟」，或者叫「歧视性定价」。

这合理吗？绝对不合理，且高风险。

这就不是单纯的经济学问题了，这是合规问题。现在的《个人信息保护法》和《反垄断法》对这种根据用户画像提供差异化价格的行为管得非常严。

从业务长远来看，这也是一种短视的「自杀式」策略。

你可以算一笔账：确实，对价格不敏感的老用户提价 15%，短期内该用户的 ARPU（每用户平均收入）会涨。

但我们要看 LTV（生命周期总价值）。一旦用户发现自己被杀熟，信任感会瞬间崩塌，流失率（Churn Rate）会飙升。

假设老用户留存率从 80% 掉到 50%，你那 15% 的溢价根本填不上用户流失的大坑。这就像是为了捡芝麻丢了西瓜，而且这西瓜还可能反手给你一告一个准。

第三部分：优化策略——如何既赚钱又不挨骂？

既然直接改原价是「找死」，但我们又想做精细化运营，想对不同支付能力的人有区分，该怎么办？

作为分析师，我会给出这三条建议：

1. 统一前端展示价，差异化后端权益。

永远不要动 List Price。所有人看到的货架价格必须是一致的。

如果想做区分，请用「优惠券」或者「会员权益」来做。

给新用户发「首单券」，名正言顺。

给老用户推「Plus 会员」或「积分抵扣」，通过提升忠诚度来变相给优惠，而不是简单粗暴地改价格。

2. 将「杀熟」转化为「动态定价」。

如果你是像网约车、酒店这种库存有限的业务，可以用供需关系来定价，而不是用人头来定价。

比如，告诉用户「现在是高峰期，价格上浮 10%」，这是基于市场行情的，用户能理解。

而不是「因为你是老李，所以你比小王贵 10%」。

这就把「对人的歧视」转化为了「对时空的定价」，逻辑上就通了。

3. 透明化与选择权。

如果你非要给不同人不同价，必须给用户选择权。

比如设置不同等级的 SKU。

老用户推荐买「尊享版」（价格高，服务好，发货快），新用户买「基础版」。

让用户自己用脚投票，而不是偷偷摸摸改数字。

说到这其实大家应该发现了，这题表面上是在问数据排查，实际上是在考你的商业价值观。

数据是冰冷的，但用数据的人得有分寸。如果分析师只盯着 GMV 增长，而忽略了用户体验和法律风险，那这种增长通常都是不可持续的。

知识点归纳

在这个回答中，我们其实运用了以下几个关键的数据与业务知识点，你可以记一下：

1. **归因分析 (Attribution Analysis)**：从结果（价格差异）倒推原因（是原价不同、券不同、还是运费不同？）。
2. **控制变量法**：在对比数据时，必须保证 SKU、时间、地点等维度一致，否则对比没有意义。
3. **幸存者偏差 (Survivorship Bias)**：不能只看成交订单，要看曝光日志，因为觉得贵的人可能根本没下单。
4. **价格歧视 (Price Discrimination)**：一级、二级、三级价格歧视的经济学原理及其在互联网中的应用边界。
5. **LTV (生命周期价值) vs CAC (用户获取成本)**：评估定价策略是否合理的财务核心指标。

好，这道题的完整逻辑大概就是这样。

我现在切换回面试官模式，针对你的回答，我有个延伸的问题想问你：

如果经过你的建议，我们取消了针对老用户的差异化定价，改成了统一价格。结果上线后发现，整体的 GMV（交易总额）竟然下降了 10%，老板现在很焦虑，让你分析原因并决定要不要回滚策略，你会怎么分析？

面试 26

【滴滴 / Uber | 策略分析 | 二面】

为了在晚高峰抢占更多的市场份额，你们对「动态调价」策略做了限制，规定暴雨天最高只能涨价 1.2 倍（竞品通常涨 2 倍）。

策略效果立竿见影：

用户侧的「呼叫订单量」激增了 25%，说明用户觉得便宜都来了。

但由于价格不够诱人，司机端出现了一个严重问题：

订单的「应答率」下跌了 15%，意味着大量用户只能对着屏幕干等，根本打不到车。

业务负责人非常乐观，认为：

「虽然现在打不到车，但用户第一反应是打开我们的 APP，因为我们便宜。只要抢占了『首选心智』，这就是巨大的品牌胜利。」

如果你是分析师，

你会认可这个「抢占心智」的逻辑吗？

你会判定这是成功的「市场扩张」，还是在制造「由于打不到车而带来的更深层失望」？

解答

第一部分：先把账算清楚，数字具有极强的欺骗性

业务负责人之所以乐观，是因为他可能只看了一个总数，或者只看了“增长率”。我们必须把账拆细了看。

题目给了两个关键变量的相对变化：

呼叫量（需求） = 原来的 1.25 倍

应答率（匹配效率） = 原来的 0.85 倍（这里通常指同比下跌 15%，即变成原来的 85%）

我们来算一下最后的“**实际完单量**”：

新完单量 = $1.25 \times 0.85 = 1.0625$

第一个结论：实际成交的单量确实增长了 6.25%。

这就是老板“嗨”的原因。表面上看，平台不仅流量来了，成交量也涨了，似乎是个“量价齐升”的好局。

但这里藏着一个巨大的隐形炸弹：被抛弃的用户数（失望流量）。

为了量化这个风险，我们假设一组基数：

假设原来呼叫量是 1000 单，应答率是 80%（高峰期正常水平）。

原来：800 人打到车，200 人没打到。

现在：呼叫量变成 1250 单，应答率变成 $80\% \times 0.85 = 68\%$ 。

现在： $1250 \times 68\% = 850$ 人打到车，400 人没打到。

第二个结论：

为了赚取这 50 个新增完单（增长 6.25%），你让打不到车的失望用户从 200 人翻倍到了 400 人（增长 100%）。

这是一笔极其危险的交易。你在用倍增的“用户怨气”来换取微薄的“成交增量”。

第二部分：深度反驳“心智占领论”

业务负责人说：“用户觉得便宜，下次还来。”这个逻辑在**暴雨天**这个特定场景下，完全是错的。

这里有一个核心的业务逻辑：**场景决定需求层级**。

平时大晴天，是非紧急场景，用户是**价格敏感型**。你便宜 5 块钱，我愿意多等 10 分钟。这时候低价确实能占领心智。

暴雨天、晚高峰，这是生存场景（回不了家、淋雨、赶时间）。

在这个场景下，用户的需求优先级变了：确定性 > 时效 > 价格。

坏心智的形成机制：

用户打开 APP，看到确实便宜（1.2 倍），于是下单。

结果转了 10 分钟圈圈，最后告诉你“暂无车辆应答”。

这时候用户感受到的不是“这家真便宜”，而是“**这家真垃圾，关键时刻掉链子**”。

所谓的“首选心智”，变成了“首选备胎”——只有在别家都打不起的时候才来看看，但并不指望能打到。

一旦用户形成了“这家平台运力不行”的印象，下次遇到急事，他会直接打开那个贵两倍但能秒接单竞品。因为在这个时候，他的时间成本远超那几十块钱。

第三部分：供给侧的崩塌——司机的“套利”行为

这道题最致命的其实不是用户端，而是司机端（供给侧）。

你限制涨价 1.2 倍，竞品涨 2 倍。请注意，司机是理性的经济人，且现在 90% 的司机都是多平台接单。

1. 风险补偿机制失效

暴雨天行车，事故风险高、拥堵严重、车损大。司机出车需要高额的“风险溢价”。竞品的 2 倍溢价是在支付这个风险成本，而你的 1.2 倍可能连司机的心理预期底线都击穿了。

2. 运力迁徙（用脚投票）

如果你是司机，左手手机响了是 1.2 倍的单，右手手机响了是 2 倍的单，你接哪个？

你肯定会把你的 APP 设为“收车”或“下线”，全职跑竞品。

这就导致了：越是需求暴涨的时候，你的真实可用运力反而在剧烈流失。

3. 劣币驱逐良币

留下来的司机可能是哪种？可能是那些在竞品平台被封号的、服务分低的，或者是不知道怎么切平台的新手。这会进一步拉低履约质量，增加司机的取消率和客诉率。

所以，这个策略是在人为制造供需剪刀差：用低价刺激出过剩的需求，同时用限价赶走了稀缺的供给。

第四部分：如果是分析师，该怎么救场？

光否定没用，既然老板非要打“低价心智”，又不能让平台崩盘，我们需要给出折中方案。

方案一：价格歧视与分层调度

不要全局锁死 1.2 倍。

对价格敏感度低、对成功率要求高的“急单”用户，提供一个“快速通道”选项（愿意加价调度）。

对只看价格的用户，明确告知：“当前排队预计 30 分钟，建议您尝试加价或等待。”

把选择权交给用户，而不是替用户做主，这样能降低“打不到车”的预期落差。

方案二：平台侧的补贴转移（烧钱换心智）

如果你坚持要用户端 1.2 倍，又要保住运力，那唯一的办法就是平台补贴。

竞品给司机 2 倍，你向用户收 1.2 倍，中间的 0.8 倍差价，平台自己补给司机。

这笔钱就是你为了“品牌心智”必须付出的营销成本（CAC）。

如果不舍得掏这笔钱，想让司机用爱发电，那最后的结果就是运力崩盘。

方案三：动态的分时策略

暴雨刚开始的 15 分钟，可以不涨价，作为“惊喜营销”。

一旦积压订单（Backlog）超过阈值（比如排队超过 50 人），立即放开价格限制，利用价格杠杆筛选掉非刚需用户，保证刚需用户的体验。

第五部分：复盘总结

这道题考察的不是算术，而是你对**双边市场生态**的理解。

- 虚荣指标（Vanity Metrics）**： 呼叫量暴涨、完单量微涨，这些都是虚荣指标。它们掩盖了“失望用户激增”这个核心毒点。
- 供需弹性（Elasticity）**： 暴雨天需求缺乏弹性（贵也要打），供给极其敏感（钱少就不跑）。逆着弹性做策略，就是逆天而行。

3. **机会成本：**司机接低价单的机会成本是失去了接竞品高价单的机会。不考虑司机的机会成本，运力一定会流失。
4. **留存的隐形杀手：**失败订单（Failed Orders）带来的负面体验，对次日留存（Day 1 Retention）和 NPS 的杀伤力是毁灭性的。

最后切换到面试官视角，我会继续追问你：

“刚才你提到了补贴转移，假设我们真的决定自掏腰包补这 0.8 倍的差价。这肯定会带来巨大的单日亏损。你作为分析师，怎么去量化评估这笔‘亏损’到底值不值？你需要追踪哪些具体的长期指标，来证明今天的烧钱是正确的？”

面试 27

【腾讯 / 字节 | 商业化分析 | 二面】

为了提升广告收入，你们将信息流中的广告加载率（Ad Load）从 5% 提升到了 8%。

实验数据显示：

广告收入直接暴涨了 50%，且 DAU 和次日留存率居然完全持平，没有任何下跌。

但你挖掘数据时，发现了一个很隐蔽的指标变化：

用户的「平均滑动速度」变快了 20%，且对正常内容的互动率（点赞/评论）微跌了 5%。

商业化负责人的结论是：

「数据证明用户的耐受度很高，他们虽然滑得快了一点，但只要没跑（留存没跌），这钱我们就该赚，不赚白不赚。」

如果你是分析师，

你会认可这个「留存没跌就是赢」的判断吗？

你会认为这是完美的平衡，还是认为「滑动变快」是某种慢性死亡的信号？

解答

我的结论非常明确：**我不认可这个判断。这不仅不是完美的平衡，反而是典型的“杀鸡取卵”。如果不干预，三个月内大盘数据必崩。**

下面我们用四个步骤，把这笔账算得明明白白。

第一部分：先把数字算清楚，效率已经崩了

很多人一看到“收入涨了 50%”，第一反应是策略大获全胜。但作为分析师，我们必须对数字极其敏感。我们来做个简单的“小学数学题”推演。

供给侧的变化（库存）： 广告加载率从 5% 变成 8%。库存涨幅 = $(8\% - 5\%) / 5\% = 60\%$ 。这意味着，你给商业化团队的“弹药”增加了 60%。

产出侧的变化（收入）： 实际收入只涨了 **50%**。

核心问题出现了： 投入增加了 60%，产出只增加了 50%。这意味着**边际收益在递减**。多塞进去的那部分广告，变现效率远低于大盘平均水平。

我们拆解一下广告收入公式：Revenue = PV（总浏览量） * Ad Load（加载率） * eCPM（千次展示收益）

题目说 DAU 和留存没变，假设人均 PV 也没变。当 Ad Load 涨了 60%，而 Revenue 只涨 50% 时，数学上必然导致 **eCPM 下跌了**。

为什么 eCPM 会跌？因为广告不仅是“量”的问题，更是“质”的问题。原有的 5% 广告，通常是系统里匹配度最高、出价最高、用户最不反感的“头部广告”。你强行新增的那 3% 广告，大概率是匹配度较差、质量平庸的“次级库存”。这部分广告不仅转化率（CVR）低，还拉低了整体大盘的效率。

所以，这 50% 的收入增长，是用“效率折损”换来的粗放式增长。

第二部分：滑动速度变快，是用户在通过“物理抵抗”

接下来看那个最隐蔽但最致命的指标：**滑动速度变快了 20%**。

商业负责人认为这只是“用户滑得快了一点”，这是极大的误判。在信息流业务中，**时间就是注意力，注意力就是金钱**。

滑动速度变快 20%，意味着用户在单位内容上停留的时间变短了。这会引发两个严重的商业化后果：

1. 广告曝光的“有效性”归零

广告主买流量是为了什么？是为了让用户看清楚他的品牌或产品。如果用户滑动速度极快，广告在屏幕上可能只停留了 0.5 秒就被划过去了。虽然在技术口径上，这算一次“曝光（Impression）”，平台也收了钱。但在用户认知里，他根本没看清这是什么。

长期来看，广告主会发现：虽然曝光量大了，但点击率（CTR）和转化数都在跌。结果就是广告主会**调低出价**，或者直接预算流失。

2. 竞价模型的恶性循环

现在的广告系统都是 OCPM（以目标转化为优化目标）为主。模型需要用户“停留、点击、转化”的数据来学习。用户滑得越快，模型收集到的正向样本就越少，负向样本（快速划过）越多。

这会导致广告推荐越来越不准，用户越看越烦，滑得更快。这是一个死循环。

所以，“滑动速度 +20%”不是用户耐受度高，而是用户开启了“人肉过滤模式”，他们在防御性地寻找能看的东西，这对商业化价值是毁灭性的打击。

第三部分：留存率的欺骗性与生态的“慢性失血”

为什么留存率没跌？因为留存率是一个极度滞后的指标。

对于高频应用，用户有强大的肌肉记忆和使用习惯。今天广告多了，用户觉得烦，但他不会立刻卸载，他会忍。等到留存率开始跌的时候，说明用户习惯已经彻底崩塌，那时候你想救都来不及了。

比留存更可怕的，是“自然内容互动率微跌 5%”。

这 5% 的互动下跌，意味着广告正在挤出优质内容的生存空间。我们来模拟一下这个业务场景：用户打开 App，想看搞笑段子。以前刷 10 条内容，有 1 条广告，他心情好，给 3 个段子点了赞。现在刷 10 条内容，有 2 条广告，还夹杂着质量一般的推荐。他的节奏被打乱了，心情变得急躁，原本想点赞的手停住了，直接划走寻找下一个刺激点。

这对创作者生态是致命的：互动率降低 -> 算法认为该内容质量下降 -> 减少流量分发 -> 创作者得不到反馈 -> 停更或生产劣质内容。

一旦优质内容供给开始减少，用户发现 App 变得“不好看”了，这时留存率就会出现断崖式下跌。这就是我说的“慢性死亡”——我们在用未来的生态健康，透支今天的现金流。

第四部分：我的策略建议

作为分析师，我不能只说“不行”，公司毕竟有营收压力。我不建议直接回滚到 5%，我建议分层处理，精细化压榨。

1. 抛弃“平均主义”，实施分层 Ad Load

全量 8% 是懒政。我们需要把用户分成三六九等（Segmentation）。对于高粘性、对广告不敏感、滑动速度稳定的核心用户，可以尝试保持 8% 甚至更高。

对于那些滑动速度明显飙升、互动率暴跌的敏感用户，立刻触发熔断机制，把 Ad Load 降回 5% 甚至更低，先保住他们的体验。

2. 引入“负向体验指数”进监控大盘

不能只看留存和 DAU。必须把“滑动速度变化率”、“短停留占比”、“负反馈点击率”列为核心监控指标（Guardrail Metrics）。设定一个阈值，一旦某个群体的滑动速度涨幅超过 10%，系统自动减少广告推送。

3. 提升广告素材的“原生度”

用户滑得快，往往是因为广告太生硬。这 50% 的收入里，我们需要分析，有多少是靠“强塞”带来的，有多少是靠“精准匹配”带来的。如果是靠强塞，这种收入不要也罢。我们需要倒逼广告主和算法团队，优化素材质量，让广告看起来像内容，降低用户的防御心理。

总结

这道题用到的分析逻辑总结如下：

- **边际效率分析**：当库存增长率 > 收入增长率，说明变现效率（eCPM）在下降。
- **指标敏感度分级**：留存率是滞后指标（Lagging），滑动速度和互动率是前置指标（Leading）。看趋势必须看前置指标。
- **双边市场模型**：商业化不能只算平台的账，要算创作者（内容供给端）的账。互动率下跌会破坏内容生态的飞轮。
- **注意力经济**：用户时间是有限资源。滑动变快 = 单位时间价值下降 = 流量贬值。

最后，面试官的视角：如果面试官问出这道题，他其实心里清楚全量 8% 是有问题的。他想听的不是你为了 KPI 强行洗地，而是看你敢不敢指出风险，并且能不能提出比“一刀切”更聪明的**分层策略**。

敢于说出“这钱赚得有毒”，并且给出解药，才是金牌分析师的价值。

附：面试官可能的追问

“你的分析逻辑很清晰，特别是关于滑动速度对 eCPM 的影响。那我想深入问一个策略落地的问题：

如果你决定对用户进行分层，针对‘高敏感用户’降低广告量。你需要构建一个预测模型来圈选这波人。**你会选取哪些具体的特征（Features）输入给模型？如果要为这个模型定一个‘损失函数’，你会怎么量化‘用户流失风险’和‘广告收入损失’之间的 Trade-off（权衡）？**”

题目 28

【今日头条 / 小红书 | 推荐策略 | 二面】

为了极致提升用户的沉浸时长，你们调整了推荐算法的「探索系数」，大幅减少了新领域的试探，只给用户推他历史最爱看的那几类内容。

AB 实验效果炸裂：

人均使用时长直接上涨了 12%，用户刷得停不下来。

但后台监测到了一个典型的「窄化」现象：

用户单日消费的「内容类目数」从平均 6 个跌到了 2 个（例如只看美女和游戏，其他全不看）。

算法负责人的态度很坚决：

「数据不说谎。用户就是喜欢看这些，我们没必要傲慢地去『教育用户』看别的。只要时长涨了，就是对用户价值的最好满足。」

如果你是分析师，
你会直接认可这个「投其所好」的逻辑吗？
你会认为这是推荐系统的胜利，还是在制造加速用户流失的「信息茧房」？

解答

面对这种「数据打架」的情况（时长涨 vs 类目跌），我们不能拍脑袋说谁对谁错，得有一套结构化的拆解思路。
我的分析框架通常是这样的：**先承认短期收益，再验证长期风险，最后给出折中策略。**
咱们一步步来拆。

第一部分：先把大方向捋一下

首先，必须得承认，算法负责人说的有一半是对的。
时长涨了 12%，这是一个非常夸张的收益。在流量红利见顶的今天，DAU（日活）和 Duration（时长）就是命根子。这说明什么？说明在**短期内**，用户确实爽到了。我们减少了探索，直接喂给他最爱吃的东西，反馈当然是即时的、热烈的。
如果我是那个算法负责人，我也得拿着这 12% 去老板面前邀功，这没毛病。
但是，问题的关键在于：**短期爽感 = 长期留存吗？**
显然不是。

这里考察的核心逻辑是：**推荐系统的「Exploit（利用）」与「Explore（探索）」的平衡。**
现在的改动是极致的 Exploit，榨干用户当前的兴趣点。但这会带来一个致命的问题——**边际效用递减。**
打个比方，你爱吃红烧肉，我为了让你今天吃得爽，一日三餐全给你上红烧肉。你今天肯定吃得巨多（时长涨了），明天可能还行，后天你就会吐了，甚至这辈子都不想进这家饭馆了（流失）。
所以，作为分析师，我不会直接否定这个实验，但我会非常警惕这个「类目数从 6 跌到 2」的信号。这是一个极度危险的预警指标。

第二部分：怎么用数据去验证这个「危险」？

光讲道理没用，算法负责人会说「你那是主观臆测，数据在涨啊」。
所以我们要找能佐证「长期风险」的数据指标。单纯看当天的 Duration 是不够的，甚至是有欺骗性的。

我们需要拉出这几个维度来看：

1. 留存率的变动 (Retention)

不要只看 Day 1 的数据。我们要看 Day 7、Day 14、Day 30 的留存。极有可能出现的情况是：实验组的用户在头三天时长很高，但到了第七天，留存率开始低于对照组。这就是「红烧肉效应」——吃腻了，人就走了。

2. 负向反馈率 (Negative Feedback)

去查一下用户的「不感兴趣」「减少推荐」甚至「举报」的点击率。当信息茧房收窄到极致（只看美女和游戏），用户很容易产生疲劳感。一旦产生疲劳，通过滑动的速度、退出的频次，以及点击「不感兴趣」的比例，都能看出来。如果这些指标在上涨，那就是崩盘的前兆。

3. 消费深度的分布 (Content Diversity)

这里有个很隐蔽的逻辑：**窄化会导致内容的快速消耗**。原本用户看 6 个类目，他的兴趣池子很大。现在只看 2 个类目，这两个类目的优质内容很快就会被刷完。一旦优质库存刷完了，算法开始推次优内容，用户体验会断崖式下跌。我们可以计算一个指标：**用户看过内容的重复率**，或者**同质化内容的曝光占比**。如果这个比例飙升，说明我们在透支内容库。

4. 广告价值 (Commercial Value)

这个点很容易被忽略，但很致命。如果用户只看「美女」和「游戏」，那么这部分流量的商业价值 (eCPM) 通常是比较低的，而且广告主也会很单一。原本用户还看「数码」「汽车」，这些是高价值广告区。现在你为了时长把这些砍了，**虽然时长涨了 12%，但可能整体的广告收入 (Revenue) 反而是跌的**。这对于公司来说，就是赔本赚吆喝。

第三部分：如何反驳「不要教育用户」这个观点？

算法负责人说「不要傲慢地教育用户」，这句话听起来很政治正确，但在业务逻辑上其实是偷换概念。

我们要做的不是「教育用户去看不喜欢的东西」，而是「**帮助用户发现他潜在喜欢的东西**」。

这就是推荐系统里「探索 (Explore)」的价值。

如果我是分析师，我会这样跟负责人沟通：

「大佬，我们不是要教育用户。但是数据表明，用户的兴趣是动态变化的。今天的『最爱』不代表明天的『唯一』。现在的策略让类目数跌到 2，实际上是在**扼杀用户未来可能产生的留存**。我看了一下数据，实验组的新用户在第 7 天的流失率比对照组高了 5 个点，而且这部分用户的 eCPM 跌了 8%。我们拿 12% 的时长增长，换来了高流失风险和低商业价值，这个账可能算不过来。」

第四部分：具体的解决策略 (Next Step)

既然问题出在「过度探索」和「过度利用」的两个极端，那解决方案肯定不是直接回滚，那样太怂了，毕竟那 12% 的时长太诱人了。

我会建议做一个**折中方案 (Trade-off)**：

1. **分层处理**：对于新用户（兴趣尚未稳定），保持高探索度，避免一来就陷入茧房；对于老用户（兴趣已固化），可以适当降低探索，但也必须保留一个「保底比例」（比如 20%）用于推荐新类目。
2. **加入「疲劳度」监控**：一旦检测到用户在某个类目下的连续消费时长过长或出现快速滑动，立刻触发「强制探索」，插入其他高热度类目的内容来「换换口味」。
3. **把「类目多样性 (Diversity)」作为一个约束项加入目标函数**。我们的目标不应该是 $\text{Max}(\text{Duration})$ ，而应该是 $\text{Max}(\text{Duration})$ under $\text{Constraint}(\text{Diversity} > \text{Threshold})$ 。

最后总结一下知识点

这道题其实串联了非常多数据分析和推荐策略的核心概念：

- **EE 问题 (Explore vs. Exploit)**：探索与利用的博弈，推荐系统的永恒主题。
- **局部最优 vs 全局最优 (Local vs Global Optimum)**：短期时长涨是局部最优，长期生态健康是全局最优。
- **信息茧房 (Information Cocoons)**：算法过度迎合导致用户视野变窄。
- **北极星指标的陷阱**：只要时长不要留存，是典型的指标选取错误。
- **边际效用递减**：同样的刺激，带来的满足感会越来越低。

这事儿其实没那么复杂，说白了就是——别为了今天的 KPI，杀了明天的用户。

【面试官追问环节】

（现在，请切换回你的面试状态。我已经听懂了你的分析，觉得逻辑很清晰。但我还有一个更刁钻的问题要问你。）

面试官：“好，你刚才提到了要看‘长期留存’（比如 7 日或 30 日留存）来验证这个改动是否导致了用户流失。但是，你应该知道，在实际的 AB 实验中，如果要等 30 天的留存数据出来，黄花菜都凉了，业务迭代速度这么快，我们不可能每一个实验都挂一个月再看结果。在这种情况下，有没有什么『短期指标』或者『中间指标』，能在 1-3 天内就极其敏锐地帮我预测出 30 天后的留存会跌？”

题目 29

【爱奇艺 / 百度网盘 | 会员增长 | 二面】

为了提升 ARPU（每用户平均收入），你们决定对连续包月会员进行调价，价格上涨了 20%。

首月数据非常亮眼：

整体会员收入直接上涨了 15%，毕竟存量用户多，扣款金额变大了。

但后台监测到一个明显的风险信号：

用户的「自动续费关闭率」比上个月翻了一倍。

业务负责人的心态很稳：

「别慌，用户只是习惯性地先关掉自动续费，嫌贵发泄一下。但只要我们的独家内容还在，下个月到期了他们还是得乖乖手动充值回来，这波涨价稳赚。」

如果你是分析师，

你会敢赌这个「用户不得不回流」的自信吗？

你会认为这是成功的提价，还是认为这预示着下个月将迎来「断崖式」的流失？

解答

业务负责人心态很稳：“别慌，用户就是嫌贵撒撒气，回头为了看剧还得乖乖手动充值，这波稳赚。”

如果你是分析师，你敢赌这个“用户不得不回流”的自信吗？

下面我带大家拆解这道题，教你怎么用数据逻辑去反驳“盲目乐观”。

第一部分：先把数字算清楚，这里藏着一个“幸存者偏差”

首先，我们得对那两个数字——价格涨 20% 和 收入涨 15%——做一个最基本的敏锐度测试。

哪怕我不看那个“取消自动续费”的指标，光看这两个数，我就觉得不对劲。

咱们来做个极简的推演：

假设原来单价是 10 元，有 100 个人交钱，总收入 1000 元。

现在涨价 20%，单价变成了 12 元。

如果用户完全没流失（大家都很乖），那总收入应该是 12 乘以 100 等于 1200 元，也就是收入应该跟着满打满算涨 20%。

但现在的现实是，收入只涨了 15%。

也就是说，现有的总收入是 1150 元。

那现在的付费人数是多少呢？用 1150 除以 12，约等于 95.8 人。

发现了吗？

就在这首月，虽然收入看起来涨了，但其实付费用户数已经瞬间流失了大概 4%。

但这还不是最恐怖的，更深层的恐怖在于“分母”。

现实业务中，会员库里通常有一半是“年卡”或“季卡”用户，他们本月根本不需要续费，也没受到涨价冲击。

这意味着，那 4% 的流失，完全是发生在本月需要扣款的“月卡用户”身上的。

如果月卡用户只占总盘子的一半，那么这批人的真实流失率其实已经高达 8% 甚至更多。

所谓的“首月亮眼”，其实是靠“更高的单价”硬生生把“变少的人头”给掩盖住了。这 15% 的增长，是牺牲了极高比例的用户规模换来的。

第二部分：硬核拆解“业务负责人的自信”

业务老大说：“用户只是嫌贵发泄一下，内容在，他们就会回来手动充值。”

这话说得挺轻巧，但在数据分析师眼里，这就是一个巨大的“漏斗转化风险”。我们不能凭感觉怼回去，我们要用漏斗模型来拆解这个过程。

我们要把用户分成三类来看：

1. **躺平党**：没发现涨价，或者不在乎，继续自动续费。这是基本盘。
2. **愤怒党**：也就是题目里那批“关闭自动续费”的人。
3. **回流党**：业务老大口中那种，关了自动续费，但因为想看剧，下个月又乖乖手动交钱的人。

业务老大的赌注，全压在“愤怒党”能不能高效转化成“回流党”。

这里有个巨大的**摩擦力**问题。

自动续费是默认选项，用户不动手就能收钱，这是最顺滑的支付体验，也是 SaaS 模式的核心壁垒。

手动充值是主动选项，用户需要：打开 App -> 发现会员断了 -> 看到广告 -> 点击充值 -> 看到那个涨了 20% 的价格 -> 犹豫一下 -> 确认支付。

每一个步骤都会流失掉一批人。

只要用户一旦切断了“自动续费”，他就从一个“无脑被动付费者”变成了一个需要“每次理性决策”的消费者。

一旦让他重新做决策，他就会重新评估：这部剧真的值这 12 块钱吗？

这时候，竞争对手随便搞个“新客 9.9 元”，这用户可能就跑了。

把“默认扣款”变成“主动决策”，这在商业逻辑上是典型的自降身价。所以我不敢赌。

第三部分：用数据验证，拒绝“我觉得”

既然不能光靠嘴说，如果你是分析师，你现在马上要拉几个关键数据来辅助决策。

我不信“下个月”，我要看历史数据和极短周期的先行指标。

1. 拉取历史“回流率”水位

我不相信这是第一次有人关闭自动续费。去拉一下过去半年的数据：

那些“主动关闭自动续费”的用户里，到底有多少人在会员过期后的 7 天内、30 天内重新手动充值了？

如果历史数据显示，主动关掉的人里只有 20% 回来了，那业务老大认为“大部分人都会回来”就是在做梦。

2. 检查“内容覆盖度”与“完播率”

业务老大说“独家内容还在”。好，那我们来看看，这批“关闭自动续费”的用户，他们最近在看什么？

如果他们正在追一部还剩 20 集才大结局的独家热剧，那业务老大可能是对的，用户为了看结局不得不充。

但如果数据显示，这批用户最近日活（DAU）都在掉，或者他们追的剧刚好下周大结局，那不管是神仙来了也救不了下个月的流失。

3. 关注全站生态的连锁反应

会员流失不仅仅是会员费少了。

用户不续费了，大概率看剧的时间也会变少，这意味着广告库存（Ad Inventory）会下降，广告收入会跌。

长视频平台的商业模式是“会员+广告”双轮驱动。为了保会员收入的 15% 增长，导致广告收入跌了 10%，这笔总账算下来到底划不划算？这也需要预警。

第四部分：分析师的最终建议

回到题目问的：这是成功的提价吗？

我的判断：短期看是财务报表的胜利，长期看是用户生态的重创。

虽然 ARPU（单用户平均收入）上去了，但 LTV（用户生命周期价值）很可能会掉。

因为涨价 20% 带来的单月收入增量，很可能抵消不了用户留存时间缩短带来的损失。比如原来用户能留 10 个月，现在涨价了，用户可能只留 3 个月就跑了。

给业务的紧急 Action Plan：

- 精准挽留：**既然这批人已经关了自动续费，说明他们对价格敏感。趁着他们会员还没过期，赶紧推一个“连续包年”或者“承诺不取消送 7 天会员”的活动，把他们重新锁回“自动续费”的状态里。千万别让他们变成“手动挡”。
- 分层提价策略：**别一刀切。对于那批高活跃、高粘性的死忠粉，涨价 20% 没问题；对于那批本来就一个月只看一次的摇摆用户，涨价就是逼他们走。能不能给这批摇摆用户发个定向优惠券，变相维持原价？

知识点总结

做完这道题，有几个核心的数据分析与商业分析概念，咱们得心里有数：

- 价格弹性：**涨价肯定会导致销量跌，关键是跌多少。如果价格涨 20%，销量跌超过 20%，总收入就会跌。这是经济学基本原理。
- 惯性与摩擦力：**订阅制生意的核心壁垒就是“懒”。自动续费利用的是惯性，取消自动续费就是增加了交易摩擦力。永远不要低估“麻烦”对转化率的杀伤力。

3. **虚荣指标：** 这里的“首月收入”就是虚荣指标。它掩盖了用户流失的真相。
4. **先行指标：** “取消自动续费率”是先行指标，它预示了未来的流失。做分析师，看先行指标比看结果指标更值钱。

现在，我切换回面试官视角。

我对你刚才的分析逻辑总体满意，特别是你算出了那个 4% 的隐性流失，这点很敏锐。但是，业务负责人现在反驳你：

“你说的都有道理，但我们这次涨价是为了筛选出高价值用户。哪怕走了一半人，只要剩下的一半人愿意付更多的钱，我们的服务器成本还降低了呢，利润率反而更高。你只关注了收入（Top-line），有没有算过利润（Bottom-line）？”

作为分析师，你怎么回应这个关于“利润”和“成本”的挑战？

题目 30

【微博 / 小红书 | 社区生态 | 三面】

为了彻底激活评论区，你们调整了排序算法，把「争议大、互怼多」的评论权重调高，强行置顶。

数据直接爆炸：

单篇内容的「评论回复量」暴涨了 40%，社区看起来极其火热。

但同时伴随一个危险信号：

用户的「举报率」和「拉黑率」翻了 3 倍，评论区戾气极重。

业务负责人却认为：

「黑红也是红。愤怒是人类互动性最强的情绪，只要用户还在吵，DAU 就在涨。这时候搞『社区净化』就是自断财路。」

如果你是分析师，

你会接受这种「以情绪换流量」的增长模式吗？

你会认为这是社区活力的体现，还是在制造无法逆转的「社区癌变」？

解答

我们不能只谈道德，因为在商业公司，道德往往打不过 KPI。我们必须证明这种增长是「有毒的」，并且是「不赚钱的」。

下面我用一套完整的分析框架，带你拆解这个“虚假繁荣”的陷阱。

第一部分：先别急着下结论，建立“生态健康度模型”

面对这种争议巨大的策略，千万别上来就急着站队支持或反对。我们要先告诉面试官，我们在评估一个策略好坏时，手里拿的是什么尺子。

我会建立一个「社区生态三角模型」，把用户拆分成利益冲突的三类人来看：

- 内容消费者（沉默的大多数）：他们是贡献 DAU 的主力，也是最脆弱的群体。
- 内容生产者（核心资产）：他们的去留，决定了你明年还有没有内容库。
- 互动参与者（当前的获益者）：也就是这次算法调整卷进来的“杠精”和“吵架王”，他们可能只占用户的极小部分。

我的核心论点是：目前的策略是用「核心资产的折损」和「商业变现能力的降级」，去换取「短期互动数据的注水」。这不是活力，这是典型的透支。

接下来，我们用数据一层层剥开看。

第二部分：拆解那个诱人的“暴涨 40%”

老板看到了“评论回复量暴涨 40%”，觉得这是泼天的富贵。作为分析师，我们要做的第一件事就是——去伪存真，拆穿这个平均数的谎言。

这里有一个极具迷惑性的数据陷阱：**回复量的增长，绝对不等于参与人数的增长。**

我们可以做一个非常现实的场景推演：

假设以前一篇帖子下面，有 100 个人看。大家都很平和，只有 5 个人评论“真好”，总评论数是 5。现在排序变了，把一条“你这穿的什么垃圾”的恶评置顶了。结果这 100 人里，有 90 个人看到这就烦了，直接划走；剩下 10 个人里，有 2 个人是杠精，这俩人你一句我一句互骂了 50 个回合。

数据表现变成了：总评论数 = 50。老板一看：哇，评论量翻了 10 倍！社区太火了！

但真实情况是：参与人数从 5 人降到了 2 人。内容消费者的跳出率可能从 20% 飙升到了 90%。这 40% 的暴涨，完全是由那极少部分“高攻击性用户”贡献的，而大部分正常用户其实是被清洗掉了。这就是典型的「**幸存者偏差**」。

所以，我申请立刻查看以下两个“打假指标”：

- UV 渗透率的变化：发评论的独立用户数（UV）到底涨没涨？如果分子（评论量）涨了 40%，但分母（评论人数）没涨甚至跌了，那就是纯粹的“噪音在空转”。
- 沉默用户的负向反馈：那些不评论、只看帖的用户，他们的“单页停留时长”和“完播率”是不是暴跌了？如果大盘时长在掉，说明这 40% 的互动是以牺牲 90% 用户的体验为代价的。

第三部分：深挖“举报率翻 3 倍”背后的财务账

这一段我们要算账。老板认为“举报无所谓”，觉得只要有人吵就有流量。大错特错。

我们要给老板算一笔「**财务与安全账**」。

1. 审核成本的指数级爆炸

在互联网产品里，举报是一个门槛极高的动作。根据行业经验，每 1 个用户点了举报，背后可能对应着 10 个用户拉黑了作者，对应着 100 个用户默默关掉了 App。

举报率翻 3 倍，意味着后台审核团队的工作量至少翻 3 倍。如果现在的审核人力撑不住，漏放了违规内容（比如涉及底线的谩骂），平台面临的不仅仅是用户流失，而是监管部门的下架风险（App 下架一天，损失多少钱，老板心里有数）。

2. 品牌安全的崩塌（商业化死穴）

这点是绝大多数初级分析师想不到的。老板说“黑红也是红”，但广告主绝对不认同。没有哪个国际大牌（比如美妆、汽车品牌）愿意自己的广告出现在一条充满谩骂、戾气极重的评论区上方。

这叫「**品牌安全（Brand Safety）**」。一旦社区被打上“戾气重”的标签，高净值的品牌广告主会第一时间撤资，剩下的流量只能卖给那些廉价的劣质广告。所以，策略导致的结果是：DAU 哪怕涨了，但「**单位流量的广告价值（eCPM）**」会暴跌。为了那点互动量，把广告单价打骨折，这笔生意做得太亏。

第四部分：致命一击——供给侧的“格雷欣法则”

这一层是最能打动业务负责人的点：供给侧改革。

社区能活下去，靠的不是看客，是创作者。我们把那些“争议大、互怼多”的评论强行置顶，等于是把恶意直接甩在了创作者脸上。

试想一下，你精心拍了一组照片发出来，结果第一条置顶评论就是骂你丑，或者杠你穿搭土，下面还有几百条跟风骂的。你的心态会怎么样？你会想：“这破地儿烂透了，我不发了。”

这就触发了经济学里的「**格雷欣法则**」——**劣币驱逐良币**。温和、优质的创作者因为受不了戾气而退网，留下的全是靠引战、博眼球为生的“营销号”和“喷子”。

我们需要马上去看这组数据：

- 高争议内容作者的「复发率」：那些评论区沦陷了的作者，下周还发笔记吗？
- 优质创作者的「删帖率」：有多少作者因为受不了乌烟瘴气，选择把高赞笔记删了？

如果这两个指标在恶化，那就是在杀鸡取卵。因为获取一个优质创作者的成本（CAC），是获取一个普通用户的几十倍。流失一个创作者，平台可能损失数万的潜在浏览量。

第五部分：我的结论与挽救方案

回到你的问题。作为分析师，我**坚决反对**这种为了短期 DAU 牺牲长期生态的“情绪换流量”模式。这不是社区活力，这是「**社区癌变**」——细胞在恶性增殖（评论暴涨），但机体在衰竭（留存和变现能力下降）。

但是，直接怼老板说“你错了”是不行的。我们要给出一个折中且更高级的策略，既保住老板的面子，又保住社区的命。

我的建议方案：

1. **重新定义「争议」的算法逻辑：**我们要区分「观点碰撞」和「情绪宣泄」。利用 NLP（自然语言处理）技术，识别评论内容。如果是针对话题本身的激烈讨论（比如讨论剧情逻辑、数码参数），这是高质量争议，可以保留；如果是包含人身攻击、阴阳怪气关键词的，属于低质量互怼，必须降权，坚决不能置顶。
2. **引入「折叠机制」而非「置顶」：**对于争议极大、回复量很高但负向分也高的评论，我们可以给它流量入口，但默认设为“折叠状态”，显示“该评论争议较大，点击展开”。这样既满足了那部分想看热闹的用户的好奇心理（点击率还在），又保护了不想看戾气的大多数用户（体验没崩），同时也安抚了创作者。
3. **设定「熔断指标」进行观测：**现在的 40% 增长可能只是第一周的“猎奇效应”。建议把这个策略再跑一周，但必须设立熔断线：一旦「新用户次日留存率」下跌超过 5%，或者「核心创作者发文量」周环比下跌超过 2%，必须立即回滚策略。用数据下跌的事实，去倒逼策略的停止。

知识点总结

这一通分析下来，我们用到了几个非常硬核的数据与商业思维：

- **虚荣指标 (Vanity Metrics)：** 总量（回复量）涨不代表生态好，必须看人均（PV/UV）和渗透率。只要看到总量暴涨，第一反应必须是质疑其质量。
- **幸存者偏差与沉默成本：** 数据只能记录下还在说话的人，记录不了那些被气走的人。分析师必须具备通过“反面指标”（跳出率、拉黑率）去推演沉默用户行为的能力。
- **双边市场效应 (Two-sided Market)：** 分析平台型产品，供给侧（创作者）的权重永远高于消费侧。创作者的流失是不可逆的生态灾难。
- **品牌安全 (Brand Safety)：** 流量不等于钱。流量的质量才等于钱。高互动的负面流量，在商业化变现上可能是负资产。
- **LTV > CAC：** 任何增长策略，如果导致用户的生命周期价值（LTV）缩短（因为被气走了），且导致召回成本（CAC）变高（因为口碑坏了），那这个增长在财务上就是亏损的。

做数据分析师，最忌讳的就是看着仪表盘上的数字欢呼，却没闻到发动机里传出来的焦糊味。这道题考的就是你嗅出这股焦糊味的能力。

面试官视角（现在轮到我追问你了）

好，刚才这个关于社区生态的回答逻辑非常清晰，特别是在创作者保护那一块，很有业务 Sense。

那么，我想顺着你提到的「创作者流失」这点继续往下挖。

假设我们现在真的要把策略改回去，把评论区净化。但是，如果不靠这种激烈的互怼，社区的互动量（Likes, Comments, Shares）短期内势必会下跌。

我想问你：如果我要去向 CEO 汇报这个「回调策略」，告诉他我们需要接受短期的互动量下跌，来换取长期的健康。你能不能帮我设计一套「核心监测指标体系 (Dashboard)」？

你需要明确告诉我：在回调期的第1天、第7天、第30天，我们分别最该盯着哪个「唯一核心指标 (North Star Metric)」，来证明我们的净化策略是走在正确道路上的？

题目 31

【美团 / 携程 | 定价策略 | 三面】

为了极致挖掘利润，你们对「高消费力用户」试行了隐性溢价策略（同款商品比别人贵 3%）。

实验结果很暴力：

单均净利润直接提升了 20%，且没有任何投诉。

但最可怕的是一个“平”的数据：

这批被“杀熟”的用户的留存率，竟然完全没有波动，数据显示他们“毫无察觉”或者“根本不在乎”。

业务负责人当即拍板：

「数据证明了，这批人就是价格不敏感。只要他们不跑，这就不是『杀熟』，这是经济学里最完美的『一级价格歧视』，必须全量推。」

如果你是分析师，

面对这个“完美”的实验数据，你会支持推全吗？

你会认为这是商业效率的极致，还是在透支企业最底层的“信用根基”？

解答

这道题看似是在聊数据实验，其实是在考你对商业模式风险的嗅觉，以及你敢不敢在巨大的短期利益面前，做一个清醒的「吹哨人」。

第一部分：别被“平稳”的留存率骗了，它是带毒的安慰剂

拿到这道题，我的第一反应不是跟着业务负责人喊“万岁”，而是后背发凉。

我们先看这道题的题眼：隐性溢价、无投诉、留存平稳。业务负责人的逻辑链条非常简单粗暴：因为「留存没降」且「没投诉」，所以「用户不在乎」，结论是「全量推」。

这个逻辑看似闭环，其实在现实业务中脆弱不堪。作为分析师，如果这时候我点头同意全量推，那大概率半年后我就得背着「导致核心用户流失」的锅离职了。

首先，我们要质疑这个实验数据的有效性。业务负责人说留存率“完全没有波动”，这在数据分析里其实是个巨大的陷阱。

酒店预订是一个典型的高客单价、低频次场景。哪怕是所谓的「高消费力用户」，一年出行几次？商务客顶多 4-6 次，度假客可能就 1-2 次。如果你的实验只跑了 2 周或者 1 个月，用户可能根本就没有产生第二次购买的需求，你怎么可能观测到留存率的变化？

在这个场景下，留存率是一个极度滞后的指标。

今天的留存率平稳，不代表用户没感觉，只代表用户「还没来得及」发现或者「还没到」下一次预订的时间点。

更致命的是，这里存在一个严重的「幸存者偏差」和「观测盲区」。用户没有投诉，不代表满意。这批高消费力用户通常时间成本很高，如果他发现自己贵了 3%，他可能根本不会花 20 分钟去找客服撕扯这几十块钱。他的报复方式是沉默的、决绝的——直接卸载，转投竞对。

一旦用户在某次闲聊中，或者偶然看到了朋友的手机界面，发现同款房间自己贵了 3%，这种「被背刺」的愤怒是指数级的。那时候掉的就不是留存率了，是直接的用户流失率，而且这部分流失是不可逆的。

第二部分：算一笔账，用数字反推业务的脆弱性

接着我们来算算账，这步非常关键。题目里给了个很诱人的数字：单均净利润提升 20%。

很多时候，业务方会被这个“20%”冲昏头脑，但分析师必须保持冷静，我们需要反推这个业务的底色。

我们来做个简单的数学推演：

假设原来的客单价是 1000 元。

题目说同款商品比别人贵 3%，也就是涨了 30 元。

题目又说，因为这 30 元的涨价，导致单均净利润涨了 20%。

这说明什么？

说明这 30 元的纯利增量，相当于原本净利润的 20%。

我们可以算出原本的单均净利润 = $30 \text{ 元} / 0.2 = 150 \text{ 元}$ 。

进一步计算，原本的净利率 = $150 \text{ 元} / 1000 \text{ 元} = 15\%$ 。

这告诉了我们什么信息？

第一，这个业务本身的净利率并不高，只有 15% 左右，属于比较辛苦的行业，经营杠杆效应很明显。

第二，也是最重要的一点：为了多赚这 30 块钱（虽然比例上是 20%，但绝对值很小），我们把风险转嫁到了谁身上？

我们都知道，获取一个高净值用户的获客成本是极高的，在 OTA 行业，把一个新客培养成高消费力熟客，成本可能是几百甚至上千元。

为了这一单多赚的 30 块钱，去赌这个用户未来所有的生命周期价值归零，这是一笔极度不对称的赌博。

在金融学里这叫「收益封顶，风险无限」。

你的收益上限就是那 3% 的溢价，但你的风险下限是品牌信用的崩塌和高价值用户的清零。这就好比你在铁轨上捡硬币，捡到了确实能买瓶水，但火车一来你就没了。

第三部分：舆论爆炸与合规红线的“黑天鹅”

业务负责人说这是经济学里的「一级价格歧视」。这里有个巨大的概念偷换，甚至涉及到了法律红线。

经济学里的一级价格歧视（按人定价），通常是建立在「双方知情」或者「产品有所区分」的前提下的。比如飞机头等舱比经济舱贵，比如早买比晚买便宜。

但我们现在做的是什么呢？是同质商品、隐性溢价。

这在互联网语境下，有一个更通俗的名字——「大数据杀熟」。

必须结合当下的现实环境来看：

第一，合规风险。现在的监管环境对于算法推荐、差异化定价是有明确的法律约束的（比如《个人信息保护法》）。针对个人特征进行的不透明的差异化定价，极大概率会被认定为违规。这不仅仅是丢客户的问题，是面临巨额罚款和整改的法律风险。

第二，舆论风险。现在的用户对「杀熟」这两个字是过敏的。如果全量推，这就不是几千个实验用户的问题了，这是几百万用户。只要有一个大 V 或者较真的用户，拿着两个手机截个图发到社交媒体，标题写着《某平台实锤杀熟，老会员比新客贵 3%》，这就是一场公关灾难。

到时候公关用来灭火的钱，可能比你这一年多赚的那 20% 利润多十倍不止。企业的「信用根基」一旦被动摇，想要重建那是难于上青天。用户一旦给平台打上“不老实”的标签，再想洗白几乎不可能。

第四部分：不用“杀熟”，怎么赚到这 20%？

那老板肯定会问：“你说得都有道理，风险我也懂了，但那 20% 的利润我眼馋啊，难道就不赚了吗？”

当然要赚，分析师的价值不是只会 Say No，而是要给出 Solution。

既然这批是高消费力用户，且实验证明了他们对价格不敏感，那正确的策略不是偷偷涨价，而是服务溢价。

我们要把「隐性涨价」变成「显性升级」。

既然他愿意多付 3%，那我们就把价格真的涨上去 5%，甚至 10%。

但是，在这个价格包里，我们给他塞进去一些高感知价值、低边际成本的服务。

这就是核心解法：利用服务差异化来做合规的价格歧视。

具体可以怎么做？

1. **优先确认权益（低成本，高痛点）**：旺季订房经常需要等待确认，甚至会被退单。对于高消费商务客，确定性比价格更重要。我们通过系统算法优先保障这批用户的房源确认。这不需要额外的现金成本，只需要算法调配资源。

2. **退改签豁免权（概率成本）**：普通价格不可退改。高价包可以提供“入住前 24 小时免费取消”。根据历史数据，高净值用户的爽约率其实是可计算的，通过精算模型，我们可以发现这个权益的实际赔付成本远低于涨上来的差价。
3. **延迟退房与房型升级（库存利用）**：如果当天酒店入住率不是 100%，延迟到下午 2 点退房，或者升级到高一级的房型，对于酒店来说边际成本几乎为零（反正房间也是空着）。但这对于用户来说，体验感提升是巨大的。

我们把这 3% 的纯价格涨幅，包装成一个「优享版」或者「商务版」SKU。

默认给他推荐这个贵的 SKU，但他可以自己点开查看详情，发现是因为多了服务才贵。

这时候，如果他懒得比价，直接订了，我们赚到了高利润。

如果他发现了，他会觉得“哦，这是个高级套餐”，而不是“平台在坑我”。

这才是真正的商业效率极致——用产品和服务的差异化，来筛选用户的支付意愿，而不是靠信息不对称来割韭菜。

总结与建议

所以，回答你的问题：

面对这个“完美”的数据，我坚决反对全量推行现有的隐性溢价策略。

我的建议是：

- **立刻叫停**：目前的「同品不同价」测试存在极高的合规和舆论风险，立即停止。
- **转化洞察**：利用“该人群价格不敏感”这一宝贵结论，转向开发「服务型溢价产品」。
- **重新测试**：设计「优享服务包」，进行新的 A/B 测试。观测指标不能只看转化率和利润，还要加入「负向反馈率」（如查看价格详情后退出、截屏行为等隐性不满指标）。
- **长期主义**：赚这 20% 的利润，要赚得光明正大，赚得可持续，赚得让用户觉得物有所值，而不是让用户觉得自己是个傻子。

数据是不会撒谎的，但解读数据的人会犯错，设计实验的人会短视。别让短期的贪婪，蒙住了看长期的眼睛。

知识点归纳

咱们复盘一下刚才分析里用到的硬核知识点，这些都是面试里的加分项：

- **滞后指标 (Lagging Indicator)**：像留存率、NPS 这种指标，反应非常慢。在低频业务中，用短周期的滞后指标来判断用户满意度，是巨大的分析误区。
- **生命周期价值 (LTV) 与获客成本 (CAC)**：做任何价格策略调整，都要算这笔账。高净值用户的 CAC 极高，为了微薄的单次利润牺牲掉整个 LTV，属于典型的捡芝麻丢西瓜。
- **不对称风险 (Asymmetric Risk)**：收益有限，风险无限。商业分析中必须识别这种结构，并极力避免。
- **经营杠杆 (Operating Leverage)**：我们反推了利润率，发现 3% 的涨价能带来 20% 的利润增长，说明原利润率较低。这展示了经营杠杆的作用：微小的营收变化带来巨大的利润波动。
- **幸存者偏差 (Survivorship Bias)**：没有收到投诉不代表没有问题，可能只是因为不满意的用户直接离开了，留下的数据本身就是被筛选过的。

面试官视角：

分析得很到位，尤其是把隐性溢价转化为显性服务这个思路，既解决了合规问题又保留了利润空间。

那么，我想追问一个执行层面的问题：

如果我们按照你的建议推出了「优享服务包」，这就涉及到了一个「默认勾选」或者「推荐排序」的问题。在做 A/B Test 的时候，除了转化率（CR）和平均客单价（AOV），你会如何量化「用户对于高价推荐的反感度」？因为用户可能不会投诉，但会有微小的行为异常，请列举 3 个具体的数据埋点指标来监测这种负面情绪。

题目 32

某品牌花重金请头部主播带货，当晚直播间战报显示 GMV 破亿，场观互动极高。但 15 天后复盘发现，实际结算金额不足战报的 40%。老板怀疑主播存在“刷单”或“假流量”行为。作为商业分析师，你会通过哪些数据维度去验证是否存在作弊嫌疑？

解答

这个问题的核心逻辑其实就三层：第一层叫**资金漏斗还原**，我们要搞清楚钱是在哪个环节丢的；第二层叫**异常特征归因**，搞清楚丢的这些钱，是正常损耗还是有人搞鬼；第三层叫**流量与互动验证**，看看那个所谓的“高场观”是不是全是机器人。

下面我带你把这事儿彻底拆明白。

第一部分：先把“虚胖”的 GMV 还原成真实的资金流（数值推导）

很多人看电商数据容易被 GMV 唬住，其实 GMV 这个指标特别“水”，只要下了单就算，哪怕没付款都算。所以，咱们第一步得做个简单的算术题，看看这 40% 的结算率到底有多离谱。

假设当晚战报 GMV 是 1 个亿。

通常在头部主播的直播间，为了制造抢购气氛，冲动下单未支付的比例大概在 30% 左右。也就是说，1 亿 GMV 里，正常应该有 7000 万是实际支付的（现金 GMV）。

现在你告诉我，15 天后实际结算金额不足 40%，也就是不到 4000 万。

我们要算一笔账：从“实际支付 7000 万”到“结算 4000 万”，中间蒸发了 3000 万。这意味着，**支付后的退款率**接近 43%（3000 万 / 7000 万）。

在美妆或标品行业，这个退货率是极不正常的（平时可能只有 10%-20%）；如果是服装行业，虽然退货率普遍高，但考虑到这是“头部主播”加“重金”的场次，如果品质没大雷，这个数据依然偏高。

所以，钱主要是在“下单未支付”和“支付后退款”这两个环节漏掉的。我们要把这 1 亿扔进漏斗里具体看：

如果是**下单未支付比例**异常高（比如达到 60%）：那这就是典型的“锁库存”。刷单团队或者竞争对手，疯狂拍下你的库存占着位置，让真实想买的用户买不到，最后时间一到订单自动关闭。但这会被算进直播间的 GMV 战报里。

如果是**支付后秒退款比例**极高：这招更隐蔽。刷单的人付了款，截图发给主播方拿佣金或者完成任务，然后转头立刻申请退款。这种“秒退”数据，是鉴别假单最直接的证据。

如果是**发货后拒收率**飙升：货到了，用户直接拒收。如果平时拒收率是 1%，这场直播飙到了 20%，那绝对有问题。

第二部分：像侦探一样去抓“假人”的特征

如果漏斗分析发现确实存在大量异常的退款，老板肯定会问：“凭什么说是主播刷单？万一是我们产品不行呢？”

这时候，你就得拿出第二把武器：**异常行为特征分析**。如果真的是刷单，数据一定会留下痕迹，哪怕他做得再真，也藏不住这几个维度：

时间维度的异常

正常的直播下单，应该是随着主播的讲解节奏波动的。主播喊“321 上链接”，销量应该激增。

如果成交数据在直播间非高潮时段（比如主播去上厕所或者在尬聊的时候）突然出现整齐划一的波峰，或者订单生成的间隔时间非常均匀（比如每秒正好 2 单），那这绝不是真人干的，是机器脚本。

地理维度的异常

这一点特别准。把所有退款订单的收货地址拉出来做个热力图。

如果发现大量的订单集中在某个不知名的偏远县城，甚至集中在某几个特定的小区、街道，或者大量的收货地址写得清清楚楚（比如几百个订单都只写了“xx 市 xx 路快递柜”），那这就叫“收货地址聚集”，是职业刷单团伙的典型特征。

用户维度的异常

看看那些退款的账号长什么样。如果是新注册的号、没有头像、昵称是乱码、历史购买记录为零，或者是那种“沉默账号”（平时不活跃，一到直播就疯狂下单），这些账号占比一旦过高，基本就能定性了。

还有一个狠招，看**设备指纹**。如果几千个订单是来自同一个 IP 地址，或者同一个设备 ID，那连辩解的机会都不用给他们留了。

凑单与客单价异常

刷单往往是为了凑金额。如果发现大量订单的金额出奇地一致，或者都是刚好卡在优惠券门槛的最低线上，而且购买的商品组合完全不符合逻辑（比如一个男号一次性买了 10 支不同色号的口红），这都是疑点。

第三部分：流量侧的猫腻，那是源头

题目里提到了“场观互动极高”，这本身就是一个巨大的疑点。我们要去验证流量的真实性，因为很多时候刷单是为了配合刷流量，做出一副“我很火”的假象来骗品牌方的坑位费。

我们要看**互动与转化的匹配度**。

假设场观 1000 万，弹幕只有几百条，或者弹幕内容全是重复的“666”、“想要”、“已拍”，没有任何关于产品的具体提问（比如“编码吗？”“孕妇能用吗？”），这大概率是机刷弹幕。

我们要看**流量留存时长**。

如果大量用户进直播间只停留了 1 秒就走了，或者所有用户的停留时长都惊人的一致（比如都是 30 秒整），这就是机器人的特征。真实的流量是符合正态分布的，有长有短。

第四部分：业务动机分析，为什么是现在？

作为分析师，我们不能只看数据，还要看**利益链条**。

为什么主播要冒着风险刷单？通常是因为品牌方和主播签了**对赌协议**（VAM）。

比如，品牌方要求 GMV 必须达到 1 亿，否则不仅不给坑位费，主播还要赔钱。当直播进行到一半，主播发现自然流量根本卖不到 1 亿时，为了保住几百万的坑位费，他们就会动用刷单团队自己买货。

只要刷单的成本（比如佣金、快递费的损失）小于他们能拿到的坑位费，他们就有动力去造假。

所以，我们需要去查阅这次合作的合同条款，看看是否存在这种高压的对赌条款，这能从动机上佐证我们的分析。

第五部分：总结一下我是怎么得出结论的

所以，回到老板的质疑。

我会先通过**资金漏斗**量化每一个流失环节的金额，计算出具体的“支付后退款率”是否远超行业均值。

然后，利用**用户画像**、**地理位置**、**下单时间**这三个维度进行交叉验证，找出是否有机器刷单或团伙作弊的特征。

接着，检查**流量互动质量**，看看是不是“虚假繁荣”。

最后，结合**合同条款**，看是否存在对赌压力导致的作弊动机。

如果数据显示：退款主要集中在发货前、下单时间呈现机械化规律、收货地址高度聚集，且互动内容极其单一，那么老板，咱们可以准备法务函了，这就是刷单。

解答中用到的知识点总结

漏斗分析模型：将 GMV 拆解为下单、支付、发货、签收等环节，定位流失点。

异常检测：利用统计学方法识别数据中的离群点（如时间波峰、地址聚集）。

同期群分析：拿本次数据与历史数据、竞品数据做对比，排除干扰因素。

用户画像分析：通过账号注册时长、活跃度、设备指纹来判断用户真实性。

对赌协议与利益分析：结合商业合同条款，从利益驱动角度分析异常数据背后的动机。

面试官视角（追问环节）：

“逻辑很清晰，特别是你也考虑到了对赌协议这个商业背景，这点很好。那我想接着问你一个更实际的问题：假设我们已经实锤了主播刷单，老板让你设计一套**复盘赔偿计算公式**，去跟主播团队谈判索赔。除了退回没卖出去的货款，你认为我们还应该向主播索赔哪些方面的损失？这些损失怎么用数据量化？比如，我们的品牌形象损失怎么算？”

题目 33

某资讯平台为了冲刺 KPI，调整了推荐算法，增加了“标题党”和“擦边/土味”内容的权重。结果显示：人均使用时长（TS）大涨 20%，点击率（CTR）显著提升。老板非常高兴准备全量上线。

作为商业分析师，你隐约觉得这是“饮鸩止渴”。请问你会选取哪些关键指标来证明这个策略长期是有害的？如何用数据说服老板叫停？

解答

第一部分：先别急着反驳，要看懂为什么数据会涨

老板之所以高兴，是因为他看到的 KPI 是实打实的增长。作为分析师，如果上来就说“这不行”，那叫由于感性反对；我们要先从逻辑上拆解，为什么这两个指标会涨，以及它们掩盖了什么。

点击率 CTR 涨，是因为标题和封面利用了人性的弱点——猎奇、软色情、贪婪。用户还没来得及思考，手指就已经点下去了。这叫「生理性点击」。

使用时长 TS 涨 20%，这个涨幅非常惊人。原因通常有两个：一是这类内容确实有“爽感”，容易让人在这个时间黑洞里停不下来；二是“标题党”往往开头很吸引人，用户为了找答案被迫看完了视频，或者在文章里翻来翻去。

这时候我们必须意识到一个核心逻辑漏洞：

CTR 和 TS 在这种场景下，变成了「生理指标」而非「满意度指标」。

用户点进去（CTR高）不代表他想看，可能是被骗进去的；用户看了很久（TS高）不代表他爽了，可能是他在找答案没找到，或者边看边骂。

这就引出了我们必须要去验证的「反向指标」。

第二部分：拆穿繁荣的假象，你需要这两组数据

既然正向指标已经失灵，我们要引入「负向体验指标」和「商业价值指标」来证明这是虚假繁荣。

1. 短跳出率与显性负反馈

这是最直接的打脸数据。

短跳出率：指用户点进去后，在 3 秒或 5 秒内迅速退出的比例。如果 CTR 涨了，但短跳出率飙升，说明这是“诈骗式点击”。货不对板，用户进来了但立刻走了，这根本不是有效流量。

显性负反馈率：用户点击“不感兴趣”、“内容质量差”、“举报”甚至“拉黑作者”的比例。这个数据平时可能很低，比如万分之一。但如果因为算法调整，这个指标翻倍了，哪怕绝对值还是很小，也是巨大的警报。这意味着用户已经被冒犯到需要动手去“惩罚”平台了。

2. 完播率的结构性崩塌

我们要把内容分层来看。是不是只有那些擦边内容的完播率高，而原本的高质量硬核内容的流量被挤压？

如果是这样，平台就在经历“劣币驱逐良币”。优质创作者发现认真写干货没人看，随便搞个震惊体标题流量就爆了，他们要么离开，要么同流合污。这会直接导致内容供给端的崩塌。

第三部分：用钱说话，把“时长增长”折算成“公司亏损”

这是老板最在意的部分，也是分析师必须具备的推导能力。我们不能只说“生态不好”，要说“这会让公司亏钱”。

我们来做个带数字的推演（假设数据）：

现状：老板看到了 TS 涨了 20%，假设这意味着广告库存（Ad Load）也增加了 20%，理论上广告收入应该涨 20%。

隐患：商业化单价（eCPM）的暴跌。

为什么？因为品牌广告主（比如汽车、美妆大牌）是非常在意「品牌安全」的。他们绝对不允许自己的广告出现在擦边、土味或者低俗内容的旁边。

一旦平台充斥着这类内容，高价值的品牌广告主会撤资，剩下的只有转化的廉价广告（比如劣质游戏、借贷广告）。

我们来算一笔账：

假设改版前，人均看 10 个广告，每个广告价值 1 元。单用户贡献 10 元。

改版后，TS 涨了，人均看了 12 个广告（库存涨了20%）。但因为环境变差，品牌主跑了，广告单价掉到了 0.7 元。

结果是：12 个广告 * 0.7 元 = 8.4 元。

看到了吗？虽然时长和库存都涨了 20%，但因为内容环境变差导致单价下跌，最终单用户的变现价值反而跌了 16%。

这个逻辑一摆出来，老板立刻就能冷静下来。时长不是钱，时长卖出去的价格才是钱。

第四部分：致命一击，关于留存与 LTV 的终极账本

除了当天的收入，更可怕的是未来的损失。这里我们要看留存率。

这种低质内容消耗的是用户的“信任感”。用户刷完后会有“贤者时间”，觉得在这个平台浪费了生命，产生厌恶感。

我们极有可能观察到：TS 涨了 20%，但次日留存掉了 1%。

别小看这 1%。对于大体量平台，留存率微小的波动会造成 LTV（生命周期价值）的剧烈变化。

公式逻辑如下：

$$LTV \approx ARPU * (1 / (1 - \text{留存率}))$$

假设原本留存率是 50%，用户的生命周期因子是 $1/(1-0.5) = 2$ 。

如果留存率掉到了 49%，生命周期因子变成 $1/(1-0.49) \approx 1.96$ 。

这还没完。通常这类策略会导致「高价值用户」先跑（因为他们难以忍受低俗内容），留下的都是「低价值用户」。所以 ARPU（每用户平均收入）也会同步下跌。

留存率下跌 + ARPU 下跌 = LTV 的双杀。

最后算下来的结果就是：我们要花 50 块钱买一个用户，但他产生的价值从 60 块跌到了 45 块。**我们在做一个“买得越多，亏得越多”的生意。**

第五部分：无法忽视的现实风险

除了数据，作为商业分析师，必须具备业务 Sense。在当下的互联网环境中，还有一个比数据更可怕的因素：**合规风险**。

你可以直接提醒老板：

“老板，TS 涨了是好事，但我们增加了‘擦边’内容的权重。现在的监管环境您也知道，如果因为低俗内容被监管点名，或者被应用商店下架整改 3 天，我们损失的不仅仅是几天的日活，而是整个品牌的安全水位。”

一旦被下架，所有的 A/B 测试、所有的算法优化、所有的 KPI 瞬间归零。这个风险成本是无穷大。

第六部分：解决方案与话术建议

分析完了，不能只当乌鸦嘴，要给方案。

建议方案：小流量隔离实验（Holdout Test）。

不要全量上线。建议保留 5% - 10% 的用户作为“纯净对照组”，保持原有的推荐逻辑。

拉长观测周期，至少看 14 天到 30 天。

重点对比这两组用户的 LTV（生命周期总价值）和留存率。如果实验组虽然时长高，但留存一路下跌，这就证明了该策略不可持续。

给老板的汇报话术：

“老板，这波 TS 涨了 20%，说明改版确实抓住了人性弱点，短期效果很猛。但我发现几个数不太对劲，想跟您同步一下风险。

首先，虽然大家看得久了，但‘骂人’的也变多了，显性负反馈涨了不少，而且 3 秒跳出率也在飙升，说明很多点击是被骗进去的。

其次，也是最关键的，我测算了一下广告价值。虽然流量涨了，但因为内容调性变低，高价的品牌广告可能会跑，导致我们最终赚的钱反而变少。

再加上监管风险，我建议咱们别急着全量。先维持现在的灰度，我再盯两周。如果两周后留存能稳住，咱们再推；如果留存继续掉，或者 LTV 算不过账，这策略咱得微调一下。”

总结一下知识点

解答这个案例，核心在于建立「短期 vs 长期」和「数量 vs 质量」的二元对立分析框架：

虚荣指标识别： TS 和 CTR 在特定场景下会骗人，必须结合短跳出率来看。

商业价值推导： 流量不等于钱。流量 * 单价 = 钱。低质内容会拉低单价（eCPM），从而降低总收益。这是很多初级分析师容易忽略的点。

LTV 模型思维： 留存率的微小变动会通过生命周期公式被放大，最终影响整个盘子的盈亏平衡。

生态位思考： 劣币驱逐良币。供给端的恶化比需求端的流失更难挽回。

合规意识： 在中国做业务，安全红线永远是第一优先级的否定项。

下面我切换回面试官视角，针对你的回答，我有个地方想深挖一下：

如果老板坚持说：“现在的竞争环境太激烈了，竞品都在搞下沉、搞擦边，我们不搞用户就被抢走了。留存掉一点可以接受，只要 TS 涨得多，用户粘性够强就行。”

面对这种“竞品压力”下的战略防御理由，你作为分析师，还能通过什么样的数据维度或者分析方法，来评估“跟进竞品搞擦边”到底是不是一个正确的防御策略？

题目 34

为了对标竞品，某电商平台全量上线了“仅退款”功能（无需退货即可退款）。上线一个月后，买家下单转化率提升了 3%，用户复购率也有所回升。

但同时，商家端客服咨询量激增，部分腰部商家开始因“亏损严重”而停止投放广告甚至撤店。老板坚持“用户第一”不动摇。作为商业分析师，你如何建立一套评估模型，来判断这个策略在当前阶段到底是“利大于弊”还是“饮鸩止渴”？

解答

回答这种宏观策略评估题，咱们的思维框架得稳，得像个操盘手。

我的分析思路是：先拆解利益冲突，再用数字做极限推演，最后建立监控模型。

这不仅仅是一个“退款”问题，本质上是“流量变现效率”与“供应链稳定性”之间的博弈。

第一部分：把“糊涂账”拆成“明白账”

首先，咱们得明确考察意图。面试官问这个，不是考你 SQL 写得快不快，而是考你有没有全局观。

题目里有两个特别显眼的信号：

1. 用户端：转化率 +3%，复购回升。（好事，符合“用户第一”）
2. 商家端：腰部商家停投广告、撤店。（坏事，动摇了平台的摇钱树）

这事儿最吊诡的地方在于，短期看 GMV 可能是在涨的，但长期看，平台可能会因为商家流失而“失血过多”。

所以，建立评估模型的第一步，是把“平台净收益”这个大公式列出来。

现在的平台收益模式通常是： $\text{平台总收益} = (\text{GMV} * \text{佣金率}) + \text{广告收入} - \text{运营成本}$ （客服/赔付/算力）

“仅退款”策略直接冲击了这公式里的每一个变量：GMV：涨了（正向）。广告收入：跌了（腰部商家不投了，负向）。运营成本：激增（客服咨询量爆了，负向）。

所以，我们的评估核心就是：GMV 增长带来的红利，到底能不能覆盖掉“广告损失”加上“运营成本暴涨”的大坑？

如果算下来是负的，那这就是饮鸩止渴。

第二部分：带入数字，做一次“生死推演”

光说逻辑不够，我们必须对题目中的“转化率提升 3%”进行压力测试。这 3% 的增量，真的能抵消“仅退款”带来的亏损吗？

我们假设一个典型的“腰部商家”模型：客单价：100 元。商品成本（COGS）：60 元。物流与包装费：5 元。广告与运营费：15 元。单均净利润：20 元（利润率 20%）。

场景一：策略上线前 假设卖出 1000 单。总利润 = $1000 * 20 = 20,000$ 元。（注：此处暂忽略普通退货，只看净成交）

场景二：策略上线后，转化率提升 3% 订单量变成了 1030 单。原本的理论利润 = $1030 * 20 = 20,600$ 元。看起来多赚了 600 元，对吧？

但是，“仅退款”来了。注意，“仅退款”对商家的杀伤力是核弹级的。普通退货，商家损失的是运费；仅退款，商家损失的是“货 + 运费 + 广告费”。每发生一单仅退款，商家的直接损失 = 商品成本 60 + 物流 5 + 广告 15 = 80 元（这还没算那 100 元原本该进账的流水）。

那么，这多赚的 600 元，能扛得住几单仅退款？ $600 / 80 = 7.5$ 单。

结论非常惊悚：在 1030 个订单里，只要有 8 个人恶意使用了“仅退款”（占比不到 0.8%），这个商家因为转化率提升带来的所有额外利润，就全部赔光了。

如果仅退款率达到了 2%（约 20 单），商家将直接亏损： $20 \text{ 单} * 80 \text{ 元损失} = 1600 \text{ 元亏损}$ 。相比之前的 20,000 元利润，虽然整体还赚钱，但利润直接缩水，且风险敞口巨大。

这就是为什么腰部商家要停止投放广告。因为他们算得过账来：广告投得越多，引来的“羊毛党”可能越多，一旦仅退款比例失控，就是卖一单亏一单。

第三部分：拆解“用户第一”的陷阱与商家分层

老板说“用户第一”，这没毛病。但作为分析师，我们要指出：如果商家死光了，用户也没东西买了，这就不是用户第一了。

这里有个非常隐蔽的逻辑陷阱：复购率回升，是因为“优质服务”带来的真心复购，还是因为“羊毛党”发现这里可以免费拿货，所以疯狂下单？

如果是后者，这种 GMV 是“带毒”的。

而且，腰部商家的流失是最致命的。头部商家（品牌大店）：利润厚，溢价高，通常有专门的预算处理坏账，他们扛得住。尾部商家（低端白牌）：本来就是卖垃圾货，甚至可能就是骗一波就走，仅退款对他们反而是一种筛选。腰部商家：他们是平台的中坚力量，讲究性价比，利润薄。一旦“钱货两空”的比例上升，他们的现金流最先断裂。

一旦腰部商家撤店，平台会出现“劣币驱逐良币”：好商家走了，剩下的要么是极其昂贵的大牌，要么是把“仅退款损耗”加价到商品里的高价低质商家。最终，用户买到的东西变贵了，用户体验反而下降。

第四部分：建立分层评估模型（Actionable Framework）

好，前面的逻辑捋顺了，现在直接给老板一套能落地的评估方案。

我不建议用一个单一的分数来定生死，建议用“红绿灯仪表盘”机制。

- 收益层（看正向，验证增长质量）核心指标：良性 GMV 增量（定义为：剔除发生仅退款及高风险用户订单后的 GMV）。辅助指标：高信用用户复购率提升幅度。我们要做一个归因：这 3% 的转化率提升，到底是谁贡献的？如果是低信用分用户贡献的，那这分文不值。
- 成本层（看负向，监控生态健康）核心指标：广告收入流失额（重点监控腰部商家）。核心指标：商家履约盈亏平衡点（Breakeven Point）。我们要算出不同类目的商家，仅退款率达到多少时会亏损，一旦大盘数据逼近这个线，必须熔断。核心指标：客服介入成本增量（人力成本也是钱）。
- 风险层（一票否决指标）熔断指标：腰部优质商家流失率（Churn Rate）。熔断指标：“仅退款”订单的申

诉率。如果商家大规模申诉，说明判罚机制有大问题，平台公正性在崩塌。

第五部分：最终的决策建议 (Trade-off)

作为分析师，不管是利大于弊还是弊大于利，最后都要给解决方案。

我的建议是：策略不能“一刀切”，必须从“全量上线”转为“精细化分层运营”。

建议一：对用户分层 能不能只对信用分 700+ 的用户，或者年消费额达到一定门槛的忠诚用户开放“仅退款”？对新用户或低信用用户，依然走退货退款流程。

建议二：对商品分层 生鲜、易损品等难以二次销售的品类，支持仅退款。高客单价、3C 数码、奢侈品，严禁系统自动仅退款，必须人工介入。

建议三：给商家一个开关 允许商家在“缴纳保证金”或“购买退货险”的前提下，选择是否加入“仅退款”计划，或者给商家申诉的绿色通道。

知识点总结

最后，咱们复盘一下这道题用到的硬核知识点：

双边市场理论：电商平台必须同时讨好买家（需求端）和卖家（供给端）。任何一方失衡，平台都会崩。单位经济模型（UE）：你得会算账。这道题里，我们算的不是 LTV/CAC，而是“单均边际贡献”。我们要看多出来的订单能不能覆盖掉“全额损失”的风险成本。幸存者偏差：看数据不能只看留下的用户复购高了，还要看那些“沉默离开”的商家带走了多少潜在价值。分层分析法：别看平均数！平均数会骗人。要把商家分层（头/腰/尾），把用户分层（高信/低信），分开看才能看到真相。

（面试官视角追问）

这一部分非常关键。你刚才提到了“良性 GMV”和“带毒的 GMV”。现在假设我们真的想把“羊毛党”识别出来。

但是，羊毛党和“对价格敏感的真实低收入用户”在行为数据上往往很像（比如都喜欢买便宜货、都喜欢领券、退款率都略高）。

你会选取哪些**特征维度 (Features)** 来构建一个分类模型，尽可能精准地把“恶意仅退款的羊毛党”和“正常维权的普通用户”区分开？请至少列举 3 个维度的具体特征。

题目 35

为了响应“降本增效”，某平台将 50% 的人工客服替换成了 AI 智能客服。上线后数据显示：平均响应时长（ART）缩短了 60%，客服人力成本下降了 40%。老板很满意。

但运营团队反馈近期用户怨气很大，复购率微跌。老板认为这是运营活动没做好，与 AI 无关。

作为商业分析师，你如何设计一套分析逻辑，来证明（或证伪）“AI 客服虽然省了钱，但其实通过逼走用户亏了更多钱”？

解答

这道题太经典了。现在所有公司都在搞“降本增效”，老板看到的是财务报表上的人力成本下降，运营看到的是用户在群里骂街。作为分析师，你的价值不是去“吵架”，而是用一套逻辑严密的账模型，把“体验”这种虚无缥缈的东西，折算成老板看得懂的“钱”。

第一部分：先拆穿“虚荣指标”的假象

老板很满意“平均响应时长（ART）缩短了 60%”，这是一个巨大的陷阱。在数据分析里，我们管这个叫“虚荣指标”。

你想想，用户问一句“我的货发哪儿了”，AI 秒回一句“亲，我不明白您的意思，请重新输入”，响应时间是 0.1 秒，数据好看得不得了。但问题解决了吗？没有。用户的血压反而升高了。

所以，开局第一步，你要告诉面试官，现在的指标体系有漏洞，必须引入两个真实的“体验质量指标”来对齐现状：

一个是“一次性解决率（FCR）”。用户进线一次能不能把事儿办完？如果上了 AI 之后，FCR 下降了，说明用户得反复找客服，或者被 AI 踢皮球。

另一个是“无效交互轮数”。如果 AI 上线后，用户平均要跟 AI 扯皮 8 轮以上才能解决问题，或者 80% 的人都最后愤怒地输入“转人工”，那个所谓的“响应快”就是无效的。这不叫效率提升，这叫“虽然回复快，但全是废话”。

第二部分：最难的一步，怎么证明是 AI 的锅，而不是运营不行？

老板现在认为是运营活动没做好才导致复购下跌。要反驳这个观点，不能靠嘴，得靠“控制变量法”。

虽然 AI 可能已经全量上线，但我们可以把用户切分成三个具体的行为组，去做同期群分析（Cohort Analysis）。这里要注意，不仅要看转人工的，还要看“被劝退”的：

第一组：AI 顺畅解决组。问题很简单（查物流、查积分），AI 直接搞定，用户没有后续纠缠。

第二组：AI 纠缠转人工组。被 AI 折磨了 5 轮以上，最后强制转了人工，带着一肚子火气。

第三组：AI 劝退组（最隐蔽的风险）。这是上一版分析容易忽略的死角。有一部分用户，跟 AI 说了两句发现解决不了，既没有转人工（可能入口太深找不到），也没有骂人，而是直接关掉了对话窗口。在系统里，这会被记录为“会话结束”，甚至可能被误判为“服务完成”。

接下来，我们看这三组人在咨询后 T+30 天的复购率变化。

如果运营活动真的没做好，那理论上这三组人的复购率应该一起跌，因为大盘环境和优惠力度是一样的。

但如果数据跑出来是这样的：第一组复购率稳定；第二组复购率暴跌；第三组（劝退组）直接流失不再打开 APP。

这时候你就可以拿着图表跟老板讲：“老板你看，没受 AI 干扰的用户（第一组），复购率是很稳的，说明运营活动没大毛病。掉得最惨的就是这波被 AI 拦住又解决不了问题的用户。这明显是服务体验导致的流失。”

这一步非常关键，它直接把因果关系锁死在“AI 服务质量”上，排除了“运营活动不行”这个干扰项。

第三部分：算总账，把“怨气”折算成“亏损”

老板是生意人，你光说“体验差”没用，你得告诉他“亏了多少钱”。我们要算一笔总账，看看到底是省得多，还是亏得多。

这个公式不仅仅是人力成本对比，准确的逻辑应该是：

净收益 = （节省的人力成本 - AI 技术及维护成本） - （因体验下降流失的 GMV + 品牌修复成本）

很多人会忽略“AI 也是有成本的”，API 调用费、训练费都是钱，这里我们先假设这部分小于人力成本。重点在于后半部分的推算。

我们来做个具体的带数推演，这一步面试时必须做，能体现你的商业敏感度：

假设节省了 40% 人力成本，一年省了 500 万。

但是，根据我们刚才的分组分析，发现经过 AI 咨询后的用户，月流失率比纯人工时期上升了 2 个百分点。

别小看这 2 个百分点。假设每天进线咨询的用户是 1 万人，一个月就是 30 万人。2% 的额外流失就是 6000 个用户。

如果这是一家电商平台，一个活跃用户的年度 LTV（生命周期价值）假设是 1000 元。

那一个月的隐性损失就是：6000 人 * 1000 元 = 600 万。

你看，一个月就在用户价值上亏掉 600 万，而一年才省 500 万人力成本。这还没算那些被气走后去社交媒体吐槽带来的品牌负面影响。这笔买卖明显做亏了。

而且这里还有一个更隐蔽的业务逻辑：高价值用户（Whales）通常问题更复杂，更需要人工。

如果数据进一步显示，流失的那 2% 里，大部分是高客单价的 VIP 用户（因为他们的问题 AI 根本听不懂），那损失的就不是平均 LTV，而是核心资产。这时候老板才会真正感到肉疼。

第四部分：给老板的建议

分析做完了，咱们不能只给坏消息，还得给方案。作为商业分析师，你得给出优化建议：

建议一：分层服务策略，别搞一刀切。通过模型识别用户等级，VIP 用户或者历史高频投诉用户，直接切人工通道，别用 AI 挡。这部分人时间值钱，经不起折腾。

建议二：设置“情绪止损阈值”。优化 AI 的转人工逻辑。如果 AI 识别到用户连续发了两次“不知道”、“人工”或者情绪激动的词，立刻、马上无缝切人工，别让用户再试了。

建议三：重新定义 AI 的 KPI。废除单一的“响应时长”考核，把“问题解决率”和“咨询后 T+7 复购率”加入 AI 团队的考核指标。如果 AI 省了钱但把客户逼走了，这个 AI 就是不合格的。

总结一下知识点

这道题其实串联了几个核心分析技能，大家可以记一下：

第一个是指标体系的防骗能力。懂得区分虚荣指标（响应时长）和北极星指标（解决率、复购率），知道单看效率指标是会骗人的。

第二个是归因分析中的控制变量思维。通过细分人群（Cohort），把“顺畅组”、“纠缠组”和“劝退组”分开看，利用不同组别的表现差异，来排除外部因素（运营活动），锁定真正的原因。

第三个是 LTV 模型的实战应用。把业务动作（客服变动）的后果，转化为财务后果。这是能否说服老板的关键。

第四个是对于“静默流失”的业务洞察。真正的分析师能看到数据里“不存在”的那部分——那些没说话就默默离开的用户，往往才是最大的损失。

面试官视角追问：

分析逻辑很清晰。那你觉得，如果我们现在的系统里，并没有现成的「用户情绪标签」数据，也就是说我们没法直接知道用户有没有骂人，也没法直接统计满意度（很多用户不填问卷就走了）。在数据缺失的情况下，你还有什么办法能侧面衡量 AI 服务对用户体验的真实折损？

题目 36

聊聊选择偏差和幸存者偏差:为什么一个看起来很牛的AB实验结果，到了生产环境就翻车了？

解答

前一天实验报表上全是绿箭头，显著性检验 p 值小于 0.05，信心满满推全上线，结果第二天大盘数据直接掉头向下，老板找你喝茶。

咱们今天别扯那些教科书上的定义，我就带你把这件事从头到尾捋一遍，看看为什么这两个偏差能把一个好好的 AB 实验搞翻车。

一、 核心逻辑：为什么实验结果不可信？

咱们先搭个框架。

AB 实验能成功的核心假设是什么？是**代表性**。

也就是说，我们默认进实验组的那 1% 或者 5% 的用户，他们的行为特征、属性分布，能完美代表剩下那 95% 的大盘用户。如果这个假设成立，那实验结果就能推而广之。

所谓的“翻车”，说白了就是**样本代表性出了问题**。

你要分析这个问题，脑子里得有这么张图：

第一步（进门前）：你是怎么挑人的？这里容易出**选择偏差**。

第二步（进门后）：人进来以后，是不是有人“死”在半路没被统计到？这里容易出**幸存者偏差**。

下面咱们一个个拆，配合业务场景你就懂了。

二、第一坑：进门前的选择偏差（你选错人了）

选择偏差，就是你在挑选实验对象的时候，有意无意地带入了某种偏好，导致你的实验组根本不是随机的，而是一群“特选用户”。

这个听起来好像很低级错误，但在实际业务代码里藏得深得很。

场景 1：只对“活跃用户”做实验

假设你们是一个电商 APP，要做一个“新版促销弹窗”的实验。为了保证实验灵敏度，你或者开发大哥在代码里写了一行逻辑：只对“过去 30 天有活跃行为”的用户触发实验。

这行代码一下去，逻辑上没毛病对吧？你想测试促销效果，当然得测活人，死人又不会下单。

这实验跑出来，转化率提升了 20%，非常显著。于是你们决定全量上线，指望大盘 GMV 也能涨个 20%。

结果呢？上线后大盘纹丝不动，甚至略有下降。

问题出在哪？

因为你的实验样本（过去 30 天活跃用户）和全量用户（包括新注册的、流失边缘的、沉睡唤醒的）根本不是一波人。

活跃用户本身对促销就敏感，粘性高，他们的转化率提升很容易。但是当你推全到生产环境，面对的是大量对平台无感、甚至反感弹窗的沉睡用户。

这时候，高频弹窗对活跃用户是锦上添花，但对那些边缘用户可能就是“骚扰”。这部分沉默的大多数可能会直接关闭通知甚至卸载。你在选人的时候，就选了一群“容易成功”的人，结果自然是“虚假繁荣”。

场景 2：技术分流导致的偏差

有的实验分流服务（Hashing）是用 Device ID（设备号）做的。

结果某些老旧机型、或者安卓低版本、或者是注重隐私开启了限制追踪的用户，根本取不到 Device ID。

这部分用户去哪了？通常代码里会有个兜底逻辑：取不到 ID 的，统一分到默认组（对照组），或者直接不进实验。

这就导致能进入“实验组”的，全是拿着新款 iPhone 或者高端安卓机的用户，甚至全是系统权限给得很大方的用户。这群人的购买力本来就强。

你最后算出来实验组客单价高，你以为是策略牛逼，其实是人家本来就有点钱。这找谁说理去。

三、第二坑：进门后的幸存者偏差

如果说选择偏差是“选错了人”，那幸存者偏差就是“看漏了死人”。

这个偏差在 AB 实验里极其隐蔽，很多资深分析师稍不留神也会栽跟头。它的核心在于：**由于某种处理策略，导致部分样本在被统计前就丢失了，我们只分析了活下来的人。**

场景：高清大图的“性能陷阱”

你们 APP 要改版详情页，在这个页面加了很多精美的高清大图，想通过视觉冲击力提升转化率。

实验跑了一周，数据好得不得了：人均浏览时长提升 15%，下单转化率提升 5%。

于是全量上线。结果上线第一天，客服电话被打爆了，订单量暴跌。

让我们来做一次详细的数据推演：

假设对照组（老版本）和实验组（新版本）理论上都分配了 1000 个用户。

对照组（老版本，图片小，加载快）：

进组用户：1000 人。

成功加载页面用户：1000 人（都能打开）。

下单用户：50 人。

计算转化率 = $50 / 1000 = 5\%$ 。

实验组（新版本，图片超大，加载慢）：

进组用户：1000 人。

成功加载页面用户：800 人。（注意！这里有 200 个拿千元机或者在那地铁弱网环境的人，因为页面转圈太久，直接关掉 APP 走了。关键点来了：埋点上报往往是在页面加载完成 onload 之后才触发的。所以这 200 个人，根本没发回来曝光埋点。）

下单用户：48 人。（因为走了 200 人，下单人数其实比对照组少了 2 个）。

你看到的报表转化率 = $48 / 800 = 6\%$ 。

你看懂了吗？

真实的业务是：下单人数从 50 降到了 48，业务其实是亏的！

但在报表上：因为分母从 1000 变成了 800，分母缩小的速度比分子快，导致转化率算出来反而从 5% 涨到了 6%。

留下来被你统计到的，全是手机好、网速快、耐心好的“幸存者”。这帮人本来体验就好，转化率自然高。而新版本直接把低端机用户“物理屏蔽”了。

这就是为什么生产环境翻车——因为生产环境是不骗人的，加载不出来的用户是真的不买单，而不是仅仅不发埋点。

四、生产环境的“隐形杀手”（不仅仅是偏差）

除了上面这俩偏差，还有几个业务上的坑，会导致实验环境和生产环境不一致。

1. 资源的全局约束（Inventory Constraint）

在实验环境里，你只切了 5% 的流量测“发大额优惠券”。这 5% 的人领券爽了，核销率很高。

你觉得没问题，推全上线。

结果全量上线后，因为领券的人太多，公司的营销预算或者商家的库存瞬间被击穿了。后面的用户虽然看到了弹窗，但点进去显示“已抢光”。这不仅没带来转化，还带来了巨大的客诉。AB 实验通常很难模拟这种“抢资源”的全局挤兑效应。

2. 新奇效应（Novelty Effect）

用户对新东西有天生的好奇。你把按钮从绿换成红，点击率短期内肯定涨，因为用户眼滑或者好奇。实验只跑一周，你看涨了就上线。

等过了两周，用户习惯了，点击率就回落了。这也是一种“时间维度”的偏差。

五、怎么避坑？（实战对策）

看到这里，你应该明白这事儿有多复杂了。面试的时候，光指出问题不行，你得给方案。

1. 必做：SRM 检验 (Sample Ratio Mismatch)

这是检测“幸存者偏差”的照妖镜。

如果在面试中，面试官问你：“实验组和对照组流量分配是 50/50，结果跑出来样本量是 100 万 vs 101 万（即 49.75% vs 50.25%），这正常吗？”

你要斩钉截铁地回答：不正常，大概率有 Bug。

不要觉得 0.5% 的差距很小。在 100 万的样本量级下，根据统计学原理（卡方检验），这么大的偏离度发生的概率极低。

一旦出现 SRM，通常意味着有一组的埋点丢失了，或者分流逻辑有漏洞（比如刚才说的设备号取不到的问题）。这时候千万别看转化率，先去修 Bug。

2. 看绝对值，不只看比率

不要只看“转化率”这种除法算出来的指标。要看分子和分母的绝对值。

如果实验组转化率高了，但进组的总人数（分母）比对照组莫名其妙少了一截，那绝对是出事了。就像刚才的高清大图案例，分母少了 20%，这才是问题的关键。

3. 做 AA 测试 (AA Test)

在策略生效前，先空跑一段时间。看看两组人在没有任何策略干预下的指标是不是一致的。如果 AA 阶段就有差异，说明分流系统有问题，或者用户本身就不均匀，赶紧重抽。

六、 知识点总结

最后，咱们把今天的干货打包一下：

选择偏差 (Selection Bias)： 发生在“入组”阶段。样本选得不随机，样本特征不等于大盘特征。常见于只选活跃用户、特定机型用户。

幸存者偏差 (Survivorship Bias)： 发生在“统计”阶段。由于技术性能、加载失败、逻辑 Bug 等原因，导致一部分“失败”的样本没被记录下来，分母变小，人为拉高了指标。

SRM (Sample Ratio Mismatch)： 样本比例失衡。这是发现上述问题的最重要手段。只要样本量分配比例显著偏离设定值，实验结果就不可信。

新奇效应 & 资源挤兑： 这些是生产环境特有的业务噪音，需要拉长时间周期或考虑库存限制来评估。

好，我的解答结束了。

现在切换回面试官模式。既然你已经明白了偏差的原理，那么我想请教你下一个问题：

“刚才你提到了 SRM（样本比率不匹配）是发现问题的关键。如果在一次面试中，我告诉你实验组和对照组的流量分配应该是 50/50，但实际跑出来是 49.5/50.5，样本量大概是 100 万级别。你会怎么判断这个差异是正常的波动，还是真的出了 SRM 问题？你会用什么具体的统计方法来验证？”

题目 37

面试真题：抖音直播间商品库存有5000个SKU，但实际产生GMV的只有800个，如何分析并优化商品运营策略？

解答

这道题的题面很短，但信息量其实很大：**5000个SKU库存，只有800个动销。**

动销率算一下： $800 / 5000 = 16\%$ 。

说实话，放在传统电商（比如淘宝店或者京东），16%的动销率虽然低，但如果是长尾的大店，好像还能忍。但在**抖音直播间**这个场景下，这个数据其实是“有毒”的。

为什么说它有毒？因为直播间是“流式”的，屏幕就那么大，解说时间就那么短。如果你在直播间的小黄车里挂了5000个品，用户手指划断了也翻不到底。这不仅会让用户觉得店铺像个杂货铺，更重要的是，大量零点击、零转化的商品会拉低整个直播间的“商品互动指标”，直接拖累你的流量权重。

第一部分：先搞清楚那4200个“废品”到底怎么回事

咱们不能上来就喊“砍掉4200个SKU”，那样老板会觉得你疯了。咱们得先做诊断，把这4200个没卖出去的货，分成三类。这里的核心逻辑是**漏斗分析**。

货卖不出去，无非就三个原因：没露脸、露脸了没人点、点了没人买。

第一类：压根没露脸的（曝光问题）

你可以去后台拉一下数据，这5000个品里，有多少是主播在直播间里**口播讲解**过的？

这里我们要算一笔**时间账**：直播间的时间是极度稀缺的资源。假设一场直播4小时（240分钟），每个品主播平均讲5分钟，哪怕主播是铁人，不喝水不喘气，一场直播撑死只能讲48个品。

那么问题来了，剩下几千个品挂在那干嘛？如果是为了凑“货架丰富度”，那它们有没有带来搜索流量？如果没有，那它们就是纯粹的**库存负担**。我敢打赌，这4200个里，至少有3000个是主播连提都没提过的“沉默库存”。

第二类：讲了但没流量的（吸引力问题）

主播讲了，或者运营把这个品弹窗弹出去了，但是点击率极低。

这说明什么？说明这个品的**卖相**不行（主图太丑），或者**选品逻辑**有问题，跟当前直播间的人群根本不匹配。比如你是个卖潮流女装的直播间，非要挂几个老年健步鞋，主播再怎么喊，粉丝也不会点的。这种品，就是纯粹在浪费直播间的流量位。

第三类：有点但没转化的（价格/详情页问题）

有人点进去看了，但是最后没下单。这时候就要看详情页停留时长和价格了。

是不是比隔壁贵了？是不是评价里有差评？还是说详情页加载太慢？这类品其实最可惜，因为流量已经进来了，只是接不住。

第二部分：给SKU贴标签，做个“大扫除”

搞清楚原因后，我们得动手了。咱们用一个最简单的**四象限法**（其实就是变种的BCG矩阵）把这5000个品归归类。

你就想象手里有两把尺子：一把是**销量（GMV）**，一把是**流量（曝光/点击）**。

1. 明星品（高流量，高GMV）—— 那800个里的头部

这些是你的命根子。你的策略是**保**。要去分析它们的库存深度够不够？会不会断货？能不能跟供应链谈下更低成本？直播间的排品节奏里，这些品是不是放在了在线人数最高的那个整点？

2. 潜力品（高流量，低GMV）—— 那4200个里的“冤种”

这些品有人看，甚至有人点，就是不买。这就得做**测试**了。是不是价格没到位？试着发个限时优惠券？是不是主播话术没讲到痛点？策略是**调**。给它们2-3次直播的机会，调整话术或价格，如果还不行，说明产品力本身有问题，直接淘汰。

3. 长尾品/凑单品（低流量，低GMV，但有特定作用）

这部分比较微妙。有些品虽然卖得少，但它是用来做**锚点**的（比如一个很贵的为了衬托主推品便宜），或者是为了**凑满减**的（比如9.9的小配件）。只要它们不占库存资金，可以留着。

4. 滞销垃圾（无流量，无GMV）

这应该是那4200个里的大多数。对于这些品，策略只有一个字：**清**。它们在直播间里只会分散用户的注意力，降低“点击转化率”，而这个指标一旦低了，抖音算法会认为你的货不行，直接给你限流。

第三部分：制定优化策略，别再犯傻了

既然现状理清楚了，接下来怎么优化？咱们得有一套组合拳。

1. 瘦身计划：直播间与货架的“物理隔离”

这是解决这道题最核心的业务手段。很多人把“直播间”和“店铺”混为一谈。

直播间（Content）：是用来做爆发的，必须是“少而精”。建议直播间的挂车数量控制在**100个以内**（包含讲解款和少量凑单款）。把那4200个不讲品，全部从直播间的小黄车里**移除**。

货架/橱窗（Shelf）：是用来做长尾和搜索的。那4200个品，如果还有库存，就只挂在店铺的“橱窗”里，或者通过短视频挂车去卖，不要占用直播间的资源。

这样，直播间的点击率会瞬间提升，因为用户看到的都是经过筛选的爆款。

2. 排品逻辑优化：过山车节奏

直播间不能一直是平的。你需要根据SKU的属性来排品：

- **引流款（福利款）**：哪怕不赚钱，用来拉停留、拉互动。
- **利润款**：那800个里的核心，用来赚钱。
- **炮灰款（对比款）**：用来衬托利润款性价比高的。

动销差的品，不要安排在黄金时间段。

3. 建立“赛马机制”

不要一次性上几千个品。每周选**10-20个新品**进入直播间测试。给他5分钟的讲解时间，或者挂在讲解位的第2-3位。如果这场直播数据好（点击率、转化率达标），就晋级到下场直播的“常驻位”；如果不行，立刻淘汰出直播间，扔回货架去。这样你的库存就是**流动的活水**，而不是一潭死水。

第四部分：深挖一点，关于“库存成本”的算账

最后咱们得算笔账，体现一下咱们的商业敏感度。

你说有5000个库存SKU，这5000个如果是**自有库存**，那仓储费、资金占用费是很吓人的。假设每个SKU备货10件，那就是5万件货。如果一件货成本50块，那就是250万压在库房里吃灰。

如果你分析出这4200个品真的卖不动，不仅要从直播间下架，更要在供应链端做**止损**。

这里特别要注意一个**陷阱**：很多人会建议改成“预售”模式（JIT，卖了再去采）。在抖音要非常小心。抖音现在的发货考核非常严，通常要求48小时内必须要有物流揽收记录。如果是那4200个长尾品，你很难保证供应链能随时发货。所以，对于实在卖不动的滞销品，最稳妥的办法是：**打包低价清仓给尾货商，或者直接退回供应商，回笼资金**。不要为了那一点点可能的销量，冒着被平台罚款和封店的风险去挂预售。

总结一下知识点

回答到这里，咱们把刚才用到的几个核心概念复盘一下：

- 1. **动销率**：有销量的SKU数 / 总SKU数。这是衡量商品利用效率的核心指标。
- 2. **人货场匹配**： 这里的核心冲突是“有限的直播时长” vs “海量的商品库存”。
- 3. **GPM (千次曝光成交金额)**： 如果那4200个品拖累了整体点击率，会导致直播间流量层级掉得很快。
- 4. **全域运营（直播 vs 货架）**： 直播间是推爆款的，货架是承接长尾的，两者要有明确的选品隔离。

面试官视角追问

“这套分析逻辑很清晰，特别是把直播间和货架分开的思路。

那么我想追问一个问题：如果我们发现，这800个动销的品，虽然卖得好，但是**退货率**高达60%（抖音女装常态），而那4200个长尾品虽然卖得少，但几乎不退货。

在这种情况下，单纯按GMV去砍掉那4200个品，会不会导致我们最终的**实际利润**崩盘？你会怎么引入‘退货率’这个指标来修正刚才的策略？”

题目 38

因果推断中的倾向得分匹配(PSM)和双重差分(DID)：什么场景该用哪个？

解答

在面试字节、美团、滴滴这类策略导向极强的大厂时，因果推断几乎是必考题。其中最高频的一个问题就是：**倾向得分匹配 PSM 和 双重差分 DID**，这两个方法到底有什么区别？什么样的业务场景该用哪一个？

很多人会背定义，说 PSM 是匹配，DID 是差分。但这只在第一层。

面试官真正想听的，是你对**数据局限性的判断**，以及你有没有**业务场景感**。

第一部分：核心决策逻辑

回答这个问题，不要上来就堆公式，先给面试官一个清晰的决策树，告诉他你脑子里有一张地图。

选择 PSM 还是 DID，核心判断依据其实就看两点：

第一点看数据维度：你手头的**数据有没有清晰的时间线**？也就是有没有“事前”和“事后”。如果有时间序列，且有明确的对照组，首选 DID。如果只有某一时刻的快照数据，或者是截面数据，那只能用 PSM。

第二点看干扰因素：你最担心的那个干扰因素，是**可见的**，还是**不可见的**？

用一句话总结结论：**PSM 解决的是“可观测”的混杂因素，而 DID 解决的是“不可观测但固定”的混杂因素。**

这就好比，PSM 是在人群中找“双胞胎”来对比；而 DID 是像拍电影一样，通过剪辑手法把“自然增长”的部分剪掉，只留“特效”部分。

第二部分：PSM 倾向得分匹配，给用户找个“克隆人”

什么场景用？

最典型的场景是**用户自选类**的业务评估。

比如，你想分析“购买了 VIP 会员的用户，留存率是不是更高？”

这里有一个巨大的业务陷阱：买 VIP 的人，本身就是那一波忠诚度最高、最爱用 App 的人。哪怕他不买 VIP，他的留存率本来就比普通人高。如果你直接拿“VIP 组”和“普通组”比，肯定会高估 VIP 的价值，这就是经典的选择性偏差。

数值推演：PSM 是怎么矫正数据的？

我们来带一组数字进去看。

假设我们有两个用户群：

A 组（买了 VIP）：平均留存率 50%。B 组（没买 VIP）：平均留存率 20%。

如果你直接减，50% 减 20% 等于 30%，你会误以为 VIP 能带来 30% 的留存提升。但这 30% 里，可能只有 10% 是 VIP 带来的，剩下 20% 是因为这群人本来就爱玩。

这时候 PSM 进场了。它的逻辑是：我们在 B 组（没买的人）里面，挑出一群人和 A 组非常像的人。

具体操作是，我们把用户的活跃度、消费力、城市等级这些特征放进模型（通常是逻辑回归），算出一个“购买 VIP 的概率分数”。

比如用户小明，买了 VIP，他的购买概率分是 0.8。我们在 B 组里拼命找，找到了一个用户小红，她没买 VIP，但她的购买概率分也是 0.8。这说明小红和小明在客观条件上几乎一模一样，唯一的区别就是“买没买”。

我们将小明和小红配对。对所有人都这么配对后，我们发现：

A 组（配对后）：留存率 50%。B 组（配对后）：留存率从原来的 20% 变成了 40%。为什么变高了？因为我们挑出来的都是高质量的“潜在 VIP”用户。

真实的因果效应 = 50% - 40% = 10%。

你看，通过 PSM，我们把原本虚高的 30% 修正回了真实的 10%。

PSM 的致命死穴（面试加分项）

PSM 看起来很完美，但它有一个巨大的局限：它只能匹配你数据库里**已经记录**下来的特征。

如果用户买 VIP 是因为他“心情好”或者“更认同品牌价值观”，这些心理因素你数据库里没有，模型就无法计算。这部分“不可观测”的差异，PSM 是消除不掉的。所以，如果你的特征维度不够全，PSM 的结果依然会有偏差。

第三部分：DID 双重差分，上帝视角的“减法”

什么场景用？

最典型的是**政策干预**或者**功能全量上线**。

比如，滴滴在“杭州”上线了一个新的派单策略，而“南京”没有上线，保持原样。你想看这个策略到底提升了多少接单率。

这时候你不能只看杭州上线前后的对比，因为可能正赶上五一假期，全国都在涨。你也不能只看杭州和南京的对比，因为杭州本来体量就比南京大。

数值推演：DID 是怎么做减法的？

DID 的核心逻辑是做两次减法，把干扰项一层层剥离。

假设数据如下：

杭州（干预组）：策略上线前接单率 100，上线后接单率 150。表面看，杭州涨了 50。但这 50 全是策略带来的吗？不一定，可能包含了自然增长。

南京（对照组）：策略上线前接单率 80，上线后接单率 100。南京什么策略都没上，它也涨了。它涨的这 20（100 减 80），就是纯粹的“季节因素”或者“大盘自然增长”。

这时候我们做 DID 计算：

第一步：算出干预组的总变化。杭州总变化 = 150 - 100 = 50。第二步：算出对照组的总变化（自然增长）。南京总变化 = 100 - 80 = 20。第三步：做差。策略带来的真实净效应 = 杭州的总变化 - 南京的总变化 = 50 - 20 = 30。

用纯文本公式表示就是：Effect = (干预组后 - 干预组前) - (对照组后 - 对照组前)

DID 的致命死穴（平行趋势）

DID 能用的前提是必须满足**平行趋势假设**。

意思就是，在策略上线之前，杭州和南京的接单率走势必须是平行的。如果杭州本来就在疯涨，而南京在跌，那你是没法拿南京做对照的。这俩必须是“同呼吸共命运”的战友，才能做比较。

如果画图发现上线前两两条线不平行，DID 直接失效。

第四部分：终极组合拳 PSM + DID

说到这里，如果想在面试里拿 S 卡，你得抛出一个进阶思路。

在实际业务里，我们经常遇到这种情况：我想用 DID，但是找不到完美的对照组。比如我就想看北京上线策略的效果，但我拿什么城市跟北京对标呢？拿上海吧，上海可能有自己的政策；拿天津吧，体量又不对等。

直接做 DID，平行趋势肯定通不过。

这时候我们可以打组合拳：**PSM-DID**。

第一步：先用 PSM。我们在全国其他所有城市的用户里，用算法挑出一波人，这波人的特征分布跟北京用户非常像。我们强行构造出一个“虚拟对照组”。

第二步：再用 DID。拿北京组和这个“虚拟对照组”去做双重差分。

先用 PSM 解决“人不对等”的问题，再用 DID 解决“时间趋势”的问题。这招一说出来，基本上就证明了你是真的懂业务实操，而不是只会背书。

总结一下

PSM 是用来解决“谁和谁比”的问题，它通过匹配看得见的特征，模拟出 AB 实验。

DID 是用来解决“时间干扰”的问题，它通过两次做差，剔除掉自然增长和固定差异。

在数据完备的情况下，DID 的因果推断效力通常优于 PSM，因为它可以剔除那些“看不见”的固定干扰。但在现实复杂的业务中，把两者结合起来用，往往才是解决棘手问题的终极杀招。

接下来，我要切换回面试官模式了。

既然你提到了 DID 需要满足「平行趋势假设」，那么我的下一个问题是：

如果在实际业务中，我们画图发现干预前的平行趋势检验（Parallel Trend Test）不通过，两条线就是不平行，你该怎么办？还有什么补救办法吗？

题目 39

用户分层的陷阱：RFM模型和K-means聚类在会员体系设计中的致命差异

解答

如果你真的在业务一线踩过坑，你会发现：在设计会员等级（Membership Tier）这件事上，盲目上 K-means 往往会带来灾难性的后果，甚至引发严重的公关危机和财务亏损。

咱们先从宏观逻辑上拆解这两者的本质区别，再用具体的数字推演看看「致命伤」到底在哪。

第一部分：底层逻辑差异，一个是「上帝切蛋糕」，一个是「甚至找不到蛋糕」

我们在做会员分层的时候，本质上是在制定一套「契约」。

RFM 模型是典型的「上帝视角切蛋糕」。我们预先设定好三个维度：最近一次消费（Recency）、消费频率（Frequency）、消费金额（Monetary）。然后分析师像上帝一样，手里拿着把刀，根据业务目标人为划定界限。比如我们规定：一年内消费满 1000 元就是金卡，不满就是银卡。这个规则是确定的、刚性的。

K-means 聚类则完全不同，它是让数据自己「找邻居」。你把一堆用户数据丢进去，告诉算法「给我分成 5 堆」，算法会根据数学上的距离（通常是欧氏距离），把特征相似的人聚在一起。算法并不知道什么是「高价值」，它只知道这群人在数学空间里靠得比较近。

搞清楚这个逻辑，我们来看具体的业务灾难。

第二部分：K-means 在会员设计中的三大「致命伤」

如果面试官问你差异，你必须把这三个点讲透，特别是第三点，关于财务的。

1. 解释性崩塌：你怎么跟用户解释他为什么是「白银会员」？

做会员体系，核心逻辑叫「规则透明」。你需要明确告诉用户：你现在还差 200 块钱就能升级，升级后能享受 9 折。这能激励用户去凑单、去复购。

如果你用 RFM，这很容易解释：「亲，规则就是满 1000 升级，你现在买了 800，加油。」

但如果你用 K-means，这就尴尬了。因为聚类出来的结果是多维特征的综合产物。你很难用一句人话总结出这个群体的边界。你总不能跟用户说：「亲，根据我们的迭代算法，你在多维空间里的向量坐标，距离那个高价值中心点的欧氏距离有点远，而且你的归一化数值在另外两个维度上权重不够，所以你被降级了。」

用户听完只会想骂人。无法清晰向用户传达升级门槛（Actionable Insight），就失去了会员体系「促活」和「提频」的意义。

2. 稳定性灾难与「被动降级」

这是最坑的一点，也是很多人没意识到的。

RFM 的阈值是固定的（绝对值）。只要用户消费达到了 1000 元，他就是金卡。

但 K-means 是相对的。它是根据当前所有样本的分布来计算中心点的。

我们来做一個具体的数值推导：

假设你的池子里原本有 1000 个用户，平均消费 500 元。这时候，双十一大促，突然进来了 50 个「超级土豪」，每个人消费了 100 万元。

如果你用 K-means，因为均值极其敏感，这 50 个土豪会瞬间把「高价值人群」的聚类中心（Centroid）拉高到一个极高的位置。这就导致了一个荒谬的结果：用户小明，上个月消费 800 元，本来属于「高价值组」。这个月他没动，也没退款。但因为那 50 个土豪把标准拉高了，小明离新的中心点太远了，算法自动把他划到了「中低价值组」。

用户明明什么都没做错，消费也没变少，却被降级了。在业务上，这叫「剥夺感」。这种情况一旦发生，客诉电话会被打爆。会员体系追求的是「安全感」和「确定性」，而 K-means 带来的是「不确定性」。

3. 财务预算的不可控风险

这一点很少有人提到，但非常关键。

做会员体系，背后是成本核算。比如，「金卡会员」每个月送一张 20 元的无门槛券。财务部门需要你算出明年要发多少钱。

如果你用 RFM，你可以很精准地测算：根据历史数据，大概有多少人能达到 1000 元门槛。比如预测有 1 万人，那预算就是 20 万。

如果你用 K-means，因为分类结果是动态的，且依赖于数据分布。如果下个月用户整体消费结构发生微小变化（比如某次活动导致大量薅羊毛用户涌入），聚类结果可能会剧烈波动。可能某个月算法判定「这一大坨人都属于 Cluster 1（高价值）」，结果原本预计 1 万人的金卡，突然变成了 3 万人。**预算瞬间超标 3 倍**。你怎么跟财务解释？说是因为算法参数收敛到了局部最优解？财务总监会把你轰出去的。

第三部分：K-means 真的不能用吗？它的正确打开方式

说到这，面试官可能会觉得你把 K-means 贬得一文不值。这时候你得往回拉一下，展现你的辩证思维。K-means 不是没用，而是不适合直接用来定对外展示的会员等级（Tier）。

它适合做这两件事：

1. 辅助制定 RFM 的阈值

我们刚才说 RFM 的阈值是人为定的，那到底定多少？是 1000 元算金卡，还是 1500 元算金卡？这时候 K-means 可以上场。你可以先把历史数据丢进 K-means 跑一下，看看数据自然分层大概在什么位置。假如算法跑出来，发现 1200 元左右确实有一个明显的断层，那我们就参考这个数，把 RFM 的金卡线定在 1200 元。**这叫：用无监督算法发现数据规律，再用规则模型固化规律。**

2. 同一层级下的精细化画像

在同一个「RFM 金卡会员」等级里，可能有两拨人：A 类：每次都买正价新品，对价格不敏感。B 类：只在全场五折时疯狂囤货，客单价极低但总量大。

这两拨人在 RFM 总分上可能一样，但在 K-means 的多维空间里会分得很开。这时候，你可以用 K-means 在金卡池子里再跑一次聚类。针对 A 类，推「新品优先体验权」；针对 B 类，推「折上折优惠券」。

结论：RFM 用来搭骨架（定等级、定权益、控预算），K-means 用来填血肉（做营销、做触达、做策略）。

第四部分：结合一个具体场景把逻辑落地

咱们举个奶茶店的例子吧，这样大家更有体感。

假设我们要给一家连锁奶茶店设计会员。

如果我们用 RFM：我们设定，一年喝 50 杯以上是「钻石粉」。这很清晰。如果你喝了 48 杯，我就给你发个弹窗：「再喝 2 杯就能升级钻石，以后每杯立减 2 元！」你会为了这个明确的目标去多买两杯。这就是数据驱动业务，利用「沉没成本」和「目标趋近效应」。

如果我们用 K-means：算法跑出来 3 个簇。簇 A：平均喝 12 杯，喜欢上午买。簇 B：平均喝 45 杯，喜欢加布丁。簇 C：平均喝 80 杯，周末买得多。

这时候问题来了，一个用户喝了 50 杯，但是他不加布丁，他在数学距离上可能离簇 B（45 杯+加布丁）很远，反而离簇 A 更近（虽然杯数差异大，但可能其他维度相似）。结果就是一个喝了 50 杯的大客户被分到了初级会员里。而且，你没法发弹窗告诉他「再加几个布丁就能升级」。这种模糊性在做权益分配的时候是致命的。

第五部分：数据标准化的隐形坑

最后再补一个技术细节，很多人在做 K-means 时会忽略「量纲」对业务的影响。

RFM 的三个指标：R（天数）：可能是 0 到 365。F（频次）：可能是 1 到 50。M（金额）：可能是 10 到 10000。

如果你不做标准化（Normalization）直接跑 K-means，因为 M 的数值最大（10000），**欧氏距离的计算会被 M 完全主导**。也就是说，算法会认为：消费金额相差 100 元的区别，远大于消费频次相差 50 次的区别。这会导致你的分类结果变成单纯按「金额」切分，R 和 F 几乎失效。

虽然我们可以用 Min-Max 归一化处理，但在归一化之后，数据的物理意义（具体的钱数、天数）就消失了，变成了 0 到 1 之间的小数。这时候如果业务方向你：「为什么这个 0.8 的人比那个 0.7 的人级别高？」你很难直观地用业务语言还原回去。这也进一步加剧了 K-means 在解释性上的困难。

知识点复盘

好，这道题解答完了，我们简单总结一下里面用到的核心概念：

- RFM 模型：**基于业务规则的客户价值模型，优势是确定性、可解释性、易于预算控制。
- K-means 聚类：**基于距离的无监督学习，优势是发现数据的自然结构，劣势是结果不稳定、易受异常值影响。
- 可解释性（Explainability）：**模型结果能否转化为用户听得懂的规则，这是会员体系的核心。
- 鲁棒性（Robustness）：**模型抵抗数据干扰的能力。K-means 鲁棒性较差，容易被「土豪」或「羊毛党」带偏节奏。
- 数据标准化（Normalization）：**处理不同量纲特征时的必要步骤，但也因此丧失了部分业务直观性。

最后，切换到面试官视角。

刚才你解释得非常透彻，特别是关于预算控制和用户感知的点，很有 Sense。那我想顺着这个思路深挖一下：

既然你说可以用 K-means 辅助 RFM 定阈值，那具体怎么做？比如 K-means 跑出来 5 类人，但我只要 3 个会员等级（银、金、钻），这时候你怎么把这 5 类映射成 3 个等级？中间的 Cut 点你会怎么选？

题目 40

数据驱动翻车现场！为什么你的归因模型总是高估最后一次点击的价值？

解答

我们要从业务错配、利益分配、技术限制三个层面把这事讲透，并且必须把账算清楚。

第一部分：别急着看模型，先看“作案现场”

要回答为什么“最后一次点击（Last Click）”会高估价值，得先明白它是怎么“记账”的。

最直观的理解就是：足球比赛里，谁踢进了临门一脚，功劳全是谁的。不管前面是谁传的球、谁断的球，只要最后是你碰进球门的，记分牌上就写你的名字。

在数据分析里，这就导致了一个巨大的盲区：我们彻底抹杀了“助攻”的价值，把“收割”当成了全部。

我们来做一个具体的数值推演，带入场景看看这会有多荒谬：

假设你在卖一款售价 5000 元的高端咖啡机。一个典型用户的购买路径是这样的：

触点 A（种草期）：用户在朋友圈刷到了精美的视频广告，觉得这机器真好看，点进去看了一眼，太贵，关了。触点 B（决策期）：三天后，他去知乎或什么值得买搜了一下测评，看到评价不错，被深度种草。触点 C（购买期）：第七天，发工资了，他直接在淘宝搜了品牌词，进店下单，成交 5000 元。

在 Last Click 的逻辑下，账单是这样算的：淘宝搜索（触点 C）：贡献 GMV = 5000 元。知乎软文（触点 B）：贡献 GMV = 0 元。朋友圈广告（触点 A）：贡献 GMV = 0 元。

你看，这数据直接“撒谎”了。如果你是一个只看报表的分析师，你会得出什么结论？你会告诉老板：“朋友圈广告 ROI 是 0，简直是浪费钱，赶紧停掉；淘宝搜索效果太好了，赶紧把预算全砸进去。”

结果呢？当你真的停掉朋友圈广告，你会发现淘宝搜索的量也跟着崩盘了。因为你切断了源头的“活水”，没有人在上游种草，哪来下游的搜索？这就是 Last Click 最大的坑：它只奖励了“收割者”，饿死了“播种者”。

第二部分：为什么它总是“高估”？拆解三个核心业务偏差

刚才那个例子是宏观的，我们现在往深了挖，Last Click 造成的高估在实际业务中会有三个非常具体的表现形式。面试时把这三点抛出来，说明你真的懂流量。

第一，对“品牌词截流”的极度高估。

这是搜索广告（SEM）里最经典的问题。很多用户其实早就决定要买了，他们去百度或谷歌搜你的品牌名，只是为了找个入口进网站而已。

这时候，Last Click 会把这单功劳全算给 SEM。但实际上，这部分流量大概率是“自然流量”，你投不投广告他都会来。Last Click 让你误以为是搜索广告带来了这个用户，导致你为了本来就属于你的用户花了冤枉钱。这就是典型的“假增量”。

第二，对“距离支付更近的渠道”的天然偏袒。

有些渠道天生就长在收银台旁边，比如返利网、优惠券网站、购物车召回邮件。

试想一下，用户都已经把商品加进购物车准备结账了，突然想搜个优惠券，于是跳出去搜了一圈，点了一个返利网的链接回来完成了支付。

Last Click 会判定：是返利网带来了这个用户。业务真相是：用户本来就要买了，返利网只是顺手牵羊。后果是：你不仅少赚了返利佣金，还错误地以为这个渠道转化率极高，甚至还想给它追加预算。

第三，严重忽视“高客单价、长决策周期”的业务特性。

越贵的东西，决策链条越长。卖房、卖车、卖企业级软件，用户可能要在 3 个月内接触你 20 次才会下单。

如果用 Last Click，那基本上只有销售人员或者最后一次销售会议是有价值的，前面所有的市场培育、白皮书下载、webinar 直播全被归零。这会导致公司的资源配置极度短视，所有人都去抢那个“最后一步”，没人愿意做前期教育市场的事儿，长此以往，销售漏斗的开口就干枯了。

第三部分：既然这么坑，为什么大家还都在用？

这个问题非常关键，必须解释清楚现实与理论的差距。大家都知道 Last Click 不准，但市面上 80% 的企业报表里默认还是它，原因主要有两点：

一个是“技术懒惰与归因窗口的限制”。这是最容易追踪的，不需要复杂的跨设备打通，不需要高深的算法。而且，很多归因工具有“回溯窗口”（比如 30 天）。如果用户第一次点击是在 31 天前，那很多模型都会失效，唯独 Last Click 永远能抓到最后那一次，虽然不准，但它“从不缺席”。

另一个更核心的原因是“财务结算的刚需”。这一点往往被忽略。你跟广告代理商结账，或者跟联盟营销伙伴分润，通常必须基于“最后那个链接”来算。你很难跟一个博主说：“哎，虽然用户是点你链接买的，但我觉得主要功劳是三天前那个展示广告的，所以我只给你结 30% 的钱。”

在商业合同里，Last Click 是目前最无可争议的“计费标准”，但这不代表它是正确的“分析标准”。做分析的，脑子得清楚这两者的区别。

第四部分：用数字证明一切——不同模型的计算推演

为了解决这个问题，我们需要引入多触点归因。别光说概念，我们必须算一下账，看看同一个订单在不同模型下，各个渠道的价值会发生什么剧烈变化。

假设路径如下：渠道 A（展示广告）-> 渠道 B（社交种草）-> 渠道 C（搜索广告）-> 成交 3000 元。

我们看看不同模型怎么分这 3000 元的业绩：

模型 1：线性归因（Linear）

逻辑：大家都有份，平分秋色。计算： $3000 / 3 = 1000$ 。结果：A 分 1000，B 分 1000，C 分 1000。评价：这种分法最“和稀泥”，虽然承认了助攻的价值，但它假设每个触点的重要性完全一样，这在业务上通常是不成立的。

模型 2：时间衰减（Time Decay）

逻辑：离购买越近，影响越大。计算：假设规则是 7 天半衰期，简单量化一下，可能 C 拿 60%，B 拿 30%，A 拿 10%。结果：C 分 1800，B 分 900，A 分 300。评价：这比较适合转化周期短、且促销驱动的业务（比如双十一买衣服），认可了临门一脚的重要性，但也没把前锋饿死。

模型 3：基于位置（Position Based / U-Shape）

逻辑：头尾最重要，中间是过程。引入用户（拉新）和促成购买（收割）各记一大功。计算：规则通常是 First Click 给 40%，Last Click 给 40%，中间剩下 20% 平分。结果：渠道 A（引入者）： $3000 * 40\% = 1200$ 元。渠道 C（收割者）： $3000 * 40\% = 1200$ 元。渠道 B（中间者）： $3000 * 20\% = 600$ 元。评价：这是目前最通用的平衡方案。你看，在这个模型下，渠道 A 的价值从 Last Click 的 0 元直接暴涨到了 1200 元！这直接决定了这个渠道的预算是会被砍掉还是被保留。

第五部分：高阶视角——从“分蛋糕”到“做实验”

如果你想展现顶级分析师的思维，一定要补充这一点。

上述所有的模型（U型、线性等），本质上都是在“人为制定分蛋糕的规则”。我们觉得头尾重要，就给 40%，但这 40% 科学吗？没人知道。

真正科学的方法是 Data-Driven（算法归因）和增量测试（Lift Test）。

算法归因（比如 Shapley Value）：这是利用博弈论的方法，让机器去跑海量数据。它会计算：“有渠道 A 参与的路径，转化率是多少？”“把渠道 A 拿掉，类似的路径转化率掉了多少？”通过对比，算出渠道 A 的“边际贡献”。如果拿掉渠道 A，转化率纹丝不动，那就算你在 Last Click 里表现再好，算法也会判定你价值为 0。

增量测试（Incrementality Test）：这是终极真理。比如我们在河北省投广告，山东省不投（作为对照组），看看河北省的销量到底比山东省多涨了多少。这部分涨出来的，才是真正的“增量”。

知识点总结归纳

1. **Last Click 的本质原罪**：割裂了用户旅程，只看结果不看过程，导致“助攻”价值归零。
2. **三大高估陷阱**：品牌词截流（抢自然流量功劳）、收银台效应（抢购前拦截）、忽视长周期（饿死上游）。

3. **生存现状**：虽然分析上不准，但在技术实现和财务结算上是目前的行业标准。
4. **模型计算差异**：
 - Last Click: C 拿 100%。
 - Linear: ABC 平分。
 - U-Shape: 两头重 (40%)，中间轻 (20%)，兼顾拉新与收割。
5. **未来趋势**：从基于规则 (Rule-Based) 转向基于算法 (Data-Driven) 和增量测试 (Lift Test)，关注真正的“边际贡献”而非“账面功劳”。

好，现在我是面试官

我要根据你刚才的回答追问你了。这一题你答得不错，但我现在有个很棘手的现实问题：

“你说 U-Shape 或者算法归因更科学，这个我也认同。

但是，如果我们公司把归因模型从 Last-Click 切换到 U-Shape，意味着 Search 部门的业绩会瞬间缩水 40%，而 Social 部门的业绩会暴涨。

这就涉及到部门之间的利益博弈和 KPI 考核了，作为数据分析师，你怎么去推行这种变革？怎么去说服 Search 部门的老大接受这个‘更科学’但对他不利的结果？”

题目 41

面试真题：知乎问答社区中，科技话题的日均浏览量占总流量的18%，但该类目下的用户互动率（点赞+评论+收藏）仅为3%（平台均值7%），可能是什么原因？

解答

当听到 18% 的流量占比对应只有 3% 的互动率，而且远低于大盘 7% 的时候，你的第一反应绝对不能是急着找借口说「这届用户不行」，而是要先拿笔算一算这组数据意味着什么，然后建立一个结构化的漏斗思维来拆解。

这道题考察的其实是对「流量性质」、「用户场景」以及「设备差异」的理解深度。

第一部分：先把数字算清楚，量化差距

别光盯着 3% 觉得低，我们先做一个简单的反向推导，看看「非科技类」的数据得达到什么水平，才能把大盘拉到 7%。

假设全站流量是 100。科技类流量占比 18%，互动率 3%。其他类目流量占比 82%，设互动率为 X。

全站互动率公式： $(18\% * 3\%) + (82\% * X) = 7\%$

计算过程： $0.0054 + 0.82X = 0.07$
 $0.82X = 0.0646$
 $X \approx 7.9\%$

你看，这个数字其实很有意思。非科技类目（情感、娱乐、职场等）的平均互动率大概在 7.9% 左右。

这意味着，科技类目（3%）并不是稍微低一点，而是呈「断崖式」下跌，不到其他类目的一半。这种数量级的差异，绝对不是一句「内容质量参差不齐」就能解释的，一定存在**结构性**和**场景性**的根本不同。

第二部分：最大的嫌疑人——流量来源与用户动机

这是最关键的切入点。

知乎的科技类话题，有一个非常特殊的属性：**极强的工具属性和搜索属性**。

我们还原一下用户场景。当一个用户在刷「情感」或「吃瓜」话题时，他通常是在 App 的推荐流里「逛」，心态是放松的、社交的。看到有意思的就点个赞，看到不爽的就喷两句，互动意愿天然很高。

但是，科技类内容的流量，根据经验判断，很大一部分并不来自站内的推荐流（Feed），而是来自**站外搜索（SEO）**。

你想想，你平时什么时候看科技类内容？很可能是手机坏了、Python 代码报错了、Excel 公式忘了、或者想买新耳机了。你去百度或者 Google 搜了一下，然后点进了一个知乎的回答。

这时候你的动机是「解决问题」，也就是「用完即走」。

场景还原：你搜“Python 列表怎么去重”，点进知乎，看到了代码，复制，跑通了，关掉网页。结果：后台记录了一个 PV（浏览量），但你大概率没有登录，或者懒得登录，更别提点赞收藏了。你的需求在“看到答案”的那一刻就已经被满足并终止了。

推断：科技区的 18% 流量里，可能包含了比其他分区高得多的「游客流量」或「一次性搜索流量」。这部分流量的天然互动率就是极低的。

第三部分：设备端的隐形杀手——PC 端的占比

这一层很多人容易漏掉。

科技类（尤其是编程、软件、办公技巧类）内容，用户阅读的设备场景是什么？**很多时候是 PC 端（电脑网页版）**。

程序员在写代码，或者白领在做 PPT，他们是在电脑浏览器上打开知乎的。

相比于 App 端，PC 网页端的交互体验是抑制互动的：

- **登录状态不稳定**：很多人网页版是未登录状态。
- **交互路径长**：App 上双击屏幕就点赞了，网页版还得把鼠标移过去点一下小手。
- **打字评论成本**：虽然键盘打字快，但网页版的评论区折叠做得比较深，不像 App 那样直接外露诱导评论。

如果后台数据显示，科技区的 PC 端流量占比达到 30% 甚至更高（而娱乐区可能 99% 都是手机端），那么互动力低就是一个必然的「设备物理属性」结果，而非内容不行。

第四部分：内容属性的“高冷”与“时效性”

这块得聊聊内容本身的特质。

1. **高门槛带来的“沉默螺旋”**：如果是一篇深度硬核的技术分析（比如 AI 算法推导），大部分用户可能处于“不明觉厉”的状态。看懂都费劲，更别说评论了。怕露怯，怕说错话被嘲讽，所以在这个领域，“**沉默的观察者**”比例会非常高。这点和情感题完全不同，情感题谁都能插两句嘴。
2. **极度理性，缺乏情绪**：互动率通常是由「情绪」驱动的。大盘 7% 的互动率里，包含了大量的争吵、站队、共鸣。但科技圈讲究客观中立。一个评测好就是好，坏就是坏，很难像情感贴那样激发强烈的“站队”欲望。没有情绪的剧烈波动，手指头按赞的动力就不足。
3. **长尾内容的时效性衰减**：科技流量里有很多是几年前的“教程”。比如“怎么重装系统”。用户搜进来，看到一个 2019 年的高赞回答解决了问题。但他看到时间是 2019 年，潜意识会觉得“这是一个死掉的帖子”，没有了参与互动的“现场感”。流量还在产生，但互动已经停止了。

第五部分：产品体验与指标定义的坑

最后，别忘了排查一下是不是“算错了”或者“指标定义偏差”。

- **收藏率 vs 点赞率**：科技类内容还有一个特点，就是“收藏率”可能会比“点赞率”高。用户觉得这代码有用，当作资料库“收藏”了备用，但他不一定“点赞”。如果我们的互动率定义是简单相加（点赞+评论+收藏）/ 浏览量，可能还看不出问题。但如果只看点赞，科技区会更惨。我们需要拆开看，是不是科技区的 **(收藏 / 浏览)** 其实远高于大盘？如果是，说明价值被认可，只是认可方式不同。
- **浏览量的定义（分母太大了？）**：这个 18% 的日均浏览量，如果包含“列表页曝光”，那可能是科技类的封面图比较吸引人（比如手机美图），大家点进去了，发现内容太硬核看不下去，马上退出了（高跳出率）。如果是这种情况，那说明不是互动差，而是**内容分发匹配度**有问题，把硬核内容推给了小白用户。

怎么验证这些猜想？

光说没用，作为分析师，你必须给出**验证方案**。我会拉下面这几组数据：

1. **分来源转化率**：对比 搜索来源 vs 站内推荐来源 的互动率差异。
2. **分设备转化率**：对比 PC 端 vs App 端 的互动率差异。
3. **用户登录率**：看浏览科技话题的用户里，未登录用户的比例是多少。
4. **互动类型拆解**：把 点赞、评论、收藏 拆开看。验证是否存在“高收藏、低点赞”的现象。

总结归纳

看到这其实就能大概心里有数了。

科技话题互动力低，核心大概率不是因为内容质量差，而是因为「工具人」属性太重 + PC 场景占比高 + 搜索流量带来的「游客效应」。

大家都把它当百科全书用，用完即走，这种“冷淡”其实反而是科技区作为“基础设施”的一种价值体现。如果非要强行提升互动率，可能会破坏这种高效获取信息的体验。

知识点复盘：

- **加权平均思维**：通过计算反推其他业务线的水平，量化差异。
- **用户动机分析**：区分“逛街心态”（Feed流）与“找货/解决问题心态”（搜索流）。
- **场景与设备**：分析师不能只看数，要看用户是在什么设备、什么环境下用的产品（PC vs Mobile）。
- **指标拆解**：总量指标（互动率）需要拆分为细分指标（赞/评/藏）来看结构差异。

(面试官视角切换)

好，刚才我们已经把“原因”拆得很透了，尤其是关于搜索流量和设备端的分析，非常有说服力。

现在，我想请你基于刚才的分析做个决策。

下一题：如果经过验证，我们发现确实是因为“搜索来源的未登录用户”占比过高（超过 50%）导致了互动率低。现在增长团队提出一个激进方案：

「针对科技类搜索来源的用户，在浏览回答超过 30% 长度时，强制弹窗引导登录（或者下载 App），不登录不让看剩下的内容。」

题目 42

面试真题：知乎问答社区中，科技话题的日均浏览量占总流量的18%，但该类目下的用户互动率（点赞+评论+收藏）仅为3%（平台均值7%），可能是什么原因？

解答

当听到 18% 的流量占比对应只有 3% 的互动率，而且远低于大盘 7% 的时候，你的第一反应绝对不能是急着找借口说「这届用户不行」，而是要先拿笔算一算这组数据意味着什么，然后建立一个结构化的漏斗思维来拆解。

这道题考察的其实是对「流量性质」、「用户场景」以及「设备差异」的理解深度。

第一部分：先把数字算清楚，量化差距

别光盯着 3% 觉得低，我们先做一个简单的反向推导，看看「非科技类」的数据得达到什么水平，才能把大盘拉到 7%。

假设全站流量是 100。科技类流量占比 18%，互动率 3%。其他类目流量占比 82%，设互动率为 X。

全站互动率公式： $(18\% * 3\%) + (82\% * X) = 7\%$

计算过程： $0.0054 + 0.82X = 0.07$
 $0.82X = 0.0646$
 $X \approx 7.9\%$

你看，这个数字其实很有意思。非科技类目（情感、娱乐、职场等）的平均互动率大概在 7.9% 左右。

这意味着，科技类目（3%）并不是稍微低一点，而是呈「断崖式」下跌，不到其他类目的一半。这种数量级的差异，绝对不是一句「内容质量参差不齐」就能解释的，一定存在**结构性**和**场景性**的根本不同。

第二部分：最大的嫌疑人——流量来源与用户动机

这是最关键的切入点。

知乎的科技类话题，有一个非常特殊的属性：**极强的工具属性和搜索属性**。

我们还原一下用户场景。当一个用户在刷「情感」或「吃瓜」话题时，他通常是在 App 的推荐流里「逛」，心态是放松的、社交的。看到有意思的就点个赞，看到不爽的就喷两句，互动意愿天然很高。

但是，科技类内容的流量，根据经验判断，很大一部分并不来自站内的推荐流（Feed），而是来自**站外搜索（SEO）**。

你想想，你平时什么时候看科技类内容？很可能是手机坏了、Python 代码报错了、Excel 公式忘了、或者想买新耳机了。你去百度或者 Google 搜了一下，然后点进了一个知乎的回答。

这时候你的动机是「解决问题」，也就是「用完即走」。

场景还原：你搜“Python 列表怎么去重”，点进知乎，看到了代码，复制，跑通了，关掉网页。结果：后台记录了一个 PV（浏览量），但你大概率没有登录，或者懒得登录，更别提点赞收藏了。你的需求在“看到答案”的那一刻就已经被满足并终止了。

推断：科技区的 18% 流量里，可能包含了比其他分区高得多的「游客流量」或「一次性搜索流量」。这部分流量的天然互动率就是极低的。

第三部分：设备端的隐形杀手——PC 端的占比

这一层很多人容易漏掉。

科技类（尤其是编程、软件、办公技巧类）内容，用户阅读的设备场景是什么？**很多时候是 PC 端（电脑网页版）**。

程序员在写代码，或者白领在做 PPT，他们是在电脑浏览器上打开知乎的。

相比于 App 端，PC 网页端的交互体验是抑制互动的：

- **登录状态不稳定**：很多人网页版是未登录状态。
- **交互路径长**：App 上双击屏幕就点赞了，网页版还得把鼠标移过去点一下小手。
- **打字评论成本**：虽然键盘打字快，但网页版的评论区折叠做得比较深，不像 App 那样直接外露诱导评论。

如果后台数据显示，科技区的 PC 端流量占比达到 30% 甚至更高（而娱乐区可能 99% 都是手机端），那么互动力低就是一个必然的「设备物理属性」结果，而非内容不行。

第四部分：内容属性的“高冷”与“时效性”

这块得聊聊内容本身的特质。

1. **高门槛带来的“沉默螺旋”**：如果是一篇深度硬核的技术分析（比如 AI 算法推导），大部分用户可能处于“不明觉厉”的状态。看懂都费劲，更别说评论了。怕露怯，怕说错话被嘲讽，所以在这个领域，“**沉默的观察**

者”比例会非常高。这点和情感题完全不同，情感题谁都能插两句嘴。

2. **极度理性，缺乏情绪：** 互动率通常是由「情绪」驱动的。大盘 7% 的互动率里，包含了大量的争吵、站队、共鸣。但科技圈讲究客观中立。一个评测好就是好，坏就是坏，很难像情感贴那样激发强烈的“站队”欲望。没有情绪的剧烈波动，手指头按赞的动力就不足。
3. **长尾内容的时效性衰减：** 科技流量里有很多是几年前的“教程”。比如“怎么重装系统”。用户搜进来，看到一个 2019 年的高赞回答解决了问题。但他看到时间是 2019 年，潜意识会觉得“这是一个死掉的帖子”，没有了参与互动的“现场感”。流量还在产生，但互动已经停止了。

第五部分：产品体验与指标定义的坑

最后，别忘了排查一下是不是“算错了”或者“指标定义偏差”。

- **收藏率 vs 点赞率：** 科技类内容还有一个特点，就是“收藏率”可能会比“点赞率”高。用户觉得这代码有用，当作资料库“收藏”了备用，但他不一定“点赞”。如果我们的互动率定义是简单相加（点赞+评论+收藏）/ 浏览量，可能还看不出问题。但如果只看点赞，科技区会更惨。我们需要拆开看，是不是科技区的 **(收藏 / 浏览)** 其实远高于大盘？如果是，说明价值被认可，只是认可方式不同。
- **浏览量的定义（分母太大了？）：** 这个 18% 的日均浏览量，如果包含“列表页曝光”，那可能是科技类的封面图比较吸引人（比如手机美图），大家点进去了，发现内容太硬核看不下去，马上退出了（高跳出率）。如果是这种情况，那说明不是互动差，而是**内容分发匹配度**有问题，把硬核内容推给了小白用户。

怎么验证这些猜想？

光说没用，作为分析师，你必须给出**验证方案**。我会拉下面这几组数据：

1. **分来源转化率：** 对比 搜索来源 vs 站内推荐来源 的互动率差异。
2. **分设备转化率：** 对比 PC 端 vs App 端 的互动率差异。
3. **用户登录率：** 看浏览科技话题的用户里，未登录用户的比例是多少。
4. **互动类型拆解：** 把 点赞、评论、收藏 拆开看。验证是否存在“高收藏、低点赞”的现象。

总结归纳

看到这其实就能大概心里有数了。

科技话题互动力低，**核心大概率不是因为内容质量差，而是因为「工具人」属性太重 + PC 场景占比高 + 搜索流量带来的「游客效应」。**

大家都把它当百科全书用，用完即走，这种“冷淡”其实反而是科技区作为“基础设施”的一种价值体现。如果非要强行提升互动率，可能会破坏这种高效获取信息的体验。

知识点复盘：

- **加权平均思维：** 通过计算反推其他业务线的水平，量化差异。
- **用户动机分析：** 区分“逛街心态”（Feed流）与“找货/解决问题心态”（搜索流）。

- **场景与设备**：分析师不能只看数，要看用户是在什么设备、什么环境下用的产品（PC vs Mobile）。
 - **指标拆解**：总量指标（互动率）需要拆分为细分指标（赞/评/藏）来看结构差异。
-

(面试官视角切换)

好，刚才我们已经把“原因”拆得很透了，尤其是关于搜索流量和设备端的分析，非常有说服力。

现在，我想请你基于刚才的分析做个决策。

下一题：如果经过验证，我们发现确实是因为“搜索来源的未登录用户”占比过高（超过 50%）导致了互动率低。现在增长团队提出一个激进方案：

「针对科技类搜索来源的用户，在浏览回答超过 30% 长度时，强制弹窗引导登录（或者下载 App），不登录不查看剩下的内容。」

目的是为了强行把这些游客转化为注册用户，提升后续的留存和互动。作为数据分析师，你支持还是反对这个策略？你需要重点监测哪几个指标来做 A/B 测试的评估？

题目 43

样本量计算的艺术：最小可检测效应(MDE)如何影响AB实验的周期与成本？

解答

很多同学第一反应是背公式。

这就错了。这道题考的不是你的记忆力，考的是你对“实验成本”和“业务价值”的敏感度。面试官其实想听的是：你知不知道为了追求过高的精度，会浪费公司多少钱？

第一部分：不要背公式，先搞懂核心逻辑

我们先建立一个最直观的分析框架。做 A/B 实验，其实就是在噪音中找信号。

MDE 也就是最小可检测效应，就是你手里那把尺子的“最小刻度”。

如果你想检测出极其微小的变化（比如转化率提升了 0.01%），这就好比你要用一把普通的尺子去量一根头发丝的直径，那你需要测量非常多次取平均值才能抵消误差。反过来，如果你只需要检测显著的大变化（比如提升 10%），那你随便量几次就能看出来了。

这里有一个至关重要的铁律，你一定要刻在脑子里：

样本量与 MDE 的平方成反比。

注意，是平方！

写成简单的逻辑表达式就是：

$n = \text{总体方差} / \text{MDE的平方}$

这意味着什么？意味着如果你把 MDE 缩小一半（想测得更精细一点），你需要的样本量不是翻倍，而是翻 **4 倍**。如果缩小到原来的三分之一，样本量就是 **9 倍**。

这个非线性关系，就是所有实验周期“爆炸”和成本失控的罪魁祸首。

第二部分：从理论到肉疼的现实

光说理论没感觉，我们来算笔账。这里我用真实的统计学计算器帮你算一下，结果可能会吓你一跳。

假设你在一家电商公司，负责优化详情页的下单转化率。现在的基准转化率是 5%。我们需要设定显著性水平 α 为 5%，统计功效 Power 为 80%。

场景一：你很贪心，想抓住微小的红利

你设定 MDE 为 **1% 的相对提升**。也就是说，你要检测出转化率从 5% 变成了 5.05%。这个变化极其微小，但在数学上要求非常严苛。

这时候套入公式计算，每组需要的样本量高达 **3,000,000（300 万）** 个用户。

如果你每天只有 1 万个用户流量进入这个页面，分流 50% 给实验组，你每天只能跑 5000 个样本。这意味着，这个实验需要跑 **600 天** 才能得出显著结论。

两年跑一个实验？业务方会直接崩溃。

场景二：你变得务实了

你觉得 1% 的提升虽好，但业务节奏快，你只关心显著的大改版。你把 MDE 设定为 **5% 的相对提升**。也就是说，你要检测出转化率从 5% 变成了 5.25%。

这时候，每组需要的样本量会瞬间掉到 **123,000（12 万）** 左右。

虽然看起来还是不少，但相比 300 万，已经少了 25 倍！同样的流量下，大约 **24 天** 就能跑完。

场景三：你追求 MVP 速度

如果业务方说：“我只有一周时间，必须出结果。”

那你只能被迫把 MDE 拉大到 **10% 甚至更高**。此时样本量可能只需要 **3 万**，几天就能搞定。

你看，MDE 从 1% 调整到 5%（放宽了 5 倍），样本量从 300 万降到了 12 万（减少了 25 倍）。这就是“平方反比”威力的具象化。

第三部分：业务视角的深度博弈

好，数字算明白了，但面试还没结束。面试官问这个问题的核心意图，是看你如何做 Trade-off 也就是权衡。

在实际工作中，我们经常面临两难：设定的 MDE 太小，流量不够，实验要跑三个月，业务方等不起；设定的 MDE 太大，又怕错过了那些虽然小、但确实有效的优化。

这时候，该怎么选？

1. 算账：ROI 与机会成本

我会直接跟业务方算一笔账。

“如果我们为了检测这 1% 的提升，让实验跑两个月。这两个月里，我们需要封锁这部分流量，意味着我们无法在这部分流量上测试其他可能带来 20% 增长的新功能。”

这就是**机会成本**。

对于初创期或快速迭代期的业务，**时间价值 > 微小提升**。我们会故意调大 MDE，只筛选那些“大鱼”。如果一个策略不能带来 5% 以上的增长，我们宁愿当它没发生，因为维护它可能还要成本。

2. 看流量池大小

这也是个很现实的问题。如果你是 Google 搜索页，流量大到没边，你当然可以把 MDE 设得很小，去抠那 0.001% 的优化，因为你一天就能跑几百万样本。

但如果你是 B 端产品，或者某个深层转化漏斗，每天只有几百个 UV。那你没得选，你只能接受一个巨大的 MDE（比如 20%）。

意思就是：除非这个改动有“整容般”的效果，否则在这个流量下我们根本测不准。承认“测不准”，也是分析师专业性的一部分。

3. 固定的时间窗口

很多时候，逻辑是反过来的。不是根据 MDE 算时间，而是根据时间定 MDE。

业务方会说：“下周就要在大促上线，这个实验最多跑 5 天。”

这时候由于时间锁死了，流量也就是样本量也就锁死了。根据公式，在样本量固定的情况下，你能检测的 MDE 其实也就确定了。

你需要做的，是算出这个 MDE，然后告诉老板：“在这个时间限制下，我们只能检测出 8% 以上的提升。如果提升只有 3%，实验结果会显示不显著，但这不代表没效果，只是我们测不出来。”

4. 高级武器：不动 MDE，怎么降样本？

如果你想展示你的技术深度，这里可以加一个“杀手锏”。

如果业务方既要 MDE 小（测得准），又要时间短（跑得快），怎么办？

这时候你可以提一个概念：**CUPED（方差缩减技术）**。

回顾公式： $n = \text{总体方差} / \text{MDE的平方}$ 。

如果 MDE 不能动，我们可以想办法降低分子的“方差”。通过引入用户实验前的历史行为数据作为协变量，我们可以消除部分噪音，从而在不降低 MDE 的前提下，显著减少所需的样本量。这在 Uber、Airbnb 等大厂是标配。

第四部分：总结一下核心知识点

回答完这个问题，我们来整理一下用到的知识卡片：

- **核心关系**：样本量与 MDE 的平方成反比。MDE 越小，样本量呈指数级暴涨。
- **三要素制约**：样本量（流量/时间）、MDE（精度）、统计功效 Power 是一个铁三角。动一个，另外两个必须变。
- **业务决策分类**：大流量业务可以追求小 MDE，做精细化运营；小流量业务只能接受大 MDE，追求 MVP 式的大改版。
- **隐性成本**：实验周期本身就是成本（机会成本），不要为了单纯的“统计显著”而牺牲业务迭代速度。

说白了，控制 MDE 就是在控制公司的**试错成本**。

你要让面试官感觉到，你不是一个只会算数的计算器，而是一个帮公司省钱、赚钱的策略师。

（面试官视角切换）

刚才这部分关于 MDE、样本量爆炸式增长以及 CUPED 的补充非常精彩，特别是纠正了很多人对样本量数量级感知的偏差。

那么，我想顺着这个实验周期的话题继续追问一下：

如果我们在做实验时，原本计划跑两周，结果跑了三天发现 P 值就已经小于 0.05 了（显著了），这时候业务方很着急，催着我要提前停止实验全量上线，你会同意吗？为什么？

题目 44

转化漏斗优化必学！为什么归因分析要区分First-touch和Last-touch模型？

解答

你要记住一句话：**你选择什么归因模型，决定了你把预算分给谁，也决定了你认为谁才是业务增长的大功臣**。这直接关系到公司的钱怎么花，以及不同部门（比如品牌部 vs 投放部）的绩效怎么算。

下面我们按照“核心差异 -> 真实业务场景推演 -> 数字化计算 -> 避坑指南”的逻辑，把这个问题彻底拆解清楚。

一、先搞清楚咱们在争什么

为什么要刻意区分 First-touch（首次触点）和 Last-touch（末次触点）？

这不仅仅是谷歌分析后台的一个设置选项，这反映了公司的**战略重心**。我们先建立一个最基本的分析框架：

- First-touch 首次互动模型：谁把用户“领进门”，谁就是老大。这关注的是**拉新和品牌认知**。它的核心逻辑是：没有第一次的看见，后面的一切都不会发生。
- Last-touch 末次互动模型：谁把用户“推下单”，谁就是老大。这关注的是**转化和临门一脚**。它的核心逻辑是：只有最后掏钱的那一刻才是真金白银，前面的都是铺垫。

这俩模型的根本矛盾在于：**用户的转化路径通常不是线性的，而是一个漫长的、跨渠道的、充满犹豫的过程。**

如果咱们只看 Last-touch（这是大多数公司的默认设置，也是财务最喜欢的设置），很容易产生一种错觉：只有最后那个发优惠券的渠道是有用的，前面做品牌曝光的渠道都是浪费钱。结果你一砍预算，发现后面那个“有用”的渠道也跟着挂了。

二、带数字的业务场景推演（必考点）

光说理论太干了，我们直接模拟一个真实的电商场景，并带入成本算一下账，你就能看到差距有多恐怖。

假设你在一家卖高端扫地机器人的公司，客单价 3000 元。这种高客单价产品，用户很少冲动下单，决策周期通常需要两周。

我们来看一个标准用户的购买路径：

- Day 1：用户在**小红书**刷到了一个博主的测评视频，觉得这东西吸力很大，种草了，但他没买，划走了。（这是 First-touch）
- Day 3：用户想起来这事儿，去**百度/Google**搜了一下品牌名，进了官网看了看参数，觉得有点贵，又关掉了。
- Day 7：用户在**朋友圈**看到了双十一大促的预热广告，还是没动。
- Day 14：用户收到了一条**短信**，写着“购物车商品仅剩 2 件，今晚下单立减 200 元”。用户一激灵，点开链接直接下单支付了 3000 元。（这是 Last-touch）

现在我们要开始分钱和分锅了。

为了算清楚，我们假设：

- 这一次小红书投放平摊到该用户身上的成本是 50 元。
- 那条短信的成本是 0.05 元。

场景 A：如果你坚持用 Last-touch 模型

- 业绩归属：3000 元销售额全部算在**短信渠道**头上。

- 成本计算：短信成本 0.05 元，带来收入 3000 元。
- 只要算一下 ROI（投入产出比）： $3000 / 0.05 = 60000$ 。
- 结论：老板一看报表，哇塞，短信营销太赚钱了！ROI 爆表！而小红书花了 50 元，转化产出是 0，ROI 是 0，简直是浪费钱。
- 决策后果：下个季度砍掉小红书预算，全部用来发短信。结果你会发现，发再多短信也没人买了，因为“源头活水”被你切断了，根本没人知道你的品牌了。

场景 B：如果你切换到 First-touch 模型

- 业绩归属：3000 元销售额全部算在小红书头上。
- 成本计算：小红书成本 50 元，带来收入 3000 元。
- ROI 计算： $3000 / 50 = 60$ 。
- 结论：种草才是王道！短信团队就是捡漏的，别发了，省点钱。
- 决策后果：你停了短信和促销，发现虽然很多人看视频、搜产品，但就是没人最后掏钱，都在观望等降价。转化率直线下降。

分析师的关键洞察：你看，同一个用户、同一笔订单，因为归因模型不同，得出的 ROI 结论是天壤之别。如果不区分清楚，完全可能导致错误的预算分配，把真正有贡献的渠道给冤杀掉。

三、深度业务决策：到底怎么选？

面试官问你“为什么要区分”，其实是想听你在不同业务阶段怎么做取舍。这里面有几个关键的业务判断标准：

1. 看产品生命周期和业务目标

- **业务刚起步 / 新品牌上市：**你急需知名度，急需拉新。这时候如果你只看 Last-touch，你会觉得所有的硬广、KOL 投放都投不下去，因为它们离成交太远了。这时候 **First-touch** 的权重必须高，要鼓励团队去外面“撒网”，哪怕短期不成交也没关系。
- **业务成熟期 / 冲业绩阶段：**流量池已经很大了，现在的任务是把存量用户变现。这时候 **Last-touch** 很重要，你要看哪个渠道能最高效地完成收割（比如重定向广告、EDM 邮件、短信）。

2. 看产品属性与决策链路

- **低客单价、决策快的产品（比如奶茶、纸巾）：**用户看到就买，链路极短。First-touch 和 Last-touch 往往是同一个，或者隔得很近，这时候区分的意义没那么大，直接看 Last-touch 效率最高。
- **高客单价、决策慢的产品（比如 B 端软件、汽车、医美、教育）：**链路极长。First-touch 带来的线索（Lead）非常珍贵，哪怕他三个月后才通过销售电话（Last-touch）成交，你也不能忽视最早那个广告功劳。如果你用 Last-touch 考核，市场部就不愿意去投高质量的内容了，只会去搞促销。

3. 这是一个“归因窗口期”的问题

这里有个细节很多人会漏掉。就算你选了 Last-touch，你还得看回溯期是多久。是 Lookback 7 天，还是 30 天？

如果你的窗口期设置得太短（比如 1 天），那 First-touch 的价值就被进一步压缩了。所以，我们在做对比的时候，通常会把这两组数据拉出来做个 **差异分析**。

比如，某个渠道在 First-touch 下的 ROI 是 5，在 Last-touch 下只有 0.5。这就说明：**这个渠道是典型的“助攻手”，而不是“射手”**。你的策略应该是：保留它作为流量入口，但不要指望它直接产出 GMV。

四、现实世界的残酷真相（必杀技）

聊到这儿，你得跟面试官展示一点“老鸟”的经验了。现实比模型要复杂得多，这里有两个巨大的坑：

第一，跨APP的数据断层（Walled Gardens）。上面的例子很完美，但现实中，用户在小红书被种草，然后切换到京东去下单。你要注意：**小红书的数据和京东的数据是不互通的！**在京东的后台看，这个用户可能是“直接访问”或者“搜索进入”的，京东根本不知道他之前看了小红书。这会导致 First-touch 的贡献被严重低估。这也是为什么现在大家都在做“全域监测”或者用“营销 mix 模型（MMM）”来推算，而不是单纯依赖追踪链接。

第二，部门利益的博弈。这其实是个管理问题。品牌部通常死守 First-touch，因为这证明了他们花钱打广告是有用的；电商运营部死守 Last-touch，因为这证明了他们的转化手段有效。作为数据分析师，你的工作不是选边站，而是**把两张表都做出来**，告诉老板：A表代表我们的未来（品牌声量），B表代表我们的现在（现金流）。我们不能只看一张表。

五、总结归纳

回答完这个问题，这几个核心点你得心里有数：

- **归因模型本质：**是规则集，决定如何将转化功劳分配给路径上的不同触点。
- **助攻效应：**必须识别出那些 ROI 低但助攻能力强的渠道（First-touch 表现好，Last-touch 表现差）。
- **ROAS 的欺骗性：**单一模型的 ROAS 往往是片面的，一定要结合 First/Last 对比看。
- **业务阶段决定模型：**拉新期看头，收割期看尾。

面试官视角：追问环节

（注意：我现在切换到面试官模式，只提问，不解答，用来测试你的临场反应）

面试官：“好的，逻辑很清晰，特别是那个 ROI 对比的例子，很形象。那你刚才也提到了，单纯看 First 或者 Last 都有点极端。如果我们现在的业务场景是——用户决策周期大概 20 天，中间会跨越 APP、微信生态和 Web 端三个环境，而且数据有断层。

在这种多端、长周期、且数据追踪不完整的环境下，你会建议我们使用什么更高级的归因方法？既然线性归因（Linear）太平均主义了，时间衰减（Time Decay）又偏向后期，有没有更科学的、甚至基于统计学的方法来评估渠道贡献？”

题目 45

解答

面试官问这个，表面上是在问算法原理，实际上是在考察你对**业务场景特征（数据量、维度、实时性）**的理解深度。

咱们直接把这两个算法放在风控的实战场景里“打一架”，你就知道谁更适合干什么活了。

第一部分：核心逻辑的本质差异

首先得建立一个大框架。虽然它俩都能用来抓坏人，但底层逻辑完全是反着的。

孤立森林（iForest）的逻辑是“切蛋糕”

它假设异常点是“疏离”且“独特”的。就像你在一堆普通人里找一个身高两米三的姚明，你不需要量每个人的身高。你只要随机划几刀（随机选择特征和切分点），很快就能把姚明单独划到一个格子里，因为他太特别了。而普通人身高差不多，挤在一起，你得切很多很多刀才能把他们分开。

这里的核心数学逻辑是：**路径长度**。

在树结构里，一个点被“孤立”所需的切分次数越少，路径越短，它就算出来的异常分数就越高。普通样本因为密集，需要切很多次才能分出来，路径就很长。

DBSCAN 的逻辑是“找邻居”

它是一种基于密度的聚类。它规定一个圈子（半径 Epsilon），看圈子里有多少人（MinPts）。如果你的圈子里没人，或者人不够多，那你就是“噪声”，也就是异常点。

它的核心逻辑是：**密度直达**。谁没朋友，谁就是坏人；或者倒过来说，谁朋友多且紧密，谁就是好人团伙，或者是抱团的黑产大军。

这一听你大概就能感觉到，在风控这种动不动几百万数据量的场景下，这两个家伙的表现会天差地别。

第二回合：实战中的效率与算力推演（iForest 完胜）

风控场景最大的特点是什么？数据量大，特征多，时效要求高。

iForest 是线性的，简直是工业界的宠儿。

它的时间复杂度大约是 $O(n)$ 。哪怕你有几百万条交易流水，它构建一堆随机树的速度非常快。因为它不需要算“距离”，它只需要随机选个特征，随机选个切分点，咔嚓一刀下去就行。

DBSCAN 就比较吃力了。

它要算距离。标准的 DBSCAN 时间复杂度是 $O(n^2)$ 。

我们可以做一个简单的算力推演：假设我们有 10 万个用户（ $n=100,000$ ）。对于 iForest，计算量级大概是 10 万乘以 树的数量（比如 100），加上一些常数，计算机瞬间算完。对于 DBSCAN，如果要两两计算距离，那是 10 万乘以 10 万，也就是 **100 亿** 次计算。如果不加复杂的索引优化，这个计算量直接能把服务器跑崩。

所以在海量数据的“海选”阶段，我肯定首推 iForest。等 DBSCAN 跑完一遍，黄花菜都凉了，黑产早把钱转走了。

第三回合：高维数据的诅咒（iForest 再胜）

风控模型的特征通常多少维？少的几十维，多的几百上千维（用户行为序列、设备指纹、IP 画像等）。

DBSCAN 对高维数据极其敏感。

这就是著名的“维度诅咒”。在高维空间里（比如超过 100 维），欧式距离会失效。点与点之间的距离差异会变得非常小，你会发现所有点之间的距离都差不多。这时候你很难选出一个合适的半径来圈人。如果你非要用 DBSCAN，你得先花大量时间做降维（比如 PCA），但这又会丢失信息。

iForest 对高维数据的容忍度比较好。

虽然它也有维度问题（太多无关特征会稀释异常的显著性），但因为它每次是随机选特征切分，那些有区分度的特征总会被选到。

而且在工程实践中，我们通常使用子采样（**Sub-sampling**）技术。比如即使你有 100 万数据，我每棵树只抽样 256 个点来建树。这不仅极快，而且极好地解决了“Swamping”（正常样本包围异常样本）和“Masking”（异常样本太多导致异常被掩盖）的问题。

第四回合：特殊场景——LBS 与团伙挖掘（DBSCAN 的反杀）

既然 iForest 这么强，那 DBSCAN 是不是就废了？也不是，在一种特定场景下，DBSCAN 是神。

那就是**基于地理位置（LBS）的风控**，以及**形状怪异的团伙挖掘**。

iForest 擅长抓“数值上的全局异常”。比如大多数人一天转账 5 次，这个人一天转账 500 次，数值差异巨大，iForest 一眼就能看到。

但在地理位置上，iForest 就很尴尬。经度和纬度是强耦合的，你不能单独把经度切一刀，纬度切一刀，那样会破坏地理空间的真实距离感。

这时候，DBSCAN 这种基于密度的算法就神了。比如外卖刷单、网约车虚假行程。黑产可能会在同一个小区里弄几百台手机在这个坐标点附近虚拟定位。这些点在地图上会聚成一个非常紧密的簇。DBSCAN 不需要假设数据是圆球形的，它可以发现任意形状的簇。如果你的目的是**挖出线下的黑产窝点**，或者识别那种沿着街道分布的异常聚集，DBSCAN（或者它的变种 HDBSCAN）有着 iForest 无法比拟的优势。

第五回合：参数调优的难易度

这点做过落地的人都懂，调参是玄学。

iForest 的参数非常少且鲁棒。基本就调两个：树的数量和每棵树的样本量。通常设个 100 棵树，采样 256 个点，效果就非常好了。你稍微改改参数，结果不会剧烈波动，稳得一匹。

DBSCAN 的参数简直是折磨。那个半径 Epsilon 和最小点数 MinPts，太难调了。Epsilon 设小了 0.01，全是异常点（噪声）；设大了 0.01，所有人都聚成一类了。最要命的是，风控数据的密度是**不均匀**的。比如大促期间的正常交易密度极高，而深夜的交易密度稀疏。DBSCAN 用**同一个**参数去扫全图，根本没法兼顾。虽然有 OPTICS 这种改进算法，但计算成本又上去了。

总结一下实战策略

如果在面试里，我会这么总结我的选型逻辑：

第一阶段：海选与冷启动（选 iForest） 在这个阶段，面对海量高维数据，我追求效率和覆盖。iForest 效率高、参数好调、不受距离度量限制，能帮我快速捞出一批嫌疑最高的样本，丢给人工审核去打标。它像是一挺**机关枪**，先进行火力覆盖。

第二阶段：精细化挖掘与空间风控（选 DBSCAN） 当我们已经锁定了一些可疑维度，特别是涉及到**地理位置（经纬度）*或者需要挖掘*特定形状的黑产团伙**时，我会把数据范围缩小，降维，然后用 DBSCAN 做精细化聚类。它像是一个**放大镜**，在局部区域找线索。

本次解答用到的知识点总结

- **iForest (孤立森林)**：基于二叉树随机切分的集成算法，核心指标是路径长度。路径越短，异常分越高。适合高维、海量数据。
- **DBSCAN**：基于密度的空间聚类算法。核心概念是半径和最小邻居数，通过密度直达关系来聚类。适合低维、空间数据、非球形簇。
- **维度诅咒**：高维空间下，距离度量失效，数据变得稀疏，基于距离的算法（如 KNN、DBSCAN）效果急剧下降。
- **Swamping & Masking**：异常检测中的两个常见问题。Swamping 是正常样本被误判为异常（因为太靠近异常）；Masking 是异常点太密集，导致被误判为正常。iForest 的子采样能很好地解决这两个问题。
- **LBS 风控**：基于 Location Based Service 的风控，是密度聚类算法的主战场。

(切换至面试官视角)

嗯，分析得很透彻，特别是关于 $O(n)$ vs $O(n^2)$ 的推演，以及 LBS 场景的补充，非常有实战意义。

既然你提到了孤立森林是基于“随机切分”的，且主要处理数值型特征比较顺手，那我想请问你：**在处理风控数据时，如果我有大量的离散型特征 (Categorical Features)，比如 '省份'、'手机品牌'、'支付渠道'，直接扔进孤立森林会有什么问题？你应该怎么预处理这些特征才能让孤立森林发挥最大效果？**

题目 46

个性化排序的核心！为什么很多信息流产品都在用 Learning to Rank(LTR)框架？

解答

第一部分：别被表象骗了，先算一笔账

很多候选人上来就会背概念，说 LTR 有 Pointwise、Pairwise、Listwise。这没错，但太书本了。面试官想听的，是你对「业务目标」和「数学目标」之间错位的理解。

咱们先算一笔具体的账，你就明白为什么传统的预测模型（比如逻辑回归预测点击率）在排序这件事上会失效。

假设我们只有两个视频：视频 A 和视频 B。

真实情况是：用户非常喜欢 A（真实分数为 10 分），一般喜欢 B（真实分数为 5 分）。

也就是：A 必须排在 B 前面。

现在我们训练了两个模型，来看看它们的表现：

模型一（预测很准，但排序错了）：

预测 A 得分：6 分。

预测 B 得分：8 分。

你看，从数值上看，预测值 6 和 8，距离真实值 10 和 5 的误差其实都在可接受范围内。

但是，模型一认为 $B > A$ ，于是把 B 排在了 A 前面。

这对用户体验是致命的，因为用户最喜欢的 A 被埋没了。

模型二（预测偏差大，但排序对了）：

预测 A 得分：100 分。

预测 B 得分：90 分。

从回归（MSE）的角度看，这个模型烂透了！预测值 100 离真实值 10 差了十万八千里。

但是，请注意，模型二认为 $A > B$ 。

在最终展现给用户时，A 依然排在 B 前面。用户根本看不到那个离谱的 100 分，用户只看到他喜欢的 A 出来了。

结论非常残酷：

如果我们用传统的回归或分类模型（Pointwise 思路），我们的优化目标是「让预测分更准」（降低均方误差 MSE 或 Logloss）。

但我们的业务目标是「让顺序更对」（提升 NDCG 或 MAP）。

这两个目标在数学上是不对齐的。刚才的例子证明了，有时候误差变大了，排序反而变好了。

这就是为什么我们需要 LTR：我们需要一个直接针对「顺序关系」进行优化的算法，而不是隔靴搔痒地去优化预测分。

第二部分：拆解 LTR 的三种进化路线

理解了核心冲突，我们再来看业界是怎么一步步解决这个问题。这里一定要结合计算成本和效果来讲。

1. Pointwise（单点法）：披着 LTR 外衣的传统模型

这是最原始的阶段。虽然把它归在 LTR 里，但它本质上还是在做回归或分类。

输入一个用户、一个视频，输出一个分。

它的死穴在于「孤立」。模型在看视频 A 的时候，完全不知道视频 B 的存在。

这就导致模型会浪费大量算力去区分「非常差」和「比较差」的视频。

比如，视频 C 的真实分是 1 分，视频 D 的真实分是 2 分。Pointwise 模型会拼命去学习 1 和 2 的区别。

但在实际业务中，C 和 D 都是垃圾，根本不会展现给用户，它俩谁排前谁排后完全没意义。我们要关注的是头部谁排第一。

2. Pairwise（配对法）：真正的 LTR 入门

这是目前性价比最高的思路。它的核心逻辑变成了「找茬」。

它不看具体的数值，而是把样本两两配对。

比如（视频 A，视频 B）。如果用户点了 A 没点 B，那标签就是： $A > B$ 。

模型的 Loss Function（损失函数）现在的目标是：尽可能减少「逆序对」的数量。

如果模型预测 $A < B$ ，这就和事实反了，Loss 就会飙升，逼着模型去把 A 提上来，把 B 压下去。

这非常符合信息流的场景——用户下滑的过程，本质上就是不断地在做「二选一」或者「多选一」的比较。

但 Pairwise 有个巨大的工程坑：样本爆炸。

如果你有 n 个文档，两两配对就是 n 的平方级复杂度。

如果有 1000 个视频，就要算 $1000 * 999$ 也就是百万级的 Pair。这对训练速度是灾难。

现实中的解决办法：负采样（Negative Sampling）。我们通常只拿「用户点击的正样本」去和「展示了但没点的负样本」做配对，而不是所有视频两两配对，这样把复杂度降下来。

3. Listwise（列表法）：上帝视角，但太贵了

这个思路最理想。它直接看整个列表的排列效果。

它想直接优化 NDCG（归一化折损累计增益）。

NDCG 是什么？简单说，就是把好东西排在前面得分很高，排在后面得分衰减很快。

比如第一名排对了得 10 分，第二名排对了可能只得 5 分，第十名排对了只得 0.1 分。

Listwise 试图让模型“理解”位置的重要性。

但它计算太复杂，收敛很难。所以在工业界，除了像 Google、百度这种对头部搜索结果极其敏感的场景，大部分推荐系统只用到 Pairwise 就够了，或者用 SoftRank 这种近似方法。

第三部分：深入实战——不可导的痛点与 Lambda 的魔法

这一段是区分「调包侠」和「算法工程师」的分水岭。

面试官可能会问：你刚才说要直接优化 NDCG，但 NDCG 这个指标是「阶跃」的，它不可导，梯度怎么算？

比如，视频 A 从第二名挪到第一名，NDCG 突变了一下。中间没有平滑的过渡，梯度断了，怎么做反向传播？

这时候你要提到 LambdaRank 或 LambdaMART。

这几个算法的天才之处在于，它们跳过了「定义 Loss」这一步，直接定义了「梯度」。

听起来很怪，对吧？

通常是：Loss -> 求导 -> 得到梯度。

LambdaRank 说：我不算 Loss 了，我直接根据 A 和 B 的位置交换会导致 NDCG 变化多少，来强行赋予它们一个“物理力”（梯度）。

如果 A 换到 B 前面，NDCG 涨了很多，那这个“力”（Lambda）就很大，狠狠地推一把。

如果 NDCG 没怎么变，这个力就很小。

这就是 LTR 在数学上的核心魔法：用 Lambda 梯度去模拟不可导的排序指标。

第四部分：业务中的隐形杀手——Position Bias（位置偏差）

在实际工作中，上 LTR 往往会遇到一个巨大的陷阱，不提这个说明你没踩过坑。

数据里充满了 位置偏差。

用户点击第一个视频，往往不是因为它是最好的，仅仅因为它在第一个位置（流量红利）。

如果你直接拿这种历史日志去训练 LTR 模型，模型会“学傻了”。

模型会认为：只要是排在第一位的特征，就是好特征。

结果就是：原来的热门内容永远排在前面，新内容永远出不来，模型完全固化了。

怎么解决？

方案一：将 Position 作为特征。

训练的时候，把「位置信息」作为一个特征喂给模型。模型会学会：“哦，原来这个点击是因为位置好带来的，不是内容好”。

预测的时候（线上服务时），把这个「位置特征」强制置为一个默认值（比如都设为 0 或者都设为 1），以此消除位置带来的偏见。

方案二：COEC（点击超越预期）。

用观察到的点击率除以该位置的平均点击率，用这个比值作为 Label 去训练，而不是直接用点击行为。

第五部分：总结与知识图谱

这一路拆解下来，逻辑链条非常完整了。总结一下核心知识点，方便你复盘：

- **核心矛盾**：回归/分类模型的 Loss（MSE/Logloss）与排序指标（NDCG/MAP）数学上不对齐。预测准不等于排序准。
- **三种范式**：
 - Pointwise：本质还是回归，忽视了样本间的相对关系，浪费算力在长尾样本上。
 - Pairwise：关注相对顺序（A>B），最常用，但有样本 $O(n^2)$ 爆炸问题，需配合负采样。
 - Listwise：直接优化整体列表，理论最强，工程落地最难。
- **数学魔法**：LambdaRank/LambdaMART 通过定义“Lambda 梯度”解决了排序指标不可导的问题。
- **业务大坑**：必须处理 Position Bias（位置偏差），否则模型会陷入“强者恒强”的死循环。

看到这里，你大概就能意识到，LTR 不仅仅是一个算法选择，它是对业务目标（用户体验排序）最精准的数学翻译。

面试官追问：

刚才你讲得非常透彻，特别是关于 Pointwise 和 Pairwise 的取舍。

现在深度学习（Deep Learning）非常流行，像 DeepFM、DIN 这些模型本质上还是 Pointwise 的结构（输入用户+物品，输出概率）。

我的问题是：如果我们既想要深度学习提取特征的强大能力，又想要 LTR 对排序的优化能力，你会怎么设计这个模型架构？比如，怎么把 Pairwise Loss 结合到深度网络里去？这在工程上会有什么新的挑战？

题目 47

面试真题：京东到家在某城市试点"30分钟达"服务后，该区域订单量提升60%且用户满意度NPS提高15分，但配送成本上涨85%，骑手人效下降30%，3个月后该服务取消，如何复盘这次决策并提出数据驱动的改进方案？

解答

面试官真正想听的是：亏在哪里？底层的经济模型是怎么崩塌的？如果不砍，这盘棋还有没有救？

第一部分：先看一眼致命的账本（UE模型崩塌）

我们先不管用户多满意，先算账。生鲜 O2O 行业是一个典型的「微利」甚至「负利」行业，每一毛钱的成本波动都能决定生死。

我们来做一次具体的带数推演，把这个模糊的百分比变成直观的钱：

假设试点前：

- 日均订单：10万单
- 单均配送成本：5元（这是行业大概水位）
- 总配送成本：50万元

试点后（数据代入）：

- 日均订单：16万单（提升60%）
- 总配送成本：92.5万元（ $50万 \times 1.85$ ，上涨85%）

现在的单均配送成本是多少？ $92.5万 / 16万 \approx 5.78元$ 。

结论 1：每送一单，配送成本直接涨了 0.78元。你可能觉得不到 1块钱无所谓？大错特错。在客单价五六十元的商超外卖里，平台的净利往往就在 1-2元之间，甚至很多时候是亏损赚规模。这突增的 0.78元成本，极大概率直接击穿了毛利模型。也就是说，订单越多，亏得越狠，且没有边际成本递减的迹象。

第二部分：深挖「人效下降30%」的业务真相

这道题最反直觉的数据是：订单密度明明增加了（涨了60%），为什么骑手人效反而下降了30%？

按照常理，订单越密，骑手顺路带单越多，人效应该更高才对。这里出现反常，说明「30分钟达」这个机制，破坏了即时配送最核心的「并单逻辑」。

我们可以还原一下骑手的真实场景：

1. 并单窗口期被压缩至极限

正常配送（45-60分钟）：骑手接到第1单，系统有 10-15分钟的时间窗口去等待第2单、第3单顺路单进来。骑手一次出车能送 3-5单。30分钟极速达：去掉商家捡货打包 10分钟，路上只剩 20分钟。骑手接到单必须立刻出发，根本等不到顺路单。**后果：**以前一次跑一串，现在一次跑一单。单次运力的产出直接腰斩。

2. 只有京东到家才会有的「捡货黑洞」

这一点必须结合业务背景看。京东到家和叮咚买菜不同，它没有前置仓，它是去沃尔玛、永辉这种大超市捡货。你想想，骑手停好车、跑进商场、找到柜台取货、再跑出来，这就要消耗极长的固定时间。如果时效要求宽裕，骑手可以一次进商场取 5 个单子。现在要求 30 分钟，骑手必须频繁进出商场，把大量时间浪费在「走路」和「爬楼」上，而不是「骑行」上。**结论 2：**这种模式下的 30 分钟达，把骑手变成了「专送」甚至「跑腿」，用外卖的价格提供跑腿的服务，这在物理上就不可能盈利。

第三部分：虚荣指标 NPS 的陷阱

NPS（净推荐值）提高了 15 分，这是项目组唯一的遮羞布。

但我们必须冷血地指出：这个 NPS 是「买」来的，不是「赚」来的。

如果你在不加价的情况下，给用户把时效从 60 分钟提升到 30 分钟，用户当然会打高分。这不叫用户体验好，这叫「超预期补贴」。

一旦你试图把这 0.78 元的成本转嫁给用户（涨运费），这个 NPS 泡沫瞬间就会破裂。面试时一定要指出这一点：没有支付意愿验证（WTP）的满意度提升，对商业模式验证是无效的。

第四部分：如果我是负责人，如何救活这个项目？

项目取消是止损，但 60% 的增长证明需求是真实的。复盘的核心在于提出「修正方案」。

如果让我重做，我绝不会搞「全量 30 分钟达」，而是做「精细化分层」。

策略一：服务分层与价格歧视 把服务拆开，把选择权给用户，把成本转嫁给刚需。

- **标准达（45-60 分钟）：** 维持原价或免运费。这是基本盘，保证骑手能并单，稳住成本。
- **极速达（30 分钟）：** 额外加价 3-5 元。
- **逻辑：** 真正急着买药、买冰淇淋的人，愿意多付这 3 元；不着急买米面油的人，会自然分流到标准达。这样既满足了高时效需求，又覆盖了专送成本。

策略二：动态维度的「地理围栏」 不要全城覆盖，数据分析要精细到「网格」。

- **切区域：** 只在订单密度极高、且离商超 1.5 公里以内的「黄金圈」开放 30 分钟达。超过这个物理距离，神仙也送不到，强行送就是拉低人效。
- **切品类（SKU）：** 这点很关键。所有的预制熟食（需要现做）、所有的超重商品（大米、成箱水），直接在系统里剔除「30 分钟达」标签。
- **逻辑：** 必须剔除那些「不仅不赚钱，还拖后腿」的异常订单。

策略三：削峰填谷的动态调度

- **闲时开放：** 下午 2 点-4 点，骑手都闲着。这时候可以免费开放 30 分钟达，因为此时的边际成本几乎为零，正好用来拉升用户体验和留存。

- **忙时熔断：**中午晚上的波峰期，运力本来就爆了，必须直接关闭极速达入口，或者要把加价提到 10 元以上，抑制需求，防止系统崩盘。

第五部分：复盘总结与知识点

这道题解答完，我们要给面试官展示一下我们的知识库。这不仅仅是一个外卖题，这是所有 O2O 业务通用的逻辑：

- **知识点 1：单体经济模型（UE）的红线** 任何增长如果导致 UE 变差（Per Order Contribution Margin 下降），且无法通过规模效应摊薄成本，那就是伪增长。
- **知识点 2：履约效率的核心是「并单」** 即时配送生意的本质是「顺路」。时效越短，并单率越低，履约成本呈指数级上升。
- **知识点 3：价格歧视（Price Discrimination）** 这是解决「高成本高体验」与「低成本低体验」矛盾的最好手段。不要试图用一种服务讨好所有人。

面试官追问（Next Question）

刚刚你的方案里提到了「针对 30 分钟极速达进行加价」。

那么问题来了：如果我们要上线这个加价功能，你如何通过历史数据分析，或者设计一个实验，来确定这个「加价金额」到底是收 3 块钱好，还是收 5 块钱好？你需要看哪些核心指标来做决定？

题目 48

美团外卖在某城市推出“准时宝”服务后，该城市骑手平均配送时长缩短了 8 分钟，但骑手差评率从 2% 上升到了 3.5%，同时用户复购率提升了 12%，如何分析这组数据背后的问题？

解答

这道题乍一看数据挺矛盾的。配送时长缩短了，用户复购率也提升了，说明“准时宝”这个产品从用户体验角度来说应该是成功的。但骑手差评率却从 2% 飙到了 3.5%，涨了 75%，这个数字就很刺眼了。

先把这几个数之间的逻辑捋清楚。

第一部分：先搞清楚这几个指标到底在说什么

配送时长缩短 8 分钟，这是个平均数。假设原来平均配送时长是 38 分钟，现在变成 30 分钟，缩短了 21% 左右。这个提升幅度其实挺大的，说明骑手确实在加速。但这里有个隐藏问题：8 分钟是怎么省下来的？是骑手骑得更快了，还是平台调度算法更优了，还是商户出餐速度提升了？这几个来源对应的业务动作完全不同。

如果我们简单做个拆解，配送时长 = 骑手接单到店时间 + 商户出餐等待时间 + 骑手取餐到送达时间。假设原来这三段分别是10分钟、15分钟、13分钟，总共38分钟。准时宝上线后，如果主要是"骑手取餐到送达"这一段缩短了，比如从13分钟降到了8分钟，那骑手的配送速度提升了38%，这个压力是很大的。

骑手差评率从2%到3.5%，绝对值看起来变化不大，但相对涨幅是75%。差评率这个指标，分母是什么很关键。如果是"被评价的订单数"，那这个涨幅就很实在；如果是"所有订单数"，而评价率本身也在变化，那口径就需要再确认。

我们来算一下：假设这个城市每天10万单，原来评价率是20%，也就是2万单有评价，其中差评400单，差评率2%。现在准时宝上线后，假设评价率提升到25%，也就是2.5万单有评价，差评变成875单，差评率3.5%。差评的绝对数量涨了一倍多，这个变化就很显著了。

用户复购率提升12%，这里得看是绝对值提升还是相对提升。如果原来复购率是50%，提升12%意味着现在是56%还是62%？差别很大。我先假设是相对提升，也就是原来50%，现在变成56%。按美团外卖的体量，6个百分点的复购率提升意味着大量的留存订单增量，这个价值是很实在的。

第二部分：这组数据为什么看起来"矛盾"？

表面上看，骑手差评率上升和用户复购率上升是矛盾的。但仔细想想，这两个指标的主体不一样。

骑手差评率反映的是骑手的服务体验，复购率反映的是用户对整个平台的满意度。用户可能觉得"虽然骑手态度差了点，但送得快我能接受"，这两件事不一定完全挂钩。

还有一个关键点：差评率上升的原因可能不是骑手服务态度真的变差了，而是"准时宝"这个产品改变了用户的预期和评价行为。

其实从用户心理角度看，这里面有个很有意思的现象。用户在评价骑手时关注的是"这一单"的体验，但决定是否复购时考虑的是"平台整体"的靠谱程度。一个用户可能某一单对骑手不满意给了差评，但因为准时宝的承诺让他觉得"这个平台至少守信"，所以下次还是会继续点。

第三部分：深挖骑手差评率上升的可能原因

原因一：骑手为了赶时间牺牲了服务细节

"准时宝"的核心卖点是超时赔付，这意味着骑手有更强的时间压力。为了不超时，骑手可能会做出一些"赶时间"的行为：不等电梯直接爬楼、放到门口就跑不等用户取餐、送餐时态度比较急躁、遇到用户电话不接的情况直接放门口而不是多等几分钟。

这些行为直接影响的是送餐末端的服务体验，用户可能会因为这些细节给差评，但同时又因为"送得快"而愿意继续使用这个平台，这就解释了为什么差评率和复购率可以同时上升。

说白了，用户的核心需求是"准时拿到饭"，骑手的服务态度是加分项而不是必选项。只要核心需求满足了，用户对软性服务的容忍度其实比我们想象的高。

原因二：准时宝改变了用户的评价心理

购买了"准时宝"的用户，心理预期发生了变化。他们付了额外的钱（虽然可能只是几毛钱），期望值更高，对服务瑕疵的容忍度更低。同样的送餐体验，非准时宝用户可能觉得"还行"，准时宝用户可能就觉得"不行"。

这是一个典型的"付费用户更挑剔"的现象，并不是骑手真的变差了，而是评价标准变了。这在消费心理学里是很常见的，付了钱就觉得自己是"甲方"，维权意识和评价意愿都会上升。

原因三：评价漏斗的变化

推出准时宝后，用户和平台的互动增加了。原来很多用户懒得评价，现在因为有赔付机制，用户可能更愿意在出问题时给反馈。差评的绝对数量可能没涨多少，但评价率整体提高了，差评率的分母变化导致数据看起来涨了。

这里还有个细节：准时宝超时赔付的流程可能会引导用户去评价。比如用户申请赔付后，系统可能会弹出"顺便给骑手评个价"的提示，这种引导会提高评价率，而且用户在刚经历了"超时"这个负面体验后，更容易给差评。

原因四：骑手群体结构发生了变化

准时宝带来的时间压力可能让一部分老骑手觉得太累而离职，新补充进来的骑手经验不足，服务质量参差不齐。如果这个城市刚好骑手流动率比较高，这个因素就不能忽视。

2024年以来外卖行业的骑手供给一直比较紧张，很多城市都在抢骑手。准时宝如果让这个城市的骑手压力明显大于其他城市，骑手可能会选择去压力更小的地方跑单。新骑手对路线不熟悉、对平台规则不了解，服务质量自然会下降。

原因五：订单结构发生了变化

这个点容易被忽略。准时宝可能吸引了一批对时效特别敏感的用户，这批用户本来就更"事儿多"——他们选择准时宝就是因为对时间要求高，对服务的整体预期也更高。这批用户的差评率天然就比普通用户高，他们的涌入拉高了整体差评率。

第四部分：用户复购率为什么还能提升？

复购率提升12%是个很实在的正向结果，说明准时宝整体上是成功的。原因可能有几个：

第一，"确定性"的价值被低估了。用户点外卖最怕的不是等得久，而是不知道要等多久。准时宝给了用户一个明确的时间预期，超时还能赔钱，这种确定性本身就很有价值。特别是在工作日午餐场景，用户可能只有1小时午休时间，能不能准时送到直接决定了他敢不敢点外卖。

第二，超时赔付降低了用户的决策成本。原来用户可能会犹豫"万一送得慢怎么办"，现在有了兜底机制，下单更果断了。这个心理机制类似于电商的"七天无理由退换"，虽然大部分人不会真的去退，但有这个保障会让人更敢买。

第三，准时宝可能带来了一波新用户。那些原来觉得外卖不靠谱的人，看到有准时承诺后愿意尝试了。新用户的复购行为会拉高整体复购率。

第四，差评用户不一定会流失。这点很关键。给差评和不再使用是两码事。用户给差评可能只是想表达不满、或者希望平台改进，但如果他的核心需求（准时送达）被满足了，他还是会继续用的。我们在分析用户行为时，经常会高估"情绪"的影响，低估"需求"的影响。

第五部分：如果我是分析师，怎么进一步拆解这个问题

光看这三个数是不够的，我会继续拉几个维度的数据：

- 1、把骑手差评分类型拆开：差评的原因是什么？"态度差""餐品洒了""送错地址"还是"没按要求放置"？如果主要是"态度差"这类软性原因，那就印证了骑手赶时间的假设。如果是"餐品洒了"变多，可能说明骑手骑太快导致颠簸。
- 2、对比准时宝用户和非准时宝用户的差评率：如果准时宝用户差评率明显更高，说明是付费用户预期提高导致的；如果两边差不多，说明是骑手整体服务质量在下降。
- 3、看骑手维度的数据：差评是集中在少数骑手身上，还是整体都在涨？如果是少数骑手拉高了整体数据，那可能是个别问题；如果是普遍上涨，那就是系统性问题。
- 4、追踪给过差评的用户后续行为：他们还会继续下单吗？如果给了差评但还在用，说明用户对"快"的需求确实压过了对"服务态度"的需求。我会拉一下"差评后7天内是否有复购"这个指标。
- 5、看看骑手端的数据：骑手的接单意愿、在线时长、离职率有没有变化？如果骑手大量流失，那长期来看准时宝可能会带来供给侧的问题。还要看骑手的超时率变化，以及超时后他们的行为变化。
- 6、分时段分析：早高峰、午高峰、晚高峰、夜宵时段的数据是否有差异？可能某些时段骑手压力特别大，差评率上升主要来自这些时段。
- 7、分商圈分析：不同商圈的餐厅密度、配送距离不同，准时宝的影响可能也不一样。CBD区域可能骑手压力更大，社区区域可能影响较小。

第六部分：这道题的考察意图和实际业务建议

面试官想看的是你能不能透过表面数据看到背后的业务逻辑。数据之间的"矛盾"往往不是真的矛盾，而是反映了不同利益方的诉求冲突，或者是同一个业务动作在不同维度上的不同影响。

这道题的核心是：用户要的是确定性和速度，骑手扛的是时间压力和服务要求，平台要平衡的是用户体验和骑手生态。准时宝短期内用骑手的压力换来了用户体验的提升，但长期来看可能要关注骑手的可持续性问题。

如果让我给业务建议，我会说：

第一，密切监控骑手侧的健康度指标。差评率上升如果伴随着骑手流失，那就是在透支未来。要设置预警线。

第二，优化调度算法而不是单纯压骑手。8分钟的时间如果主要靠骑手跑得更快来省，那是不可持续的。应该想办法从调度优化、商户出餐提速这些环节来省时间。

第三，考虑对差评类型做分级处理。"态度差"这种软性差评和"送错地址"这种硬性差评，对骑手的考核权重应该不一样。

知识点总结

- 1、指标口径问题：差评率的分母是什么、复购率是绝对提升还是相对提升，这些细节直接影响结论。
- 2、辛普森悖论意识：整体数据的变化可能掩盖了分群数据的真实情况，需要下钻分析。
- 3、多利益方视角：用户、骑手、平台三方的诉求不同，同一个策略对不同方的影响可能相反。
- 4、领先指标vs滞后指标：差评率是当前的体验反馈，复购率反映的是用户的长期决策，两者的时间窗口不同。
- 5、定量分析思维：遇到百分比变化要追问是绝对值还是相对值，遇到比率要追问分母是什么。

- 6、用户分群思维：准时宝用户和非准时宝用户可能本身就是两类人，不能混在一起看。
- 7、因果vs相关：数据变化是准时宝导致的，还是只是时间上的巧合？需要有对照组或者用前后对比的方法来验证。

追问环节

如果数据显示：准时宝用户的差评率是4.2%，非准时宝用户的差评率反而从2%降到了1.8%，你会怎么解读这个现象？

题目 49

倾向得分匹配：为什么随机AB测试不是万能的？什么场景下必须用PSM？

解答

做数据分析的人都知道AB测试是因果推断的"金标准"，随机分组能消除混杂因素，实验结果可以直接归因。但实际业务中，很多时候你根本没办法做AB测试，或者做了也不可信。

这时候就需要请出观察性研究的大杀器——倾向得分匹配。

第一部分：AB测试为什么会"失灵"？

先说几个真实场景。

场景一：已经发生的事情没法随机

比如老板问你：我们去年做了一个高端会员升级活动，参加活动的用户后续消费提升了30%，这个活动效果到底怎么样？

问题来了：活动已经结束了，用户是自己选择参加还是不参加的，根本不是随机分配的。那些主动参加活动的用户，本来就可能是更活跃、更愿意消费的人。30%的提升里面，有多少是活动带来的，有多少是用户本身的特质？你分不清。

这个30%里面，假设真实的活动效果只有10%，另外20%是用户自身特质带来的，那你如果直接用30%去汇报，就是把效果夸大了三倍。老板据此追加预算，下次可能就翻车了。

场景二：不能做随机分组

比如你想研究"用户投诉后给予补偿是否能挽回用户"。你能随机让一部分投诉用户得到补偿、另一部分不补偿吗？业务上不允许，客服不答应，法务也不答应。

再比如，研究"会员等级对消费的影响"，你不能随机把一部分符合升级条件的用户卡住不让他升，这对用户不公平。

场景三：随机分组有伦理问题

医学上很多研究都有这个问题。你不能随机让一组人抽烟、另一组人不抽烟来研究吸烟和肺癌的关系。商业领域虽然没那么极端，但类似逻辑也存在，比如你不能随机让一部分员工降薪来研究薪资对绩效的影响。

场景四：样本量不够做AB

有些低频场景，比如大额订单、VIP用户流失，样本本来就少，再一分组就更没法做统计检验了。假设一年只有200个VIP流失，你要研究挽留策略的效果，分成实验组对照组各100人，样本量根本不够做显著性检验。

场景五：选择性暴露

有些功能用户可以自己选择用不用，比如APP里的某个工具、某个会员权益。用了这个功能的用户留存更高，但你不知道是功能带来的效果，还是本来就是活跃用户才会去用这个功能。

第二部分：那PSM到底是个什么东西？

核心思想一句话：既然没法真的随机分组，那就人工"制造"一个和实验组尽可能相似的对照组。

怎么"制造"？靠匹配。

假设我们要研究"参加某活动对消费的影响"。参加活动的用户是实验组，没参加的用户是对照组。但这两组人可能本身就不一样：参加活动的用户可能年龄更大、消费能力更强、历史购买频次更高。

PSM的做法是：先用一个模型（通常是逻辑回归）预测每个用户"参加活动的概率"，这个概率就叫做"倾向得分"。然后，对于每一个参加活动的用户，从没参加活动的用户里找一个倾向得分最接近的人配对。

这样配对之后，两组人在"参加活动的倾向"上就被拉平了。理论上，唯一的差异就是"参没参加活动"这件事本身。

为什么用一个综合得分而不是直接按每个变量匹配？因为变量太多的话，按每个变量都精确匹配几乎不可能。你要找一个年龄、性别、消费金额、登录频次、会员状态都和某个用户一模一样的人，太难了，这叫"维度灾难"。倾向得分把多个变量压缩成一个数，匹配就变得可行了。

第三部分：举个具体的例子，带数字

假设电商平台做了一个"老用户专属优惠券"活动，领了券的用户下单率是45%，没领券的用户下单率是20%，差了25个百分点。老板问：这25%是优惠券的功劳还是这批用户本来就爱买？

我们手上有这些数据：用户是否领券、用户年龄、性别、过去30天消费金额、过去30天登录次数、是否是会员。

先看看两组用户的特征对比：

领券组：平均消费金额800元，平均登录15次，会员占比60%

未领券组：平均消费金额400元，平均登录6次，会员占比25%

一眼就能看出来，领券的用户本身就是更活跃、消费能力更强的人。直接比较下单率是不公平的。

第一步，建立倾向得分模型。用逻辑回归，因变量是"是否领券"，自变量是年龄、性别、消费金额、登录次数、会员状态。模型会给每个用户算出一个0到1之间的得分，表示他领券的概率。

第二步，检查倾向得分分布。领券组的平均倾向得分是0.68，未领券组的平均倾向得分是0.32。差距明显，说明两组人确实本身就不一样，PSM是有必要的。

但同时要看两组的得分分布是否有重叠。如果领券组的得分全都在0.6以上，未领券组的得分全都在0.4以下，那就没法匹配了。假设我们检查后发现，两组在0.4到0.7之间有足够重叠，那匹配可以进行。

第三步，匹配。用最近邻匹配加卡钳。对于每个领券用户，从未领券用户里找倾向得分差距在0.05以内的最接近的人。比如小王领了券，倾向得分是0.58，我们就从未领券用户里找一个得分在0.53到0.63之间的人配给他。

匹配结果：原来领券组有5000人，匹配后保留了4200对有效配对。

第四步，匹配后检验平衡性。检查匹配后的两组人，各个特征变得多接近了：

匹配后领券组：平均消费金额650元，平均登录12次，会员占比48%

匹配后未领券组：平均消费金额620元，平均登录11次，会员占比45%

差距从原来的100%以上缩小到了5%左右，平衡性大幅改善。

第五步，计算效应。匹配后领券组下单率42%，匹配后未领券组下单率31%，差异是11个百分点。

结论：优惠券的真实效果大约是11个百分点的下单率提升，而不是原来看到的25个百分点。原来那25个百分点里，有14个百分点是因为领券用户本身就更活跃带来的。

第四部分：PSM有哪些匹配方法？

最近邻匹配：给每个实验组用户找一个倾向得分最接近的对照组用户，一对一配对。简单粗暴，但可能会损失很多样本，而且有些"最近邻"其实也不够近。

卡钳匹配：只有倾向得分差距在某个范围内（比如正负0.05或正负0.2倍标准差）的才能配对，差太远的宁可不配。这样能保证匹配质量，但会损失更多样本。

核匹配：不是一对一，而是用多个对照组用户的加权平均来"合成"一个对照。权重根据倾向得分的距离来定，越近权重越大。好处是不会损失样本，坏处是理解起来没那么直观。

分层匹配：把倾向得分切成几个区间（比如分成5层或10层），同一区间内的用户互相比对。这个方法比较稳健，但层数的选择有点主观。

逆概率加权：不做匹配，而是给每个用户加一个权重。实验组用户权重是1/倾向得分，对照组用户权重是1/(1-倾向得分)。这样加权后的样本可以直接比较。

实际使用中，最常见的是最近邻匹配加卡钳，或者核匹配。

第五部分：PSM的几个大坑

坑一：只能控制观察到的变量

这是PSM最大的局限。如果有一个变量你没采集到，但它同时影响"是否参加活动"和"结果"，那PSM也救不了你。

比如研究优惠券效果时，用户的"价格敏感度"是个很关键的变量。价格敏感的人更容易领券，也更容易因为有券才下单。但如果你的数据里没有这个字段，PSM就控制不住它。这时候你估计出来的效果可能还是偏高的。

这个问题在统计学上叫"不可观察混杂"，是观察性研究的通病，不是PSM独有的，但用PSM的时候一定要意识到这个局限。

坑二：共同支撑假设

匹配的前提是：对于任意倾向得分，实验组和对照组都要有足够的样本。如果实验组用户的倾向得分集中在0.7到0.9，而对照组用户的倾向得分集中在0.1到0.3，那中间这一大段就没法匹配。

这时候即使强行匹配，也只能匹配到很少的样本，而且这些样本可能不具代表性。比如领券组里得分0.7的人可能是边缘用户，不能代表典型的领券用户。

解决办法是在匹配前检查倾向得分的分布图，看看重叠区域有多大。如果重叠太少，要么换方法，要么只能承认"对于某些类型的用户，我们估计不了效果"。

坑三：模型设定的影响

倾向得分是用模型算出来的，模型设定不同，得分就不同，最终结论也可能不同。用逻辑回归还是随机森林？要不要加交互项？要不要做变量转换？这些选择都会影响结果。

好的做法是做敏感性分析：用不同的模型设定算一遍，看看结论是否稳健。如果换个模型设定结论就大变，那这个分析的可信度就要打折扣。

坑四：匹配后样本量大幅缩水

如果实验组和对照组本来就差异很大，匹配后能用的样本可能很少。这时候统计power不够，结论可能不稳定，置信区间会很宽。

比如原来实验组5000人，匹配后只剩1000对，样本量缩水了80%。这时候即使点估计说效果是10%，置信区间可能是-5%到25%，根本没法下结论。

第六部分：PSM在业务中的实际应用

案例一：营销活动归因

用户自主参加的营销活动，没法随机分组，用PSM来估算活动的真实增量效果。这是最常见的应用场景。

案例二：功能使用效果评估

比如想知道"使用过小程序的用户留存是否更高"。使用小程序的用户可能本身就更活跃，直接比较不公平。PSM可以匹配出两组相似用户再比较。

案例三：政策效果评估

比如公司推了一个新的提成政策，但不是强制的，销售可以选择是否接受。接受的销售业绩更好，但可能是因为他们本来就能能力强。PSM可以帮助分离政策效果和个人能力。

案例四：用户分层后的定价策略

不同价格档位的用户，本身特征就不同。想比较不同定价策略的效果，PSM可以辅助构建可比较的用户组。

案例五：广告渠道归因

通过某个渠道来的用户转化率更高，是渠道效果好，还是这个渠道本身就吸引了更优质的用户？PSM可以帮助拆解。

第七部分：什么时候用PSM，什么时候用别的方法？

如果你能做真正的随机AB测试，别犹豫，做AB。PSM始终是次优选择。

如果有个明确的"门槛"触发干预，比如消费满1000元送礼品，用回归不连续设计可能更合适。

如果有时间维度的政策变化，比如某个城市先上了新功能、另一个城市后上，可以考虑双重差分。

如果干预是随时间变化的，比如用户可以随时开关某个功能，可能要用更复杂的因果推断方法，比如工具变量或者合成控制法。

PSM最适合的场景是：干预已经发生、用户自选择参与、你有较丰富的用户特征数据、而且两组用户的倾向得分分布有足够重叠。

一个简单的判断标准：如果你做完PSM后，匹配后样本量还剩原来的60%以上，而且平衡性检验各个变量的标准化差异都小于0.1，那这个PSM大概率是靠谱的。

知识点总结

- 1、选择性偏差：用户自选择参与某个活动，导致实验组和对照组本身就不可比。这是观察性研究的核心问题。
- 2、混杂变量：同时影响"是否接受干预"和"结果"的变量，是因果推断的大敌。PSM的目的就是控制这些混杂变量。
- 3、倾向得分：用可观察变量预测用户接受干预的概率，用来做匹配或加权。本质是把多维匹配问题降维成一维匹配问题。
- 4、共同支撑假设：实验组和对照组在倾向得分空间上要有足够重叠，否则匹配无法进行或效果估计不可靠。

- 5、平衡性检验：匹配后要检查各个协变量在两组间是否平衡，这是PSM成功与否的关键指标。常用的标准是标准化差异小于0.1。
- 6、不可观察混杂：PSM只能控制你观察到的变量，观察不到的混杂因素依然存在，这是PSM的硬伤，使用时要谨慎解读结论。
- 7、敏感性分析：换不同的模型设定、不同的匹配方法，看结论是否稳健，这是增强PSM可信度的重要步骤。

追问环节

如果匹配后检查发现，实验组的平均历史消费金额还是比对照组高20%，你会怎么处理？直接用这个匹配结果，还是有别的办法？

题目 50

回归不连续设计：京东PLUS会员年消费满10000元可升级为金牌会员，发现金牌会员的次年消费额比普通会员高出40%，这个40%真的是会员等级带来的吗？怎么算？

解答

这道题看起来很诱人：金牌会员比普通会员消费高40%，是不是说明会员升级机制很成功？但你稍微想一下就会发现：能消费到10000元以上的用户，本来就是消费能力强的人。那这40%的差距，到底是会员等级带来的，还是用户本身的差异？

这时候就得请出回归不连续设计了。

第一部分：为什么简单比较不靠谱？

先假设一些数据来把问题说清楚。

假设京东PLUS会员有两个等级：消费满10000元自动升级为金牌会员，否则是普通会员。我们观察到的数据是：

金牌会员（今年消费10000元以上）：平均有15000人，次年平均消费15400元
普通会员（今年消费10000元以下）：平均有85000人，次年平均消费11000元

直接算： $15400 / 11000 = 1.4$ ，金牌会员比普通会员高40%。

但问题在于，今年消费15000元的人和今年消费5000元的人，根本不是一类人。前者可能是高收入白领、平台重度用户、对京东有强烈偏好；后者可能是偶尔使用、价格敏感、随时可能流失。

这些差异本身就会导致明年消费的差距，跟会员等级没有必然关系。即使不给那个消费15000的用户升级，他明年大概率也会消费更多。

所以这40%里面，会员等级到底贡献了多少？直接比较根本说不清楚。

第二部分：回归不连续设计的核心思想

核心思想一句话：利用"门槛"附近的用户，来做因果推断。

为什么要聚焦门槛附近？

消费9999元的用户和消费10001元的用户，本质上是差不多的人。他们的收入、消费习惯、对平台的忠诚度应该非常接近——毕竟只差了2块钱，这点差距可以认为是随机波动。

但就是因为这2块钱的差距，一个人被分到了"普通会员"，另一个人被分到了"金牌会员"。

这种"差一点点就跨过门槛"的情况，制造了一个类似随机分组的效果。门槛两边的人特质差不多，唯一的区别就是会员等级。这时候比较他们的次年消费，差异就可以更可靠地归因于会员等级本身了。

这就是回归不连续的精髓：不是在全量用户中找可比的人（那太难了），而是聚焦在门槛附近这个"天然实验"上。

第三部分：具体怎么操作？带数字推导

我们把视线聚焦在10000元这个门槛附近。

假设我们取门槛上下500元范围内的用户，也就是消费在9500元到10500元之间的用户。

这个范围内的数据：

消费9500到9999元的用户（普通会员）：2000人，次年平均消费10800元

消费10000到10500元的用户（金牌会员）：2200人，次年平均消费12500元

先验证一下这两组人是不是真的差不多：

普通会员组：平均年龄32岁，女性占比55%，历史购买频次每月4.2次

金牌会员组：平均年龄33岁，女性占比53%，历史购买频次每月4.5次

各项指标差距都在10%以内，可以认为这两组人是高度可比的。

现在比较他们的次年消费： $12500 - 10800 = 1700$ 元

这1700元就是会员等级带来的因果效应估计值。

换算成比例： $1700 / 10800 = 15.7\%$ ，约等于16%。

结论：会员升级的真实效应大约是16%的消费提升，而不是最开始看到的40%。

那剩下的24%去哪了？被"选择性偏差"解释掉了。能消费到10000以上的用户本身就是高消费倾向的人，即使不升级，他们也会比普通用户消费更多。

第四部分：用图来理解会更直观

如果我们以"今年消费额"为横轴，"次年消费额"为纵轴，把所有用户画上去，会看到这样的图：

整体趋势：有一条向上倾斜的趋势线，今年消费越多的人，明年消费也越多。这是正常的消费惯性。

关键观察：在10000元这个点上，趋势线会出现一个"跳跃"或者说"断层"。10000元右边的点（金牌会员）明显比按照趋势线预测的位置高出一截。

这个"跳跃"的高度，就是会员等级带来的因果效应。

如果会员等级没有任何效果，趋势线应该是一条平滑的曲线，不会有跳跃。正是因为跨过10000元会触发一个"干预"（升级会员、获得专属权益），才产生了这个断层。

反过来，如果门槛没有跳跃，说明会员等级对消费没有额外刺激作用，用户只是按照原有的消费惯性在走。

第五部分：回归不连续设计的关键假设

这个方法不是万能的，有几个重要假设必须成立。

假设一：用户不能精确操控自己是否跨过门槛

如果用户可以精确控制自己的消费额，那门槛两边的人就不是随机的了。

举个反例：如果京东大张旗鼓宣传"消费满10000元即可升级金牌会员，享受5折专属优惠"，很多用户可能会在9900元的时候专门凑单到10001元。这时候门槛右边的用户就是"特别想升级"的人，可能比左边的用户更在意会员权益、更价格敏感、更有策略性。这两组人就不可比了。

怎么检验这个假设？看门槛附近的用户分布。如果分布平滑，说明没有操控；如果门槛右边的用户异常"堆积"（比如10000到10100元的用户数量远超9900到10000元），说明有操控行为。

假设二：门槛附近的用户特征连续变化

意思是，在10000元附近，用户的年龄、收入、购物偏好等特征应该是渐变的，不应该出现突变。

如果在10000元这个点，用户特征突然跳变，说明有其他因素在起作用。比如可能有另一个系统在10000元这个点做了筛选，导致门槛两边的用户本质上不同。

可以通过画图检验：看看年龄、性别比例、历史购买频次等变量在门槛附近是否平滑。如果这些变量也在10000元出现跳跃，那RDD的结论就不可信了。

假设三：除了会员等级，没有其他干预在这个门槛上发生变化

如果京东还有其他政策也是以10000元为门槛（比如10000元以上免运费、10000元以上送专属客服、10000元以上参加抽奖），那效应就混在一起了，没法分辨是会员等级的效果还是其他政策的效果。

这种情况叫"门槛堆叠"，是RDD分析的大敌。

第六部分：带宽选择的权衡

"带宽"就是我们取门槛附近多大范围的用户来做分析。

带宽太窄（比如只取9900到10100的用户）：好处是门槛两边用户高度可比；坏处是样本量太少，可能只有几百人，统计不稳定，置信区间很宽。

带宽太宽（比如取5000到15000的用户）：好处是样本量大；坏处是门槛两边用户差异变大，不够"可比"了，估计会有偏。

这是一个权衡。实践中的做法是：

1、用多个带宽做分析，比如正负300元、正负500元、正负1000元，看结论是否稳健。如果三个带宽得出的效应都在15%左右，说明结果可靠。如果带宽一变结论就大变，说明结果不稳健。

2、用统计方法自动选择最优带宽。有一些技术手段可以根据数据特征计算"最优带宽"，但这个比较进阶。

第七部分：RDD和其他因果推断方法的比较

和AB测试比：AB测试需要事先随机分组，是主动干预；RDD利用的是自然形成的门槛，是被动观察。AB测试是金标准，但很多时候做不了（比如不能随机决定谁升级谁不升级）；RDD是替代方案，前提是有一个合适的门槛。

和PSM比：PSM是在全量用户中匹配相似的人，依赖于你观察到的变量是否足够完整。RDD聚焦在门槛附近，依赖于门槛的性质是否合适。PSM对样本量要求高但可以估计全量效应；RDD样本量要求低但只能估计门槛附近的效应。

和双重差分比：双重差分需要时间维度的政策变化（比如某个时间点上线了新功能），RDD需要的是截面上的门槛（比如消费满某个金额触发某个权益）。两者适用场景不同。

第八部分：业务中哪些场景可以用RDD？

场景一：会员等级升级

消费满X元升级，年龄满Y岁获得某个权益，积分满Z分兑换某个礼品。这些都有明确门槛，可以用RDD分析门槛跨越带来的效果。

场景二：信用评分阈值

比如芝麻信用分超过650可以免押金租车，超过700可以享受酒店信用住。可以用RDD分析这些权益的真实效果。

场景三：考核评级

员工绩效评分超过某个分数可以获得晋升机会，可以用RDD分析晋升对后续绩效的影响。

场景四：地理边界

比如北京和河北交界处，北京这边有某个补贴政策，可以比较边界两侧商户的表现。

场景五：时间门槛

比如某个功能在某个时间点上线，上线前后的用户可以做类似分析（这个更接近断点回归的时间序列版本，学术上叫中断时间序列）。

第九部分：实际操作中的注意事项

- 1、先画图。在做任何回归之前，先画散点图和拟合线，看看门槛附近是否真的有明显跳跃。如果没有肉眼可见的跳跃，可能效应本身就不大，或者RDD在这个场景下不适用。
- 2、检验假设。画密度图看门槛附近用户有没有"堆积"（操控检验）；画协变量图看各特征在门槛附近是否连续（连续性检验）。
- 3、多带宽检验。用不同带宽看结论是否稳健。结论对带宽敏感的话要小心。
- 4、做安慰剂检验。在其他没有门槛的点（比如8000元、12000元）做同样的分析，应该看不到跳跃。如果这些点也有跳跃，说明你的方法可能有问题，或者有其他混杂因素。
- 5、报告置信区间。门槛附近样本量通常不大，点估计的不确定性可能很高。别只报告"效应是16%"，要报告"效应是16%，95%置信区间是8%到24%"。

知识点总结

- 1、门槛效应：在有明确门槛触发干预的场景下，可以利用门槛来做因果推断。这是RDD的核心应用场景。
- 2、局部随机化：门槛附近的用户，除了是否跨过门槛以外，其他特征应该高度相似，类似于随机分组。
- 3、跳跃估计：因果效应就是门槛两侧结果变量的跳跃幅度。
- 4、操控检验：检查用户是否能精确控制自己是否跨过门槛。看门槛附近的密度分布是否平滑。
- 5、连续性检验：检查协变量（用户特征）是否在门槛处连续。如果协变量也跳跃，说明有混杂。
- 6、带宽选择：范围太窄样本不够，范围太宽可比性下降，需要权衡和稳健性检验。
- 7、局部平均效应：RDD估计的是"门槛附近用户"的效果，不一定能推广到所有用户。这是一个局限。

追问环节

如果发现在10000元门槛附近，用户有明显的"堆积"现象——就是消费刚好10000到10100的用户特别多，远超9900到10000的用户，你会怎么解读？还能用RDD吗？

题目 51

用户生命周期价值：拼多多发现通过"砍一刀"拉新的用户首单转化率高达65%，但这批用户的LTV该怎么算？为什么不能只看首单？

解答

"砍一刀"拉来的用户首单转化率65%，看起来效果炸裂。但如果你只看这个数就觉得砍一刀是神级增长策略，那就太天真了。

首单转化率高不等于这批用户有价值，LTV才是判断一个获客渠道好坏的终极指标。

第一部分：先搞清楚为什么首单转化率可能是个"虚假繁荣"

砍一刀的机制是什么？用户想免费拿到某个商品，需要拉新朋友帮忙砍价。被拉来的新用户为了帮朋友砍价，通常要先完成一笔订单才能获得砍价资格，或者需要下载APP、完成新人任务等。

所以这65%的首单转化率，很大程度上是"被逼出来的"，而不是用户自己真的想买东西。这和正常的自然转化完全不是一回事。

这些用户的典型画像可能是：本来对拼多多没什么需求，就是帮朋友砍价顺便凑了一单；买的可能是9.9包邮的便宜货，客单价极低；下完首单就完成任务了，后面可能就卸载APP了；对平台没有任何忠诚度，纯粹是被社交关系裹挟来的。

如果只看首单转化率，你会觉得砍一刀效果太好了，比任何付费投放都强。但如果看LTV，可能会发现这批用户后续几乎不产生任何价值，全是"僵尸用户"。

第二部分：LTV到底是什么？怎么理解？

LTV就是用户生命周期价值，指的是一个用户从成为你的用户到完全流失这段时间里，总共给你贡献的收益。

最简单的LTV公式是这样的：

$LTV = \text{平均每单利润} \times \text{用户生命周期内的订单数}$

或者换一种更通用的表达：

$LTV = ARPU \times \text{用户生命周期长度}$

其中ARPU是平均每用户每月（或每年）贡献的收入或利润。

举个最简单的例子：如果一个用户平均每月在你这消费100块，你的利润率是20%，也就是每月利润20块。这个用户平均能在你这待10个月，那他的LTV就是 $20 \times 10 = 200$ 块。

LTV的意义在于：它能告诉你这个用户值不值得花钱去获取。

如果获客成本（CAC）是50块，LTV是200块，那每个用户你能赚150块，获客越多赚得越多。

如果获客成本是50块，LTV只有30块，那每获取一个用户你就亏20块，获客越多亏得越多。

所以LTV/CAC这个比值，是判断一个增长策略是否健康的核心指标。

第三部分：砍一刀用户的LTV该怎么算？带完整推导

我们来模拟一组尽可能贴近真实的数据。

假设砍一刀拉来了10000个新用户，我们追踪他们12个月的行为。

首月（第1个月）：

注册用户：10000人

首单转化用户：6500人（65%转化率，看起来很高）

首单平均客单价：25元（大部分是9.9元、19.9元的低价商品凑的）

首月总GMV： $6500 \times 25 = 162500$ 元

首月活跃用户（下过单的）：6500人

第2个月：

这个月还活跃的用户（又下了单的）：2000人

月度留存率： $2000 / 6500 = 30.8\%$

平均客单价稍微提升：35元（留下来的人可能确实有需求）

月GMV： $2000 \times 35 = 70000$ 元

第3个月：

还活跃的用户：1200人

相比首月留存： $1200 / 6500 = 18.5\%$

平均客单价：40元

月GMV： $1200 \times 40 = 48000$ 元

第6个月：

还活跃的用户：600人

相比首月留存： $600 / 6500 = 9.2\%$

平均客单价：50元

月GMV： $600 \times 50 = 30000$ 元

第12个月：

还活跃的用户：300人

相比首月留存： $300 / 6500 = 4.6\%$

平均客单价：60元

月GMV： $300 \times 60 = 18000$ 元

把12个月的GMV加起来，大约在40-45万左右（中间几个月我省略了，按留存曲线可以估算）。

这里要注意，我们算的是全部10000个拉新用户的总价值，不是只算转化了的6500人。因为那3500个没转化的人，也是你花了获客成本的。

平均到每个拉新用户的12个月GMV： $\text{约}420000 / 10000 = 42$ 元

假设拼多多的平台利润率是20%（扣掉商家分成、物流补贴、运营成本等），那每个用户的12个月LTV约等于： $42 \times 20\% = 8.4$ 元

取个整数，约8块钱。

而拼多多通过砍一刀拉一个新用户的成本是多少？这个成本包括：砍价商品的补贴分摊、新人优惠券、红包奖励等。假设平均每个新用户的获客成本是5元。

那么 $LTV / CAC = 8 / 5 = 1.6$

1.6这个比值意味着什么？花5块钱拉一个用户，12个月能赚回8块，回报率60%。听起来还行，但考虑到资金成本（钱放银行也有3-4%的利息）、运营成本、风险成本，这个回报率其实很一般。

行业里通常认为LTV/CAC要达到3以上才算健康。1.6说明砍一刀这个渠道“能赚钱但不太赚钱”。

第四部分：为什么不能只看首单？用数据说话

如果只看首单数据，你会得到完全不同的结论。

首单视角：

首单转化用户6500人，首单GMV 16.25万

首单利润（按20%算）：3.25万

获客总成本：10000人 $\times$ 5元 = 5万

首单利润 - 获客成本 = 3.25万 - 5万 = -1.75万

只看首单的话，砍一刀是亏本生意！每投入5万获客成本，首单只能赚回3.25万。

但如果看12个月LTV的话：

总利润：8.4万

获客成本：5万

最终赚了3.4万。

所以首单亏钱不代表渠道不行，要看后续能不能回本。

反过来也一样，有些渠道首单数据很漂亮：

首单转化率80%

首单客单价200块

首单利润率极高

但如果这些用户全是被超大力度折扣吸引来的薅羊毛党，买完第一单就再也不来了，那LTV可能还不如砍一刀。

首单只是故事的开头，LTV才是故事的结局。

第五部分：不同渠道的LTV对比才有战略意义

假设拼多多同时还有两个获客渠道，我们来对比一下。

渠道A：砍一刀（刚才算过）

获客成本CAC：5元

12个月LTV：8元

LTV/CAC：1.6

渠道B：品牌广告投放

获客成本CAC：30元

首单转化率：20%（看起来低多了）

但首单客单价：150元

12个月留存率：25%（远高于砍一刀的4.6%）

12个月人均累计GMV：300元

12个月LTV： $300 \times 20\% = 60$ 元

LTV/CAC： $60/30 = 2.0$

渠道C：老用户推荐

获客成本CAC：15元（推荐奖励）

首单转化率：50%

首单客单价：80元

12个月人均累计GMV：200元

12个月LTV： $200 \times 20\% = 40$ 元

LTV/CAC： $40/15 = 2.67$

对比结论：

砍一刀：LTV/CAC 1.6，获客成本最低但用户质量也最差

品牌广告：LTV/CAC 2.0，用户质量更好，值得更多投入

老用户推荐：LTV/CAC 2.67，性价比最高

如果预算有限，应该优先扩大老用户推荐和品牌广告的规模，砍一刀可以作为补充但不应该是核心策略。

如果只看首单转化率，你会觉得砍一刀65%转化率远超品牌广告的20%，应该all in砍一刀。这就是典型的被首单数据误导。

第六部分：LTV计算中的几个坑

坑一：用户还没流失，怎么算生命周期？

这是最常见的问题。你今天看到的用户可能才来了3个月，还没完全流失，怎么知道他一辈子值多少钱？

解决办法一：用固定窗口期。比如统一用"12个月LTV"或"24个月LTV"，保证口径一致。

解决办法二：用留存曲线外推。根据历史数据拟合一条留存衰减曲线（通常是指数衰减或幂律衰减），然后对曲线积分，预测用户的总生命周期。

解决办法三：用概率模型。比如BG/NBD模型，可以根据用户的购买频率和最后购买时间，预测他未来还会买几次。

坑二：不同用户差异太大

砍一刀用户里面：

大部分人（70%）LTV可能是0，买完首单就再也没来过

有一小部分人（20%）LTV可能是20块，偶尔回来买点便宜货

极少数人（10%）LTV可能是200块，真的成了平台忠实用户

平均LTV是8块，但这个8块可能不能代表任何一个真实用户。

解决办法：分群计算。按用户来源、用户特征、首单行为等维度分群，每个群单独算LTV。比如"砍一刀来的+首单超过50元+7天内二次购买"的用户，LTV可能有50块，值得重点运营。

坑三：利润口径不统一

有人算LTV用的是GMV，有人用的是毛利，有人用的是净利润。口径不一致的话，LTV数字就没法比较。

标准做法：用边际利润（毛利润减去可变成本）作为LTV的收入口径。固定成本（如办公室租金）不应该分摊到LTV里。

坑四：没考虑资金的时间价值

今天赚的1块钱和一年后赚的1块钱，价值不一样。如果公司资金成本是10%，那一年后的1块钱只值今天的0.9块。

理论上应该对未来的收益做贴现： $LTV = \text{第1个月收益} + \text{第2个月收益}/(1+r) + \text{第3个月收益}/(1+r)^2 + \dots$

实际操作：很多公司为了简化不做贴现。但如果用户生命周期很长（比如保险、金融行业可能是10年），贴现的影响会很大。

第七部分：LTV驱动的业务决策

LTV不是算出来看看就完了，要用来驱动决策。

决策一：获客预算怎么分配？

把预算分配给LTV/CAC比值更高的渠道。砍一刀1.6，品牌广告2.0，那品牌广告应该拿更多预算。

决策二：什么样的用户值得重投入？

根据用户早期行为预测LTV，对高LTV潜力用户加大运营投入（比如专属客服、大额优惠券），对低LTV用户减少投入（不要在他们身上浪费运营资源）。

决策三：产品应该怎么设计？

$LTV = ARPU \times \text{生命周期}$ 。提升留存就是延长生命周期，直接提升LTV。如果能把留存率从30%提升到40%，LTV可能会翻倍。

决策四：定价策略怎么定？

如果用户LTV足够高，前期可以接受亏损获客（先亏后赚）；如果LTV很低，就要控制获客成本，甚至放弃某些渠道。

知识点总结

- 1、LTV的定义：用户从获取到流失期间贡献的总价值。是评估用户质量和渠道质量的核心指标。
- 2、LTV vs 首单：首单只是起点，很多用户首单高但后续流失，也有用户首单低但后续价值很大。不能用首单代替LTV。
- 3、LTV/CAC：这个比值决定了获客是赚钱还是亏钱。一般认为3以上是健康的，2是及格线，2以下要小心。
- 4、分群思维：不同渠道、不同用户群的LTV差异很大，平均值可能掩盖问题。要分群分析。
- 5、留存与LTV：留存是LTV最重要的驱动因素。留存率提升10个百分点，LTV可能提升50%以上。
- 6、预测LTV：用户还没流失时，需要用留存曲线和消费模型预测未来的LTV。
- 7、LTV驱动决策：用LTV指导获客预算分配、用户运营优先级、产品设计方向。

追问环节

如果发现砍一刀用户的首月留存率只有31%，但留下来的那31%用户的后续消费能力非常强（人均月消费100元以上），你会怎么优化这个渠道？是继续大规模拉新然后靠漏斗筛选，还是想办法提升首月留存？

题目 52

增量测试与因果归因：抖音电商发现直播间挂购物车的商品点击率是普通视频的3倍，但如何证明这3倍提升真的来自"购物车"功能本身，而不是用户本来就想买？

解答

直播间购物车点击率是普通视频的3倍，这个数听起来很惊人。但你稍微想一下就会发现问题：会点进直播间的用户，和刷到普通视频的用户，本来就不是一类人。

那这3倍的差距，到底是购物车功能带来的，还是用户本身的购买意愿差异？

这就是增量测试要解决的问题。

第一部分：先理解问题出在哪

直播间用户 vs 普通视频用户，本身就存在巨大差异：

进直播间的人可能本来就有购物需求。他们可能搜索了商品、关注了主播、专门进来看商品讲解。这类用户的购买意愿本来就比刷短视频的用户高得多，这不是购物车的功劳。

刷到普通视频的人可能只是在消磨时间。他们可能对商品没有任何预期，纯粹是被内容吸引，不是来买东西的。即使在视频里放个购物链接，点击率也不会高。

这两类人的转化率差3倍，太正常了。即使没有购物车功能，直播间用户的购买率也会比普通视频用户高，可能也能高2倍。

所以关键问题变成了：购物车功能本身，在这3倍的差距里，到底贡献了多少？

这个功能本身贡献的那部分，就叫做"增量效应"。

第二部分：什么是增量测试？核心概念

增量测试的核心思想：构造一个"没有干预"的反事实世界，和"有干预"的真实世界做对比。

在这个场景下：

真实世界：直播间有购物车，用户可以一键点击购物车购买

反事实世界：直播间没有购物车，用户只能通过其他方式购买（比如复制口令、搜索商品名、主动访问店铺）

增量效应 = 有购物车时的转化率 - 没有购物车时的转化率

问题在于：你没法让同一批用户同时经历两种情况。同一个人要么看到了购物车，要么没看到，不能两个都经历。所以需要用实验设计来构造近似的对比。

这就是因果推断最基本的问题：反事实不可观察。我们只能用实验或统计方法来近似估计。

第三部分：怎么设计增量测试？

最标准的做法是AB测试。

把用户随机分成两组：

实验组：看到有购物车的直播间

对照组：看到没有购物车的直播间（或者购物车被弱化/隐藏）

然后比较两组的转化率差异，这个差异就是购物车功能的增量效应。

为什么随机分组很重要？因为随机分组可以保证实验组和对照组的用户特征在统计上是相似的。两组的购买意愿、消费能力、使用习惯应该差不多。这样转化率的差异就可以归因于购物车功能本身，而不是用户差异。

但这里有几个实操问题要考虑：

问题一：直播是实时的，怎么做AB？

直播是实时的，同一个直播间不能同时给一部分人显示购物车、另一部分人不显示。技术上可能需要做"平行直播间"（同一个主播同时开两个直播间，一个有购物车一个没有），成本很高。

或者用"录播AB"：用同一个直播录像，给不同用户展示不同的界面版本。

问题二：如果完全不显示购物车，对照组体验太差

不显示购物车的话，用户可能根本不知道这个直播是卖货的，整个体验完全不同，不是一个公平的对比。

可能的解决方案：不是完全去掉购物车，而是弱化。比如对照组的购物车按钮很小、放在角落、颜色不显眼。这样体验差距没那么大，对比更公平。

问题三：用户可能有其他购买渠道

即使不点购物车，用户也可以通过搜索、收藏、其他入口完成购买。购物车只是一个入口，不是唯一路径。

这意味着对照组的转化率不会是0，而是"基础转化率"。增量测试测的是购物车在基础转化率之上的额外贡献。

第四部分：更实际的增量测试设计方案

方案一：购物车位置/显著程度测试

不完全去掉购物车，而是改变购物车的显著程度：

实验组A：购物车按钮在屏幕中央，非常显眼，闪烁提示

实验组B：购物车按钮在右下角，正常大小

对照组C：购物车按钮在左上角，很小，灰色，不容易发现

比较三组的转化率，可以推算购物车的可见度对转化的影响。

方案二：时间差分法（上线前后对比）

在购物车功能上线前和上线后，对比同一批用户的购买行为变化。

假设某个品类在2023年11月没有直播购物车功能，2024年1月上线了。

对比同一批用户在两个时期的转化率变化。需要注意控制季节性因素（比如双11、年货节会影响转化率），否则可能把节日效应归因给购物车功能。

可以用双重差分的思路：找一个没有上线购物车的品类作为对照，看实验品类的转化率变化减去对照品类的转化率变化，差额就是购物车功能的效果。

方案三：地区分层测试

在部分地区/城市先上线购物车功能，其他地区暂时不上。对比两批地区的转化率差异。

这个方案操作难度较低，但要注意地区之间可能本身就有差异（比如北京用户和三线城市用户消费习惯不同），需要选择特征相近的地区做对比。

第五部分：用数字说明增量效应

假设我们做了一个AB测试：

实验组（有购物车）：10万用户，购买转化率4.5%，GMV 180万
对照组（购物车弱化）：10万用户，购买转化率3.2%，GMV 128万

先验证两组用户是否可比：

实验组平均年龄28岁，女性占比62%，平均历史消费320元
对照组平均年龄27岁，女性占比60%，平均历史消费315元

差异很小，说明随机分组做得不错，两组可比。

计算增量效应：

增量转化率 = $4.5\% - 3.2\% = 1.3\text{个百分点}$
增量GMV = $180\text{万} - 128\text{万} = 52\text{万}$

如果只看实验组数据，你会觉得购物车带来了4.5%的转化率。但实际上，购物车的增量效应只有1.3%。剩下的3.2%是用户本来就会产生的基础转化——即使没有购物车，他们也会通过搜索、收藏等方式购买。

增量贡献比例 = $1.3\% / 4.5\% = 29\%$

也就是说，购物车功能只贡献了29%的转化，另外71%的转化即使没有购物车也会发生（只是路径不同）。

这个结论对业务决策非常重要：

如果你以为购物车带来了100%的转化，你可能会过度投入购物车功能的优化，觉得"只要购物车好了，转化率就能翻倍"。

如果你知道购物车只贡献了29%，你会更均衡地分配资源到其他环节（比如直播内容质量、商品匹配度、用户触达效率、页面加载速度）。

第六部分：增量测试的几个关键概念详解

概念一：基础转化 vs 增量转化

基础转化：即使没有这个功能/渠道，用户也会发生的购买。这是用户自身需求驱动的。
增量转化：因为这个功能/渠道存在，额外多出来的购买。这是功能/渠道创造的价值。

增量测试的目的就是区分这两部分。

在购物车的例子中：

基础转化率3.2%：这些用户即使没有购物车，也会通过其他方式买。购物车只是方便了他们。
增量转化率1.3%：这些用户如果没有购物车，可能就不会买了。购物车真正"创造"了这些转化。

概念二：自然转化 vs 引导转化

自然转化：用户自己有需求，自己完成购买，不需要任何引导

引导转化：通过某个功能/活动/推送，促使用户完成购买

购物车功能属于"引导转化"的手段，但它的增量效应取决于：有多少用户是因为看到购物车才产生购买冲动的，而不是本来就想买、购物车只是提供了便利。

概念三：归因窗口

用户点击购物车后多久内完成的购买，算是购物车带来的？

1分钟内？1小时内？1天内？7天内？

窗口期越长，归因给购物车的转化越多，但也越可能"抢"了其他渠道的功劳。比如用户今天点了购物车，但没买，第二天通过搜索买了，这算购物车的功劳还是搜索的功劳？

常见做法是用"首次触达归因"或"末次触达归因"，但这些方法都有问题。更科学的做法是用增量测试来直接衡量。

第七部分：为什么增量测试很重要？业务意义

原因一：避免资源错配

如果某个功能的增量效应其实很小，但你以为它很重要，就会在上面投入过多资源。

比如购物车功能如果只贡献29%的增量，那花大量人力去优化购物车的颜色、位置、动效、按钮文案，可能不如去优化商品详情页、直播间互动体验、用户推荐算法。

原因二：避免虚假归因，防止抢功劳

在多触点用户旅程中，每个触点都想把转化归到自己头上。

如果不做增量测试：

直播间会说"我带来了100%的转化"

搜索渠道也会说"我带来了100%的转化"

广告投放也会说"我带来了100%的转化"

商品推荐也会说"我带来了100%的转化"

加起来超过100%了，显然有问题。增量测试能帮你看清楚每个触点的真实贡献，避免内部"抢功劳"的政治问题。

原因三：优化投放和运营策略

如果知道某个渠道的增量效应高，就应该多投资资源；如果增量效应低，就应该少投或者换策略。

比如发现购物车增量效应只有29%，但直播间话术的增量效应有50%（通过测试不同话术版本得出），那应该把更多资源投入到话术优化，而不是购物车UI优化。

第八部分：增量测试的局限性和注意事项

局限一：实验成本高

要做真正的增量测试，需要划分实验组和对照组，可能会牺牲一部分用户的体验（对照组看不到某个功能），或者需要技术开发来支持分组。

局限二：结论可能不稳定

增量效应会随着用户群体、时间、产品版本而变化。今天测出来29%的增量，可能明年只有15%（因为用户习惯变了），也可能变成40%（因为功能优化了）。

需要定期重测，不能一劳永逸。

局限三：不能完全替代归因模型

增量测试适合评估单个功能/渠道的效果，但如果要同时分配多个渠道的功劳，还需要结合归因模型。增量测试是"点"的分析，归因模型是"面"的分析。

局限四：可能有溢出效应

如果实验组和对照组用户之间有互动（比如社交分享），一个组的行为可能影响另一个组，导致增量估计不准。

知识点总结

- 1、增量效应的定义：因为某个干预存在而额外产生的效果。是判断功能/渠道真实价值的核心指标。
- 2、基础转化 vs 增量转化：基础转化是本来就会发生的，增量转化是干预带来的额外部分。两者要分开看。
- 3、反事实思维：增量测试的本质是构造"没有干预会怎样"的反事实世界，和真实世界对比。
- 4、AB测试是金标准：随机分组可以消除选择性偏差，让增量估计更可靠。
- 5、归因窗口：功能触达后多长时间内的转化算它的功劳，需要根据业务特征合理设定。
- 6、资源分配依据：根据增量效应大小分配资源，而不是根据"看起来的转化率"。增量效应低的功能，投再多资源效果也有限。
- 7、定期重测：增量效应会随时间变化，需要周期性更新估计。

追问环节

如果AB测试结果显示：实验组和对照组的转化率差异只有0.3%，统计检验的p值是0.08，你会怎么解读这个结果？是购物车功能真的没用，还是实验设计有问题？

题目 53

面试真题：网易云音乐"年度听歌报告"分享率今年下降了15%，但DAU和用户时长都在增长，可能是什么原因？作为数据分析师你会怎么排查？

解答

按常理说，活跃用户多了、用户粘性强了，愿意分享的人应该更多才对。为什么分享率反而下降了？

这道题考的是你能不能从多个角度拆解问题，而不是拍脑袋给一个答案。

第一部分：先把分享率这个指标拆清楚

分享率 = 分享人数 / 某个基数

这个基数是什么？不同口径差别很大：

- 口径一：分享人数 / 看到报告的人数
- 口径二：分享人数 / 生成报告的人数
- 口径三：分享人数 / 点击报告入口的人数
- 口径四：分享人数 / 全量DAU

如果口径是"分享人数 / 看到报告的人数"，那分享率下降可能是因为：看到报告的人变多了，但增量用户里愿意分享的比例较低。

如果口径是"分享人数 / 全量DAU"，那这个分享率还受"看到报告的渗透率"影响。可能是渗透率下降了（看到报告的人变少了），也可能是看到后分享的比例下降了。

第一个动作：确认分享率的口径是什么，把分子分母都拉出来单独看看。很可能口径一确认清楚，问题就能定位一半。

第二部分：假设口径确认了，分享率下降的可能原因

假设口径是"分享人数 / 看到报告的人数"，分享率从去年的25%降到了今年的21%，下降了4个百分点（相对下降16%）。

可能原因一：用户结构变了

今年新增的用户可能和老用户不一样。

如果今年DAU增长主要来自下沉市场、年龄更大的用户、或者社交分享意愿较低的用户群体，整体分享率自然会被拉低。

举个例子：00后用户可能特别喜欢分享年度报告到朋友圈，而70后用户可能根本不知道怎么分享。如果今年70后用户占比提升了，整体分享率就会下降。

可以验证的方法：把用户分群，分别看老用户和新用户的分享率，看不同年龄段用户的分享率。如果老用户分享率和去年差不多，新用户分享率很低，说明是结构问题。

可能原因二：报告内容吸引力下降

今年的报告可能没有去年好玩、没有去年有话题性、设计没有去年出圈。

年度报告要有分享欲望，通常需要几个要素：

有趣的数据：比如"你听的歌击败了99%的用户"，这种数据很有炫耀价值

有共鸣的标签：比如"深夜emo选手""凌晨失眠专家"，这种标签容易引发讨论

有传播性的设计：好看的海报、独特的视觉风格、可以截图的形式

如果今年的报告内容比较平淡，没有让人"想发朋友圈"的冲动，分享意愿就会下降。2024年年底网易云的年度报告设计有没有出圈？可以和往年对比一下社交媒体上的讨论量。

可以验证的方法：看用户在报告页面的停留时长、浏览完成率、截图行为。如果这些指标也下降了，说明内容吸引力可能有问题。也可以看社交媒体上关于网易云年度报告的讨论热度，是不是比往年低。

可能原因三：分享路径或入口变了

分享按钮的位置、分享流程的便捷程度，都会影响分享率。

如果今年做了产品改版，把分享按钮从显眼位置移到了角落，或者分享流程变得更复杂了（比如需要多点几步），分享率自然会下降。

还有一个可能是分享形式变了。去年可能可以一键生成好看的海报，今年可能需要手动截图，麻烦程度增加，分享率就会下降。

可以验证的方法：对比今年和去年的产品设计，看分享入口有没有变化。看分享按钮的点击率（曝光到点击的转化率），如果点击率下降了，可能是入口问题。

可能原因四：外部环境变了

社交平台的政策、用户的社交分享习惯、竞争对手的动作，都可能影响分享率。

几个可能的外部因素：

用户整体分享意愿下降：2024年很多人说"朋友圈越来越冷清了"，用户发动态的频率在下降，不光是网易云的报告，所有产品的分享率可能都在下降。

竞争对手抢了话题：如果QQ音乐、Spotify、Apple Music的年度报告同期发布，而且设计更出圈，用户的注意力可能被分散了。

社交平台限流：微信、微博有时候会对第三方产品的分享内容进行限流，如果网易云的分享被平台限制了可见度，用户分享的动力也会下降。

可以验证的方法：看看公司其他产品的分享率有没有类似趋势，看行业报告里有没有相关数据，看竞品的年度报告热度。

可能原因五：分享渠道受限或成功率下降

如果微信、微博等平台对网易云的分享做了限制（比如屏蔽链接、限制传播、需要额外确认），分享成功率下降，用户试了几次分享不成功，后续就不愿意分享了。

可以验证的方法：看分享到不同渠道的成功率，有没有某个渠道的成功率大幅下降。比如分享到微信的成功率从95%降到了70%，那就是渠道问题。

可能原因六：时间节点不对

年度报告通常在12月或1月发布。如果今年发布时间和去年不同，或者和其他热点事件撞车了，分享率可能会受影响。

比如今年12月底正好有个重大新闻事件刷屏，用户的注意力都在那个事件上，年度报告的分享就被压下去了。

可以验证的方法：对比发布时间，看看发布当天和发布后一周的社交媒体热点有没有更抢眼的事件。

可能原因七：报告触达方式变了

去年可能是主动推送弹窗提醒用户查看年度报告，今年可能改成了被动入口（用户需要自己去找）。触达效率下降，看到报告的人变少，虽然看到后分享的比例可能差不多，但整体分享人数会下降。

要分清是"触达率下降"还是"分享转化率下降"。

第三部分：排查的优先级和步骤

如果我是分析师，会按这个顺序排查：

第一步：确认数据口径

确保去年和今年用的是同一个统计口径。把分子（分享人数）和分母（基数）都单独拉出来，看看各自的变化趋势。

比如：

去年：100万人看到报告，25万人分享，分享率25%

今年：150万人看到报告，31.5万人分享，分享率21%

分享人数其实涨了26%，只是看到报告的人涨得更多（50%），所以分享率下降了。这说明"触达"做得好，但"内容吸引力"可能有问题。

第二步：做分群对比

把用户按老用户/新用户、年龄段、城市级别、会员/非会员等维度分群，分别看各群体的分享率变化。

如果发现是某个群体的分享率大幅下降（比如老用户分享率从28%降到24%），问题可能出在那个群体对应的原因上。

如果发现各群体分享率都差不多，但群体结构变了（新用户占比增加），那是辛普森悖论。

第三步：看漏斗数据

把整个用户旅程拆开：

登录APP → 看到报告入口曝光 → 点击进入报告页 → 浏览报告（完成率） → 点击分享按钮 → 选择分享渠道 → 分享成功

看哪个环节的转化率下降了。

如果是"点击分享按钮"这一步下降了，可能是分享入口设计问题。

如果是"分享成功"这一步下降了，可能是分享渠道受限。

如果是"浏览报告完成率"下降了，可能是内容吸引力问题。

第四步：对比产品变化

今年的报告页面和去年有什么不同？分享按钮位置、分享文案、分享海报样式、报告内容设计有没有变化？

如果有明显的产品改动，这可能就是主因。

第五步：看外部因素

分享到不同渠道的比例和成功率有没有变化？竞争对手（QQ音乐、Spotify等）的年度报告分享率怎么样？社交媒体上关于年度报告的话题热度怎么样？

第四部分：DAU和用户时长增长，为什么分享率还下降？

这个看似矛盾的现象，其实可以这么理解：

理解一：DAU增长不等于"愿意分享的用户"增长

如果DAU增长主要来自"听歌刚需"用户（只是用来听歌，不太参与社交功能），这批用户会拉高DAU，但不会分享年度报告。

理解二：用户时长增长不等于"对年度报告感兴趣"

用户可能花更多时间听歌、刷评论、看歌单，但对年度报告这个特定功能不感兴趣。时长增长和报告分享是两件完全不同的事情。

理解三：辛普森悖论

假设老用户分享率30%，新用户分享率10%。

去年用户结构：老用户100万，新用户20万

去年整体分享率 = $(30\% \times 100 + 10\% \times 20) / 120 = 26.7\%$

今年用户结构：老用户100万，新用户50万（新用户增长了150%）

今年整体分享率 = $(30\% \times 100 + 10\% \times 50) / 150 = 23.3\%$

看起来分享率下降了3.4个百分点，但老用户和新用户各自的分享率其实没变，只是用户结构变了。

DAU和时长增长，可能恰恰是因为拉来了大量"低分享意愿"的新用户，他们贡献了活跃度，但稀释了分享率。

第五部分：分析完之后怎么汇报？

如果让我出一份分析报告，我会这么组织：

第一部分：现象描述

年度报告分享率从去年的25%下降到今年的21%，下降16%（4个百分点）。同期DAU增长12%，用户人均时长增长8%。分享绝对人数增长了26%。

第二部分：原因拆解（按贡献度排序）

- 1、用户结构变化（贡献约60%）：新用户占比从15%提升到25%，新用户分享率（12%）远低于老用户（28%）。这是主因。
- 2、分享入口调整（贡献约25%）：今年分享按钮从页面底部固定位置改到了页面顶部滚动区域，分享按钮点击率下降18%。
- 3、报告内容吸引力（贡献约15%）：用户在报告页面的平均停留时长从45秒下降到38秒，浏览完成率从72%下降到65%。今年报告的标签设计可能没有去年有共鸣。

第三部分：核心结论

分享率下降主要由用户结构变化导致，产品层面的分享入口调整和内容吸引力下滑是次要因素。分享绝对人数仍在增长，说明年度报告整体仍是成功的增长工具。

第四部分：建议

- 1、针对新用户设计更有分享点的报告内容，比如强调"新用户专属成就"
- 2、AB测试恢复分享按钮的原有位置，或者增加分享引导文案
- 3、在报告中增加更有话题性的标签和数据，提升内容的传播性
- 4、在分享后增加社交反馈，比如"已有X位好友看过你的报告"，刺激分享动机

知识点总结

- 1、指标拆解：分享率 = 分享人数 / 基数，要先搞清楚基数是什么，把分子分母分开看。
- 2、分群分析：用户结构变化可能导致整体指标下降，即使每个分群内部没有变化（辛普森悖论）。
- 3、漏斗分析：把用户旅程拆成多个环节（曝光→点击→浏览→分享→成功），定位问题出在哪个环节。
- 4、辛普森悖论：整体趋势和分群趋势可能相反，不能只看整体数据。
- 5、内外部因素并重：产品变化、用户习惯变化、外部平台政策变化，都要考虑。
- 6、结构化汇报：现象 → 原因（按贡献度排序） → 结论 → 建议，清晰有层次。

7、区分绝对值和比率：分享率下降但分享人数增长，说明产品整体是成功的，只是效率有待优化。

追问环节

如果进一步分析发现，新用户的分享率（12%）其实和去年新用户的分享率（11%）差不多，老用户的分享率从28%下降到了24%，你会怎么调整分析方向？问题可能出在哪里？

题目 54

双重差分DID：星巴克在部分城市试点取消"第三空间"堂食服务、只保留外带和外卖后，试点城市的单店日均订单量下降了15%，但人力成本节省了25%，如何用双重差分法评估这个策略的真实效果？

解答

星巴克的"第三空间"一直是它的核心卖点——不只是卖咖啡，而是卖一个可以坐下来办公、聊天、发呆的空间。但这个空间是有成本的：要租更大的店面、要雇更多店员、要维护更多设施。

现在试点取消堂食，订单量降了15%，但人力成本省了25%。这个策略到底是赚了还是亏了？直接比较试点城市和非试点城市的数据靠谱吗？

不靠谱。因为试点城市和非试点城市本身可能就不一样。这时候就需要用双重差分法。

第一部分：为什么不能直接比较试点和非试点城市？

假设星巴克选了北京、上海作为试点城市取消堂食，成都、杭州作为对照城市保持原样。

试点后数据：

北京上海：单店日均订单180单，人力成本8000元/天

成都杭州：单店日均订单210单，人力成本10000元/天

直接比较会得出结论：取消堂食导致订单量下降30单（14%），人力成本节省2000元。

但问题是：北京上海和成都杭州本来就不一样。

北京上海的咖啡市场竞争更激烈。瑞幸、Manner、Seesaw这些品牌在一线城市门店密度更高，用户选择更多。即使不取消堂食，北京上海的单店订单量可能本来就比成都杭州低。

北京上海的用户对"第三空间"的依赖可能更低。一线城市用户节奏快，外带和外卖比例可能本来就更高，取消堂食的冲击反而更小。

反过来也可能：北京上海的用户可能更看重"第三空间"体验，毕竟房价贵、家里地方小，星巴克是很多人的"免费办公室"。

不管是哪种情况，直接比较都会把"城市本身差异"和"政策效应"混在一起。

第二部分：双重差分的核心思想

双重差分的精髓是：用"变化的变化"来消除固有差异。

怎么理解？我们需要两组数据：

第一个差分：试点城市的"政策前后"变化

北京上海试点前（2024年3月）：单店日均订单212单

北京上海试点后（2024年6月）：单店日均订单180单

变化：下降32单

第二个差分：对照城市的"同期"变化

成都杭州同期2024年3月：单店日均订单220单

成都杭州同期2024年6月：单店日均订单210单

变化：下降10单

双重差分效应 = 试点城市变化 - 对照城市变化 = (-32) - (-10) = -22单

这-22单才是取消堂食真正导致的订单下降。

为什么要减去对照城市的变化？因为对照城市也下降了10单，说明这个时期整个咖啡市场可能都在下滑。可能是季节因素（6月天热了喝咖啡的人少了）、可能是经济因素（消费降级）、可能是竞争加剧。这10单的下降和取消堂食没关系，是"时间趋势"，要剔除掉。

双重差分的妙处就在于：通过对照组，我们可以把"时间趋势"剥离出去，剩下的就是纯粹的政策效应。

第三部分：用公式更清楚地理解

把订单量数据整理一下：

试点城市（北京上海）：政策前212单，政策后180单，变化-32单

对照城市（成都杭州）：政策前220单，政策后210单，变化-10单

双重差分公式：

$DID = (试点后 - 试点前) - (对照后 - 对照前)$

$DID = (180 - 212) - (210 - 220)$

$DID = (-32) - (-10)$

$DID = -22单$

这-22单就是我们要找的"因果效应"——取消堂食导致的订单下降。

换一种理解方式：

如果没有取消堂食，北京上海应该和成都杭州一样只下降10单，从212单变成202单。
但实际上北京上海变成了180单，比"应该"的202单少了22单。
这22单就是政策的影响。

同样的逻辑算人力成本：

试点城市：政策前10500元/天，政策后8000元/天，变化-2500元
对照城市：政策前10200元/天，政策后10000元/天，变化-200元

$$DID = (-2500) - (-200) = -2300 \text{元}$$

取消堂食真正节省的人力成本是2300元/天/店。对照城市也省了200元，可能是因为整体在做人员优化，这部分不是取消堂食带来的。

第四部分：双重差分的关键假设——平行趋势

双重差分有一个非常重要的假设：如果没有政策干预，试点城市和对照城市的变化趋势应该是一样的。
这叫"平行趋势假设"，是DID有效性的核心前提。

什么意思？假设没有取消堂食这个事，北京上海的订单量变化应该和成都杭州差不多。比如都下降10单，或者都增长5单，或者都持平。两条线是平行的。

如果这个假设成立，那试点城市多出来的那部分变化（-22单）就可以归因于政策。

如果这个假设不成立呢？

比如北京上海本来就在走下坡路——竞争太激烈、市场饱和了，即使不取消堂食，订单量也会比成都杭州跌得更多。那我们估计的-22单里面，可能有一部分是"本来就会跌的"，政策效应被高估了。

反过来，如果北京上海本来势头更好——虽然竞争激烈但品牌力强、用户忠诚度高，订单量应该比成都杭州更稳。那我们估计的-22单可能还低估了政策的负面影响。

怎么验证平行趋势？

看历史数据。在政策实施之前的半年甚至一年，试点城市和对照城市的趋势是不是平行的？

比如看2023年7月到2024年2月（政策前）的月度订单量：

如果北京上海和成都杭州每个月的增减幅度差不多，两条线基本平行，说明假设成立。

如果北京上海一直在往下掉、成都杭州在往上走，两条线发散，说明假设不成立，DID结论不可信。

实际操作中，通常会画一张"平行趋势图"，横轴是时间，纵轴是指标，画两条线，看政策前是否平行。

第五部分：完整的效果评估——算一笔财务账

现在我们有了双重差分的结果：

订单量效应：-22单/天/店
人力成本效应：-2300元/天/店

怎么判断这个策略值不值？需要把效应转化为财务指标。

收入损失计算：

假设星巴克的客单价是38元（一杯拿铁大概这个价）。
订单损失带来的收入损失： $22\text{单} \times 38\text{元} = 836\text{元/天/店}$

假设毛利率是65%（咖啡的毛利率一般比较高）。
订单损失带来的毛利损失： $836\text{元} \times 65\% = 543\text{元/天/店}$

成本节省计算：

人力成本节省：2300元/天/店

此外还可能节省：
水电成本（不用维护堂食区）：约200元/天/店
清洁耗材成本：约50元/天/店
设备折旧（减少桌椅损耗）：约30元/天/店

总成本节省：约2580元/天/店

净效益计算：

净效益 = 成本节省 - 毛利损失 = $2580 - 543 = 2037\text{元/天/店}$

每家店每天净赚2037元。
一个月（30天）：6.1万元
一年：74万元

如果试点城市有100家店，一年能多赚7400万。

但这只是短期财务账，还有几个重要问题要考虑：

第一，长期品牌影响。取消"第三空间"会不会损害星巴克的品牌定位？星巴克一直卖的是"体验"不是"咖啡"，价格比瑞幸贵一倍还有人买，靠的就是第三空间。如果变成纯外带店，用户凭什么不去买9.9的瑞幸？

第二，用户流失的滞后效应。短期订单只下降22单，但这些流失的用户去哪了？如果他们转向了竞争对手并且形成了新习惯，长期损失会更大。需要追踪6个月甚至1年的数据。

第三，租金成本有没有下降？取消堂食后如果能换更小的店面，租金能省一大笔。但如果店面合同没到期、没法缩小面积，那租金成本不变，空间却浪费了。

第四，外卖和外带的体验有没有变好？取消堂食后如果能把资源集中在提升出品速度、优化外卖包装，可能反而能拉动外卖订单增长，部分抵消堂食损失。

第六部分：双重差分的几个变体和进阶

变体一：多期双重差分（交错DID）

如果政策不是在同一时间点实施的（比如北京1月实施、上海3月实施、深圳5月实施），可以用多期DID。每个城市有自己的"处理时点"，通过更复杂的模型估计平均效应。

变体二：三重差分（DDD）

如果担心试点城市有其他变化同时发生，可以再加一个维度。

比如不仅比较星巴克试点/非试点城市，还比较星巴克和瑞幸。如果瑞幸在北京上海没有出现类似的订单下滑，说明星巴克的下滑确实和取消堂食有关，不是城市整体的问题。

三重差分 = (星巴克试点城市变化 - 星巴克对照城市变化) - (瑞幸试点城市变化 - 瑞幸对照城市变化)

变体三：倾向得分加权DID

如果试点城市和对照城市特征差异很大，可以用倾向得分给对照城市加权，让两组更可比。比如根据城市的人口、人均收入、咖啡店密度等特征计算匹配权重。

第七部分：实际业务中怎么用DID？

DID是因果推断的重要工具，适用于"某个时间点在某些对象上实施了政策"的场景。

场景一：价格策略测试

在部分区域涨价或降价，用DID评估对销量和收入的影响。比如在A城市涨价10%，用B城市作为对照。

场景二：功能/产品上线评估

在部分用户中上线新功能，用DID评估对留存或转化的影响。比如在A地区上线"预约取餐"功能，B地区暂时不上。

场景三：门店策略测试

在部分门店试点新的运营方式（延长营业时间、改变陈列方式、增加自助结账），用DID评估效果。

场景四：政策效果评估

某个城市出了新政策（比如禁止外卖满减、外卖限时送达规定），用DID评估对业务的影响。这种情况下你没有控制权，但可以用其他城市作为对照来评估政策冲击。

知识点总结

- 1、双重差分的核心逻辑：用"变化的变化"消除组间固有差异。第一次差分是时间维度（前后对比），第二次差分是组间维度（试点vs对照）。
- 2、平行趋势假设：政策实施前，试点组和对照组的变化趋势应该是平行的。这是DID有效的核心前提，必须检验。
- 3、因果效应估计：DID估计的是"平均处理效应"，即政策对试点组的平均影响。
- 4、验证方法：用政策前的历史数据画平行趋势图；用安慰剂检验（在没有政策的时间点假装有政策）验证方法可靠性。
- 5、财务评估：把效应转化为财务指标，综合评估策略的净效益，同时考虑短期和长期影响。

- 6、进阶方法：多期DID处理交错实施、三重差分排除其他干扰、倾向得分加权提高可比性。
- 7、局限性：DID只能估计平均效应；如果平行趋势不成立结论不可信；如果有其他政策同时实施效应会混淆。

追问环节

如果发现政策实施前，试点城市的订单量已经在下滑（每月下降2%），而对照城市是持平的，这种情况下还能用双重差分吗？结论会有什么问题？应该怎么处理？

追问解答

这种情况说明"平行趋势假设"不成立，直接用双重差分会有偏差。

问题在哪？

双重差分的核心假设是：如果没有政策干预，试点城市和对照城市的变化趋势应该是一样的。

但现在的情况是：政策实施前，北京上海已经在每月下降2%，成都杭州是持平的。两条线不是平行的，而是在发散。

这意味着：即使不取消堂食，北京上海也会继续下降。那政策实施后观察到的下降，有多少是政策导致的，有多少是"本来就会下降"的，就分不清了。

结论会有什么偏差？

假设真实情况是这样的：

政策前6个月，北京上海每月下降2%，累计下降了约12%

如果没有政策干预，北京上海在政策后还会继续下降

但政策真的加速了下降

用简单的双重差分，我们会高估政策的负面效果。

举个数字例子：

政策前：北京上海100单/天，成都杭州100单/天

政策后（假设3个月）：

北京上海实际变成75单（下降25单）

成都杭州变成100单（持平）

简单DID = (-25) - (0) = -25单

但如果北京上海本来就在以每月2%速度下滑，3个月后即使没有政策也会变成94单（下降6单）。

真实的政策效应 = -25 - (-6) = -19单，而不是-25单。

简单DID高估了6单的政策负面效果。

应该怎么处理？

方法一：用"趋势调整的双重差分"

不假设平行趋势，而是假设"趋势差异保持稳定"。

也就是说，如果政策前北京上海每月比成都杭州多下降2%，政策后这个趋势差异也会持续。

政策效应 = 实际观察到的差异 - 预期的趋势差异

这需要有足够长的政策前数据来估计趋势差异。

方法二：加入时间趋势项

在回归模型里加入城市特定的时间趋势项：

$$Y = \beta_0 + \beta_1 \times \text{试点} + \beta_2 \times \text{政策后} + \beta_3 \times \text{试点} \times \text{政策后} + \beta_4 \times \text{试点} \times \text{时间} + \epsilon$$

β_3 是政策效应， β_4 是试点城市特有的时间趋势。这样可以控制住趋势差异。

方法三：换对照组

如果北京上海和成都杭州趋势不平行，试着换其他城市做对照。

比如找一些和北京上海趋势更相似的城市（可能是其他一线城市、或者竞争同样激烈的城市）。

可以用倾向得分匹配或合成控制法来构造更好的对照组。

方法四：做敏感性分析

用不同的趋势假设做计算，看结论的变化范围。

假设趋势差异是每月1%、2%、3%，分别计算政策效应，看结论是否稳健。如果结论对趋势假设很敏感，那就要谨慎解读。

方法五：承认局限性

如果没有办法解决趋势不平行的问题，就要在报告里明确说明：

"由于试点城市 and 对照城市在政策前趋势不平行，DID估计可能存在偏差。估计的政策效应是-25单，但真实效应可能在-19单到-25单之间。"

诚实地承认方法的局限性，比过度自信更专业。

总结

平行趋势是DID的核心假设。如果假设不成立：

- 1、直接用简单DID会得出有偏的结论
- 2、需要用趋势调整、换对照组、或敏感性分析来修正
- 3、如果没法修正，就要明确说明结论的局限性

题目 55

合成控制法：携程想评估2026年春节期间在广州投放的品牌广告效果，但广州没有设置对照组，如何用合成控制法构造一个"虚拟广州"来做对比？

解答

广告效果评估是个老大难问题。投了几千万的品牌广告，到底带来了多少增量？

如果当时做了AB测试——广州投广告、深圳不投——那好办，直接比较就行。但现实是：广州投了，没有设置对照组。事后想评估效果，怎么办？

这时候就需要合成控制法出场了。

第一部分：为什么传统方法不好用？

方法一：直接对比广州和深圳

广州投了广告，深圳没投。春节期间广州的订单量增长了35%，深圳增长了28%。

能说广告带来了7%的增量吗？

不能。因为广州和深圳本来就不一样。

广州是传统的商业中心和交通枢纽，春节返乡流量巨大，这个特征深圳没有。广州有更多的文旅资源（长隆、白云山、广州塔），深圳偏科技商务。两个城市的用户构成、消费能力、出行目的地分布都不一样。

即使不投广告，广州的春节增长也可能和深圳不一样。所以这7%的差距里，有多少是广告效果，有多少是城市本身差异，分不清。

方法二：对比广州的今年和去年

广州2026年春节订单增长35%，2025年春节增长25%。

能说广告带来了10%的增量吗？

也不能。因为2024年和2023年的大环境不一样。

2024年春节可能有更多利好因素：假期天数不同、高铁新线路开通、热门景点新开放、消费信心恢复程度不同。这些因素都会影响增长，和广告无关。

反过来也可能有利空因素：如果2024年春节天气不好，增长反而可能被拖累，广告效果可能被低估。

核心问题：我们缺少一个"如果广州没投广告会怎样"的反事实场景。这个反事实不可观察，只能用方法去近似估计。

第二部分：合成控制法的核心思想

既然找不到一个完美的对照城市，那就用多个城市"合成"一个虚拟的对照。

核心思路：用其他没投广告的城市（深圳、杭州、成都、武汉、南京、西安、长沙等）按照一定权重加权平均，构造一个"虚拟广州"。

这个虚拟广州不是任何一个真实城市，而是多个城市的加权组合。它在广告投放之前的表现应该和真实广州高度相似——订单量相近、增长趋势相近、季节性规律相近。

如果虚拟广州和真实广州在广告投放前高度相似，那我们就有理由相信：广告投放后，虚拟广州的表现就是"真实广州如果没投广告会怎样"的合理估计。

广告效果 = 真实广州的表现 - 虚拟广州的表现

第三部分：具体怎么操作？完整流程

步骤一：选择候选对照城市（供体池）

选择一批没有投放品牌广告的城市作为候选"供体"。假设携程在春节期间只在广州投了品牌广告，其他城市都没投。

候选城市：深圳、杭州、成都、武汉、南京、西安、长沙、苏州、青岛、厦门

选择标准：

同期没有投放品牌广告（核心要求）

数据完整可得

城市规模和广州有一定可比性（不要用县城去合成一线城市）

最好涵盖不同类型的城市（旅游城市、商务城市、交通枢纽城市）

步骤二：收集广告投放前的历史数据

收集广州和所有候选城市在广告投放前至少12-24个月的月度数据：

核心指标：月度订单量、月度GMV、月度活跃用户数

用户特征：新客占比、客单价、复购率

城市特征：常住人口、人均GDP、旅游资源评分、交通便利度

时间范围：假设广告在2024年1月投放，那就收集2022年1月到2023年12月的数据。

步骤三：用算法寻找最优权重

合成控制法的核心是找到一组权重 $w_1, w_2, w_3, \dots, w_n$ ，使得：

$$\text{虚拟广州} = w_1 \times \text{深圳} + w_2 \times \text{杭州} + w_3 \times \text{成都} + \dots + w_n \times \text{厦门}$$

这组权重需要满足：

所有权重之和等于1

每个权重非负（不能有负权重）

加权后的虚拟广州在广告投放前和真实广州最接近

"最接近"通常用均方误差来衡量：最小化虚拟广州和真实广州在2022-2023年每个月订单量的差距。

假设算法给出的最优权重是：

深圳：32%

杭州：25%

成都：18%

武汉：12%

南京：8%

其他城市：5%（权重太小，基本不起作用）

这意味着：虚拟广州 = $0.32 \times \text{深圳订单量} + 0.25 \times \text{杭州订单量} + 0.18 \times \text{成都订单量} + \dots$

步骤四：验证拟合效果

检查虚拟广州在广告投放前的表现是否和真实广州足够接近。

画一张图，横轴是时间（2025年1月到2025年12月），纵轴是月度订单量。画两条线：真实广州（蓝色）和虚拟广州（橙色）。

如果两条线高度重合、几乎分不开，说明合成效果非常好。

如果两条线有明显差距，比如虚拟广州一直比真实广州低10%，说明这组候选城市没法很好地"合成"广州，结论可能不可信。

拟合质量指标：

平均绝对百分比误差（MAPE）< 5%：非常好

MAPE 5-10%：可以接受

MAPE > 10%：拟合效果差，结论要谨慎

假设我们的MAPE是3.2%，拟合效果很好。

步骤五：计算广告效果

现在看广告投放后（2024年1-2月春节期间）的数据：

真实广州：订单量243万单

虚拟广州：订单量218万单（用同样的权重计算）

广告效果 = 243 - 218 = 25万单

相对效果 = 25 / 218 = 11.5%

结论：春节期间的品牌广告大约带来了11.5%的订单增量，约25万单。

如果这次广告花了500万，那每单的获客成本是500万/25万 = 20元。如果平均客单价是400元、利润率15%，那每单利润60元，广告ROI = 60/20 = 3。这个ROI相当不错。

第四部分：合成控制法的关键要求和假设

要求一：拟合期的匹配要足够好

如果虚拟广州和真实广州在广告投放前就差很远，那投放后的差距也没法归因于广告。

为什么？因为如果拟合不好，说明虚拟广州没能真正"模拟"广州的特性。它在广告后的表现也就不能代表"广州没投广告会怎样"。

一般要求：拟合期的平均误差要小于5%，最好小于3%。如果误差太大，要么换候选城市，要么承认这个方法在这个场景下不适用。

要求二：候选城市要有足够的多样性

如果所有候选城市都和广州差距很大，那怎么加权也合成不出一个像广州的东西。

比如如果候选城市全是三四线城市，那无论怎么加权，订单量规模都远小于广州，没法合成。

需要候选城市在各个维度上"包围"广州——有的城市订单量比广州高、有的比广州低；有的城市增长快、有的增长慢。这样才能通过加权组合出接近广州的特征。

要求三：候选城市不能受到同样或类似的干预

如果深圳虽然没投品牌广告，但投了效果广告、或者做了大促活动，那深圳的数据就"不干净"，不能作为供体。

所有供体城市在研究期间应该"保持正常运营"，没有重大的营销活动或外部冲击。

要求四：时间序列要足够长

拟合期太短的话，可能只是偶然匹配上了，不是真的规律相似。

一般要求至少12个月的拟合期，最好有24个月以上。

第五部分：怎么判断结论是否可信？

结论出来了，怎么知道是不是靠谱？需要做各种检验。

检验一：安慰剂检验（供体城市检验）

对每个候选供体城市都假装它是"处理组"，用其他城市合成它，看看能不能发现类似的"效应"。

比如假装深圳投了广告（实际没投），用杭州、成都、武汉等合成一个"虚拟深圳"，看2024年春节深圳的真实表现和虚拟表现差多少。

如果深圳也发现了10%的"效应"，那说明这个方法可能不可靠——因为深圳根本没投广告，不应该有效应。

如果只有广州能发现显著效应（11.5%），其他城市的"效应"都在正负3%以内波动，说明广州的效应是真实的。

检验二：时间安慰剂检验

假装广告是在更早的时间点投放的（比如2023年10月），用同样的方法计算那个时间点的"效应"。

2023年10月广州没有投广告，所以不应该有效应。如果在那个时间点也发现了10%的效应，说明方法有问题，可能是拟合本身的偏差。

检验三：敏感性分析（换供体组合）

换不同的候选城市组合，看结论是否稳健。

比如把深圳排除在外，只用杭州、成都、武汉、南京合成，看效应是多少。

把所有一线城市排除，只用二线城市合成，看效应是多少。

如果不同供体组合下，效应都在10-13%之间，说明结论稳健。

如果换几个城市后结论从11%变成了3%或者25%，说明结论对城市选择很敏感，不够稳健，要谨慎解读。

第六部分：合成控制法 vs 双重差分

两者都是因果推断的方法，但适用场景不同。

双重差分（DID）的要求：

- 需要一个"平行"的对照组
- 处理组和对照组在干预前趋势一致
- 适合有天然对照组的场景

合成控制法的要求：

- 不需要单一对照组
- 用多个单位加权合成对照
- 适合没有天然对照组、只有单一处理单位的场景

举个例子：

如果携程在广州、深圳、杭州同时投了广告，可以用成都、武汉作为对照组做DID。

如果只在广州投了广告，没有天然对照组，那用合成控制法更合适。

合成控制法更灵活，但也更复杂，结论的可信度更依赖于拟合质量和各种检验。

第七部分：业务中还有哪些场景可以用？

合成控制法特别适合"单一处理单位、事后评估"的场景。

场景一：区域性政策或活动评估

某个省份/城市出了新政策（旅游补贴、消费券）或做了专属活动，想评估效果。没有同期对照组，可以用其他省份/城市合成。

场景二：单个大客户或合作伙伴的效果评估

某个大客户做了专属营销活动、某个航司做了联合促销，想评估效果。可以用其他类似客户/航司合成对照。

场景三：品牌事件的影响评估

某个负面舆情事件发生后（如酒店卫生门、机票大数据杀熟争议），想评估对订单量的影响。可以用其他时期或竞品合成对照。

场景四：门店/站点关闭或开业的影响评估

关闭某个线下门店后，想评估对区域线上订单的影响。可以用其他区域合成对照。

场景五：产品重大改版的效果评估

APP做了一次重大改版，但没法做AB测试（改版是全量上线的）。可以用竞品APP或历史趋势合成对照。

知识点总结

- 1、核心思想：用多个未处理单位加权合成一个虚拟对照，模拟处理单位"如果没有干预会怎样"。
- 2、权重确定：算法自动寻找最优权重，使得合成单位在干预前和处理单位最接近（最小化拟合误差）。
- 3、拟合质量：干预前的拟合越好，干预后的效应估计越可信。MAPE小于5%是基本要求。
- 4、安慰剂检验：对其他供体单位做同样的分析，确保只有处理单位有显著效应。
- 5、敏感性分析：换不同的供体组合，确保结论稳健。
- 6、适用场景：单一处理单位、没有自然对照组、有足够的候选供体和历史数据、事后评估。
- 7、局限性：如果候选供体不够丰富，可能无法合成出良好的对照；对数据质量和时间序列长度要求高；计算相对复杂。

追问环节

如果发现无论怎么调整权重，虚拟广州在广告投放前3个月的表现总是比真实广州低5-8%，这种情况下还能用合成控制法吗？结论会有什么偏差？应该怎么处理？

追问解答

这种情况说明拟合质量不够好，直接用合成控制法的结论会有偏差。但不是完全不能用，需要做一些调整和修正。

问题在哪？

合成控制法的前提是：虚拟对照在干预前能很好地"模拟"真实处理单位的表现。如果拟合期就差5-8%，说明候选供体城市"合成"不出广州的特征。

可能的原因：

广州有某些独特特征其他城市组合无法复制的。比如广州是华南交通枢纽、有独特的粤语文化、有长隆等独特旅游资源。

候选供体城市不够丰富或不够多样。如果候选城市都是北方城市，可能怎么组合都无法模拟南方城市广州。

广州在某个特定时段有特殊事件。比如广交会期间订单量会异常高，其他城市没有这个特点。

结论会有什么偏差？

如果虚拟广州系统性地比真实广州低5-8%，那广告效应估计也会受影响。

假设：

真实广州广告期间：243万单

虚拟广州广告期间：218万单

简单计算的效应 = $243 - 218 = 25$ 万单

但如果虚拟广州本身就偏低5-8%，那218万单可能低估了"没有广告时广州应有的表现"。

如果按6%的偏差修正：虚拟广州应该是 $218 \times 1.06 = 231$ 万单

修正后的效应 = $243 - 231 = 12$ 万单

广告效应可能被高估了一倍！

应该怎么处理？

方法一：用偏差修正

计算拟合期的平均偏差比例，然后对广告期的虚拟广州进行修正。

假设拟合期虚拟广州平均比真实广州低6%：

修正系数 = 1.06

修正后虚拟广州 = 原虚拟广州 $\times$ 1.06

这是最简单的修正方法，但假设偏差比例是稳定的。

方法二：扩大候选供体池

加入更多城市作为候选供体，特别是和广州特征更接近的城市。

比如加入东莞、佛山、深圳（如果深圳没投广告的话）、厦门、福州等华南城市。

也可以加入一些同样是交通枢纽的城市，比如郑州、武汉。

更丰富的供体池可能能更好地合成广州的特征。

方法三：使用协变量匹配

不只是匹配订单量这个结果变量，还要匹配影响订单量的因素：

- 城市人口
- 人均GDP
- 旅游资源评分
- 交通便利度（机场吞吐量、高铁站数量）
- 历史同期增长率

在优化权重时同时考虑这些协变量，可能能得到更好的拟合。

方法四：报告置信区间

承认拟合有误差，报告一个区间而不是点估计。

比如："广告效应估计在12万单到25万单之间，中点值约18万单。由于拟合期存在5-8%的误差，实际效应可能接近区间下界。"

方法五：换一种评估方法

如果合成控制法实在不适用，可以考虑其他方法：

- 如果有足够的历史数据，可以用时间序列预测（比如用2022-2023年的数据预测2024年春节，然后和实际值比较）
- 如果有其他城市同期投了广告，可以用双重差分
- 如果能获取用户级数据，可以用倾向得分匹配

总结

拟合期偏差5-8%是一个警告信号：

- 1、不能直接用简单的效应估计，可能会显著高估广告效果
- 2、要么用偏差修正、要么扩大供体池、要么报告区间
- 3、如果偏差太大（比如超过10-15%），可能要承认合成控制法在这个场景下不适用，换其他方法

题目 56

B站首页推荐位有5个不同的运营活动banner，传统AB测试需要跑2周才能出结果，如何用多臂老虎机算法边测试边优化，减少流量损失？

解答

B站首页的banner位是黄金流量入口，每天几千万用户会看到。现在有5个活动banner要选一个放上去，传统做法是跑两周AB测试，然后选点击率最高的那个。

但问题来了：两周里有大量流量被分配给了效果差的banner，白白浪费了。能不能一边测试一边优化，让好的banner尽早获得更多流量？

这就是多臂老虎机要解决的问题。

第一部分：传统AB测试的问题在哪？

假设5个banner的真实点击率分别是（当然实际中我们事先不知道）：

Banner A：3.2%（最好）

Banner B：2.8%

Banner C：2.1%

Banner D：1.9%

Banner E：1.5%（最差）

传统AB测试的做法：把流量平均分成5份，每个banner分20%流量，跑两周，最后看谁点击率高，选那个全量上线。

两周后我们确实能找出A是最好的。但过程中有什么损失？

假设两周内这个位置总共有1000万次曝光。

平均分配的话：每个banner各200万次曝光

实际点击情况：

A：200万 × 3.2% = 6.4万点击

B：200万 × 2.8% = 5.6万点击

C：200万 × 2.1% = 4.2万点击

D：200万 × 1.9% = 3.8万点击

E：200万 × 1.5% = 3.0万点击

总计：23万点击

如果一开始就知道A最好，全部流量给A会怎样？

1000万 × 3.2% = 32万点击

损失 = 32万 - 23万 = 9万点击

这9万点击就是AB测试的"探索成本"——为了找出最优选项而付出的代价。这9万点击本可以带用户进入活动页面、产生转化、贡献收入。

而且这还是"理想情况"。实际中如果效果差异更大，损失会更严重。比如如果A是5%、E是0.5%，损失会是灾难性的。

能不能减少这个代价？

第二部分：多臂老虎机的核心思想

多臂老虎机这个名字来自赌场的老虎机。想象你面前有5台老虎机（每台有一个"臂"来拉），每台的回报率不同但你事先不知道具体是多少。你有有限的硬币可以投，目标是赚最多的钱。

策略一：先每台试10次，然后只玩回报最高的那台。

这就是传统AB测试的逻辑——先探索、后利用。问题是探索期间浪费了很多硬币在差的机器上。

策略二：边玩边调整。一开始每台都试试，哪台表现好就多玩哪台，表现差的逐渐减少。但也不能完全放弃表现差的——万一它只是运气不好、实际很好呢？

第二种策略就是多臂老虎机算法的思路。

核心挑战是平衡"探索"和"利用"：

探索（Exploration）：尝试不确定的选项，获取更多信息，减少未来的不确定性

利用（Exploitation）：选择目前看起来最好的选项，获取当前收益

纯探索（一直平均分配流量）：损失太多当前收益

纯利用（一直全给目前最好的）：可能因为样本太少而选错，错过真正最优的选项

好的算法需要在两者之间找到动态平衡：早期多探索、后期多利用。

第三部分：几种常见的MAB算法

算法一：Epsilon-Greedy (ϵ -贪婪)

最简单的算法。每次分配流量时：

有 ϵ 的概率随机选一个banner（探索）

有 $1-\epsilon$ 的概率选目前点击率最高的banner（利用）

假设 $\epsilon=0.1$ ，那就是10%的流量随机分配用于探索，90%的流量给目前最优的选项。

例子：假设目前A点击率最高。来了一个用户：

掷骰子，10%概率触发随机，90%概率触发贪婪

如果触发随机：从A/B/C/D/E中随机选一个展示

如果触发贪婪：展示A

优点：简单好理解，5分钟就能实现

缺点： ϵ 是固定的。早期数据少时探索不够（10%可能不够），后期数据多时探索太多（其实已经很确定A最好了，还在浪费10%流量探索）

改进版：Decaying Epsilon-Greedy，让 ϵ 随时间递减。早期 $\epsilon=0.3$ 多探索，后期 $\epsilon=0.01$ 几乎不探索。

算法二：UCB（Upper Confidence Bound，置信上界）

考虑两个因素：这个选项的平均点击率，以及我们对这个估计的"确定程度"。

尝试次数越少的选项，不确定性越高。即使目前点击率看起来低，也给它一些机会——因为它可能只是样本太少导致的偏差，真实点击率可能很高。

公式大概是：UCB值 = 平均点击率 + 不确定性加成

每次选择UCB值最高的那个。

例子：

A：展示了10万次，点击率3.1%，不确定性很低， $UCB = 3.1\% + 0.1\% = 3.2\%$

E：展示了1000次，点击率1.5%，不确定性很高， $UCB = 1.5\% + 1.0\% = 2.5\%$

虽然E的点击率低，但因为数据少不确定性高，UCB值还不算太低，还有被选中的机会。

随着E被展示更多次，如果它真的不行，不确定性会下降，UCB值会降到很低，就不会再被选中了。

优点：有理论保证，长期来看能达到接近最优的总收益

缺点：对参数设置有要求，实际调优需要经验

算法三：Thompson Sampling（汤普森采样）

用贝叶斯思想。为每个banner维护一个点击率的概率分布（通常用Beta分布）。

每次分配流量时，从每个banner的分布中随机采样一个值，选采样值最高的那个。

点击率估计越确定的banner，分布越窄，采样结果越集中在真实值附近。

点击率估计越不确定的banner，分布越宽，采样结果波动大，有机会"爆冷"被选中。

例子：

A：数据多，分布集中在3.0%-3.4%之间，这次采样得到3.2%

E：数据少，分布分散在0%-4%之间，这次采样碰巧得到3.5%

这次E的采样值更高，E被选中展示。如果E真的不行，多展示几次后它的分布会收窄到1.5%附近，以后采样值就很难超过A了。

这样自然地实现了探索和利用的平衡：不确定的选项有更大的"惊喜"概率，但随着数据积累，差的选项会自动被淘汰。

优点：效果通常最好，在实践中广泛使用，Google、Netflix等大厂都在用

缺点：理解和实现稍复杂，需要维护概率分布

第四部分：用Thompson Sampling跑一遍B站的场景

我们来模拟一下Thompson Sampling怎么运作。

初始状态：5个banner，每个都没有数据，假设先验都是Beta(1,1)分布（代表完全不知道，点击率可能是0-100%任意值）。

第1天：冷启动，每个banner各分配2万次曝光

结果（假设真实点击率生效）：

A：640点击，点击率3.2%

B：520点击，点击率2.6%

C：450点击，点击率2.25%

D：410点击，点击率2.05%

E：280点击，点击率1.4%

更新每个banner的Beta分布：

A：Beta(1+640, 1+19360) → 分布集中在3.2%附近

E：Beta(1+280, 1+19720) → 分布集中在1.4%附近

第2天：根据Thompson Sampling分配流量

每次有用户来，从5个分布中各采样一个值，选最高的那个展示。

因为A的分布中心在3.2%，采样值大概率在3.0%-3.4%之间。

E的分布中心在1.4%，采样值大概率在1.2%-1.6%之间。

A采样值高于E的概率非常大，所以A会获得大部分流量。

假设第2天分配结果：

A：8万次曝光（40%）

B：4万次曝光（20%）

C：3万次曝光（15%）

D：3万次曝光（15%）

E：2万次曝光（10%）

第3-7天：继续动态调整

随着数据积累，A的优势越来越明确。到第7天分配可能变成：

A：15万次曝光（75%）

B：3万次曝光（15%）

C/D/E：共2万次曝光（10%）

第8-14天：基本锁定

到后期，A已经很确定是最优的：

A：18万次曝光（90%）

其他：共2万次曝光（10%）

最终效果对比

传统AB测试（平均分配14天）：

每个banner各200万次曝光

总点击：23万

Thompson Sampling（动态调整14天）：

A获得约700万次曝光

B获得约150万次曝光

C/D/E共获得约150万次曝光

总点击：约28万

多赚了5万点击，减少了约55%的探索损失。

而且Thompson Sampling还有个额外好处：如果A真的是最优的，它更早获得更多流量，活动效果更早达到峰值。

第五部分：实际业务中怎么落地？

落地步骤一：确定要优化的指标

是点击率、转化率、还是GMV？指标不同，"最优"的定义不同。

对于B站banner，通常看点击率（CTR）。但如果活动目标是拉新，可能要看"点击后7日留存率"。如果目标是变现，可能要看"点击后付费金额"。

选错指标会导致优化方向错误。比如追求点击率可能选出一个"标题党"banner，点击高但转化差。

落地步骤二：确定候选项和流量规模

5个banner，每天100万曝光，计划跑2周。

如果候选项太多（比如20个），可以先用规则筛选掉明显差的，再用MAB在剩下的里面选。

落地步骤三：选择算法

Thompson Sampling通常是首选，效果好且有成熟的开源实现。

如果团队技术能力有限，Epsilon-Greedy也可以，虽然不是最优但实现简单，效果也不会差太多。

不建议自己从零实现UCB，参数调优比较复杂。

落地步骤四：设置安全机制

最小流量保证：每个banner至少5%流量，防止好banner因为早期运气差被彻底放弃。

防止"锁死"：设置衰减机制，让早期数据权重降低。万一早期数据有偏（比如展示给了特殊用户群），不会永久影响结论。

异常监控：如果某个banner点击率突然暴跌（可能是素材挂了），要有告警机制。

落地步骤五：设置结束条件

什么时候可以"宣布胜出"结束测试？

方法一：看置信度。如果A的点击率95%置信区间下界已经高于B的置信区间上界，可以认为A显著胜出。

方法二：看收益曲线。如果连续3天A获得的流量比例都超过85%，说明算法已经很确定A最优。

方法三：设置最长时间。无论如何，跑到2周就结束，避免无限期测试。

第六部分：MAB vs 传统AB测试，什么时候用哪个？

用MAB的场景：

选项之间差异可能较大：差异大意味着探索成本高，MAB优势明显。如果A是5%、E是0.5%，平均分配会浪费大量流量。

时间敏感：活动周期短（比如就7天），等不起两周AB测试。

流量珍贵：每一次曝光都很珍贵，不想浪费在差选项上。比如核心用户的推送位。

可以接受"没有严格p值"：MAB的目标是最大化收益，不是假设检验。如果老板只关心"选最好的"而不需要论文级别的统计结论，MAB就够了。

用传统AB测试的场景：

需要严格的统计显著性：比如医疗场景（药物有效性）、金融场景（风控模型），需要确定的p值和置信区间。

选项之间差异可能很小：如果A是3.2%、B是3.1%，差异只有0.1%，探索成本本来就不高，MAB优势不明显。

需要事后分析：传统AB测试的数据更均衡，更容易做事后的用户分群分析、归因分析。MAB的数据量不均衡，分析起来更麻烦。

组合使用的策略：

先用MAB快速筛选，从10个选项中找出3个较好的。

再对这3个做传统AB测试，获得严格的统计结论和详细的分群分析。

第七部分：MAB的几个坑和注意事项

坑一：冷启动问题

新选项刚上线没有数据，可能被算法"冷落"。尤其是用Epsilon-Greedy时，新选项要等很久才能攒够数据。

解决办法：设置最小曝光保证。每个选项前1000次曝光强制平均分配，之后再启用MAB逻辑。

坑二：非平稳环境

如果选项的真实点击率在变化（比如A的创意看多了审美疲劳、随节日热度变化），算法可能跟不上。

解决办法：加入时间衰减机制，让近期数据权重更高。比如只用最近7天的数据计算点击率。

坑三：延迟反馈

如果优化目标是"付费转化", 用户点击后可能几天后才付费。算法基于不完整的数据做决策, 可能会误判。

解决办法: 考虑反馈延迟, 使用"延迟修正"的算法变体, 或者用更短期的代理指标(比如加购率)。

坑四: 样本量不均衡的统计问题

最后A获得了90%的流量、E只有1%。A的点击率估计会很准, E的估计会很不准。这种不均衡可能导致一些事后统计分析困难。

如果后续需要对E做详细分析, 可能需要单独补充数据。

知识点总结

- 1、探索vs利用权衡: MAB的核心问题是平衡"尝试不确定选项"和"利用当前最优选项"。
- 2、三种常见算法: Epsilon-Greedy简单但不够智能; UCB有理论保证; Thompson Sampling实践效果最好。
- 3、动态流量分配: MAB根据实时数据动态调整流量, 让好选项更早获得更多流量。
- 4、减少探索损失: 相比平均分配, MAB可以减少30-60%的探索损失。
- 5、落地注意事项: 设置最小流量保证、处理冷启动、考虑延迟反馈、设置结束条件。
- 6、适用场景: 时间敏感、选项差异大、流量珍贵、可接受非严格统计检验的场景。
- 7、与AB测试的关系: 不是替代关系, 而是互补关系, 可以组合使用。

追问环节

如果运营希望在第5天增加一个新banner F, 这个新banner该怎么加入正在运行的MAB系统? 会不会影响之前的结论? 应该怎么处理?

追问解答

可以加入, 但需要特殊处理, 否则新banner可能"吃亏"。

问题在哪?

到第5天时, 原来的5个banner已经积累了大量数据。假设A已经展示了50万次, 有1.6万点击, 点击率稳定在3.2%左右, 算法对A的点击率估计很有信心。

新banner F刚加入, 展示0次, 点击0次, 什么数据都没有。

如果用Thompson Sampling:

A的分布: Beta(16001, 483999), 非常集中在3.2%附近

F的分布: Beta(1, 1), 从0%到100%都有可能

虽然F的分布很宽，采样可能会采到较高的值，但A的分布已经很集中，每次采样都在3.1%-3.3%之间。F要想"爆冷"胜出，需要采样到3.3%以上，概率大约50%。

所以F刚加入时确实有机会获得一些流量。但如果F的前几次展示运气不好（点击率偶然偏低），它的分布会迅速收窄到低位，后续就很难翻身了。

这就是"冷启动"问题：新选项可能因为早期运气不好被算法"误杀"。

应该怎么办？

方法一：强制初始探索

给F一个"保护期"，比如前1万次曝光强制平均分配，不参与MAB竞争。

这1万次曝光让F积累足够的数据，然后再把F纳入MAB系统。

这样可以避免F因为早期样本太少而被误判。

方法二：用乐观初始化

给F一个"乐观"的先验分布，比如Beta(100, 100)而不是Beta(1, 1)。

这相当于假设F一开始就有不错的表现（50%点击率的先验），需要足够多的数据才能推翻这个假设。

这样F在数据少的时候会获得更多曝光机会。

方法三：设置最小流量保证

无论算法怎么分配，每个选项至少获得5%的流量。

这样F虽然是新来的，也能保证每天有一定的曝光量，不会被完全冷落。

方法四：独立测试后再合并

先把F单独拉出来，和当前最优选项A做一轮头对头的AB测试。

比如用10%的流量做F vs A的测试，跑3天看结果。

如果F表现不错，再把F纳入MAB系统，并且用测试期间积累的数据初始化F的分布。

会不会影响之前的结论？

对之前的结论（A是最优）影响不大，因为A已经有足够的数据支撑。

但如果F真的比A更好，那之前的"最优"结论就需要更新了。

从业务角度看，这不是坏事——如果F是更好的选项，我们希望能尽快发现它。

具体影响：

如果F加入后表现一般（比A差），那A继续保持最优地位，前5天的结论不变。

如果F加入后表现很好（比A好），那系统会逐渐把流量切到F，最终结论会从"A最优"变成"F最优"。

如果F加入后表现和A差不多，那两者会竞争流量，最终结论可能是"A和F都不错，选哪个都行"。

实际操作建议

如果运营经常要加入新banner，建议建立一个标准流程：

- 1、新banner必须先经过"冷启动期"，获得至少5000-10000次曝光
- 2、冷启动期的流量从"最小保证流量"中分配，不影响主要选项的流量
- 3、冷启动期结束后，根据积累的数据初始化分布，再纳入MAB系统
- 4、如果新banner在冷启动期表现很差（点击率低于平均水平50%），可以直接淘汰，不纳入MAB

这样既保证了新选项有公平的测试机会，又不会因为频繁加入新选项而扰乱整个实验系统。

题目 57

饿了么发现某次促销活动的整体ROI只有0.8（亏损），但活动曝光量、点击率、加购率都很高，问题出在哪个环节？怎么拆解分析？

解答

活动曝光高、点击高、加购高，但ROI只有0.8，这组数据放在一起就很诡异。

按理说前面每个环节都表现不错，最后结果应该是赚钱的才对。但现在是亏钱的，说明后面某个环节出了大问题。

这就需要把漏斗拆开，一层一层往下看。

第一部分：先搞清楚ROI是怎么算的

$ROI = \text{收益} / \text{成本}$

$\text{活动ROI} = \text{活动带来的增量收益} / \text{活动投入成本}$

如果ROI是0.8，意味着投入100块只赚回80块，亏了20块。

这里要注意"增量收益"这个词。不是说活动期间产生了100万GMV，收益就是100万。很多用户可能本来就会下单，活动只是让他们"顺便"用了优惠。真正的增量是：活动期间GMV - 如果没有活动会产生的GMV。

我们需要拆解两个方向：

成本有没有问题：是不是投入太多了？成本结构是否合理？
收益有没有问题：是不是赚得太少了？GMV不够还是利润率不够？

收益 = GMV × 利润率

GMV又可以拆成完整的漏斗：

GMV = 曝光量 × 点击率 × 加购率 × 下单率 × 客单价

现在题目说曝光、点击率、加购率都高，那问题可能出在：

- 下单率（加购后没下单）
- 客单价（下单了但金额低）
- 利润率（有GMV但不赚钱，被补贴吃掉了）
- 成本侧（投入太高，或者投入结构有问题）

第二部分：完整拆解漏斗，带数据

假设我们拿到了完整数据：

活动总投入：50万
其中：红包/满减补贴 30万，广告投放 15万，运营人力 5万

漏斗数据：

曝光量：500万次
行业平均曝光量（同类活动）：300万
对比结论：曝光确实很高，做得不错

点击率：8%（点击40万次）
行业平均：5%
对比结论：点击率确实高，素材吸引人

加购率：25%（加购10万人）
行业平均：15%
对比结论：加购率也高，商品有吸引力

下单率：30%（下单3万人）
平时活动：50%
对比结论：下单率低了20个百分点，问题在这里！

客单价：55元
平时活动：65元
对比结论：客单价也低了15%，也是问题

总GMV：3万 × 55元 = 165万

利润计算：

平台抽成比例：假设15%，即24.75万

但平台补贴支出：30万（满减红包）

平台净收益：24.75 - 30 = -5.25万？

这还没算广告费。如果把广告费也算进去，亏损更多。

实际ROI = (24.75 - 30) / 50 = -10.5%？

等等，题目说ROI是0.8，不是负数。说明可能是用的不同口径。

用GMV口径的ROI：165万 / 50万 = 3.3（但这个不是真实收益）

用毛利口径（不扣补贴）：24.75万 / 50万 = 0.495

用毛利口径（扣补贴后）：(24.75 - 30) / 50 = 负数

题目说0.8，可能是某种中间口径。无论如何，ROI低于1就是亏损。

第三部分：逐层对比找问题

问题一：下单率为什么从50%掉到30%？

这是最大的问题。10万人加购，但只有3万人下单，7万人流失了。

如果下单率能恢复到50%，下单人数就是5万，GMV就是275万，整体情况会好很多。

可能原因：

原因A：满减门槛设置不当

活动是"满50减10"，但很多用户加购金额只有35-40块。

他们加购后发现凑不到50块的满减门槛，又不想为了10块钱强行多买，就放弃了。

验证方法：看流失用户在加购时的购物车金额分布。如果大量集中在40-49元区间，说明是门槛问题。

原因B：配送费劝退

加购后进入结算页，发现要加5块配送费。原本45块的订单变成50块，用户觉得不划算就放弃了。

验证方法：看结算页的跳出率。如果结算页跳出率比平时高很多，而且流失用户的订单金额普遍接近免配送门槛，说明是配送费问题。

原因C：库存或配送时间问题

用户加购后发现商品没货了，或者配送时间要1小时以上（饿了），就放弃了。

验证方法：看流失用户加购的商品的库存情况和配送时效。

原因D：优惠规则太复杂

需要先领券、再凑单、还要满足时段限制，用户嫌麻烦就放弃了。

验证方法：看用户从加购到下单的操作步骤数，以及各步骤的流失率。

问题二：客单价为什么从65元掉到55元？

客单价下降了15%，也不是小问题。同样的下单人数，客单价低15%意味着GMV也低15%。

可能原因：

原因A：活动吸引了低消费用户

大力度促销（比如新人专享、超低价爆款）吸引了很多价格敏感用户，他们只买最便宜的东西。

验证方法：看下单用户的历史客单价分布。如果大量是历史客单价低于30元的用户，说明吸引了低价值用户。

原因B：满减门槛设置导致"卡点"行为

如果是"满50减10"，用户会倾向于刚好凑到50块就下单，不会多买。

平时没有满减的话，用户可能会买65块的东西。有满减后，用户精打细算只买50块。

验证方法：看下单金额的分布。如果大量订单集中在50-55元区间（刚过满减门槛），说明是门槛导致的卡点行为。

原因C：主推品类的客单价本身就低

这次活动主推的是下午茶（奶茶、咖啡、甜点），客单价天然比正餐低。

验证方法：看品类结构。如果下午茶品类占比比平时高很多，说明是品类结构问题。

问题三：补贴效率怎么样？

30万补贴真的带来了增量吗？

如果这30万补贴大部分给了"本来就会下单的老用户"，那就是浪费。

验证方法：把用户分成两类：

近7天有下单的老用户

近7天没下单的新/沉默用户

看补贴的分布：

如果70%的补贴给了老用户——补贴效率低，这些人本来也会下单

如果70%的补贴给了新/沉默用户——补贴在激活用户，效率高

第四部分：根据分析给出建议

假设我们定位到核心问题是：

下单率低，主因是"满减门槛太高+配送费劝退"

客单价低，主因是"门槛卡点行为"

补贴效率低，主因是"老用户薅羊毛"

优化建议：

建议一：降低满减门槛，改成"满30减6"

现在的"满50减10"门槛太高，用户凑不到就放弃。
改成"满30减6"，门槛低、用户更容易达到、下单率会提升。
虽然单笔补贴金额小了，但下单人数可能翻倍，总GMV反而更高。

建议二：对低客单价订单减免配送费

对于30-50元的订单，补贴2-3块配送费。
这样用户不会因为配送费在最后一步流失。
成本可能比满减更可控。

建议三：补贴定向给新用户和沉默用户

老用户只给小额优惠（或不给）。
把大额补贴集中给新用户首单、30天未下单用户。
提高补贴的增量效率。

建议四：设置阶梯满减，鼓励用户多买

不只是"满50减10"，改成"满30减5、满50减12、满80减20"。
鼓励用户向更高档位凑单，提升客单价。

第五部分：漏斗分析的标准方法论

漏斗分析的核心是"分层拆解 + 对比基准"：

第一步：画出完整漏斗

曝光 → 点击 → 浏览 → 加购 → 结算 → 支付成功

根据业务特点可以细化。外卖场景还可以加上"选地址""选配送时间"等环节。

第二步：计算每层转化率

点击率 = 点击 / 曝光

加购率 = 加购 / 点击

下单率 = 下单 / 加购

支付成功率 = 支付成功 / 下单

第三步：和基准对比

时间对比：和上周、上月、去年同期比

活动对比：和上次类似活动比

竞品对比：和行业平均水平比

第四步：定位问题层

哪一层转化率下降最明显（相对降幅最大），问题就在那一层。

比如下单率从50%降到30%，降幅40%，这是最大的问题。

第五步：深挖问题层内部

按用户类型拆：新用户vs老用户

按品类拆：正餐vs下午茶

按时段拆：午高峰vs晚高峰

按金额拆：高客单价vs低客单价

第六步：归因到具体原因

是产品体验问题（页面卡顿、流程复杂）

是运营策略问题（门槛设置、补贴规则）

是用户质量问题（吸引了错误的用户群）

是外部因素（天气、竞争对手、节假日）

知识点总结

- 1、漏斗拆解思维：把最终结果（ROI）拆解成多个环节的乘积，逐层分析定位问题。
- 2、对比分析法：同比、环比、横比、基准比，没有对比就没有判断。
- 3、ROI口径要清晰：用GMV算还是用毛利算、要不要扣补贴，口径不同结论不同。
- 4、转化率陷阱：前面环节转化率高不代表最终效果好，要看完整漏斗的每一层。
- 5、补贴效率：补贴给增量用户才有效，给存量用户是浪费。要测算补贴的增量ROI。
- 6、用户质量vs数量：低质量用户虽然转化了，但客单价低、复购率低，长期价值有限。
- 7、门槛设计学问：满减门槛要匹配用户的自然消费水平，太高会劝退，太低会降低客单价。

追问环节

如果进一步分析发现，下单率低主要是因为"配送费"——用户在结算页看到要加5块配送费就流失了，你会建议怎么优化这个活动？

追问解答

配送费导致结算页流失，这是个很典型的"临门一脚"问题。用户都已经加购了、进结算页了，说明购买意愿很强，结果被5块钱配送费劝退了。这5块钱的"感知成本"可能让平台损失了几十万的GMV。

怎么优化？有几个方向可以考虑。

方向一：针对性减免配送费

不是所有订单都免配送费，而是针对"差一点就下单"的用户减免。

具体策略：

订单金额30-49元的用户，减免3元配送费（用户实付2元）

订单金额20-29元的用户，减免2元配送费（用户实付3元）

订单金额50元以上的用户，本来就免配送费，不需要额外补贴

为什么这样设计？

30-49元的用户是"最可惜"的人群。他们购物车金额已经不低了，但没到50元免配送门槛。这时候5块钱配送费的"刺痛感"最强——"我都花了45块了，还要多付5块运费？"

针对这个人群做3块钱的补贴，用户实付2块配送费，心理接受度高很多，下单率可能大幅提升。

算一笔账：

假设30-49元区间有2万流失用户，补贴3元后能挽回1万人下单。

客单价40元，新增GMV = $1\text{万} \times 40\text{元} = 40\text{万}$

补贴成本 = $1\text{万} \times 3\text{元} = 3\text{万}$

毛利（15%抽成） = $40\text{万} \times 15\% = 6\text{万}$

净收益 = $6\text{万} - 3\text{万} = 3\text{万}$

这3万就是"挽回"的利润，原本这些用户是要流失的。

方向二：用"凑单神器"引导用户跨过免配送门槛

与其补贴配送费，不如引导用户多买一点，既免了配送费，又提升了客单价。

具体策略：

在结算页检测到用户订单金额在40-49元时，弹出"再买X元免配送费"的提示

同时推荐几个小额凑单商品（3-10元的小食、饮料、加料）

强调"加一瓶饮料就免5元配送费，划算"

为什么有效？

用户心理是"既然都要付5块配送费，不如多买5块钱的东西，还能免配送费"。

5块钱的商品对用户来说是"实物"，5块钱的配送费是"空气"。同样花5块钱，用户更愿意换成商品。

效果估算：

如果40-49元区间的用户有30%选择凑单到50元以上，客单价从45元提升到55元，GMV提升22%，同时下单率也会提升。

方向三：调整满减结构，让配送费"隐形"

现在的问题是：用户在结算页才看到配送费，产生"加价"的负面感受。

可以调整活动设计，让配送费被"吸收"到满减里。

具体策略：

把"满50减10"改成"满45减10，免配送费"

用户只需要凑到45元，就能享受减10元+免配送。心理感受是"我45元的东西只用付35元"，而不是"45元的东西要付50元（45+5配送费）再减10"。

虽然实际补贴力度差不多，但用户感知完全不同。

方向四：对高流失风险用户实时干预

用算法识别"即将流失"的用户，实时弹窗挽留。

具体策略：

用户在结算页停留超过30秒没有操作，触发弹窗
弹窗内容："限时优惠：现在下单减免3元配送费，仅限10分钟"
制造紧迫感，推动用户完成下单

为什么有效？

用户在结算页犹豫通常是在做"值不值"的心理博弈。一个限时优惠可以打破这个僵局，让用户觉得"现在下单更划算"。

方向五：测试最优配送费补贴策略

不同补贴力度的效果可能不同，可以用AB测试找到最优解。

测试组设计：

- 组A：不补贴配送费（对照组）
- 组B：补贴2元配送费
- 组C：补贴3元配送费
- 组D：全免配送费

每组跑一周，比较下单率、客单价、总GMV、ROI。

可能发现：补贴3元和全免的下单率差不多，但补贴3元成本更低，ROI更优。

综合建议

如果让我给一个综合方案，我会这样建议：

- 1、短期：针对30-49元订单补贴3元配送费，快速挽回流失用户。
 - 2、中期：上线"凑单神器"功能，引导用户自己跨过免配送门槛，减少补贴依赖。
 - 3、长期：通过AB测试找到最优的配送费策略，并将配送费逻辑融入满减设计，减少用户的"加价感知"。
- 核心思路是：配送费不是不能收，但要让用户感知不到它，或者觉得"值得"。

题目 58

淘宝用户小王在购买前经历了：刷到短视频广告→搜索商品→看直播→领优惠券→下单，这5个触点各自贡献了多少？不同归因模型会给出什么不同结论？

解答

用户小王买了一件299块的衣服。在这之前他刷到了广告、搜索了商品、看了直播、领了优惠券，最后才下单。

问题来了：这299块的功劳归谁？

广告团队说：没有我投的广告，用户根本不知道这个商品存在，100%功劳是我的。

搜索团队说：用户主动搜索了我们的关键词，说明有明确购买意图，功劳是我的。

直播团队说：用户看完直播才下的单，临门一脚是我踢的，功劳归我。

优惠券团队说：用户领了券才下单的，没有券他肯定不会买，功劳归我。

每个团队都想抢功劳，加起来远超100%。这就是归因问题——在多触点用户旅程中，如何公平地分配转化功劳。

第一部分：为什么归因这么难？

核心原因：反事实不可观察。

我们只观察到一个现实：用户经历了广告→搜索→直播→优惠券→下单这个路径，最后转化了。

但我们无法同时知道：

如果用户没看到广告，他还会不会买？可能会（因为他有需求），也可能不会（因为他根本不知道有这个商品）

如果用户没看直播，他还会不会买？可能会（因为广告已经种草了），也可能不会（因为他还在犹豫）

如果用户没领券，他还会不会买？可能会（只是少省点钱），也可能不会（觉得不划算）

这些"如果"是反事实场景。同一个用户不可能同时走两条路径，我们永远观察不到反事实。

不同的归因模型，本质上是对这些"反事实"做不同的假设和估计。

第二部分：常见的归因模型有哪些？

模型一：末次触点归因（Last Touch Attribution）

规则：100%功劳归给转化前的最后一个触点。

小王的情况：最后一个触点是"领优惠券"（假设领券后立即下单），所以优惠券拿走100%功劳，即299元全算优惠券的。

业务逻辑：这个模型认为"临门一脚"最重要。用户最后接触的东西直接促成了下单。

优点：简单，容易理解，容易实现，每个转化都能清晰归因到一个渠道。

缺点：完全忽略了前面触点的贡献。如果没有广告，用户根本不会进入这个链路。广告团队会很委屈："我辛辛苦苦把用户引进来，最后功劳全被优惠券抢走了？"

适用场景：促销活动效果评估。想知道"最后推动用户下单的是什么"。

模型二：首次触点归因（First Touch Attribution）

规则：100%功劳归给用户接触的第一个触点。

小王的情况：第一个触点是"短视频广告"，所以广告拿走100%功劳，299元全算广告的。

业务逻辑：这个模型认为"用户获取"最重要。是第一个触点把用户带进来的，没有它就没有后面的一切。

优点：重视用户获取，强调拉新渠道的价值。

缺点：忽略了后续触点的推动作用。广告只是让用户知道这个商品，但直播讲解、优惠券刺激才让用户最终决定购买。直播团队会说："用户看广告的时候还在犹豫，是我的直播让他下定决心的，凭什么功劳全归广告？"

适用场景：品牌广告效果评估。想知道"哪个渠道擅长带来新用户"。

模型三：线性归因（Linear Attribution）

规则：功劳平均分给路径中的所有触点。

小王的情况：4个触点（广告、搜索、直播、优惠券），每个分25%功劳，即各74.75元。

业务逻辑：这个模型认为"每个触点都有贡献"，没有谁更重要谁更不重要。

优点：公平，不会让任何渠道觉得被忽视。

缺点：过于"平均主义"。实际上不同触点的贡献肯定不一样。用户可能只是随手点了一下搜索，但在直播间看了30分钟详细讲解。把这两个触点算同样的功劳显然不合理。

适用场景：日常渠道监控。不想让指标大起大落，保持各渠道数据稳定。

模型四：时间衰减归因（Time Decay Attribution）

规则：离转化越近的触点，分到的功劳越多。越早的触点功劳越少。

假设衰减系数是每隔一步衰减50%。

小王的情况（从后往前算权重）：

优惠券（最后）：权重8

直播（倒数第2）：权重4

搜索（倒数第3）：权重2

广告（最早）：权重1

归一化后：

优惠券： $8/15 = 53\%$ （159元）

直播： $4/15 = 27\%$ （80元）

搜索： $2/15 = 13\%$ （40元）

广告： $1/15 = 7\%$ （20元）

业务逻辑：离下单越近的触点，对用户决策的影响越"新鲜"、越直接。

优点：符合直觉——用户在下单前5分钟看的东西，肯定比一周前看的影响更大。

缺点：可能低估了早期触点的"种草"价值。广告虽然是一周前看的，但正是那个广告在用户心里埋下了种子。

适用场景：电商转化分析。购买决策周期较长的品类。

模型五：位置归因/U形归因（Position-Based/U-Shaped）

规则：首尾触点各分40%，中间触点平分剩下的20%。

小王的情况：

广告（首）：40%（119.6元）

优惠券（尾）：40%（119.6元）

搜索+直播：各10%（各29.9元）

业务逻辑：第一个触点负责"获客"，最后一个触点负责"转化"，这两个环节最重要。中间的触点是"培育"，重要性相对低。

优点：同时重视"用户获取"和"转化推动"，是首次和末次归因的折中。

缺点：中间触点可能被低估。比如直播可能是关键转折点——用户看广告时还很犹豫，看完直播就决定买了——但只分到10%。

适用场景：综合评估各阶段渠道。同时考虑拉新和转化。

模型六：数据驱动归因（Data-Driven Attribution）

规则：用算法根据历史数据自动学习每个触点的贡献。

方法：分析大量用户的转化路径，看不同触点组合对转化率的影响差异，用统计模型或机器学习推算每个触点的边际贡献。

常用方法包括：马尔科夫链模型、Shapley值方法、逻辑回归等。

优点：最科学，基于数据而不是人为假设。能捕捉触点之间的交互效应。

缺点：需要大量数据（至少几万条转化路径），模型复杂，结果不容易解释。

适用场景：数据量充足的大平台。需要精细化归因指导预算分配。

第三部分：用数据说明不同模型的结论差异

假设淘宝一个月内有100万个转化订单，总GMV 1亿。涉及到5个渠道：短视频广告、搜索、直播、优惠券、信息流推荐。

用不同模型计算各渠道的GMV贡献：

末次触点归因结果：

优惠券：4000万（40%）

直播：2500万（25%）

搜索：2000万（20%）

信息流：1000万（10%）

短视频广告：500万（5%）

首次触点归因结果：

短视频广告：3500万（35%）

信息流：2500万（25%）

搜索：2000万（20%）

直播：1500万（15%）

优惠券：500万（5%）

线性归因结果：

搜索：2200万（22%）

短视频广告：2000万（20%）

直播：2000万（20%）

优惠券：2000万（20%）

信息流：1800万（18%）

看到差异了吗？

在末次归因下，优惠券是最大功臣（40%），短视频广告是最小的（5%）。

在首次归因下，短视频广告是最大功臣（35%），优惠券反而最小（5%）。

在线性归因下，各渠道比较均衡，都在18-22%之间。

同样的数据，不同模型给出的结论完全相反！

这直接影响资源分配决策：

如果用末次归因，老板可能说："短视频广告才贡献5%，太低了，砍预算！"

如果用首次归因，老板可能说："优惠券才贡献5%，取消这个成本！"

两个决策都可能是错误的。

第四部分：哪个模型是对的？怎么选？

残酷的答案是：没有"正确"的模型，只有"适合"的模型。

归因模型是一种"约定"，关键是团队达成共识，并且和业务目标匹配。

选择模型要看业务目标：

如果目标是拉新：用首次触点归因更合适。这样能识别出哪些渠道擅长带来新用户，指导拉新预算分配。

如果目标是促转化：用末次触点归因更合适。这样能识别出哪些触点能"临门一脚"推动下单，指导转化策略优化。

如果目标是全面优化：用数据驱动归因更合适。虽然复杂，但能更准确地反映每个触点的真实贡献。

如果没有特别目标：用位置归因或时间衰减是折中选择。不会太偏颇，各团队也容易接受。

实践建议：

多模型并行，交叉验证。不要只用一个模型。用3-4个模型分别跑一遍，看结论差异。如果不同模型结论一致（比如搜索在各模型下都排前3），说明这个结论可靠。如果结论矛盾很大，说明需要进一步深挖。

结合业务逻辑判断。归因模型给出的是数字，但业务解读要结合逻辑。比如优惠券在末次归因下贡献很大，但这不代表"优惠券创造了需求"。更可能是"用户本来就想买，优惠券只是加速了决策"。这时候要做增量实验来验证。

定期校准。用户行为在变化，归因结论也会变化。建议每季度重新跑一次归因分析，更新结论。

第五部分：数据驱动归因的核心思路

简单解释一下数据驱动归因是怎么算的。

核心思想：比较"有某触点"和"没有某触点"的路径，看转化率差异。

假设我们有10万个用户的转化路径数据：

路径类型A：广告 → 下单，有2万用户，转化了400人，转化率2%

路径类型B：广告 → 搜索 → 下单，有3万用户，转化了1500人，转化率5%

路径类型C：广告 → 搜索 → 直播 → 下单，有2万用户，转化了1600人，转化率8%

路径类型D：搜索 → 直播 → 下单（无广告），有1万用户，转化了300人，转化率3%

.....

从这些数据可以推算：

广告的边际贡献：有广告 vs 无广告的转化率差异

搜索的边际贡献：有搜索 vs 无搜索的转化率差异

直播的边际贡献：有直播 vs 无直播的转化率差异

Shapley值方法：借鉴博弈论中"合作博弈"的概念，计算每个触点加入"联盟"后带来的边际贡献，然后取平均。这种方法能处理触点之间的交互效应（比如广告+直播的组合效果可能大于两者单独效果之和）。

实际实现会更复杂，但核心思路就是：从数据中学习每个触点的"边际影响"，而不是靠人为规则假设。

知识点总结

- 1、归因问题的本质：反事实不可观察。我们只知道用户经历了什么，不知道如果少一个触点会怎样。
- 2、规则归因模型：末次、首次、线性、时间衰减、位置归因。简单但有偏颇，适合快速分析。
- 3、数据驱动归因：基于历史数据学习触点贡献，更科学但更复杂，适合精细化运营。
- 4、模型选择原则：没有"正确"只有"适合"。根据业务目标选择，并和团队达成共识。
- 5、多模型交叉验证：用多个模型跑一遍，结论一致的更可靠，结论矛盾的需要深挖。
- 6、归因直接影响决策：不同归因模型会得出相反的结论，直接影响预算分配和渠道策略。

追问环节

如果数据显示：用户路径中有"直播"触点的转化率是10%，没有"直播"触点的转化率是6%，能直接说直播带来了4%的增量吗？为什么？

追问解答

不能直接这么说。这4%的差异不一定是直播"带来"的，可能是"选择性偏差"导致的。

问题在哪？

有直播触点的用户和没有直播触点的用户，可能本身就不是一类人。

选择进入直播间的用户，可能本来购买意愿就更强。他们可能已经看过广告、搜索过商品、犹豫了很久，现在进直播间就是想"最后确认一下"再下单。这类用户即使不看直播，转化率也会比较高。

随便刷到商品但没进直播间的用户，可能只是好奇点进来看看，没有强烈购买意愿。这类用户即使被"强行拉进直播间"，转化率也不会很高。

这就是选择性偏差：进直播间的用户和不进直播间的用户，在"购买意愿"这个变量上本身就有差异。直接比较两组的转化率，会把"用户本身差异"和"直播效果"混在一起。

怎么区分真实效果？

方法一：做AB测试

随机把用户分成两组：

实验组：推送直播入口，引导进直播间

对照组：不推送直播入口

比较两组最终的转化率差异。因为是随机分组，两组用户的"本身特征"应该差不多，差异可以归因于"直播"。

假设结果：实验组转化率8%，对照组转化率6%，那直播的真实增量是2%，而不是4%。

方法二：用倾向得分匹配

从"没进直播间"的用户里，找出一批和"进了直播间"的用户特征相似的人（年龄、历史购买、浏览行为都接近），然后比较他们的转化率。

这样可以控制住用户本身的差异，让比较更公平。

方法三：看直播进入方式

区分"主动进入直播间"和"被动推送进入直播间"的用户：

主动进入的用户：购买意愿强，转化率本来就高

被动推送进入的用户：购买意愿未知，如果他们的转化率也明显提升，说明直播确实有效果

总结

10% vs 6%的差异里面：

可能有2%是直播真正带来的增量（因果效应）

可能有2%是用户本身差异导致的（选择性偏差）

直接用4%来汇报直播效果，会高估直播的价值。

这也是为什么归因分析很难——我们看到的数据是"相关"，但要判断"因果"需要更严谨的方法。

题目 59

面试真题：快手发现某类创作者的涨粉速度下降了20%，但平台整体的创作者数量和内容发布量都在增长，可能是什么原因？如何定位问题？

解答

涨粉速度下降了20%，但平台整体在增长。这个数据组合看起来很矛盾。

按理说平台增长意味着流量池变大，创作者应该更容易涨粉才对。为什么某类创作者的涨粉反而变慢了？

这道题考的是你能不能多角度思考、分层拆解，而不是上来就拍一个答案。

第一部分：先确认问题的口径

涨粉速度是怎么定义的？这个问题很关键，不同口径对应完全不同的问题。

口径一：绝对涨粉数

比如这类创作者以前月均涨粉1万，现在只涨8000，下降了20%。

如果是这个口径，问题可能是：曝光量变少了、涨粉率变低了、或者两者都有。

口径二：涨粉率

涨粉率 = 新增粉丝数 / 曝光量

以前每1万次曝光能涨100粉，现在只能涨80粉，下降了20%。

如果是这个口径，问题更可能在内容吸引力或用户关注行为上。

口径三：人均涨粉数

人均涨粉 = 这类创作者的总新增粉丝 / 这类创作者的人数

如果创作者数量暴增但总粉丝增长有限，人均涨粉自然下降。

口径四：相对涨粉速度

和其他类型创作者对比，这类创作者的涨粉速度占比下降了。

这可能意味着其他类型创作者在抢用户的关注。

第一步：找运营确认具体口径是什么，分子分母分别是什么，时间窗口是什么。

第二部分：可能的原因假设

假设口径确认后是"这类创作者的人均月涨粉数下降了20%"。

可能原因一：这类创作者的曝光量下降了

平台整体流量在涨，但流量分配发生了变化。

可能的子原因：

推荐算法调整了，给这类内容的曝光权重降低了。比如快手在2024年加强了对直播电商的扶持，短视频的曝光可能被压缩。

新的内容品类在抢流量。比如微短剧火了，平台给微短剧更多曝光，其他品类的曝光就少了。

这类创作者的内容时长、更新频率等不符合算法当前偏好。比如算法现在更喜欢竖屏15秒以内的内容，但这类创作者还在做横屏3分钟的内容。

验证方法：

拉这类创作者的人均曝光量变化趋势。

如果人均曝光量下降了30%，涨粉速度下降20%就很正常——曝光少了，涨粉自然少。

还可以看曝光在各品类间的分布变化，确认是否有其他品类在抢流量。

可能原因二：用户的关注行为变了

用户"关注"这个动作的整体频率在下降。

可能的子原因：

产品改版了，关注按钮变小了、位置变了、流程变复杂了，用户不容易点到。

用户习惯变了，更多人选择"点赞""收藏"而不是"关注"。现在用户可能更习惯"刷到就看"，而不是主动关注后等更新。

用户已经关注了很多账号，不想再关注新的了。关注列表太长反而是负担。

验证方法：

看全平台的"关注率"（总关注次数 / 总曝光量）变化。

如果全平台关注率都在下降，说明不是这类创作者的问题，是用户行为或产品设计的整体变化。

如果只有这类创作者的关注率下降，那问题在这类内容本身。

可能原因三：这类创作者的内容质量下降了

内容层面出了问题。

可能的子原因：

内容同质化严重，用户审美疲劳了。这类内容的创意被用烂了，用户看多了就不想关注了。

头部创作者产出变少或离开了。快手可能一批头部创作者转去了抖音或其他平台，拉低了这类内容的整体质量。

新入局的创作者水平参差不齐。因为门槛低，大量新人涌入，平均质量下滑。

验证方法：

看这类创作者的内容互动指标：点赞率、评论率、完播率、分享率。

如果互动率也在下降，说明内容吸引力可能有问题。

可以按创作者粉丝量级分层（头部、腰部、尾部），看是哪一层的内容质量在下滑。

可能原因四：这类创作者数量暴增，稀释了人均涨粉

题目说"创作者数量在增长"。这个增长如果主要来自这类创作者，就会稀释人均指标。

假设这类创作者从1万人增长到1.5万人，总涨粉数只增长了20%。

总涨粉：从1000万增长到1200万

人均涨粉：从1000降到800，下降了20%

即使总量在涨，人均也可能在跌。

更多创作者在争夺同一批用户的关注。用户每天的"关注配额"有限，不可能无限关注新账号。竞争变激烈了，人均涨粉自然下降。

验证方法：

看这类创作者的数量增长率和总涨粉增长率。

如果数量增长快于涨粉增长，就是"供给过剩"导致的人均下降。

可能原因五：外部竞争加剧

用户的时间和注意力被其他平台抢走了。

比如同类型内容在抖音更火了，用户转移阵地了。快手的用户时长可能在下降，可分配的关注行为也在减少。

验证方法：

看这类创作者的用户画像和平台整体的用户时长变化。

如果用户在快手的时长在下降，说明外部竞争是一个因素。

可能原因六：辛普森悖论——分群都在涨，整体在跌

这类创作者可能包含多个子类别，各子类别可能分别在涨，但因为结构变化导致整体下降。

例子：

子类别A（新手创作者）：原来占比30%，涨粉速度低，现在占比60%

子类别B（成熟创作者）：原来占比70%，涨粉速度高，现在占比40%

虽然A和B各自的涨粉速度可能都在提升，但因为低涨粉速度的A占比提升了，整体被拉低了。

验证方法：

把这类创作者拆成几个子类别（按粉丝量级、按细分内容类型、按地区），分别看涨粉速度变化。

如果发现分群都在涨，只是结构变了，那结论就完全不同了。

第三部分：排查的优先级和步骤

如果我是分析师，会按这个顺序排查：

第一步：确认数据口径

涨粉速度具体指什么？绝对值还是比率？人均还是总量？时间范围是什么？和哪个基准比下降了20%？

第二步：拆解涨粉公式

总涨粉 = 人数 × 人均涨粉

人均涨粉 = 人均曝光 × 涨粉率

看是哪个因子在下降。

第三步：看曝光量变化

这类创作者的总曝光量有没有变化？人均曝光量有没有变化？

如果人均曝光下降了，问题在流量分配。

如果人均曝光不变或上升，问题在涨粉率。

第四步：看涨粉率变化

涨粉率 = 新增粉丝 / 曝光量

如果涨粉率下降了，说明单次曝光带来的关注效率变低了。下一步要分析是内容问题还是用户行为问题。

第五步：对比全平台关注率

全平台的"关注率"有没有变化？

如果全平台关注率都在下降，说明是产品或用户习惯问题，不是这类创作者独有的问题。

如果只有这类创作者的涨粉率下降，说明是这类内容的问题。

第六步：分群分析

这类创作者能不能再细分？

按粉丝量级分：头部（>100万）、腰部（1-100万）、尾部（<1万）

按细分内容类型分

按创作者活跃度分

看是所有子群都在下降，还是某个子群拉低了整体。

第七步：对比内容质量指标

看点赞率、评论率、完播率、分享率。

如果这些指标也在下降，说明内容吸引力变弱了。

如果这些指标稳定或上升，但涨粉率下降，说明用户"喜欢但不关注"，可能是用户行为变化。

第八步：看创作者供给变化

这类创作者的数量变化、人均发布频率变化、头部创作者的活跃度变化。

如果供给增长快于需求增长，就会出现"内卷"。

第四部分：可能的结论和建议

场景一：排查后发现

人均曝光量没变
涨粉率下降了25%
全平台关注率基本稳定
这类创作者数量增长了50%

结论：创作者供给过剩导致竞争加剧。

更多创作者在争夺同一批用户的关注，用户的关注"配额"被更多人瓜分。人均涨粉自然下降。

建议：

短期：优化推荐算法，让优质创作者获得更多曝光，拉开和普通创作者的差距。
中期：提升内容审核标准和推荐精准度，减少低质量内容对优质内容的干扰。
长期：帮助这类创作者做内容差异化，减少同质化竞争。引导新人创作者往差异化方向发展。

场景二：排查后发现

人均曝光量下降了35%
涨粉率基本稳定

结论：问题在流量分配。

可能是推荐算法调整、新品类在抢流量、或者这类内容不符合当前的推荐策略。

建议：

了解算法调整的原因——是有意降权这类内容（比如平台战略调整），还是意外效果（比如算法bug）。
如果是有意降权，评估对创作者生态的长期影响。这类创作者如果流失会有什么后果。
如果是意外效果，反馈给算法团队调整。

场景三：排查后发现

人均曝光量稳定
涨粉率下降
内容互动率（点赞、完播）也在下降

结论：内容质量下滑。

可能是同质化严重、审美疲劳、或者头部创作者流失。

建议：

分析内容同质化程度，识别创意枯竭的信号。
查看头部创作者的活跃度，是否有流失迹象。
推出创作激励计划，鼓励内容创新。

知识点总结

- 1、口径先行：涨粉速度的定义要明确，是绝对值还是比率，分母是什么，时间窗口是什么。
- 2、多假设并行：先列出所有可能的原因，再逐一排查，不要上来就锁定一个答案。
- 3、分层拆解：总指标 = 曝光量 × 涨粉率 = 人数 × 人均涨粉。把总指标拆成多个环节，定位问题出在哪一层。
- 4、对比分析：和全平台比、和其他类型创作者比、和历史基准比。
- 5、分群分析：整体下降可能掩盖了分群的真实情况，要下钻看子群体。
- 6、辛普森悖论意识：分群都在涨、整体在跌，可能是结构变化导致的。
- 7、从数据到建议：分析完要能给出可执行的建议，不只是"发现问题"，还要"解决问题"。

追问环节

如果进一步分析发现：头部创作者（粉丝>100万）的涨粉速度其实提升了10%，但腰尾部创作者（粉丝<10万）的涨粉速度下降了35%，你会怎么解读这个现象？对平台有什么影响？

追问解答

这个数据说明：流量正在向头部集中，形成了"马太效应"——强者更强，弱者更弱。

怎么解读这个现象？

解读一：推荐算法可能在强化头部

算法可能更倾向于推荐已经有大量粉丝的内容。原因可能是：

头部内容的互动数据更好（点赞、评论、完播率高），算法认为它更"优质"

头部内容的"确定性"更高——推给用户大概率会喜欢，不容易翻车

平台可能在追求用户体验的短期指标（比如人均观看时长），头部内容更容易达成

结果就是：头部获得更多曝光 → 更多涨粉 → 更高的互动数据 → 再获得更多曝光。形成正向循环。

腰尾部内容曝光变少 → 涨粉变难 → 数据变差 → 更少曝光。形成负向循环。

解读二：用户的关注行为在向头部集中

用户可能更倾向于关注已经有很多粉丝的账号——"这么多人关注，应该不错"。这是一种社会认同心理。

同时用户的"关注配额"有限，他们会把有限的关注机会给"更值得"的账号，也就是头部账号。

解读三：内容生产的能力差距在拉大

头部创作者可能有更专业的团队、更好的设备、更成熟的内容方法论，产出的内容质量稳定提升。

腰尾部创作者大多是个人或小团队，内容生产能力有限，在竞争中越来越难突围。

对平台有什么影响？

影响一：创作者生态健康度下降

如果腰尾部创作者长期涨不了粉，他们会：

失去创作动力，产出频率下降

转向其他平台寻找机会

彻底放弃创作

这会导致平台的创作者供给单一化——只剩下头部在玩，腰尾部消失。

长期来看，头部也会受影响：没有腰部的上升空间，头部自己也没有竞争压力，内容创新可能放缓。

影响二：内容多样性下降

腰尾部创作者往往是垂直细分领域的玩家，他们的内容可能小众但独特。

如果这批人都走了，平台的内容会变得同质化——全是头部在做的热门品类，小众内容消失。

用户的选择变少，长期可能导致用户流失。

影响三：用户价值可能被高估

短期内，头部内容确实能带来更高的用户时长、更好的互动数据。

但如果用户发现"刷来刷去都是这几个人"，可能会感到无聊。头部内容的边际效用递减。

而且头部创作者的商业化变现能力强，但他们也更有议价能力，可能对平台提出更高的分成要求。

影响四：平台竞争力受损

其他平台（比如抖音、B站）如果对腰尾部创作者更友好，这批创作者可能会迁移。

创作者迁移会带走一部分忠实粉丝，影响平台的用户规模和活跃度。

平台应该怎么应对？

建议一：调整推荐算法，给腰尾部更多曝光机会

设置"新人扶持流量池"，保证新人和小号有基本的曝光量

算法中加入"多样性"因子，避免流量过度集中

对优质的腰尾部内容给予额外推荐权重

建议二：优化涨粉路径，降低腰尾部的涨粉门槛

推出"关注推荐"功能，在用户关注头部时推荐类似的腰尾部账号

优化账号主页设计，让用户更容易发现和关注小号

给腰尾部创作者更多的互动工具（比如粉丝群、直播权限）

建议三：建立创作者成长体系

提供创作指导、数据工具、培训课程，帮助腰尾部创作者提升内容质量

设置涨粉目标和激励，鼓励腰尾部创作者持续产出

定期评选"潜力新人"，给予额外曝光和资源支持

建议四：监控生态健康度指标

把"腰尾部创作者涨粉速度""创作者留存率""内容多样性指数"纳入平台健康度监控

设置预警线，一旦腰尾部数据恶化就启动干预措施

总结

头部涨、腰尾部跌，短期看起来指标还行（毕竟头部在涨），但长期可能导致生态失衡。

平台需要在"用户体验（推头部内容）"和"生态健康（扶持腰尾部）"之间找到平衡。过度追求短期指标可能牺牲长期竞争力。

题目 60

瑞幸咖啡发现2025年Q3整体门店销售额同比增长18%，但拆分到一二线城市和下沉市场后，两边的同比增速都只有10%左右，为什么整体增速比各分组都高？这是数据出错了么？

解答

看到这道题，估计很多人第一反应是：这数据肯定出bug了吧？整体增长18%，两个分组都只有10%左右，数学上不可能啊。

但这还真不是数据出错。这是一个经典的统计陷阱，叫辛普森悖论。这个悖论在数据分析实战中经常出现，但很多人不知道怎么识别和解释，所以面试官特别喜欢考。

先直接说结论：整体增速完全可以比所有分组都高，关键就在于各分组的"权重"变了。说白了，就是蛋糕的切法变了。

第一部分：用一个干净的例子把道理讲透

我直接构造一个最能说明问题的场景。

假设2024年Q3瑞幸的销售情况是这样的：

- 一二线城市销售额：80亿
- 下沉市场销售额：20亿
- 整体：100亿

如果两边都老老实实增长10%，到2025年Q3就是88亿+22亿=110亿，整体也是10%。这没毛病，数学上完全对得上。

但瑞幸这两年干了什么？疯狂在下沉市场开店啊。根据公开信息，瑞幸2024年新开门店超过5000家，其中大部分都开在三四线城市和县城。这意味着下沉市场的门店数量和销售额权重都在快速提升。

所以真实情况可能是这样的：

2024年Q3：

- 一二线城市：80亿（权重80%）
- 下沉市场：20亿（权重20%）
- 整体：100亿

2025年Q3：

- 一二线城市老店增长10%：从80亿涨到88亿
- 下沉市场老店增长10%：从20亿涨到22亿
- 但是！下沉市场新开了一大堆店，这些新店贡献了8亿销售额

算一下：88+22+8=118亿，整体增长18%。

你看，问题就出在这儿了。题目说的"两边增速都是10%"，很可能指的是同店增速，也就是只算去年就存在的门店；而"整体增速18%"是包含了新店贡献的总增速。这俩口径根本不是一回事。

这就是为什么面试官问这道题的时候，你第一反应应该是追问：这个10%是同店增速还是区域整体增速？口径不齐，分析就会出问题。

第二部分：辛普森悖论的本质是什么

辛普森悖论听起来玄乎，其实核心逻辑就一句话：当你把数据分组看的时候是一个结论，合起来看又是另一个结论，这时候多半是权重结构发生了变化。

这个现象最早是在医学研究中被发现的。比如有两个医院A和B，分别统计手术成功率。A医院整体成功率90%，B医院整体成功率85%。看起来A医院更好对吧？

但如果你把病人按病情轻重拆开看：

- 轻症患者：A医院成功率95%，B医院成功率98%
- 重症患者：A医院成功率70%，B医院成功率75%

卧槽，每个分组B医院都比A医院高啊！为什么整体A医院反而更高？

因为A医院接诊的轻症患者比例更高（比如80%），而B医院重症患者比例更高（比如60%）。轻症患者成功率本来就高，A医院靠着大量轻症患者把整体数字拉上去了。

放到瑞幸这个场景里，逻辑是类似的。下沉市场在整体销售额中的占比大幅提升了。去年下沉市场可能只占20%，今年可能占到35%甚至更多。虽然两边的同店增速都是10%，但"结构性变化"本身就创造了额外的增长。

这就好比你班上有两个学生，一个考90分一个考60分，平均分75。第二年两个人都进步了10%，一个99分一个66分，平均分应该是82.5分，涨了10%对吧？但如果这时候又转来了5个平均分85分的新同学，全班平均分可能就变成了86分，涨幅就不止10%了。那全班平均分的变化，就不能只看那两个老生的进步幅度了。

第三部分：这道题到底在考什么

面试官想看三个东西：

第一，你能不能识别出辛普森悖论。当整体指标和分组指标打架的时候，你的第一反应应该是：是不是权重变了？是不是口径不一致？很多候选人看到这种数据就慌了，开始怀疑数据质量，或者硬着头皮瞎解释。但真正有经验的分析师会马上想到辛普森悖论这个可能性。

第二，口径意识够不够强。同店增速和整体增速是两个完全不同的指标。同店增速剔除了新店影响，更能反映"存量业务"的健康度；整体增速包含新店，反映的是"公司整体规模"的变化。这俩都有用，但不能混着看。在实际工作中，很多数据打架的问题，最后都是口径问题。谁统计的、用什么公式算的、包不包含某些特殊情况，这些细节不清楚，分析就是在空中楼阁。

第三，业务sense。你得知道瑞幸2024-2025年在干嘛。如果你知道他们在下沉市场疯狂扩张，门店数量翻了快一倍，那这个数字就很好理解了。这就是为什么面试官喜欢用真实公司出题，他们想看你平时有没有关注行业动态，有没有对业务的基本感知。

第四部分：如果你是瑞幸的分析师，看到这数据该干嘛

光识别出辛普森悖论还不够。面试官可能会追问：那你作为分析师，接下来会做什么分析？这时候你要展现的是结构化思维和落地能力。

1、把增长来源拆清楚

18%的整体增速要拆成三块：同店增长贡献了多少、新店贡献了多少、区域结构变化贡献了多少。

具体怎么拆呢？

第一步，算同店增速的贡献。假设同店增速是10%，那同店贡献的增长就是去年存量销售额×10%。如果去年存量是100亿，那同店贡献就是10亿。

第二步，算新店贡献。今年新开的店贡献了多少销售额？这部分是纯增量，去年是0，今年有了就是增长。

第三步，区域结构变化的贡献比较难算，通常需要用加权分解的方法。但核心思路是：如果下沉市场占比从20%提升到35%，而下沉市场的增速比一二线高，那结构变化本身也会贡献一部分增长。

拆完之后，可能发现：同店贡献8个点，新店贡献7个点，结构变化贡献3个点。这样老板才能知道增长是"质量型"的（老店在持续变好）还是"靠铺店堆出来"的（全靠开新店撑着）。

2、盯紧下沉市场的单店效率

如果下沉市场的新店越开越多，但单店平均销售额在往下掉，那可能是过度扩张的信号。开店容易，养店难，这个在餐饮和零售行业太常见了。

瑞幸的下沉市场门店，客单价可能只有一二线的60%-70%，因为下沉市场消费能力有限，竞争对手（比如蜜雪冰城、库迪）的价格战也更激烈。如果单店销售额持续下降，即使门店数量在涨，长期来看也不健康。

所以要建一个"新店成熟曲线"的监控：新开的店在第3个月、第6个月、第12个月的销售额分别是多少？和一二线城市的新店对比怎么样？和去年同期开的新店对比怎么样？

3、搞清楚一二线为什么只有10%

一二线城市只有10%的增速，这个数字其实挺一般的。瑞幸在一二线的品牌认知度已经很高了，增长空间确实有限，但10%还是偏低。

要分析的问题包括：

- 是市场饱和了？一二线城市的瑞幸门店密度已经很高，用户没有那么多增量需求了？
- 是被库迪这些竞争对手抢了份额？2024年库迪疯狂开店，很多店就开在瑞幸隔壁，价格还更便宜。
- 是消费降级导致客单价下降了？用户还是那些用户，但买的杯数少了或者买的产品便宜了？

这些都需要进一步拆解才能定位。

第五部分：现实中辛普森悖论还会在哪儿出现

这道题的底层逻辑，在很多业务场景都会出现。作为数据分析师，你应该对这类"整体和分组打架"的情况保持敏感。

场景一：留存率悖论

某个APP整体次日留存率在涨，但拆分到各个渠道看，每个渠道的留存都在跌。

这时候可能是高留存渠道的占比在提升。比如原来60%的用户来自信息流广告（留存20%），40%来自应用商店（留存40%），整体留存是28%。现在应用商店占比提升到60%，即使两个渠道的留存都跌了几个点，整体留存可能还是涨的。

场景二：转化率悖论

某个电商平台整体转化率在跌，但各个品类的转化率都在涨。

这时候可能是低转化品类的流量占比增加了。比如原来服装占流量的50%（转化率8%），3C占50%（转化率3%），整体转化率5.5%。现在3C占比提升到70%，即使两个品类转化率都涨了，整体转化率可能还是降的。

场景三：客单价悖论

某个餐饮品牌整体客单价在涨，但所有门店的客单价都在跌。

这时候可能是高客单价门店的占比在提升。比如商场店客单价80元，社区店客单价50元。如果新开了一批商场店，整体客单价就会被拉高，即使每家店的客单价都在降。

所以遇到"整体"和"分组"数据打架的情况，第一反应就是去看权重结构有没有变化。这个思路在日常分析中特别好用，能帮你快速定位很多看似矛盾的数据问题。

知识点总结：

- 辛普森悖论：整体趋势与分组趋势矛盾时，原因通常是分组权重发生了变化
- 口径意识：同店增速和整体增速是两个不同指标，要先对齐口径再分析
- 增长拆解：同店贡献、新店贡献、结构变化贡献要分开算，才能判断增长质量
- 业务sense：了解行业动态和公司战略，能帮助你更快理解数据背后的原因

追问：

如果面试官继续问："那我们应该用整体增速还是同店增速来评估业务健康度？"你会怎么回答？

【追问回答】

这个问题没有标准答案，因为两个指标评估的东西不一样。得看你想评估什么，以及公司当前处于什么阶段。

首先说说这两个指标各自反映的是什么。

整体增速反映的是"公司规模在不在扩张"。它包含了所有因素：老店增长、新店增量、关店影响、区域结构变化等等。投资人和老板最关心的往往是这个指标，因为它直接影响营收、估值、市场份额这些硬指标。如果你是一家上市公司，财报里披露的营收增速就是整体增速。

同店增速反映的是"存量业务健不健康"。它剔除了新开店和关店的影响，只看那些持续运营超过一定时间（通常是12个月）的门店。这个指标更能反映单店的运营效率、用户复购情况、客单价变化等"质量"维度的东西。

两个指标都看，才能得出完整的判断。

我用一个2×2矩阵来说明不同组合意味着什么：

情况一：整体增速高，同店增速也高

这是最健康的状态。说明老店在持续增长，用户粘性好，复购强；同时新店也在贡献增量，扩张策略是有效的。这种情况下，公司既有"质"又有"量"，可以放心继续当前的战略。

典型例子：一个品牌处于快速成长期，产品力强，用户口碑好，老店业绩持续向上；同时品牌势能高，新开的店也能快速起量。这是最理想的增长模式。

情况二：整体增速高，但同店增速低甚至负增长

这时候要警惕了。整体增长主要靠开新店撑着，老店的吸引力在下降。这种增长模式是不可持续的，因为：

- 新店的边际效益会递减。第100家店和第1000家店的效率不一样，越开越难。
- 老店如果持续下滑，说明产品力或者用户体验在变差，长期会影响品牌。
- 一旦新店开不动了（比如好位置开完了、资金链紧张了），增长就会失速。

瑞幸如果是这种情况，就需要警惕。虽然现在整体增速还不错，但如果同店增速持续走低，说明可能在"用数量换时间"，需要尽快解决老店的问题。

情况三：整体增速低，但同店增速高

这说明存量业务很健康，用户粘性好，单店效率在提升；但扩张速度慢了。

这种情况要分两种可能来看：

一种是主动收缩。比如公司判断市场已经饱和，或者当前阶段应该聚焦盈利而不是规模，所以减少了开店速度。这种情况下，虽然整体增速放缓，但业务质量在提升，是健康的。

另一种是被动收缩。比如融资困难、好位置被竞争对手抢了、加盟商不愿意开店了。这种情况虽然同店还不错，但扩张能力受限，需要找到突破口。

情况四：整体增速低，同店增速也低

这是最危险的信号，说明业务在全面收缩。老店在下滑（产品力或用户体验出了问题），新店也开不动（扩张遇到瓶颈或者战略收缩）。这种情况需要深挖原因：是市场整体在萎缩？是被竞争对手打残了？还是内部管理出了问题？

所以回到面试官的问题：应该用哪个指标来评估业务健康度？

我的回答是：两个都要看，而且要交叉分析。

具体来说，我会建立一个监控仪表盘，同时追踪这两个指标的趋势。如果两个指标走势一致（同涨同跌），那判断比较简单。如果两个指标走势相反，就要深挖原因，判断当前是处于"健康扩张期"还是"泡沫扩张期"。

另外还有一个维度很重要：新店成熟周期。

新开的店，在6个月后能不能达到老店80%的销售额水平？如果能，说明扩张策略是对的，新店能够快速成熟；如果差距很大，说明可能在"为了开店而开店"，新店的质量有问题。

回到瑞幸这道题。如果我是瑞幸的分析师，我会把这两个指标放在一起看，再加上几个辅助维度：

- 下沉市场同店增速 vs 一二线同店增速：看下沉市场的门店质量如何
- 新店6个月成熟率：看新开的店能不能快速起量
- 单店盈利比例：看有多少店是赚钱的，有多少店在亏

只有这些维度综合起来看，才能判断瑞幸当前的增长是健康的还是有隐患的。

最后补充一点：不同发展阶段，对两个指标的侧重点也不同。

如果公司处于高速扩张期（比如瑞幸2023-2024年），整体增速可能更重要，因为这个阶段的核心目标是抢占市场份额、建立规模壁垒。同店增速稍微差一点可以接受，只要不是太离谱。

如果公司处于成熟期或者盈利期（比如瑞幸2025年以后可能的状态），同店增速就变得更重要了。这个阶段规模扩张的边际效益递减，更应该关注单店效率、用户复购、客单价提升这些"质量"指标。

所以面试官问这个问题，其实是想看你有没有"场景化思维"——知道不同情况下应该关注什么，而不是给一个死板的答案。

题目 61

为什么看用户留存不能只看整体留存率？如何用同期群分析识别产品真正的留存问题？

解答

很多同学汇报留存的时候喜欢说："我们次日留存45%，7日留存25%，30日留存15%。"

听起来挺专业是吧？但说实话，这种"整体留存率"有时候会把你带沟里去。

为啥？因为整体留存率是把不同时间进来的用户混在一起算的，你根本看不出来留存到底是在变好还是变差。就好像你把所有年级的学生成绩混在一起算平均分，你根本不知道是哪个年级在进步、哪个年级在退步。

这时候就得用同期群分析了。这个方法在互联网公司的用户增长和产品分析中特别常用，面试也经常考，但很多人只知道名字，不知道怎么用、用来解决什么问题。

第一部分：同期群分析到底是个啥

同期群分析，英文叫Cohort Analysis，说白了就是把用户按"什么时候来的"分成不同的组，然后分别追踪每一组后来的表现。

比如你是个电商APP的分析师：

- 10月注册的用户是一群（10月同期群）
- 11月注册的用户是另一群（11月同期群）
- 12月注册的用户又是一群（12月同期群）

然后你分别看这三群人在注册后第7天、第30天、第60天还剩多少。

这样做的好处是，你能清楚地看出来：

- 10月的用户留存好还是12月的好？
- 留存是在逐月改善还是恶化？
- 11月的留存突然变差，是不是那个月干了啥事儿？

这些问题，光看整体留存率你是看不出来的。整体留存率就像一个"平均数"，把所有的信息都压缩成了一个数字，细节全丢了。

第二部分：整体留存率怎么就会骗人了

我举个具体的例子你就懂了。

假设你们产品2025年Q4的整体30日留存是18%，和Q3差不多。老板一看，行啊，留存稳住了，继续保持。

但你如果把同期群数据拉出来，可能是这样的：

10月那批用户的30日留存：22%
11月那批用户的30日留存：16%
12月那批用户的30日留存：12%

我去，留存明明在一路往下掉啊。那整体为啥还是18%呢？

原因很简单。整体留存率在计算的时候，10月那批用户的权重更大，因为他们人数多（毕竟来得早，可能拉新力度也大），而且已经过了30天可以纳入统计了。11月12月的用户还在"成长期"，很多人还没到30天，权重相对小。所以整体数字被10月的好表现给"撑"住了。

但等到明年1月你再看，整体留存率可能就直接跳水了。到时候老板问怎么回事，你说"其实10月就开始跌了"，这就很尴尬了对吧。更惨的是，这时候再想挽救已经晚了，因为问题早就出现了，你只是没发现。

这就是为什么我们说，整体留存率是一个"滞后指标"。它反映的是过去的平均水平，不是当前的真实趋势。同期群分析才是"领先指标"，能让你更早发现问题。

第三部分：同期群分析能帮你发现啥

用这个方法，你能发现很多藏在整体数据下面的问题：

1、留存趋势到底是涨是跌

如果连着几个月的同期群留存都在往下走，那八成是产品出问题了。可能是新功能不好用，可能是竞品在抢人，可能是投放渠道质量在下滑。

反过来，如果留存在逐月提升，那说明你们做的优化是有效的，可以继续加码。

这个趋势判断特别重要。很多公司的产品其实已经在走下坡路了，但因为只看整体留存率，被历史的好数据"遮住了眼睛"，等到发现的时候已经晚了。

2、某次改动到底有没有用

假设你们10月15号上线了个大版本，改了新用户引导流程。那你就可以对比"10月上半月的同期群"和"10月下半月的同期群"，看留存有没有变化。

如果下半月的留存明显比上半月高，那说明新引导流程是有效的。如果反而更低了，那就要赶紧回滚或者排查问题。

这比看整体留存率精准太多了，因为你把"时间"这个变量给控制住了。整体留存率会被各种因素干扰，但同期群分析能帮你更准确地评估单个改动的效果。

3、不同渠道的用户质量差多少

把同期群再按渠道拆一下，你就能看到每个渠道带来的用户质量：

- 应用商店来的用户，30日留存20%
- 信息流广告来的用户，30日留存8%
- 老用户邀请来的用户，30日留存35%
- KOL推荐来的用户，30日留存25%

得，这下你就知道预算该往哪边倾斜了。别花大钱买一堆"一日游"用户。

而且这个分析可以更细。比如信息流广告还可以按平台拆（抖音、快手、微信）、按素材类型拆（效果素材、品牌素材）、按定向人群拆（新用户、老用户）。拆得越细，越能发现问题和机会。

4、用户到底在哪个节点流失最多

同期群分析还能帮你找到流失的"关键期"。

比如你发现大部分用户都是在第3到7天流失的，那这个时间段就是留存的关键窗口。你应该重点在这个阶段做引导、推送、或者召回，而不是等用户都流失了再去做。

不同产品的流失关键期不一样。工具类APP可能第1-3天最关键（用户要么马上觉得有用，要么马上卸载）；社交类APP可能第7-14天最关键（用户需要时间建立社交关系）；电商类APP可能第30天左右最关键（用户需要有复购需求才会留下来）。

通过同期群分析，你可以找到自己产品的流失关键期，然后针对性地设计留存策略。

第四部分：同期群分析怎么做

操作步骤其实不难，关键是要有结构化的思路：

第一步，确定分群维度

最常见的是按注册时间分，可以按周也可以按月。流量大的产品可以按天分，更精细。

如果你想做更深入的分析，还可以按其他维度分群：

- 按渠道分：不同渠道来的用户分开看
- 按用户类型分：付费用户和免费用户分开看
- 按地域分：一线城市和下沉市场分开看

分群的维度取决于你想回答什么问题。

第二步，确定观察指标

最常看的是留存率。但你也可以换成别的，比如首次付费转化率、累计消费金额、活跃天数，看你关心啥。

指标的选择要和业务目标挂钩。如果你是做付费订阅的产品，可能更关心"7日内付费转化率"；如果你是做电商的，可能更关心"30日累计GMV"。

第三步，拉数据画成矩阵

经典的呈现方式是一个矩阵图（也叫"热力图"或"留存三角"）：

- 纵轴是不同的同期群（1月群、2月群、3月群...）
- 横轴是"注册后第N天"（Day1、Day7、Day30...）
- 格子里填对应的留存率

如果用颜色来表示留存率的高低，就会形成一个很直观的"热力图"，一眼就能看出哪里有问题。

第四步，找规律找异常

看这个矩阵的时候有几个视角：

竖着看：某一列数字普遍偏低，说明这个时间点是用户流失的关键期，要重点干预。比如所有同期群在Day3都有明显下降，那Day3就是你的"留存悬崖"，需要想办法填平。

横着看：某一行数字普遍偏低，说明这批用户本身质量有问题，可能是那段时间的渠道不行，或者遇到了什么外部事件（比如竞品大促抢走了高质量用户）。

斜着看：往右下角逐渐降低是正常的（用户会自然流失），但如果某个区域下降得特别快，就要去查原因了。比如11月群的留存曲线明显比10月群陡峭，那11月肯定发生了什么。

第五部分：几个实战中的坑

做同期群分析的时候，有几个常见的坑要避免：

1、口径一定要统一

"登录算活跃"和"打开APP算活跃"是两码事，留存率可能差出一大截。做分析之前先把口径定义清楚，别到时候自己把自己绕进去了。

更要注意的是，如果要做历史对比，一定要确保口径一直是一致的。有些公司会在某个时间点调整活跃的定义，这时候前后的数据就不能直接比了。

2、样本量别太小

如果某个同期群只有几百人，那留存率波动会很大，今天20%明天可能就变30%了，没有统计意义。一般每个群至少要有几千人才比较稳。

如果你的产品日活不够大，可以考虑用周同期群代替日同期群，或者用月同期群代替周同期群，让每个群的样本量足够大。

3、别光看比率，也看绝对数

留存率是个比率，但有时候你还得看绝对人数。

比如10月群有10万人，30日留存20%，那是2万活跃用户。

12月群有5万人，30日留存25%，那只有1.25万活跃用户。

虽然12月留存率高，但贡献的活跃用户反而少。所以两个维度都要看。

4、一定要结合业务事件

如果某个同期群的留存突然变差，别光看数据，要去查那段时间发生了什么。是不是换了投放渠道？是不是产品出了bug？是不是竞品搞了个大促？是不是有什么社会事件影响了用户行为？

孤立地看数据是没意义的，数据要和业务动作对上才能得出结论。

5、注意"选择偏差"

同期群分析看的是"留下来的用户"，但"流失的用户"同样重要。有时候你需要同时分析流失用户的特征，才能找到留存问题的根源。

比如你发现11月群留存特别低，光看留存用户的行为可能看不出问题，但如果你去分析流失用户的特征，可能发现他们大多来自某个特定渠道，或者在某个功能上遇到了问题。

知识点总结：

- 同期群分析：按用户进入时间分组追踪后续行为，是留存分析的核心方法

- 整体留存的问题：混合不同时期用户，可能掩盖真实趋势，是一个"滞后指标"
- 核心价值：发现趋势、评估改动、对比渠道、定位流失节点
- 实操要点：口径统一、样本量足够、比率和绝对数都看、结合业务事件

追问：

如果同期群分析发现最近3个月的留存率都在持续下降，你会从哪些方向去排查原因？

追问解答

留存连续3个月下降，这个信号已经很明确了，不是偶然波动，肯定有系统性的问题。作为分析师，你需要有一个结构化的排查思路，而不是东一榔头西一棒槌地乱找。

我会从以下几个方向去排查，按照"从外到内、从宏观到微观"的顺序：

第一，先看渠道结构有没有变

把每个月的新用户按渠道拆开看。有可能是投放策略变了，比如信息流广告的占比从20%提升到了50%，而信息流来的用户天然留存就低。

具体怎么看呢？

第一步，拉出每个月各渠道的新用户占比，看结构变化。

第二步，拉出每个渠道的留存率，看各渠道本身的留存有没有变化。

第三步，做一个"因素分解"：整体留存下降，有多少是因为渠道结构变化导致的，有多少是因为各渠道留存本身下降导致的。

如果发现是渠道结构变化导致的，那就不是产品问题，是投放问题。要么优化投放素材和定向（提高低质量渠道的用户质量），要么调整渠道预算分配（把钱花在高质量渠道上）。

如果发现各渠道的留存都在下降，那问题可能出在产品本身，继续往下排查。

第二，看产品最近有没有大改动

留存下降的时间点，和产品迭代的时间对一下。如果11月上线了个新版本，然后11月、12月的同期群留存就开始跌，那大概率是这个版本有问题。

具体是什么问题，还得再拆：

1、新用户引导流程有没有变？

新用户引导是留存的第一道关口。如果新版本改了引导流程，比如步骤变多了、跳过按钮不明显了、加载时间变长了，都可能导致新用户早期就流失。

可以看Day1留存的变化。如果Day1留存明显下降，那很可能是引导流程的问题。

2、核心功能有没有变？

核心功能为用户留下来的理由。如果核心功能的交互变了、性能变差了、或者功能被砍了，用户可能就不愿意用了。

可以看核心功能的使用率变化。如果新版本上线后，核心功能的日均使用次数、使用时长都在下降，那问题可能出在这里。

3、技术性能有没有变差？

APP的启动速度、页面加载速度、崩溃率等技术指标，都会影响用户体验。如果新版本引入了性能问题，用户可能会默默流失。

可以拉出技术监控数据，看崩溃率、ANR率、启动时间等指标有没有恶化。

第三，看用户画像有没有变化

如果最近几个月拉来的用户，年龄、地域、设备这些画像发生了明显变化，也可能影响留存。

比如以前主要是一二线城市的年轻白领，现在下沉到三四线了，用户的需求和使用习惯可能不太一样，产品可能需要做适配。

再比如以前主要是iOS用户，现在Android占比提升了。如果你的Android版本体验不如iOS，留存自然会下降。

具体怎么看？把新用户按画像维度分组，分别看留存率：

- 一线城市 vs 下沉市场
- 18-24岁 vs 25-35岁 vs 35岁以上
- iOS vs Android
- 新机型 vs 老机型

如果发现某个群体的留存明显更低，而这个群体的占比又在增加，那就找到问题了。

第四，看外部环境

有时候留存下降不是你的锅，是市场环境变了。

1、竞品在搞事情

竞品出了个爆款功能，或者在疯狂做补贴，把你的用户吸走了。

可以通过行业报告、竞品监测工具、或者简单的应用商店排名来判断竞品最近有没有异常动作。

2、赛道在降温

如果整个赛道都在走下坡路，那你的留存下降可能是大势所趋。

比如2022-2023年社区团购赛道就是这样，很多产品的留存都在下降，不是某一家的问题，是整个市场在收缩。

3、用户需求在变化

用户的需求不是一成不变的。可能以前他们需要你的产品解决某个问题，现在这个问题被别的方式解决了，或者用户本身的需求变了。

比如疫情期间很多在线办公、在线教育产品的留存都很高，疫情结束后用户需求变了，留存自然下降。

第五，做用户调研

数据能告诉你"发生了什么"，但不一定能告诉你"为什么"。

如果数据层面实在找不到明确原因，就直接找流失用户做访谈。找一批最近30天流失的用户，问他们：

- 你为什么不用我们的产品了？
- 是找到了更好的替代品吗？是哪个产品？
- 是觉得我们的产品不好用吗？哪里不好用？
- 是你的需求变了吗？
- 如果我们做什么改进，你会回来用吗？

用户调研的好处是能获得数据无法提供的"定性洞察"。有时候一句用户的吐槽，比一万行数据更有价值。

当然，做用户调研也有技巧：

- 样本要够：至少访谈20-30个流失用户
- 要有代表性：不同渠道、不同画像的用户都要覆盖
- 问题要开放：别只问是非题，多问"为什么""能举个例子吗"
- 要会追问：用户的第一反应往往是表面原因，要通过追问挖到根本原因

第六，分层去看

别把所有用户混在一起看。可以按用户类型分层：

- 新用户留存下降了还是老用户活跃度下降了？
- 付费用户留存怎么样，免费用户呢？
- 高活用户和低活用户呢？
- 不同地域、不同渠道的用户呢？

分得越细，越容易定位问题。

比如你可能发现，核心高活用户的留存其实很稳定，下降的主要是边缘用户。那问题可能不是核心功能出了问题，而是边缘用户本来就不是目标用户，他们的流失是正常的。

再比如你可能发现，付费用户的留存很高，免费用户的留存很低。那可能是付费墙设置得太高了，免费用户看不到产品的价值就走了。

第七，建立归因模型

如果你的资源充足，可以建立一个更系统的留存归因模型。

核心思路是：把所有可能影响留存的因素都列出来，然后用数据分析方法（比如回归分析、决策树、SHAP值等）来量化每个因素的影响程度。

这样你就能得出一个结论：比如"留存下降的主要原因是渠道A的占比增加（贡献40%的下降）和新用户引导完成率下降（贡献30%的下降）"。

有了这个归因结果，你就知道应该优先解决什么问题了。

总之，留存下降一定有原因，关键是要有结构化的排查思路，别上来就瞎猜。从渠道结构、产品改动、用户画像、外部环境这几个大方向入手，层层拆解，一定能找到问题的根源。

题目 62

盒马发现2025年下半年会员用户整体复购率环比下降了8%，但不知道是哪类用户在流失，如何用RFM模型定位问题用户群并制定针对性策略？

解答

盒马发现复购率下降了8%，老板问你怎么回事。

你说"用户不爱买了"？这肯定不行。你得告诉老板：到底是哪类用户不买了。是高价值用户在跑，还是本来就不稳定的低价值用户在流失？是所有人都在掉，还是只有某一撮人出了问题？

这时候就得请RFM模型出场了。这个模型在电商、零售、会员运营领域用得特别多，是用户分层分析的基础工具，面试也经常考。

第一部分：RFM是啥

RFM是三个指标的组合：

- R是Recency，最近一次消费距今多久
- F是Frequency，消费频次
- M是Monetary，消费金额

这三个维度一组合，用户就能被分成不同的类型。

举几个例子：

- R低、F高、M高：最近刚买过，买得多花得多，这是你的宝贝用户，要好好维护
- R高、F低、M低：很久没来了，以前也不怎么买，这是价值不高的沉默用户，不用花太多精力
- R高、F高、M高：以前是大客户，但最近很久没出现了，这是最需要警惕的流失用户，要重点召回

用户分好类之后，你就可以看：复购率掉了8%，这8%到底是谁贡献的？是宝贝用户跑了（那就很严重），还是本来就没什么价值的用户自然流失了（那可能还好）？

第二部分：用RFM定位盒马的问题用户

假设你是盒马的分析师，拿到这个问题怎么做？

第一步，给每个用户算RFM得分。

这里的关键是"分数段怎么定"。不能拍脑袋，要根据盒马用户的实际分布来定。

比如R得分可以这样算：

- 最近7天内有消费：5分
- 8-14天：4分
- 15-30天：3分
- 31-60天：2分
- 60天以上：1分

F得分：

- 过去90天消费5次以上：5分
- 3-4次：4分
- 2次：3分
- 1次：2分
- 0次：1分

M得分：

- 过去90天消费超过2000元：5分
- 1000-2000：4分
- 500-1000：3分
- 200-500：2分
- 200以下：1分

这个分数段怎么定，最好先拉一下用户的分布情况，用五分位数或者业务经验来划分。

第二步，给用户打标签。

有了得分之后，你可以把用户分成几类。经典的分法是按照RFM得分的高低组合，分成8种类型：

"核心用户"：R、F、M都很高，三个维度都在4分以上。这是你最宝贵的用户群，要重点维护。

"高潜力用户": R高、M高, 但F还不够。说明他们愿意花钱, 但还没养成高频消费的习惯。应该想办法提升他们的消费频次。

"需要唤醒的用户": R低、但F和M都高。这群人以前是常客, 现在不来了。这是最危险的群体, 需要重点召回。

"新用户": R高, 但F和M都低。刚来不久, 还没来得及多次消费。需要做好新客培育。

"一般用户": 三个维度都在中间, 不好不坏。可以通过运营活动尝试提升。

"低价值用户": 三个维度都偏低。可能是自然流失的用户, 或者本来就不是目标客群。

第三步, 对比各群体的复购率变化。

把2025年上半年和下半年的数据分别算一遍, 看每个群体的复购率怎么变的:

假设结果长这样:

- 核心用户: 复购率从85%降到82%, 小幅下滑3个点
- 需要唤醒的用户: 复购率从60%降到45%, 跌了15个点
- 一般用户: 从40%降到38%, 基本稳定
- 低价值用户: 从15%到14%, 没啥变化

得, 问题定位到了: "需要唤醒的用户"这群人在大量流失。

这就是RFM的价值: 把一个模糊的"复购率下降8%", 拆解成了一个明确的"某个特定用户群流失严重"。有了这个定位, 后续的分析和行动就有方向了。

第三部分：找到问题群体之后怎么干

知道是哪群人出问题了, 接下来就是找原因、定策略。

1、先把这群人的画像拉出来

他们主要买什么? 生鲜、日用品、还是熟食即食?

他们什么时候下单? 早上买菜还是晚上囤货?

他们是线上为主还是爱逛门店?

他们在哪些城市? 客单价分布怎样?

有了画像, 你就能开始猜问题出在哪了。比如如果这群人主要买生鲜, 那可能是生鲜品质或价格出了问题; 如果主要在某几个城市, 那可能是那几个城市有特殊情况。

2、列几个假设

假设一: 这群人主要买生鲜, 但最近生鲜涨价了, 他们觉得不划算跑了。

假设二: 这群人主要在某几个城市, 而那几个城市的竞品(叮咚、朴朴、美团买菜)在搞大促。

假设三: 盒马最近调整了配送时间或起送门槛, 影响了这群人的体验。

假设四: 这群人以前喜欢周末逛门店, 但最近门店调整了布局或营业时间。

3、用数据验证

如果是价格问题，就去看这群人常买商品的价格变化，以及价格变化后的购买量变化；
如果是竞争问题，就对比不同城市的流失率差异，看是不是某些城市特别严重；
如果是体验问题，就去看投诉率、差评率有没有上升，看配送时效有没有变差；
如果是门店问题，就看门店客流和转化率有没有变化。

4、针对性地干预

找到原因之后，运营策略就很明确了：

价格敏感的，就针对这群人的常购品类发券，或者做"老客专享价"；
被竞品抢走的，就加强会员权益，比如会员专享价更低、积分翻倍、免费配送门槛降低；
体验问题导致的，先把体验修好（提升配送时效、保证商品品质），再做召回活动；
门店问题的，优化门店动线和陈列，或者加强门店的线上引流。

关键是：策略要针对问题群体的特征来定制，而不是一刀切地给所有用户发券。一刀切既浪费预算，效果也不好。

第四部分：RFM的几个坑

RFM好用，但也有局限性，实际操作中得注意：

1、它是看历史的，不是预测未来的

RFM根据过去的数据算，反映的是"已经发生"的行为。一个用户现在R很低（很久没买），不代表他永远不回来。可能只是最近忙、出差、或者需求暂时减少了。

所以RFM要定期更新，别算一次就躺着不动了。建议至少每周更新一次，对于高频场景（像盒马这种买菜的）甚至可以每天更新。

2、新用户别和老用户混在一起

新用户刚注册，R肯定高（刚来嘛），但F和M可能很低——人家还没来得及买多次呢。如果直接套RFM，可能把新用户错误归类成"低价值"。

正确的做法是：把"注册30天内的新用户"单独拎出来，用不同的逻辑来评估和运营。新用户的核心指标应该是"首单转化率""7日复购率"，而不是RFM。

3、R、F、M的权重不一定一样

三个维度哪个更重要，要看业务特点。

盒马这种高频消费的场景，F（消费频次）可能比M（消费金额）更重要。因为买菜这事儿讲究习惯和粘性，用户一旦养成习惯，每次消费金额不会差太多，关键是来不来。

但如果是卖高端化妆品的，M可能比F更重要。因为一单就是大几千，复购频次没那么高，但只要复购就是大单。

权重怎么设，可以用历史数据来验证：看RFM得分和用户LTV（生命周期价值）的相关性，哪个维度相关性最高，就给更大的权重。

4、分层之后要有动作

RFM的目的不是分层本身，而是分完层之后要有针对性的动作。如果分完层放在那里不管，那这个分析就白做了。

每个层级都应该有对应的运营策略：

- 核心用户：维护关系，防止流失，可以给专属权益
- 高潜力用户：刺激消费频次，可以做凑单优惠
- 需要唤醒的用户：召回，可以发"好久不见"的优惠券
- 新用户：培育，做好首单后的跟进
- 低价值用户：可以降低投入，或者尝试激活

第五部分：RFM的进阶玩法

基础的RFM会用了之后，还可以有一些进阶的玩法：

1、RFM动态监控

不只是看某个时间点的RFM分布，而是看用户在不同时间点的RFM变化。比如一个用户上个月是"核心用户"，这个月变成了"需要唤醒的用户"，那他就是要重点关注的"降级用户"。

可以建一个"用户流动矩阵"，看每个月有多少用户从A类变成了B类，从B类变成了C类。这样能更早发现问题。

2、RFM + 其他维度

RFM只考虑了消费行为，但用户还有很多其他特征：年龄、地域、偏好品类、获客渠道等。可以把RFM和这些维度结合起来，做更细致的分层。

比如"需要唤醒的用户"里，可以再按城市拆分，看是哪些城市的流失更严重；可以按偏好品类拆分，看是买生鲜的流失了还是买日百的流失了。

3、机器学习方法

更高级的做法是用机器学习方法（比如K-Means聚类、决策树、随机森林）来做用户分层。这些方法可以自动发现用户的聚类特征，不需要人工设定R、F、M的分数段。

但机器学习方法的问题是解释性差，业务部门可能不太容易理解"为什么这个用户被分到这个类"。所以很多公司还是用RFM作为基础方法，简单、直观、容易沟通。

知识点总结：

- RFM模型：用最近消费时间、消费频次、消费金额给用户分层，是用户分析的基础工具
- 核心价值：把"整体下降"拆到具体群体，精准定位问题，而不是一刀切地分析
- 实操流程：算得分→打标签→对比变化→找原因→定策略
- 注意事项：定期更新、新老用户分开、权重要结合业务、分层之后要有动作

追问：

如果分析发现"需要唤醒的用户"流失主要集中在3个城市，你会怎么进一步排查原因？

追问解答

如果发现流失集中在3个城市，那接下来的排查方向就很明确了，要找这3个城市的"特殊性"。按照"从外到内、从竞争到自身"的顺序来排查：

第一，看竞品动作

这3个城市是不是竞品在搞事情？比如叮咚买菜、朴朴、美团买菜在这些城市搞了大力度补贴、新用户优惠、或者开了新的前置仓。

怎么看呢？

首先，可以去这3个城市的竞品APP上看看有没有明显的促销活动。下载竞品APP，注册个新账号，看看新用户优惠力度、首单折扣、会员权益有没有变化。

其次，可以去看行业数据。艾瑞、易观这些第三方机构有时候会发布生鲜电商的城市市占率数据，看看这3个城市的竞品份额有没有明显上升。

再次，可以问问一线的运营同学和配送员，他们对竞品动态的感知往往是最敏锐的。

如果确认是竞品在搞事情，那应对策略可能包括：加大这3个城市的投放力度、推出针对性的促销活动、加强会员权益。但要注意的是，打价格战是双刃剑，要算清楚ROI。

第二，看盒马自己在这3个城市有没有变化

这3个城市是不是最近做了什么调整？

比如：

- 关了几家门店？门店关闭会直接影响周边用户的购物便利性。
- 调整了配送范围？有些地址从能配送变成不能配送了？
- 提高了起送门槛？从39元起送变成49元起送？

- 调整了配送费？从免费配送变成收配送费？
- 砍掉了某些商品品类？用户想买的东西买不到了？
- 更换了配送服务商？导致配送时效变差？

这些信息需要和业务部门对一下。可以找运营、供应链、门店管理的同事聊聊，看看最近几个月在这3个城市有没有做过什么调整。

如果发现是自身调整导致的问题，那就要评估：这个调整是必须的吗？能不能回滚？如果不能回滚，有没有其他方式弥补用户体验的损失？

第三，看这3个城市的用户结构

这3个城市的用户结构有没有特殊性？

比如，这3个城市以前是盒马大力补贴拉新的城市，用户本来就是"薅羊毛"属性的，补贴一停就跑了？

或者，这3个城市的用户画像和其他城市不一样？比如消费能力更低、对价格更敏感、对品质要求不那么高（这时候竞品的低价策略就更有吸引力）？

可以拉一下这3个城市流失用户的画像，和其他城市的流失用户对比，看看有没有明显差异。

第四，看品类和商品维度

这3个城市的用户，主要买什么品类？

如果他们主要买生鲜，那可以看看这3个城市的生鲜价格、品质、品种有没有变化。生鲜是高频刚需品类，用户对价格和品质都很敏感。

如果他们主要买某个特定商品（比如某个网红产品），那可以看看这个商品最近有没有缺货、涨价、或者下架。

品类分析可以帮你找到更具体的问题点。

第五，看时间线

这3个城市的流失是什么时候开始的？

把每个城市每周的流失率画一条曲线，看看流失是从哪周开始加剧的。然后对应那一周发生了什么事情：盒马自己的调整、竞品的动作、节假日、天气变化、社会事件等。

时间线分析可以帮你建立"事件→结果"的因果联系。

第六，做用户调研

数据能告诉你"发生了什么"，但不一定能告诉你"为什么"。

如果前面几个方向都没找到明确原因，就直接找这3个城市的流失用户做访谈。问他们：

- 你最近为什么不在盒马买菜了？
- 你现在在哪里买菜？为什么选择那里？

- 对盒马有什么不满意的地方？
- 如果盒马做什么改进，你会回来吗？

找20-30个流失用户做深度访谈，通常能获得很多数据无法提供的洞察。

第七，做对照实验

如果你有了初步假设（比如猜测是配送时效问题），可以在这3个城市做个小范围测试：

比如，给一部分流失用户发一个"配送时效保证"的承诺（下单后1小时内送达，超时赔偿），看能不能把他们召回。

如果测试有效，就坐实了假设；如果没效，就继续排查其他方向。

总之，城市维度的异常往往是最容易找到原因的，因为它给了你一个很明确的"对照组"（其他城市正常，就这3个不正常）。顺着这个思路查下去，通常能找到答案。

题目 63

海底捞2025年秋季推出"工作日午市6.9折"活动后，午市客流量提升了35%，但门店整体日营收只增长了3%，作为数据分析师你会怎么分析这组数据？

解答

这道题乍一看挺奇怪的：午市客流量涨了35%，日营收却只涨了3%？那多出来的人都白吃了吗？

仔细一算你就懂了，问题出在折扣上。

第一部分：先把账算明白

日营收 = 午市营收 + 晚市营收

午市营收 = 客流量 × 客单价

活动打6.9折，相当于客单价直接砍了31%。

我们假设活动前午市的情况是这样的：

- 客流量：100人
- 客单价：150元
- 午市营收：15000元

活动后：

- 客流量涨35%：135人
- 客单价打6.9折：103.5元
- 午市营收：135 × 103.5 = 13972.5元

你看，客流涨了35%，但客单价跌了31%，算下来午市营收反而还降了一点点。

那整体日营收为什么能涨3%呢？只有一个可能：晚市在涨。午市这边打折打亏了，晚市那边没打折、正常增长，把午市的亏损给补上了，整体才能微微涨3%。

第二部分：为什么折扣效果这么差

这里面有几个关键点：

1、价格弹性不够大

降价31%，客流只涨35%。用价格弹性的公式算： $35\% \div 31\% \approx 1.13$

价格弹性只有1.13，意思是降价带来的客流增量，刚刚够抵消降价本身的损失。如果弹性不到1.45左右，这个折扣活动在午市这一场就是亏钱的。

2、午市和晚市的客人不一样

午市主要是附近的上班族，时间紧、预算有限，对价格敏感。晚市主要是家庭聚餐、朋友小聚，不差钱，更看重体验和氛围。

所以午市即使客流涨了，客单价和消费时长都比晚市低，对营收的拉动作用本来就有限。

3、可能有"时段转移"

还有个可能性：一部分原来晚上来吃的人，看到午市有6.9折，就改成中午来了。

如果真是这样，那午市增加的客流里有一部分根本不是增量，而是从晚市"偷"过来的。晚市客流下降的话，整体营收自然涨不上去。

第三部分：这道题考什么

面试官想看的是你能不能把这个问题拆清楚。

1、会拆营收结构

日营收不是一个数，得拆成午市和晚市。午市营收 = 客流 × 客单价 × 折扣系数。你得能拆到这个粒度才能分析问题。

2、懂价格弹性

降价不是万能的。如果价格弹性不够大，降得越多亏得越多。

3、有业务sense

能想到午市晚市客群不同，能想到时段转移的可能性。这些都是加分项。

###

第四部分：如果你是海底捞的分析师该怎么做

如果这不是面试题，而是真让你做分析，你应该这么干：

1、把午市晚市的营收分开看

活动前后，午市营收是涨了还是跌了？晚市呢？只有拆开看才能知道问题在哪。

2、看客单价到底降了多少

理论上是6.9折，但实际情况呢？用户可能因为便宜多点了几道菜，实际折扣可能没到31%。或者反过来，用户就是冲着便宜来的，只点最便宜的套餐，实际客单价比预期还低。

3、查晚市客流有没有下降

这个很重要。如果晚市客流在活动期间明显下降了，那就说明有时段转移。午市增加的人头，一部分是从晚市抢来的，不是真正的增量。

4、看新客占比

午市新增的这批人，有多少是新客户、有多少是老客户换时间来？如果都是老客户换时间，那这个活动的拉新价值就很低。

第五部分：这活动到底值不值得做

从短期营收看，这个活动的ROI不太行。日营收只涨3%，但午市打了31%的折扣。

但从战略角度看，可能还有其他价值：

1、午市本来就是闲置时段

海底捞的店租是固定成本，午市空着也是空着。能多来一批客人，哪怕利润薄，也比坐着亏租金强。

2、培养用户习惯

有些人以前不吃午市火锅，觉得太重或者时间不够。6.9折给了他们一个尝试的理由。如果吃得开心，以后可能变成常客。

3、卡位竞争对手

如果周边其他火锅店没有午市折扣，海底捞的6.9折就能把对价格敏感的那批人抢过来。自己没多赚，但对手也没赚到。

所以这个活动划不划算，不能只看短期营收那3%，还得看长期用户留存、午市坪效利用率、竞争格局这些维度。

知识点总结：

- 营收拆解：日营收 = 午市 + 晚市，要分开算
- 价格弹性：降价带来的客流增量如果不够大，就会亏
- 时段转移：折扣可能是把其他时段的客流搬过来了，不是真增量
- 战略视角：短期亏的活动，长期可能有别的价值

追问：

如果你发现午市增加的客流中有40%是从晚市转移过来的，你会建议继续还是停止这个活动？

【追问回答】

40%是晚市转移过来的，这个比例挺高的，说明活动的"真实拉新效果"只有60%。但我不会简单建议停止，这种事情没有非黑即白的答案，得综合分析几个维度才能给出建议。

第一，先把账算清楚：活动的真实ROI是多少

这是最核心的问题。我们需要把所有的收益和成本都算进去。

收益端：

午市客流涨了35%。但其中40%是晚市转移的，那真正的增量客流是 $35\% \times 60\% = 21\%$ 。

假设活动前午市每天100人，活动后是135人。其中真正的新增是21人（21%的增量），晚市转移过来的是14人（35人的40%）。

这21人的新增客流，每人消费约103.5元（150元打6.9折），贡献增量营收约2174元。

成本端：

但成本不只是折扣成本。要算几块：

第一块，折扣成本。原来的100个午市顾客，现在也享受6.9折了，每人少收了46.5元（ $150 \times 31\%$ ），总计少收4650元。

第二块，晚市转移的损失。那14个从晚市转过来的人，如果他们晚上来，客单价可能是200元（晚市客单价通常比午市高）。现在中午来了，只花103.5元。每人少收了96.5元，总计少收1351元。

第三块，可变成本。多来的35个人，食材成本、服务成本也会增加。假设每人可变成本50元，增加了1750元。

算下来：

增量收入 = $21人 \times 103.5元 = 2174元$

折扣损失 = $100人 \times 46.5元 = 4650元$

晚市转移损失 = $14人 \times 96.5元 = 1351元$

可变成本增加 = $35人 \times 50元 = 1750元$

净损失 = $4650 + 1351 + 1750 - 2174 = 5577元/天$

如果按这个简化模型算，午市6.9折活动每天要亏5500多元。一个月下来就是16.7万。

当然，这只是一个简化计算，实际数字要根据真实数据来。但这个思路很重要：不能只看客流涨了多少，要把所有的成本和收益都算进去。

第二，看短期ROI之外的价值

虽然短期算下来是亏的，但有些价值是短期ROI算不出来的：

1、午市坪效利用

海底捞的门店租金是固定成本。午市如果空着，租金照样要付。只要午市能覆盖可变成本（食材、人工），多来的客人就不算亏。

从这个角度看，即使折扣很大，只要每桌能覆盖边际成本，就比空着强。

2、用户习惯培养

有些用户以前从不吃午市火锅。6.9折给了他们一个尝试的理由。如果体验好，以后可能变成习惯。

可以看看活动期间的新客，在活动结束后的复购率。如果复购率不错，说明活动有长期价值。

3、竞争压制

如果周边的火锅店没有午市折扣，海底捞的6.9折就能把价格敏感的客户吸过来。自己没多赚，但竞争对手也没赚到。

这种策略在竞争激烈的商圈可能是必要的。

4、品牌曝光

午市客流增加，就有多人进店体验海底捞的服务。即使这次是冲着便宜来的，下次可能会带朋友晚上来（不打折的时候）。

这种"先体验再转化"的逻辑在餐饮行业很常见。

第三，看那40%转移用户的后续行为

这40%的转移用户是最需要关注的群体。他们的行为决定了活动的长期影响：

情况一：活动结束后，他们回到晚上来吃

这是最好的情况。说明他们只是临时"薅个羊毛"，并没有改变消费习惯。活动期间少赚了一点，但活动结束后一切恢复正常。

情况二：活动结束后，他们变成午市常客

这也不错。虽然午市利润薄，但总比流失强。而且午市客流增加可以提升坪效。

情况三：活动结束后，他们觉得"没折扣不来"

这是最糟糕的情况。活动把他们"教育"成了价格敏感型用户，以后只在有折扣的时候才来。

情况四：活动结束后，他们干脆不来了

可能觉得没有折扣就不划算，也不想晚上来，干脆不吃海底捞了。这意味着活动反而加速了用户流失。

要判断是哪种情况，需要跟踪活动结束后2-4周这批用户的行为。如果发现大量用户变成了"情况三"或"情况四"，那活动的长期危害就很大了。

第四，我的建议：不是简单地继续或停止，而是优化规则

基于上面的分析，我的建议是：不要简单地继续或停止，而是优化活动规则，减少时段转移、提高真正的拉新效果。

方案一：区分新客和老客

新客享受6.9折，老客享受8折或者不打折。这样可以避免老客户为了省钱而改变消费时段。

具体操作上，可以通过会员系统识别：首次到店的新客扫码注册后享受6.9折；已有消费记录的老客只能享受8折或者其他优惠。

方案二：限制折扣使用次数

每个用户每月只能享受2次午市6.9折。这样即使老客户想转移时段，也只能转移有限的次数。

方案三：改成满减或指定菜品折扣

把"全场6.9折"改成"午市满200减50"或者"午市锅底半价"。这样可以降低整体折扣力度，同时还能刺激用户多消费。

满减的好处是：用户为了凑满减会多点菜，客单价可能不降反升。

方案四：和晚市做差异化

午市推出"快速套餐"——固定菜品组合、60分钟用餐时间、6.9折。这样和晚市的"慢慢吃、随便点"形成差异化，吸引的是真正有午市需求的上班族，而不是晚市用户换个时间来。

方案五：设置时段隔离

如果用户在午市使用了6.9折优惠，当月晚市消费可以获得一个小优惠（比如送一份小菜）。这样用户不会觉得"午市折扣用了，晚市就亏了"，反而会两个时段都来。

第五，如何向业务部门汇报这个结论

如果我是分析师，我会这样向业务部门汇报：

首先，肯定活动的正面效果：午市客流确实增加了35%，这说明价格策略是有效的，用户对折扣是有反应的。

然后，指出发现的问题：但我们发现40%的增量客流是从晚市转移过来的，不是真正的新增。这意味着活动的拉新效率只有预期的60%，而且还造成了晚市收入的损失。

接着，给出量化评估：按我们的测算，活动的短期ROI是负的，每天大约损失X元。但如果考虑坪效利用、用户习惯培养等长期价值，损失可能会小一些。

最后，给出优化建议：建议不要直接停止活动，而是优化规则。具体方案包括：区分新老客折扣力度、限制每月使用次数、改成满减形式等。建议选择1-2个方案做小范围测试，看哪个效果更好。

这样的汇报既有数据支撑，又有具体建议，业务部门会更容易接受。

为什么有些AB实验跑了两周还是"没有显著差异"? 是实验真的没效果，还是样本量根本不够？怎么在实验前算清楚需要多少样本？

解答

做AB实验的时候，经常碰到这种情况：跑了两周，结果出来是"没有显著差异"。

产品经理问：是策略没用，还是实验有问题？

很多时候，问题就出在样本量不够。这是AB实验里最常见的坑之一，但很多人不知道怎么提前规避。

第一部分："没有显著差异"到底是什么意思

先解释一下这个概念。

当我们说两个版本有"显著差异"，意思是这个差异大概率是真实的，不是随机波动搞出来的。

通常用p值来判断，p值小于0.05就认为有显著差异。

但问题是，p值大于0.05有两种可能：

第一种，真的没差异。策略确实没用，两个版本一样。这时候得出"没有显著差异"的结论是正确的。

第二种，有差异但检测不出来。策略其实是有效的，但因为样本量太小，数据波动太大，效果被"噪音"淹没了，你看不出来。

第二种情况就是"样本量不够"导致的假阴性。假阴性的意思是：本来应该检测出来的效果，因为样本量不足，被误判为"没有效果"。

这两种情况的结论完全相反，但表面上看起来一样（都是p值大于0.05）。所以你必须要在实验开始之前就算清楚需要多少样本量，否则实验结果出来了你都不知道该怎么解读。

第二部分：为什么样本不够就看不出效果

打个比方你就懂了。

假设你想知道一枚硬币是不是公平的。你扔了10次，6次正面4次反面。

你能断定这硬币有问题吗？不能，10次太少了，6:4可能就是运气。即使这枚硬币真的有问题（比如正面概率是60%），10次实验也很难检测出来。

但如果你扔了1000次，600次正面400次反面，那你就有很强的理由怀疑这硬币不对劲了。因为如果硬币是公平的，1000次里出现600:400的概率非常低。

AB实验也是这个道理。如果策略带来的提升很小（比如只有1%的相对提升），样本量又不够，那这1%的提升就会被随机波动给"吃掉"，你根本看不出来。

用统计学的语言说：当效应量（effect size）很小的时候，你需要很大的样本量才能有足够的"统计功效"（statistical power）来检测出这个效应。

第三部分：怎么在实验前算清楚需要多少样本

样本量的计算取决于四个东西，这四个参数决定了你需要多少人才能做出可靠的结论：

1、基线指标

你现在的指标是多少？比如当前的转化率是5%。

基线指标越低，通常需要的样本量越大。因为低基线意味着事件发生的次数少，统计波动更大。

2、最小检测效应（MDE）

你想检测多大的变化？这是最关键的参数。

比如你想检测10%的相对提升，就是从5%涨到5.5%。这个0.5个百分点的绝对提升，就是你的最小检测效应。

MDE设得越小，需要的样本量越大。如果你想检测1%的相对提升（从5%到5.05%），那需要的样本量可能是10%提升的100倍。

所以设MDE的时候要务实：不要设得太小（需要的样本量会大到不现实），也不要设得太大（可能漏掉真正有意义的效果）。

3、显著性水平（alpha）

通常是0.05，意思是你能接受5%的假阳性率。也就是说，如果实验组和对照组实际上没有差异，你有5%的概率会错误地得出"有差异"的结论。

alpha设得越小（比如0.01），需要的样本量越大，但假阳性的风险也越低。

4、统计功效（power）

通常是0.8，意思是如果真的有效，你有80%的概率能检测出来。反过来说，有20%的概率会漏掉真正的效果（假阴性）。

power设得越高（比如0.9），需要的样本量越大，但假阴性的风险也越低。

有这四个参数，就能用公式算出需要多少样本量了。公式本身挺复杂的，但现在有很多在线工具可以直接算，比如Evan Miller的样本量计算器、Optimizely的计算器等。你把这四个数输进去，工具告诉你每组需要多少人。

举个例子：

- 基线转化率：5%
- 想检测的最小提升：10%（从5%到5.5%）
- 显著性水平：0.05
- 统计功效：0.8

算出来每组大概需要3万人，两组一共6万人。

如果你的日活只有1万，那至少得跑6天才够。如果日活只有5000，那要跑12天。

第四部分：实战里常踩的坑

做AB实验的时候，有几个关于样本量的常见错误：

1、想检测的效应太小了

这是最常见的问题。产品经理说"我想检测这个改动能不能提升1%的转化率"，但1%的相对提升需要的样本量可能是几十万甚至上百万。

如果你的产品日活只有几万，这个实验根本做不了，或者要跑好几个月。

正确的做法是：在设计实验之前，先算一下不同MDE需要多少样本量，然后选一个现实可行的MDE。如果算下来实验周期太长，就要考虑：这个改动值不值得做实验？能不能通过其他方式验证？

2、没到时间就跑去看结果

有些人实验跑了3天就去看结果，发现p值是0.06，离0.05很近了，于是决定"再跑两天应该就显著了"。

这是很危险的做法，叫做"偷看"（peeking）。每次偷看都会增加假阳性的概率。如果你跑了7天的实验，每天都看一次结果，最终的假阳性率可能不是5%，而是15%甚至更高。

正确的做法是：事先定好实验周期和样本量，到时间再看结果，中间不要看。或者用专门设计的"序贯检验"方法，允许中途查看但会调整显著性阈值。

3、忽略了方差

样本量不只和均值有关，还和方差有关。

如果你看的指标波动特别大（比如用户消费金额从0到几万不等），那需要的样本量会更大。因为高方差意味着数据更"吵"，更难看出真正的效果。

有些团队只看平均值觉得差不多了，结果忽略了方差，算出来的样本量远远不够。

一个解决办法是：对高方差指标做"截尾"处理，比如把消费金额超过1000元的都算作1000元。这样可以降低方差，减少需要的样本量。

4、分流比例太保守

如果你只给实验组分了5%的流量，那积累样本的速度会慢得让人崩溃。

当然也不能100%都给实验组，因为你还需要对照组。50:50分流是积累样本最快的方案。

如果担心实验策略有风险，可以先用10%流量跑几天看看有没有明显问题，确认没问题后再调成50:50。

5、忽略了多重比较问题

如果你同时测试了5个指标，每个指标的显著性水平都是0.05，那至少有一个指标出现假阳性的概率是 $1-(0.95)^5 = 22.6\%$ 。

这就是"多重比较"问题。如果你看很多指标，总能找到一个"显著"的，但可能只是巧合。

解决办法是：事先定好主指标和次要指标。主指标用0.05的阈值，次要指标用更严格的阈值（比如0.01），或者用Bonferroni校正。

第五部分：跑完了还是没显著性怎么办

如果实验结束了还是没有显著差异，有几个选择：

1、检查样本量是否真的够了

回去看看当初的样本量估算。如果当时估算需要6万人，但实际上只跑了4万人，那"没有显著差异"可能只是因为样本量不够。这时候可以继续跑，直到达到预定的样本量。

但如果样本量已经够了，那"没有显著差异"可能就是真实的结论。

2、接受结果，不上线

如果样本量足够，实验设计也没问题，那"没有显著差异"就是真实的结论。这时候最好的选择是：不上线这个改动，或者回去重新设计一个更好的方案。

很多人不愿意接受"实验失败"的结果，总想找各种理由来证明改动是有效的。但这是很危险的心态。实验的目的就是为了避免上线没用的改动，如果实验说没效果，那就是没效果。

3、看次要指标和分人群

有时候主指标没动，但次要指标有变化。比如转化率没变，但客单价提升了；或者整体没变，但新用户转化率提升了。

这些发现也有价值，但要注意不能"事后诸葛亮"地挑选有利的结果。如果事先没有定义这些次要指标，那这些发现只能作为"探索性分析"，需要后续实验来验证。

4、做定性分析

实验数据说"没有显著差异"，但用户可能有其他反馈。可以做一些用户访谈或问卷，了解用户对新版本的感受。

也许新版本在某些方面确实更好，只是没有反映在你选择的指标上。这时候可以考虑换一个指标重新实验。

知识点总结：

- 样本量不够会导致假阴性：有效但检测不出来
- 四个关键参数：基线指标、最小检测效应、显著性水平、统计功效
- 实验前一定要先算样本量：别拍脑袋定实验周期
- 常见坑：效应太小、偷看结果、忽略方差、分流太保守、多重比较

追问：

如果算出来需要10万样本，但你们产品日活只有5000人，你会怎么办？

【追问回答】

如果需要10万样本但日活只有5000人，按50:50分流，每天进入实验的用户只有5000人，那要跑20天才能攒够样本。

20天太长了。这期间外部环境可能会变（节假日、促销活动、竞品动作），用户行为也可能有周期性波动，这些都会干扰实验结果。所以不能简单地"硬等"，需要想其他办法。

我会从以下几个方向来解决这个问题：

第一，接受检测更大的效应

这是最直接的办法。需要10万样本，通常是因为你想检测一个很小的效应（比如5%的相对提升）。如果你把MDE从5%调到15%，需要的样本量会大幅减少，可能只需要1万多人。

这样的话，日活5000人，跑2-3天就够了。

代价是什么？如果真实效果在5%-15%之间，你可能检测不出来。但如果策略真的有15%以上的提升，你是能发现的。

这个trade-off需要和业务方讨论：一个只有5%提升的改动，值不值得上线？如果不值得，那就没必要费劲去检测它，直接把MDE设到15%就行。

第二，换一个方差更小的指标

有些指标天然方差大（比如用户消费金额，从0到几万不等），有些方差小（比如是否点击，只有0和1两个值）。

方差越大，需要的样本量越大。如果你能找到一个相关但方差更小的替代指标，需要的样本量会更少。

举个例子：如果你想测试一个新的支付流程是否能提升GMV，直接用GMV做指标可能方差很大。但你可以用"支付页面到支付成功的转化率"作为替代指标——这个指标方差更小，而且和GMV高度相关。

当然，换指标要确保新指标和业务目标是强相关的，否则就是"指标替换谬误"。

第三，用更高效的实验方法

有一些统计方法可以在同样的样本量下提高检测精度：

1、CUPED方法

CUPED（Controlled-experiment Using Pre-Experiment Data）利用用户的历史数据来降低方差。核心思路是：用户的实验期行为和历史行为是相关的。通过控制历史行为的影响，可以降低实验期数据的方差，从而用更少的样本检测出效果。

很多大厂（Google、Uber、Airbnb）都在用这个方法，据说可以把需要的样本量降低30%-50%。

2、分层抽样

如果用户群体差异很大（比如新老用户的转化率差很多），可以在分流的时候做分层：确保实验组和对照组在新老用户、地域、设备等维度上的比例是一致的。

这样可以减少组间差异带来的方差，提高检测精度。

3、配对设计

如果可能的话，可以在同一个用户身上做"前后对比"（比如用户在改版前后的行为变化），而不是在不同用户之间做对比。这样可以大幅降低个体差异带来的方差。

但这个方法在AB实验里不太常用，因为用户往往只能分到一个组。

第四，考虑是否真的需要AB实验

有些改动风险很低，收益很明确，不一定需要严格的AB实验。

比如：

- 修复一个明显的bug（用户投诉很多）
- 优化一个很慢的页面（加载时间从5秒降到1秒）
- 行业通用的最佳实践（比如在支付页面加上安全标识）

这些情况下，直接上线观察数据变化就行了，没必要做AB实验。

AB实验适合的场景是：改动有不确定性，可能有正向效果也可能有负向效果，需要数据来验证。如果改动的方向是确定的，只是不知道效果有多大，可以考虑其他验证方式（比如用户调研、灰度发布观察）。

第五，接受更高的风险

如果时间紧迫，你也可以接受更高的假阴性风险。

比如把统计功效从80%调到60%。这意味着：如果策略真的有效，你只有60%的概率能检测出来（有40%的概率会漏掉）。

需要的样本量会减少很多，实验周期可以缩短。

代价是：可能会漏掉一些真正有效的策略。但在资源有限的情况下，这可能是一个合理的trade-off。

第六，做定性验证而不是定量验证

如果样本量实在不够，可以考虑用定性方法来验证：

- 1、用户访谈：找20-30个用户，让他们使用新版本，收集反馈。
- 2、可用性测试：观察用户使用新版本的过程，看有没有明显的问题或改进。
- 3、专家评审：找几个有经验的产品经理或设计师，评估新版本是否比旧版本好。

这些方法不能给出精确的"提升了X%"的结论，但能帮你判断改动的方向是否正确。

第七，如何向业务方沟通这个问题

如果业务方坚持要做AB实验，但样本量确实不够，你需要向他们解释这个限制：

首先，解释清楚样本量和可检测效应的关系："我们的日活是5000，如果想检测5%的提升，需要跑20天。如果只跑7天，我们只能检测到15%以上的提升。"

然后，给出几个选项让业务方选择：

- 选项A：跑20天，可以检测5%的提升
- 选项B：跑7天，只能检测15%以上的提升
- 选项C：不做AB实验，直接上线观察

最后，让业务方做决策。这样他们就能理解实验的局限性，而不是到时候看到"没有显著差异"就质疑分析师的能力。

总之，样本量不够的问题没有完美解决方案，只能在"检测精度""实验周期""风险承受"之间做权衡。关键是在实验开始之前就把这些限制讲清楚，而不是等实验跑完了才发现样本量不够。

题目 65

唯品会发现2025年双11期间新用户数同比增长55%，但这批新用户的30天留存率只有9%（去年同期是16%），如何分析新用户质量下滑的原因？

解答

新用户增长55%，听起来不错对吧。但30天留存从16%跌到9%，接近腰斩，这就很扎心了。

我带你算一笔账。假设今年双11唯品会拉了310万新用户，比去年的200万多了110万。按30天留存算，今年留下来的是310万乘以9%等于27.9万；去年留下来的是200万乘以16%等于32万。

你看到问题了吗？新用户暴涨55%，但最终留下来的人反而还少了4万。如果算上获客成本的增长，今年的ROI大概率是负的。

用户来了一堆，留不住，那拉新的钱基本打水漂了。这道题考的就是：怎么分析新用户质量下滑的原因，怎么找到问题出在哪。

第一部分：先把问题拆开

留存下滑，本质上就两种可能：

第一种可能，来的人变了。今年拉来的用户和去年不是同一类人，他们本来就不适合这个平台。可能是渠道质量变差了，也可能是目标人群定位偏了。

第二种可能，产品体验变了。来的人其实差不多，但产品或者服务体验变差了，用户来了之后觉得"不过如此"，就不再来了。可能是双11订单太多导致物流慢了，也可能是大促过后价格落差太大。

这两个方向分析思路完全不同，所以第一步要做的不是马上开始分析，而是先确定方向。怎么确定呢？用数据交叉验证。

如果是"来的人变了"，那我们把渠道拆开看，每个渠道的留存率应该跟去年差不多，但渠道结构变了，低质量渠道占比提升了。

如果是"产品体验变了"，那每个渠道的留存率都在下降，不只是结构问题。

两种情况的分析方法和解决方案都不一样，先判断清楚再往下走。

第二部分：按渠道拆开看

第一步要做的，就是按渠道把留存拆开。

我们假设拉取了各渠道的用户数和30天留存率，结果是这样的：

品牌广告渠道来了46.5万人，30天留存18%，和去年的19%差不多。这个渠道主要是在微博、小红书这些平台投品牌曝光广告，用户是主动搜索或者被品牌内容吸引来的，质量一直比较稳定。

信息流广告渠道来了108.5万人，30天留存6%，去年同期是12%，跌了一半。这个渠道是在抖音、快手、头条这些平台买量，通过算法推荐触达用户。

社交裂变渠道来了62万人，30天留存4%，去年是10%，跌得更狠。这个渠道是通过"邀请好友得红包"之类的裂变活动拉来的。

直播带货渠道来了93万人，30天留存5%。这是今年新增的重点渠道，双11期间在各大主播直播间做了大量投放。

再看各渠道的用户占比变化。去年的结构是：品牌广告40%，信息流30%，裂变30%。今年变成了：品牌广告15%，信息流35%，裂变20%，直播带货30%。

问题一下子就清楚了。

品牌广告渠道留存最高，但占比从40%骤降到15%。为什么？因为预算被挪走了。市场部把钱挪去投直播带货了，觉得直播带货能更快拉量冲GMV。

直播带货是新渠道，一下子抢了30%的份额，但留存只有5%。相当于用30%的新用户拖后腿，每100个新用户里有30个来自这个渠道，只能留下1.5个。

整体留存下滑，主要原因就是渠道结构变了。高质量渠道被压缩，低质量渠道疯狂扩张。

我们来验算一下。如果今年的渠道结构跟去年一样（品牌广告40%，信息流30%，裂变30%），按照今年各渠道的留存率算，整体留存应该是多少？

40%乘以18%，加上30%乘以6%，再加上30%乘以4%。等于7.2%加1.8%加1.2%，总共10.2%。

实际的9%比10.2%还低一点，说明除了渠道结构变化，各渠道本身的留存质量也有下降。但主要矛盾还是结构问题。

第三部分：深挖各渠道的问题

知道是渠道问题之后，还得继续往下挖。每个渠道留存下滑的原因可能不同，得分别诊断。

1、直播带货为什么留存这么低？

直播场景有几个特点。第一是冲动消费占比高。用户在直播间看到主播喊"三二一上链接"，价格又很诱人，很容易就下单了。但这种购买决策不是深思熟虑的，买完可能就后悔了，更别说复购。

第二是用户对价格极度敏感。来直播间的人就是冲着低价来的，他们不care是唯品会还是拼多多，谁便宜就在谁那买。这种用户天然留存就低。

第三是品牌认知弱。很多用户可能都不知道自己买的东西是从唯品会发货的，以为是主播自己的店。买完一次，压根没形成"我是唯品会用户"的认知，下次自然不会主动打开唯品会APP。

我们可以进一步验证这个判断。看看直播渠道来的用户，下单商品类型是什么。如果集中在低单价的爆款商品，比如9.9元的袜子、19.9元的T恤，那基本坐实了"薅羊毛型用户"的判断。

2、信息流渠道为什么留存也在跌？

信息流留存从12%跌到6%，跌了一半，这个问题也不小。

几个可能的原因需要排查。

第一种可能是投放素材变了。为了冲双11的量，广告素材可能更激进了，标题党横行。比如"1元抢iPhone"、"0元购物"之类的吸睛素材，点击率高，但吸引来的都是"占便宜"型用户，不是真正的目标客群。

我们可以拉一下11月份各条创意的点击率和对应用户的7天留存。如果发现点击率高的素材，对应用户留存反而低，那基本可以确认是素材问题。

第二种可能是定向人群松了。为了完成新用户目标，投放人群可能扩得太宽了。去年定向的是"25-40岁、一二线城市、有品牌消费偏好"的人群，今年可能把年龄放宽到18-50岁、城市扩展到三四线，精准度自然下降。

第三种可能是竞争加剧。双11期间所有电商都在疯狂抢人，用户可能同时被淘宝、京东、拼多多、唯品会的广告轰炸。能被抢来的人，很可能是"谁给优惠就去谁那"的摇摆用户，天然留存就低。

3、裂变渠道为什么也跌了？

裂变渠道从10%跌到4%，跌得最狠。

最可能的原因是裂变机制变了。我们需要对比今年和去年的裂变规则。

去年可能是"邀请1位好友，双方各得20元无门槛券"，规则简单，邀请门槛低，被邀请人得到的是实打实的优惠，有动力下单和复购。

今年可能变成了"邀请3位好友才能拆50元红包"，规则复杂了，用户为了拆红包可能随便拉3个人凑数。被拉来的人可能根本不想买东西，注册完就卸载了。

另外还要看裂变奖励的发放形式。如果今年把"无门槛券"改成了"满199减50券", 对于首单用户来说门槛太高了, 可能券过期了都没用掉, 自然不会再来。

第四部分：从用户画像维度看

除了渠道, 还可以从用户画像来分析。用户画像的变化往往能揭示更深层的问题。

拉取今年和去年双11新用户的基础画像数据做对比：

年龄分布方面, 去年25-35岁用户占60%, 18-24岁占20%, 35岁以上占20%。今年18-24岁用户占50%, 25-35岁占30%, 35岁以上占20%。

这个变化很关键。18-24岁的年轻用户有几个特点：消费能力相对有限, 很多还是学生或者刚工作；对品牌忠诚度低, 更容易被各种新平台吸引；决策周期短, 容易冲动消费但也容易放弃。

唯品会的定位是"品牌特卖", 核心用户应该是有一定消费能力、追求品牌但又想省钱的人群, 这个画像更匹配25-35岁的人群。年轻用户占比大幅提升, 说明拉新策略偏离了核心目标用户。

地域分布方面, 去年一二线城市用户占55%, 三四线城市占45%。今年三四线城市占60%, 一二线城市只占40%。

下沉市场的用户特点是价格敏感度高、品牌认知相对弱、更容易被低价吸引但对品牌忠诚度也低。当他们发现拼多多更便宜时, 可能就转投拼多多了。

设备类型方面, 也可以看看iOS用户和安卓用户的占比变化。通常iOS用户的消费能力和留存都比安卓用户高一些。如果今年安卓用户占比大幅提升, 也能部分解释留存下滑。

如果用户画像发生了这些结构性变化, 留存下滑就很好解释了。不是用户"质量变差了", 而是我们拉来的用户本来就不是目标客群。

第五部分：从产品体验维度看

如果渠道结构和用户画像都没太大变化, 那问题可能出在产品体验上。大促期间的体验问题尤其容易被忽视。

1、首单体验是否有明显恶化？

双11订单量暴增, 物流压力巨大。我们需要查看11月11日-20日期间的几个关键指标。

发货时效方面, 去年双11期间平均发货时间是2.3天, 今年是多少？如果变成了4-5天, 用户体验肯定下降。

物流投诉率方面, 物流相关的投诉是不是比平时高出很多？如果新用户第一单就等了一周才收到货, 他们大概率不会再来。

缺货率方面, 双11的爆款商品是不是很多都缺货了？用户下单发现发不了货, 或者收到"缺货退款"通知, 体验直接拉到谷底。

我们可以算一下首单体验对留存的影响。把新用户按首单配送时效分组：2天内收到货的、3-5天的、5天以上的, 分别看他们的30天留存率。如果2天内收到货的留存15%, 5天以上的留存只有5%, 那物流时效就是一个关键影响因素。

2、价格落差是否太大？

双11期间商品价格很低，过后价格恢复正常。如果用户双11花49元买了一件原价199元的衬衫，双11过后发现同款衬衫要169元，心理落差会很大。

他们会觉得"唯品会平时太贵了"，只有大促才值得来。这种用户的行为模式就是"大促来一次、平时不活跃"，30天留存自然很低。

这种情况下留存低不完全是因为用户质量差，也是大促定价策略导致的正常现象。但如果去年同样是大促，今年的价格落差比去年更大，那就需要审视定价策略了。

3、竞品是否在抢人？

双11期间用户可能同时下载了好几个电商APP。淘宝、京东、拼多多、唯品会可能都装了，哪个有活动就打开哪个。

大促结束后，手机上不需要这么多购物APP，用户会卸掉几个。唯品会可能就是那个被卸载的。为什么？可能是其他平台的日常优惠更吸引人，也可能是其他平台的商品更丰富，还可能只是其他平台的使用习惯更强。

这个问题可以通过竞品分析来验证。看看双11期间从唯品会流失的用户，有多少在其他电商平台变活跃了。

第六部分：给出建议

分析完原因之后，得给出能落地的建议。不是泛泛而谈，而是针对具体问题给出具体方案。

1、优化渠道结构，设置质量门槛

不要为了冲新用户数牺牲质量。直播带货可以继续做，但要设置门槛。比如只和留存率超过8%的主播继续合作，ROI低于1的主播果断停掉。

同时保证品牌广告渠道的预算，这是高质量用户的稳定来源。可以设定一个"渠道质量混合目标"，比如整体新用户里，30天留存超过10%的渠道必须占50%以上。

2、优化投放素材和定向策略

信息流素材要回归唯品会的核心价值——品牌特卖、正品保障、大牌折扣，而不是只喊"便宜"、"白菜价"。吸引来的用户要跟平台调性匹配。

定向人群要做负向过滤。比如剔除过去半年在拼多多高频消费的用户，这类用户对低价的追求太极端，可能不是唯品会的目标客群。同时收紧年龄和地域定向，回归核心人群。

3、做好新用户留存运营

新用户首次购买后要有系统的留存策略。次日推送欢迎消息和新人专属优惠；3天后推送个性化商品推荐；7天后如果还没复购，推送召回活动。

双11来的用户尤其需要在大促后做召回。因为他们习惯了大促价格，日常价格接受度低。可以设计"双11回归用户专属价"，给他们一个比日常价略低、但比大促价高的价格台阶，让他们逐渐适应。

4、关注并改善首单体验

双11的物流和客服压力要提前准备。跟物流合作方签好协议，保证大促期间的发货时效；提前备货，减少缺货概率；客服团队扩容，及时响应用户问题。

对于首单体验差的用户，比如物流延迟超过5天的，主动推送致歉和补偿优惠券，把流失风险降到最低。

知识点总结：

- 第一，分析新用户留存，可以从渠道、用户画像、产品体验三个维度切入，这三个维度层层递进。
- 第二，渠道结构变化是最常见的原因：高质量渠道被压缩、低质量渠道扩张，整体留存自然下滑。
- 第三，用户画像变化也很关键：年龄、地域、来源不同，留存特征就不同，不能把所有用户混为一谈。
- 第四，大促期间新用户天然留存偏低，不能只看增长数量不看质量，否则就是虚假繁荣。

追问：

如果发现主要是直播带货渠道的问题，但业务部门坚持要继续投放直播冲GMV，你会怎么和他们沟通？

【追问回答】

这种情况在公司里太常见了。业务部门有GMV压力，你作为数据分析师说"这个渠道质量不行"，他们肯定不爱听。这道题考的不只是分析能力，更是沟通和协作能力。数据分析师的价值不是"证明自己是对的"，而是"帮业务做出更好的决策"。如果分析结果不能影响决策，那分析就没有意义。

我的处理思路是：不要对抗，而是换位思考，找到双方都能接受的方案。

第一步：理解业务部门的真实诉求

业务部门坚持要投直播，背后一定有原因。不要急着否定，先搞清楚他们为什么这么坚持。

可能的原因有几种。

- 第一种是KPI压力。业务部门今年的目标是"新用户增长50%"或者"双11GMV达到XX亿"。直播渠道是能最快完成KPI的手段。如果砍掉直播，他们担心完不成目标。
- 第二种是老板指令。可能是VP或者CEO说了"今年要重点布局直播"，业务部门只是在执行上级的战略意图。他们想停也停不了。
- 第三种是信息不对称。业务部门可能只看到了直播渠道带来了多少GMV，没看到这批用户的后续留存和复购数据。他们不是不讲理，是掌握的信息不全面。

搞清楚原因之后，沟通方式就不一样了。如果是KPI压力，就帮他们想怎么在完成KPI的同时兼顾质量；如果是老板指令，可能要推动更高层面的讨论；如果是信息不对称，把数据摊开来看就行。

第二步：用数据说话，但不是指责

不是说"直播渠道不好，你们别投了"，而是把账算清楚，让业务自己判断。

我会准备一个ROI对比分析。

直播渠道的情况是这样的：获客成本假设是35元每人，30天留存5%，按照历史数据推算，这批用户1年的LTV（客户生命周期价值）大概是42元。ROI是42除以35等于1.2，勉强打平，稍微有点赚。

品牌广告渠道的情况是：获客成本假设是60元每人，比直播贵很多。但30天留存18%，1年LTV推算是180元。ROI是180除以60等于3.0，是直播渠道的2.5倍。

然后我会这么说："从短期看，直播渠道获客成本低，GMV转化快，完成今年的目标没问题。但从长期看，直播渠道的用户价值不到品牌渠道的四分之一。如果我们长期重仓直播，明年的复购GMV会有很大缺口。"

数据摆出来，结论让业务自己得出，比你直接说"直播不行"有说服力得多。

第三步：承认双方的诉求都有道理

这一点很重要。业务部门要GMV，这是他们的职责所在，完全合理。如果你表现出"你们就知道冲量，不管质量"的态度，沟通就没法进行下去了。

我会这么说："我完全理解今年GMV目标的压力，直播渠道确实是能快速拉量的有效手段，这一点没有问题。我想讨论的是，有没有可能在完成今年目标的同时，也为明年的复购打下基础？"

把问题从"要不要投直播"转变成"怎么投直播能兼顾短期和长期"，双方就有共同讨论的基础了。

第四步：提出折中方案

纯粹的分析报告没有用，要给出能落地的方案。

我会提出几个建议。

第一个建议是控制直播渠道的占比上限。直播渠道可以继续投，但占新用户总量的比例控制在30%以内，不要无限扩张。剩下的70%必须来自品牌广告和精准信息流等高质量渠道。这样既能享受直播渠道的拉新效率，又不会让整体用户质量跌得太狠。

第二个建议是设置直播主播的质量门槛。不是所有主播都值得投。我们可以根据历史数据，筛选出用户留存率超过8%的优质主播，只跟这些主播合作。留存率低于5%的主播，ROI很可能是负的，果断停掉。

第三个建议是对直播渠道用户做强化留存运营。既然知道这批用户的留存天然偏低，就要投入更多资源去做留存。比如首单后立刻推送SVIP会员权益，用会员锁定用户；或者设计"直播用户专属复购券"，给他们一个回来的理由。

第四个建议是建立分渠道的效果追踪机制。以后不只是看每个渠道带来了多少新用户，还要持续追踪30天留存、90天留存、6个月复购GMV。把这些指标纳入渠道评估体系，让业务部门在做投放决策时有更全面的信息。

第五步：如果还有分歧，建议做测试

如果业务部门还是坚持要大幅提升直播投放比例，不要硬怼，建议做个测试。

我会这么提议："我们可以做个AB测试。选两个用户规模相当的城市，A城市按照你们的方案，直播渠道占比提到50%；B城市保持现有结构，直播占30%。3个月后对比两个城市的新用户数、整体留存率、复购GMV。用数据来验证哪个方案更优。"

测试的好处是：第一，双方都有机会证明自己的判断；第二，即使测试结果不利于某一方，对方也更容易接受，因为是数据说话，不是人在争论；第三，即使大规模铺开了某个方案，我们也知道备选方案的效果，随时可以调整。

第六步：把问题升级到更高层面讨论

如果测试方案业务也不接受，坚持要全面铺开直播投放，那可能需要把这个问题升级。

不是去"告状"，而是推动一个跨部门的讨论。因为这涉及到公司层面的战略取舍：短期GMV和长期用户资产，哪个更重要？

我会建议组织一个讨论会，把业务部门、用户运营、财务都拉进来，把数据和分析摊开。如果公司的战略就是"先冲规模，不计短期盈利"，那直播高投放也是合理的选择。如果公司更看重健康增长，那就需要调整渠道策略。

这种决策不应该由数据分析师或者某个业务部门单独做，而是需要更高层面的对齐。

关键心法总结

处理这种跨部门分歧，核心是不要对立，而是换位思考。

第一，先理解对方为什么这么想。业务有业务的压力和逻辑。

第二，用数据说话，但不要用数据打脸。数据是为了帮助决策，不是为了证明谁对谁错。

第三，提出建设性的方案，而不是只说"不行"。光批评不给方案，等于没说。

第四，把分歧转化成共同的问题。不是"你们想投直播，我不同意"，而是"我们怎么既完成GMV目标，又保证用户质量"。

第五，实在谈不拢就测试，用数据说话，比争论更有效率。

归根结底，数据分析师的价值不只是出分析报告，更是推动分析结果转化为更好的业务决策。如果你的分析很准确但没人听，那分析的价值就是零。

题目 66

为什么调研"成功案例"做出来的策略往往会翻车？数据分析中最容易踩的幸存者偏差陷阱有哪些？

解答

很多公司喜欢做"成功案例研究"：找几个业绩最好的销售问问他们怎么干的；找几个留存最高的用户看看他们有什么特征；找几个增长最快的产品分析分析他们的策略。

然后把这些"成功经验"总结成方法论，写进培训手册，全公司推广。

听起来挺有道理对吧？成功者肯定做对了什么，我们照着学就行了。但这里面有个巨大的坑，叫幸存者偏差。

不夸张地说，这是数据分析中最常见、最隐蔽、也最容易让人翻车的陷阱之一。

第一部分：幸存者偏差到底是啥

说白了就是：你只看到了"活下来"的，没看到"死掉"的。

最经典的例子是二战飞机的故事。

当时美国军方想给轰炸机加装甲，保护飞行员减少伤亡。他们收集了所有返航飞机的数据，仔细统计弹孔分布位置。数据显示，机翼和机身中弹最多，于是军方打算在这些地方加装甲。

但有个统计学家叫亚伯拉罕·沃尔德提出了不同意见：慢着，我们看到的都是飞回来的飞机。那些被打中引擎的飞机呢？它们压根没回来啊。

机翼和机身中弹多，恰恰说明这些位置即使被打中也能飞回来。而那些中弹后没回来的飞机，很可能是被打中了引擎。

所以真正该加装甲的是引擎，而不是那些"中弹但还能飞回来"的位置。

这就是幸存者偏差的本质：你的样本里只有成功者或幸存者，失败者根本不在样本里，所以你得出的结论是有偏的，甚至是完全相反的。

这个陷阱危险的地方在于：数据看起来是客观的，分析看起来是严谨的，结论看起来是合理的。但因为样本不完整，整个分析从一开始就错了。

第二部分：工作中常见的幸存者偏差陷阱

在实际工作中，这个坑到处都是。我挑几个最常见的场景给你拆解。

陷阱一：只分析高价值用户

这是最典型的幸存者偏差场景。

业务部门说："我们想知道怎么让用户变成高价值用户。"于是你拉取了所有高价值用户的数据，分析他们的行为路径、注册来源、使用时长、购买品类.....然后总结出一套"高价值用户养成路径"。

问题来了：那些走了同样路径却没变成高价值用户的人呢？你压根没看到他们。

举个具体例子。你发现高价值用户有一个共同特征：他们都在注册7天内完成了首单。于是你建议产品团队强化7天内首单的引导。

但如果你去看那些没变成高价值用户的人，可能发现他们中也有60%在7天内完成了首单。只是他们买完一次就走了，没有复购。

这说明"7天内首单"只是高价值用户的一个"共性"，不是他们变成高价值用户的"原因"。真正的区分因素可能是别的，比如首单购买的品类、首单的客单价、或者注册来源。

陷阱二：只分析留存用户

你想知道用户为什么留存，于是去看留存用户都做了什么：他们看了哪些内容、用了哪些功能、买了哪些商品。

但你没看流失用户。也许流失用户也做了同样的事情，只是他们还是走了。

我见过一个真实案例。某内容平台分析留存用户，发现他们平均每天刷15条视频。于是产品团队优化推荐算法，想让更多用户刷够15条。

结果留存率没提升，反而略有下降。

后来复盘发现：刷15条不是留存的原因，而是留存的结果。用户因为喜欢这个平台才刷这么多，不是刷这么多才喜欢。

而且流失用户里也有不少每天刷10+条的，只是他们刷完就走了。真正影响留存的是"有没有关注喜欢的创作者"，不是"刷了多少条"。

正确的做法是：对比留存用户和流失用户的行为差异，找到两者之间真正的分界线，那才可能是影响留存的关键因素。

陷阱三：只学习成功产品

公司想做新业务，于是研究了市场上几个成功产品，总结它们的共同策略：都做了社交分享、都有积分体系、都有会员等级.....

然后给新产品也照搬这些功能。

但那些失败的产品呢？可能它们用了一模一样的策略，只是死了。你看不到它们，是因为死掉的产品不会被报道，不会被研究，不会被写进商业案例。

媒体和商学院喜欢写成功故事，因为成功故事有传播价值。失败故事没人爱看，所以失败的案例就被选择性地遗忘了。

结果就是：你以为成功产品的共同点是成功的原因，其实可能只是运气、时机、资源。那些共同点对成功既不是充分条件，也不是必要条件。

陷阱四：只看转化用户的行为

你分析了完成购买转化的用户，发现他们平均浏览了5个商品页。于是你向产品团队建议：优化推荐逻辑，引导用户多浏览商品！

但问题是：那些浏览了5个商品页但没转化的用户呢？你没统计。

如果这批人也很多，那"浏览5个商品页"可能根本不是转化的关键因素。可能浏览3个就够了，也可能浏览10个也不会转化。

你只看转化用户，得出的结论是"转化用户浏览了5个商品页"，这是一个事实。但你想说的结论是"浏览5个商品页会提升转化率"，这是一个因果判断。两者之间差了十万八千里。

陷阱五：只调研满意用户

这个陷阱更隐蔽一些。

公司做用户调研，发了一份问卷，收回了1000份回复。结果显示满意度很高，9成用户表示满意。

但问题是：那些不满意的用户呢？他们可能早就流失了，根本不会看到你的问卷；或者看到了也懒得填，因为他们已经不在乎这个产品了。

愿意花时间填问卷的，本身就是对产品有好感的用户。你的样本天然就是有偏的。

这种情况下，高满意度可能是一个危险信号，因为它掩盖了真实的问题。

第三部分：怎么避免踩坑

了解了陷阱之后，关键是怎么避免。我总结了四个原则：

原则一：永远问一句"失败者在哪里"

这是最重要的思维习惯。

每当你分析成功案例的时候，强迫自己同时去看失败案例。

不要只问"成功者有什么共同点"，要问"成功者和失败者的区别是什么"。

如果成功者有的东西，失败者也有，那这个东西就不是成功的原因。只有成功者有但失败者没有的东西，才可能是关键因素。

这个思维方式听起来简单，但在实际工作中很容易被忽略。因为失败者的数据往往更难获取，或者根本没人关心。但正是这些被忽略的数据，才能帮你避免幸存者偏差。

原则二：用对照组的思维

做分析别只盯着一个群体。要有对照组。

分析高价值用户时，同时拉一批低价值用户做对比。看哪些特征是高价值用户独有的，哪些是所有人都有的。只有独有的特征才可能是关键因素。

这个方法叫"差异分析"或者"对照分析"。在医学研究里，这叫"病例对照研究"：你想知道什么因素导致某种疾病，就找一批患病的人和一批没患病的人，对比他们在各种因素上的差异。

数据分析也是同样的逻辑。

具体操作上，对照组的选择很关键。对照组应该和目标组在其他方面尽量相似，只在你关心的那个结果上不同。比如分析高价值用户时，对照组应该是"同时期注册、同渠道来源、但最终没变成高价值用户"的人，而不是随便拉一批低活跃用户。

原则三：警惕"事后归因"

很多成功经验都是事后总结的。成功了之后，怎么解释都有道理。

"我们成功是因为注重用户体验"——但失败的公司难道不注重用户体验吗？可能人家也很注重，只是没成功。

"我们成功是因为快速迭代"——但失败的公司难道不快速迭代吗？可能人家迭代得更快，只是方向错了。

"我们成功是因为创始人有格局"——这个更没法证伪了。什么叫有格局？成功了就有格局，失败了就没格局？

所以对事后归因要保持怀疑，多问一句"失败的那些人是不是也这么做了"。如果失败者也这么做了，那这个因素就不是成功的原因。

原则四：用实验验证因果

如果通过数据分析得出了一个因果假设，最靠谱的验证方法是做AB实验。

比如你觉得"用过某功能的用户留存更高"，那就设计一个实验：

实验组的新用户，在入门引导时被强引导使用这个功能。对照组的新用户，保持原有流程，不做额外引导。

跑一段时间后，看实验组的留存率是不是比对照组高。

如果实验组确实高，说明这个功能对留存有因果作用。如果没区别，说明你之前的分析有幸存者偏差——"用过功能的用户留存高"只是相关关系，不是因果关系。可能是留存高的用户才有动力去探索功能，而不是用功能让他们留存高。

第四部分：几个真实场景的深度拆解

让我用几个更详细的例子，帮你加深理解。

例子1：流失用户召回的幸存者偏差

有个电商平台想提升流失用户召回率。他们分析了所有被成功召回的用户（收到召回短信后30天内重新活跃的用户），发现一个共同特征：这些用户在流失前都购买过母婴类商品。

于是运营团队决定：给母婴用户发专属召回短信，重点推母婴促销活动。

看起来很有道理对吧？数据显示成功召回的用户都买过母婴商品，那我们就重点召回母婴用户。

但问题来了：那些收到短信但没被召回的用户呢？可能他们中也有很多买过母婴商品。

正确的分析方法是：把收到召回短信的用户分成两组——被召回的和没被召回的。然后对比这两组在各种特征上的差异。

做完这个对比分析后，可能发现一个不同的结论：真正影响召回成功率的因素不是"买没买过母婴商品"，而是"流失前最后一单距今多久"。

流失不超过60天的用户，召回率是25%；流失超过90天的用户，召回率只有3%。而母婴用户在被召回组和未召回组的比例差不多，都是40%左右。

这说明"母婴用户"只是成功召回用户的一个特征，不是被召回的原因。真正应该优先召回的是"流失时间短"的用户，而不是"母婴用户"。

例子2：销售话术研究的幸存者偏差

某公司想总结出一套"成功销售话术"。他们访谈了业绩排名前10%的销售，问他们平时怎么跟客户沟通的。

这些Top销售有一个共同特点：他们都很喜欢跟客户聊个人生活，比如孩子上学、周末安排、兴趣爱好。他们说这样能拉近关系、建立信任。

于是公司把"聊私人生活"写进了销售培训手册，要求所有销售学习。

结果呢？推广几个月后，整体销售业绩没有明显提升。

后来做了一个更全面的分析：不只看Top销售，也看业绩中等和业绩垫底的销售。结果发现，聊私人生活这件事，各个业绩层的销售都在做。Top销售在做，业绩差的销售也在做。

真正区分Top销售和普通销售的不是"聊不聊私人生活"，而是"产品知识的专业度"和"客户需求的挖掘能力"。Top销售能快速识别客户的真实需求，并精准匹配产品卖点；普通销售则是泛泛地介绍产品，缺乏针对性。

"聊私人生活"只是Top销售的一个习惯，不是他们成功的原因。可能恰恰是因为他们专业能力强，才有底气花时间聊闲天。

例子3：爆款产品功能分析的幸存者偏差

公司想做一款新的社交产品。产品经理研究了市场上几个成功的社交APP，发现它们都有"附近的人"功能。于是他决定，新产品也要做这个功能，而且要重点做。

但问题是：有"附近的人"功能但没火的社交产品可能更多。你只是没看到它们，因为它们已经死了，应用商店都搜不到了。

幸存下来的社交产品确实都有"附近的人"功能。但这可能是"活下来的社交产品都会加这个功能"，而不是"加了这个功能就能活下来"。

更合理的分析方法是：找到过去几年所有做过社交产品的公司（包括成功的和失败的），看看有"附近的人"功能的产品，成功率是否比没有这个功能的产品更高。

如果有和没有这个功能的产品，成功率差不多，那这个功能就不是成功的关键因素。

当然，这种分析在实际操作中比较难做，因为失败产品的数据很难获取。但至少你要有这个意识：只看成功案例得出的结论可能是错的。

知识点总结：

第一，幸存者偏差的本质是样本偏差：你只看到了成功者或幸存者，失败者不在你的样本里，所以结论是有偏的。

第二，最常见的陷阱场景包括：只分析高价值用户、只分析留存用户、只学习成功产品、只看转化用户、只调研满意用户。

第三，避免幸存者偏差的四个原则：永远问"失败者在哪里"、用对照组思维、警惕事后归因、用实验验证因果。

第四，核心认知要记住：成功者的共性不等于成功的原因。"相关"不等于"因果"。

追问：

如果你在分析中发现了一个"成功用户的共同特征"，你会用什么方法来验证这个特征到底是不是成功的原因？

【追问回答】

这是一个非常实际的问题。在日常工作中，我们经常会发现成功用户的某些共同特征，但到底是不是"原因"，需要用科学的方法来验证。

我会按照"由浅入深、由快到慢"的顺序，用四种方法来验证。

第一种方法：加上失败者做对比分析

这是最快、最基础的方法。

我发现成功用户有这个特征，那我首先要去看失败用户有没有这个特征。

举个具体例子。假设我分析发现，高付费用户（月消费超过500元）有一个共同特征：他们都在注册30天内领取过会员优惠券。看起来"领券"和"高付费"之间有关联。

但先别急着下结论。我需要去看低付费用户（月消费低于100元）是什么情况。

如果高付费用户中领过券的占85%，低付费用户中领过券的也有80%，那这个特征就不是关键因素。两个群体在这个特征上的分布太接近了，区分不出谁是高付费谁是低付费。

但如果高付费用户中领过券的占85%，低付费用户中领过券的只有30%，差距很大，那这个特征就可能是关键因素，值得进一步验证。

这个方法的关键是：不只看特征在成功用户中的分布，还要看它在失败用户中的分布。只有两者差异明显，才说明这个特征有区分度。

统计学上，可以用卡方检验或者Fisher精确检验来判断这个差异是否具有统计显著性。

第二种方法：控制其他变量，做多因素分析

对比分析能告诉你这个特征有没有区分度，但可能存在混杂因素。

什么意思呢？可能成功用户有这个特征，是因为他们还有其他特征。这个特征只是其他特征的"伴随现象"，不是独立的影响因素。

举个例子。你发现高付费用户中"领过券"的比例高。但仔细一看，领券的用户大多是25-35岁的女性用户，而这个年龄段的女性本来就是平台的高付费核心人群。

也就是说，可能不是"领券"导致高付费，而是"25-35岁女性"既容易领券、又容易高付费。领券只是一个表面现象。

怎么排除这种干扰呢？用多元回归分析或者逻辑回归。

把"年龄"、"性别"、"注册时长"、"注册渠道"这些因素都放进模型，控制住它们的影响，然后看"领券"这个因素单独对"高付费"的影响有多大。

如果控制了其他变量之后，"领券"对"高付费"仍然有显著的正向影响，那它可能真的是一个独立因素。

如果控制了其他变量之后，"领券"的影响消失了或者变得很弱，那说明它只是跟其他因素相关，本身不是原因。

第三种方法：做时序分析，检查因果方向

即使通过对比分析和多因素分析，确认这个特征跟成功之间有独立的关联，也还不能下因果结论。因为关联可能有两个方向：

A导致B，或者B导致A。

回到领券的例子。可能不是"领券导致高付费"，而是"高付费意愿导致领券"。

那些本来就打算花钱的用户，更有动力去找优惠券，所以他们既领了券、又消费了很多。但领券只是一个伴随行为，不是驱动消费的原因。

怎么判断因果方向？看时间顺序。

我会把用户的行为按时间线排列：注册时间、领券时间、首次付费时间、变成高付费的时间。

如果大多数用户是"先领券、后变成高付费"，而且领券和变成高付费之间有合理的时间间隔（比如领券后7天内首次大额消费），那"领券导致高付费"的假设更可信。

如果大多数用户是"先已经消费很多了，然后才领券"，或者"领券和消费几乎同时发生"，那"领券"可能只是高付费用户的一个伴随行为，不是原因。

另外还可以做一个更细致的分析：看看领券前后用户的消费行为有没有明显变化。如果领券后消费明显增加，支持因果假设；如果领券前后消费差不多，说明领券可能不是驱动因素。

第四种方法：设计AB实验验证因果

前面三种方法都是基于历史数据的分析，都存在一个根本性的问题：无法完全排除未观测到的混杂因素。

最靠谱的因果验证方法，是做随机对照实验，也就是AB实验。

如果我假设"领券导致高付费"，我可以设计这样一个实验：

把新注册的用户随机分成两组。实验组的用户在注册后会收到一个明显的弹窗，引导他们领取会员优惠券。对照组的用户不会收到这个弹窗，一切保持正常流程。

关键词是"随机分组"。随机分组保证了两组用户在所有特征上（无论观测到的还是未观测到的）都是平均分布的。两组之间唯一的系统性差异就是"有没有被引导领券"。

实验跑一段时间后（比如60天），对比两组用户的付费情况：付费转化率、人均消费金额、高付费用户比例。

如果实验组的这些指标显著高于对照组，那就可以下结论："引导领券确实能提升付费"，因果关系成立。

如果两组没有显著差异，那说明之前的分析有幸存者偏差——"领过券的用户付费高"只是相关关系，不是因果关系。可能是愿意付费的用户本来就会去领券，而不是领券让他们愿意付费。

AB实验是因果推断的金标准。但它也有局限：需要时间成本、需要一定的样本量、有些场景不适合做实验（比如不能随机给用户涨价）。所以在实际工作中，通常是先用前三种方法快速筛选和验证假设，对于重要的假设再用AB实验做最终确认。

总结一下验证流程

如果我在分析中发现了一个"成功用户的共同特征"，我会按这个顺序来验证：

第一步，先做对比分析，看这个特征在成功用户和失败用户中的分布差异。如果差异很小，基本可以排除，不用继续了。

第二步，如果差异明显，做多因素分析，控制其他变量，看这个特征是否有独立的影响。如果控制变量后影响消失，说明它只是其他因素的伴随现象。

第三步，如果多因素分析显示仍有独立影响，做时序分析，确认因果方向。是这个特征导致成功，还是成功导致这个特征？

第四步，如果前三步都支持因果假设，而且这个发现对业务足够重要，设计AB实验做最终验证。

这套流程从快到慢、从粗到细，能帮你在有限的时间和资源下，尽可能准确地判断一个特征是否真的是成功的原因。

题目 67

叮咚买菜发现2025年Q4某城市的用户月均下单频次从4.2次降到了3.1次，但该城市用户数和GMV都在增长，可能是什么原因？这个下降是好事还是坏事？

解答

这道题乍一看挺矛盾的：下单频次降了，但用户数和GMV都在涨？这怎么可能？

但仔细想想，这几个指标的关系没那么简单。这道题的核心其实是考你两个能力：一是指标拆解的能力，二是判断指标变化好坏的能力。

第一部分：先把指标关系捋清楚

GMV可以用一个经典公式来拆解：

$$GMV = \text{用户数} \times \text{人均下单频次} \times \text{客单价}$$

这三个因素是乘法关系，不是加法关系。这意味着什么？意味着一个因素下降，只要其他因素涨得够多，整体结果还是可以涨的。

我们用具体数据来模拟一下：

假设Q3的情况是：用户数10万人，人均下单4.2次，客单价80元。那么GMV就是10万乘以4.2乘以80，等于3360万。

Q4的情况变成了：用户数15万人，人均下单3.1次，客单价90元。GMV就是15万乘以3.1乘以90，等于4185万。

你看，虽然下单频次从4.2降到了3.1，跌了26%。但用户数从10万涨到15万，涨了50%；客单价从80涨到90，涨了12.5%。三个因素综合作用下，GMV反而涨了24%。

这个计算告诉我们一个重要结论：单看某一个指标的变化是不够的，要看整体的乘法效果。

频次下降不一定是坏事，关键要看背后是什么原因，以及其他指标是怎么配合的。

第二部分：频次下降的几种可能原因

下单频次下降，可能的原因有很多种。不同原因代表不同的业务含义，有的是好事，有的是坏事，有的是中性的。我们来一个个拆解。

可能性一：用户结构变了，新用户占比提高了

这是最常见的原因。

新用户刚刚注册，对平台还不熟悉，还没养成在这个平台买菜的习惯。他们的下单频次天然就比老用户低。

假设老用户的月均下单频次是5次，新用户只有2次。如果Q3的用户里新用户占20%、老用户占80%，整体平均频次就是5乘以0.8加上2乘以0.2，等于4.4次。

到了Q4，因为做了大量拉新，新用户占比提高到50%，老用户占50%。即使两类用户各自的频次没变，整体平均频次就变成了5乘以0.5加上2乘以0.5，等于3.5次。

你看，频次从4.4降到3.5，纯粹是因为用户结构变了，不是因为用户行为变差了。

这种情况下，频次下降不是坏事，而是用户增长的正常伴生现象。只要新用户后续能被培养成高频用户，这个下降是可以接受的。

可能性二：客单价提升了，用户消费行为升级了

如果客单价明显提升，用户可能因为"一次买够"而减少了下单次数。

以前用户的习惯可能是：每次买50块钱的菜，一周买两次，月消费400块。现在变成了：每次买100块钱的菜，一周买一次，月消费400块。

下单频次从每周2次变成每周1次，看起来降了50%。但月消费金额没变，用户只是换了一种消费方式。

这种情况下，频次下降可能还是好事。为什么？因为每一单都有固定的配送成本。用户一次买100块比分两次各买50块，配送成本降低了一半，但贡献的GMV是一样的。平台的履约效率提升了，利润率可能还会提高。

可能性三：用户需求饱和或被竞品分流

用户对买菜的需求是有上限的。一个三口之家，每月买菜的预算可能就是1500-2000块，不会因为平台多了就多吃。

如果用户已经在叮咚买够了，或者开始去盒马、美团买菜、朴朴分散购买，在叮咚这边的下单频次自然会降。

这种情况就需要警惕了，因为可能意味着用户粘性在下降、份额在被竞品蚕食。

怎么判断是不是这种情况？看留存率和人均消费金额。如果留存率在下降，或者人均消费金额（频次乘以客单价）也在下降，那大概率是被分流了。

可能性四：大促活动的影响，Q3是异常高值

如果Q3刚好有大促活动，比如周年庆、618、或者平台自己的补贴季，用户趁着优惠多下了几单，Q3的频次就被人为拉高了。

到了Q4，大促结束，回归正常，频次就显得低了。

这种情况下，Q4的频次才是真实水平，Q3是被大促抬高的异常值。频次下降只是回归正常，不代表业务变差。

怎么验证这个假设？去看Q3和Q4的促销活动力度对比，再看看Q3期间有没有异常的流量和订单高峰。

可能性五：季节性因素

Q4是10-12月，正好是秋冬季节。买菜的习惯可能和春夏天不一样。

冬天很多人可能更倾向于囤货，一次性多买一些耐储存的蔬菜和肉类，减少下单次数。而夏天因为食材不易保存，可能更倾向于少量多次购买。

这种季节性波动是正常现象，不代表业务出了问题。可以看看去年同期的数据，对比一下Q3到Q4的频次变化是否符合季节性规律。

第三部分：怎么判断频次下降是好事还是坏事

知道了可能的原因之后，关键是怎么判断这个下降到底是好是坏。我会从四个维度来综合判断。

维度一：拆分新老用户分别看频次变化

这是最关键的一步。

把用户按注册时间分成两组：老用户（比如注册超过6个月）和新用户（注册不足6个月）。分别计算两组的月均下单频次，看Q3到Q4各自的变化。

如果老用户的频次稳定甚至上升，只是因为新用户占比高拉低了整体平均值，那就不用担心。这说明存量用户的质量没问题，增量用户需要时间培养。

如果老用户的频次也在明显下降，那就需要深入排查了。老用户是平台的核心资产，他们的行为变化往往预示着更深层的问题。

维度二：看人均消费金额（ARPU）

频次降了，但人均消费金额有没有降？

人均消费金额等于下单频次乘以客单价。这个指标比单纯的频次更能反映用户的真实消费价值。

假设Q3的人均消费是4.2次乘以80元等于336元，Q4变成3.1次乘以90元等于279元。人均消费降了17%，这就比较严重了。

但如果Q4变成3.1次乘以110元等于341元，人均消费反而涨了，那频次下降就不是问题，用户只是换了一种消费方式。

维度三：看留存率

频次下降的同时，用户的留存率是什么情况？

把当月活跃用户（至少下单1次）的比例计算出来，看Q3到Q4的变化。

如果留存率也在下降，比如从60%降到50%，那说明用户真的在流失。频次下降只是流失的一个表现，更严重的问题是用户在离开。

如果留存率稳定，只是单用户的下单次数减少了，情况可能没那么糟。至少用户还在，只是买得少了。

维度四：看竞品动态

这个城市的竞品有没有在发力？

去查一下盒马、美团买菜、朴朴、永辉生活在这个城市的动态。有没有开新仓？有没有大力补贴？有没有推出新的会员政策？

如果竞品在这个时间段密集发力，那用户被分流的可能性很大。这种情况下，频次下降是一个危险信号。

可以做一个竞品对标分析：看看我们流失的用户有没有在竞品那边活跃。如果有数据渠道能获取这个信息，会非常有价值。

第四部分：如果是我会怎么具体分析

说了这么多方法论，落到实操层面，我会按这个顺序来分析：

第一步：拆分用户群体看频次变化

把用户按多个维度分组，看每个群体的频次变化：

按用户生命周期分：新用户（0-3个月）、成长期用户（3-6个月）、成熟用户（6-12个月）、老用户（12个月以上）。哪个阶段的用户频次在降？

按消费层级分：高价值用户（月消费超过800元）、中等用户（300-800元）、低价值用户（低于300元）。高价值用户的频次如果在降，那就是大问题。

按活跃程度分：重度用户（月下单超过8次）、中度用户（4-8次）、轻度用户（1-3次）。重度用户的频次变化尤其值得关注，他们是平台的铁粉。

通过这种拆分，可以精准定位是哪类用户在降，而不是笼统地说"频次降了"。

第二步：计算客单价和人均消费金额的变化

把Q3和Q4的客单价拉出来对比。如果客单价明显提升，频次下降可能是正常的"合并购买"行为。

再算人均消费金额的变化。人均消费金额是判断用户价值的核心指标，比频次更重要。

第三步：分析漏斗数据

用户行为漏斗的各个环节有没有变化？

打开率：用户打开APP的频次有没有降？如果打开率也在降，说明用户连浏览的兴趣都没了。

加购率：用户把商品加入购物车的比例有没有变？如果打开了但加购少了，可能是商品不吸引人了。

转化率：加入购物车后实际下单的比例有没有变？如果加购了但不下单，可能是价格或者凑单门槛的问题。

通过漏斗分析，可以定位问题出在哪个环节：是"不来了"、"来了但不感兴趣"、还是"感兴趣但不买"。

第四步：做用户调研

如果数据层面找不到明确原因，就做用户访谈。

找一批频次下降明显的用户（比如Q3月均下单5次以上，Q4变成3次以下），做深度访谈。问他们：

最近买菜的习惯有没有变化？是买得少了还是去别的平台买了？

如果去了别的平台，是什么原因？价格？配送速度？商品品质？品类丰富度？

对叮咚有什么不满意的地方？有什么改进建议？

用户的直接反馈往往能发现数据看不到的问题。

第五步：做竞品对标分析

去看看竞品在这个城市的动作。

美团买菜有没有新开仓？盒马有没有做大促？朴朴有没有扩品类？

如果竞品在发力，再结合我们的用户流失数据，就能判断是不是被分流了。

第五部分：频次下降到底是好事还是坏事

总结一下判断逻辑：

场景一：频次下降是好事或中性

如果满足以下条件，频次下降可能是好事或者中性：

- 第一，主要是新用户占比提高导致的整体平均值下降，老用户频次稳定。
- 第二，客单价明显提升，人均消费金额没降甚至上升。
- 第三，用户留存率稳定，没有明显流失。
- 第四，没有竞品大规模分流的迹象。

这种情况下，频次下降是用户增长或消费升级的正常表现。用户数和GMV都在涨，说明业务整体是健康的。

场景二：频次下降是坏事

如果出现以下情况，频次下降就是危险信号：

- 第一，老用户的频次也在明显下降。
- 第二，人均消费金额在下降。
- 第三，用户留存率在下滑。
- 第四，竞品在这个城市大力发力。

这种情况下，虽然短期GMV还在涨（靠用户数增长撑着），但长期可能会出大问题。用户粘性在下降，核心用户在流失，这是业务衰退的前兆。

所以单看"频次下降"一个数字是没意义的，得结合用户结构、消费金额、留存率、竞品动态来综合判断。数据分析的价值不在于计算出某个数字，而在于理解这个数字背后的业务含义。

知识点总结：

- 第一，指标拆解的思维：GMV等于用户数乘以频次乘以客单价。一个指标下降，可能被其他指标的上升所弥补，要看整体效果。
- 第二，用户分层分析：新老用户、高低价值用户的行为模式可能完全不同。整体平均值的变化可能是结构变化导致的，不代表每类用户都在变。
- 第三，多维度交叉验证：判断一个指标变化是好是坏，不能只看这一个指标，要结合用户结构、消费金额、留存率、竞品动态等多个维度综合判断。
- 第四，抓住核心问题：频次下降背后的核心问题是"用户结构变化"还是"用户行为变化"？前者可能是好事，后者需要警惕。

追问：

如果进一步分析发现老用户的下单频次也在下降，你会从哪些方向去排查原因？

【追问回答】

如果老用户的频次也在下降，那问题就比较严重了。不能用"新用户拉低平均值"来解释，得深入排查真正的原因。老用户是平台的核心资产，他们的行为变化往往预示着更深层的问题。我会从以下几个方向系统性地排查。

第一个方向：先排除"正常"的可能性

在怀疑出了问题之前，先排除一些正常的情况。

首先看客单价。把老用户的客单价和人均消费金额拉出来。如果客单价涨了、人均消费金额没变或者还涨了，那可能只是消费方式变了，问题不大。

比如老用户Q3的情况是：月均下单5次，客单价70元，人均消费350元。Q4变成：月均下单3.5次，客单价100元，人均消费350元。频次降了30%，但消费金额没变，说明用户只是把小单合并成大单了，本质上没有流失。

如果人均消费金额也在下降，比如从350降到280，那就是真的出问题了，需要继续排查。

其次看季节性。对比去年同期，Q3到Q4的频次变化是否存在类似的季节性规律。如果去年也是类似的下降幅度，那可能是正常的季节波动。

如果排除了这两个因素，频次下降还是无法解释，那就要认真查问题了。

第二个方向：看竞品动态

这是最重要的外部因素。

我会去调查这个城市的竞品近期有什么动作：

盒马方面：有没有新开门店或前置仓？有没有推出新的会员权益？比如88VIP的生鲜折扣有没有加大力度？

美团买菜方面：有没有在这个城市扩大覆盖？配送时效有没有提升？有没有大额补贴？

朴朴超市方面：有没有进入这个城市或者扩大范围？他们的生鲜品质和价格是不是更有竞争力？

永辉生活、叮咚买菜的其他竞品：有没有什么新动作？

如果竞品在这个时间段密集发力，老用户被分流的可能性很大。这种情况下，我们需要做竞品对标分析，找出我们在哪些方面被竞品超越了。

更进一步，如果有数据渠道，可以看看我们流失的老用户有没有在竞品那边下单。比如通过用户调研直接问"最近有没有用其他买菜APP"，或者通过第三方数据分析竞品的用户增长情况。

第三个方向：看叮咚自己有没有变化

很多时候问题不在外部，在内部。我会排查叮咚最近有没有什么变化影响了用户体验。

产品层面：

配送时效有没有变化？以前30分钟达，现在变成1小时了吗？配送体验是生鲜电商的核心竞争力，时效变差会直接影响用户粘性。

商品品类有没有调整？是不是砍掉了一些品类？热门商品是不是经常缺货？老用户习惯买的东西买不到了，自然就去别的地方买。

价格有没有变化？是不是涨价了？或者同样的商品在竞品那边更便宜？

凑单门槛有没有提高？以前满39免配送费，现在变成满59了吗？门槛提高会影响用户的下单频次。

运营层面：

优惠力度是不是减少了？以前每周都有优惠券，现在变成每月一张了吗？

会员权益是不是缩水了？比如免配送费的门槛提高了、专属优惠减少了。

Push推送是不是变少了或者变得不精准了？用户可能是"忘了"来买菜，而不是主动不买。

这些内部变化往往是慢性的，不容易被发现。但累积起来会显著影响用户体验和粘性。

第四个方向：按品类拆分看频次变化

老用户买的品类结构有没有变化？

我会把老用户的下单品类拆开看：蔬菜、水果、肉类、海鲜、粮油、乳制品、零食饮料.....每个品类的下单频次分别是什么变化？

可能会发现一些有意思的情况：

比如蔬菜的频次稳定，但海鲜和水果的频次明显下降。这可能说明海鲜和水果的品质或价格出了问题，用户去别的地方买这些品类了。

或者生鲜品类的频次都在下降，但日用品的频次在上升。这可能说明用户对我们的定位在改变，从"买菜平台"变成"便利店"。

通过品类拆分，可以定位到具体的问题品类，然后针对性地去查这个品类出了什么问题：是供应商换了？品质下降了？价格涨了？还是竞品在这个品类更有优势？

第五个方向：做用户调研

数据分析能告诉你"是什么"，但不一定能告诉你"为什么"。有些问题必须直接问用户。

我会设计一个定向的用户调研。

调研对象：选取频次下降明显的老用户。比如Q3月均下单6次以上，Q4变成3次以下的用户。

调研方式：可以是电话访谈，也可以是问卷调查。电话访谈能获得更深入的信息，问卷调查能覆盖更多样本。

调研问题：

最近买菜的整体习惯有没有变化？是买得少了还是换地方买了？

如果去了别的平台，是哪个平台？为什么选择那边？

对叮咚最近有什么不满意的地方？是商品、价格、配送还是其他？

如果要让你增加在叮咚的购买频次，需要什么条件？

用户的直接反馈往往能发现数据看不到的问题。比如"最近送的菜不新鲜了""配送员态度变差了""优惠券没以前划算了"这些定性的反馈，在数据里是看不到的。

第六个方向：做留存和流失分析

频次下降可能只是表象，更深层的问题可能是流失。

我会看老用户的留存曲线有没有变化。把Q3和Q4的老用户30天留存、60天留存、90天留存拉出来对比。

如果老用户是"还在用但用得少了"，那问题相对可控，可以通过运营手段拉回来。

如果老用户是"用着用着就不用了"，留存曲线在加速下降，那就是流失问题了，比单纯的频次下降更严重。

对于流失的老用户，要做流失原因分析。在他们流失之前发生了什么？最后一单的体验怎么样？有没有投诉记录？通过这些信息，可以找到流失的具体原因。

第七个方向：做同比和环比分析

最后，要把时间维度拉长来看。

环比分析：Q4比Q3降了，是不是Q3太高了？Q3有没有什么特殊事件（大促、补贴）？

同比分析：今年Q4和去年Q4相比，频次是什么情况？如果同比也在下降，说明问题是持续性的；如果同比还是涨的，说明整体趋势还是好的。

趋势分析：把过去一年每个月的频次画出来，看整体趋势。是一直在降？还是波动性的？还是最近几个月才开始降？

通过时间维度的分析，可以判断这个问题是短期波动还是长期趋势，从而决定应对的紧迫程度。

总结一下排查框架

如果老用户频次下降，我会按这个顺序排查：

第一步，先排除正常因素，看客单价和季节性。

第二步，看外部竞品，有没有被分流。

第三步，看内部变化，产品和运营有没有影响体验的调整。

第四步，按品类拆分，定位具体的问题品类。

第五步，做用户调研，直接问用户原因。

第六步，做留存分析，判断是频次问题还是流失问题。

第七步，做时间维度分析，判断是短期波动还是长期趋势。

每一步都要有数据支撑，有结论判断，最终形成一个完整的诊断报告。不能只是列出可能的原因，要通过数据验证哪个原因是真正的问题所在。

题目 68

贝壳找房发现使用"VR看房"功能的客户，最终成交转化率是未使用用户的3倍。业务部门很兴奋想全量推广，但作为分析师，你如何证明这3倍提升是因为VR功能本身，还是因为本来就有强烈购房意愿的客户才更爱用VR？

解答

第一部分：别被“3 倍转化率”冲昏头脑

老板看到报表兴奋地跑来说：“数据分析师，你看！用了 VR 看房功能的用户，成交转化率是没用过的人的 **3 倍**！这功能太神了，下个季度我们要全量推广，强制引导所有用户都用 VR，这样我们的 GMV 岂不是能翻三倍？”

这时候，作为一名资深数据分析师，你的背脊应该发凉。

为什么？因为这大概率是一个经典的“**自我选择偏差**” (Self-Selection Bias) 陷阱。

你可以给老板举个最通俗的例子：

“老板，穿爱马仕的人平均资产是穿优衣库的人的 100 倍。那如果我们强制给每个穿优衣库的人发一个爱马仕包包，他们的资产就会瞬间翻 100 倍吗？”

显然不会。

- 是“有钱”导致了“买爱马仕”。
- 同样，大概率是“**本来就想买房、意向极高**”的用户，才会花时间去研究 VR、去拖动全景图。
- 而不是 VR 这个功能本身让他们凭空产生了买房的念头。

这 3 倍的差距里，混杂了大量的“**用户本身资质**” (User Intent) 带来的噪音。如果你直接拿这个结论去推全，最后的增量可能微乎其微，甚至因为强行打扰用户导致卸载率飙升。

我们的任务，就是把“**VR 功能真实的因果贡献**”，从这堆混杂的数据里提炼出来。这时候，普通的回归分析已经失效了，我们需要一把手术刀——**工具变量** (Instrumental Variable, IV)。

第二部分：寻找那只“上帝之手”——工具变量 Z

要证明因果，最科学的方法是 A/B Test (RCT)。如果你能**强迫**一组用户必须用 VR，另一组**绝对不许用**，那最好了。

但在现实业务中，你做不到。

你不能拿枪指着用户说“你必须点开 VR”，你也不能把 VR 入口藏起来不让核心用户用（会遭投诉）。

我们处于一种 **Imperfect Compliance**（不完全依从）的状态。

这时，我们需要引入一个**工具变量 Z**。

在贝壳找房的场景下，最好的工具变量 Z，是一个“**随机的鼓励机制**”。

我们可以设计这样一个实验：

- **用户群体随机切分为两半。**
- **Z=0（对照组）**：维持现状，APP 界面正常，VR 入口在详情页二级菜单，不显眼。
- **Z=1（实验组）**：APP 首页增加一个巨大的 Banner —— “VR 看房体验升级，身临其境”。

为什么这个 **Banner (Z)** 是一个完美的工具变量？

我们来检查 IV 的两个核心假设：

1. 相关性 (Relevance)：

- 这个 Banner 会提升 VR 的使用率吗？
- 肯定会。实验组看到广告，点进去试用 VR 的人肯定比对照组多。Z 与 X (使用VR) 强相关。
- 数据检验：我们可以计算第一阶段 F 统计量，通常要求 $F > 10$ 以避免弱工具变量问题。

2. 外生性 / 排他性 (Exclusion Restriction)：

- 这个 Banner 会直接导致用户买房吗？
- 几乎不会。这就一张图片，用户不会因为看了一张图片就掏几百万买房。
- **Banner 影响成交的唯一路径，只能是：Banner -> 用户点了 VR -> VR 体验好 -> 促进成交。**
- 这保证了 Z 只能通过 X 来影响 Y。

第三部分：用 Wald 估计量算出真实 ROI

好了，实验跑了两周，数据出来了（以下为模拟数据，方便计算）：

1. 实验组 (Z=1, 有 Banner)：

- 总人数：100,000 人
- **VR 使用人数 (X=1)**：25,000 人（使用率 25%）
- **最终成交人数 (Y=1)**：2,200 人（成交率 2.2%）

2. 对照组 (Z=0, 无 Banner)：

- 总人数：100,000 人
- **VR 使用人数 (X=1)**：15,000 人（使用率 15%）
- **最终成交人数 (Y=1)**：2,000 人（成交率 2.0%）

现在我们要开始推导了。

如果你只看意向性分析 (ITT, Intention to Treat)：

- 实验组比对照组，成交率提升了 $2.2\% - 2.0\% = 0.2\%$ 。
- 这 0.2% 是 Banner 带来的整体提升。

但老板问的是：“VR 这个功能本身到底有多大威力？”也就是对于那些“真正受影响去用了 VR 的人”，转化率提升了多少？

我们要计算 **LATE (Local Average Treatment Effect)**，使用 Wald 估计量公式：

$$\text{LATE} = (Y_{\text{exp}} - Y_{\text{con}}) / (X_{\text{exp}} - X_{\text{con}})$$

代入数字：

- 分子（Y 的变化，Total Effect）：

$$2.2\% - 2.0\% = +0.2\%$$

(这是 Banner 带来的总成交率提升)

- 分母（X 的变化，Compliance Rate）：

$$25\% - 15\% = +10\%$$

(这是 Banner 带来的 VR 使用率净增量)

- 计算 LATE：

$$0.2\% / 10\% = 2\%$$

结论：

VR 功能对成交转化率的真实因果提升，是 2 个百分点。

第四部分：深度业务解读与决策建议

等一下，我们回头看看题目里说的“3 倍”。

假设基础转化率是 1% 左右。

- 题目现象：VR 用户转化率 3% vs 非 VR 用户 1%。(3 倍，差异 2 个点)。
- 我们算出的 LATE：提升 2 个百分点。

在这个特定的模拟数据下，似乎 VR 真的很有用？

但更常见的情况是：

- Total Effect (分子) 可能非常小，比如只有 0.05%。
- Compliance (分母) 是 10%。
- $LATE = 0.05\% / 10\% = 0.5\%$ 。

这意味着什么？

即使数据表面上显示 VR 用户转化率极高（3 倍），那大多是因为只有真心想买房的人才去用 VR。

真正的 VR 功能，可能只能把转化率从 2.0% 提升到 2.5%（提升 25%），而不是翻 3 倍。

给业务方的最终建议：

1. 别做白日梦：全量推广 VR 绝对不会让 GMV 翻 3 倍。
2. 真实收益评估：根据 Wald 估计量算出的 2%（或 0.5%）的真实 Lift，去乘以全量推广后的预期覆盖人数，这才是你应该 commit 的 KPI。
3. 成本核算：如果拍摄一套 VR 的成本很高，而 LATE 算出来的提升带来的佣金收入覆盖不了成本，那这个功能甚至可能是亏钱的，只能作为品牌建设，不能作为效果工具。
4. 人群策略：既然选择性偏差这么严重，说明 VR 对高潜用户是“刚需”。我们应该把 VR 作为一个“高潜用户筛选器”。谁用了 VR，销售就重点跟进谁，而不是试图逼迫那些随便看看的人去用 VR。

总结知识点

1. **选择性偏差 (Selection Bias)**: 观测到的相关性往往被混杂因素（如用户意愿）污染。
2. **工具变量 (IV)**: 寻找一个只通过 X 影响 Y 的外生变量 Z。
3. **鼓励性设计 (Encouragement Design)**: 在无法强制用户行为时，通过随机投放广告/入口作为 IV。
4. **Wald 估计量**: $\text{因果效应} = \frac{\text{结果的差异}}{\text{行为的差异}}$ 。

追问

如果我没法做 A/B 实验（不能发 Banner），能不能用“用户所在小区的网络宽带速度”或者“用户手机型号”做工具变量？

追问解答

这是一个非常精彩的脑洞，也是面试中经常考察的“**自然实验 (Natural Experiment)**”思路。当无法进行人工干预（RCT/A/B Test）时，我们试图在观测数据中寻找天然的工具变量。

我们来逐一审核这两个候选 IV 的资格：

候选一：用户手机型号 (是否是旗舰机)

假设逻辑：

- 旗舰机性能好 -> 跑得动 VR -> 用户更倾向于用 VR (相关性 $\checkmark$)
- 手机型号 -> 不直接决定是否买房 (外生性 ?)

审核结果：不合格 (Fail)。

原因：违背了外生性 (Exclusion Restriction)。

用旗舰机的人，通常经济实力更强。经济实力强的人，本身购房的预算和成交概率就更高。

这里存在一条**后门路径 (Back-door Path)**：

手机型号 (Z) <--- 经济实力 (U) ---> 买房 (Y)

Z 和 Y 即使不通过 X (VR) 也有强相关。如果你用手机型号做 IV，你算出来的“VR 效果”里，其实混入了大量的“这是个有钱人”的效应。这会让你的结论严重偏高。

候选二：用户所在区域的瞬时网络速度 (4G/5G/WiFi 信号强度)

假设逻辑：

- 网速快 -> VR 加载快 -> 用户更愿意用 VR；网速慢 -> VR 转圈圈 -> 用户放弃 (相关性 $\checkmark$)

- 网速快慢 -> 与用户是否想买房无关 (外生性 ?)

审核结果：勉强合格，但有风险 (Borderline)。

优势：

瞬时的网络波动（比如此时此刻信号塔拥堵）相对于用户的经济实力来说，确实比较随机。一个有钱人也可能走进电梯没信号。

风险 (Exclusion 挑战)：

1. **长期的区域性偏差**：如果“网速快”是因为用户住在市中心豪宅区（基站密），而“网速慢”是因为用户住在远郊。那“网速”又变成了“地段/经济实力”的代理变量，再次违背外生性。
2. **体验溢出**：网速慢不仅影响 VR，还影响看普通图片、看视频、甚至跟经纪人聊天的体验。
如果 网速慢 -> 图片打不开 -> 用户流失 -> 不买房。
那么 Z (网速) 就不仅仅通过 X (VR) 影响 Y，它还通过其他路径影响 Y。这也违背了排他性。

最佳实践建议：寻找更纯粹的“技术故障”

在非实验环境下，最好用的 IV 往往来自“随机的系统故障”或“随机的规则边界”。

例子：

假设贝壳的系统曾经在某周二下午，因为 CDN 故障，导致身份证号尾号为奇数的用户无法加载 VR 功能，而偶数用户正常。

这就是一个完美的 **自然实验 (Natural Experiment)**！

- **Z (身份证尾号奇偶)**：完全随机，跟有钱没钱无关。
- **X (能用VR吗)**：奇数不能，偶数能。强相关。
- **Y (买房)**：身份证尾号显然不决定买房。

你可以直接比较这两组用户在那段时间的转化率差异，除以 VR 使用率的差异。这比用手机型号、网速都要干净得多、科学得多。

总结：

在寻找 IV 时，**外生性 (Exclusion)** 是最大的拦路虎。永远要问自己：“这个变量 Z，除了影响 X，真的没有任何其他路径能碰到 Y 吗？”如果有一丝犹豫，这个 IV 就不能用。

题目 69

视频号在做“点击率(CTR)”优化的AB实验。实验组CTR提升了2%，显著性检验 $p < 0.05$ 。但是，直接对CTR（点击/曝光）做t检验不仅不严谨，还可能犯错。为什么？在比率型指标（Ratio Metrics）的统计检验中，你应该用什么方法（Delta Method / Bootstrap）

解答

第一部分：一个价值上亿的统计学陷阱

想象一下，你在视频号团队。

算法工程师上线了一个新模型，A/B 测试跑了一周。

后台显示：

- 实验组 CTR：5.1%
- 对照组 CTR：5.0%
- **显著性检验：p-value = 0.03 (< 0.05)**

工程师开香槟庆祝：“提升显著！全量上线！”

作为数据分析师，你冷静地看了一眼计算逻辑，发现他直接用了普通的 **t-test**（或者 **Chi-square test**）来算 p 值。

你立刻叫停：“别急着全量，这个 p 值是假的，真实的 p 值可能高达 0.2。”

工程师惊了：“为什么？教科书上不都这么教的吗？”

这个问题如果不解决，公司可能会把大量无效甚至负向的策略推全，长期损失不可估量。

第二部分：为什么普通 t 检验会失效？

核心矛盾在于：随机分组的单位 (**Randomization Unit**) 和 分析的单位 (**Analysis Unit**) 不一致。

1. 随机化单位是“人”：我们按 User ID 把用户分进实验组和对照组。
2. 分析单位是“曝光”：CTR = Sum(Clicks) / Sum(Views)。

普通 t 检验的致命假设是：样本之间是“独立同分布” (i.i.d.) 的。

但在 CTR 计算中，分母是 View。

- 用户小明看了 100 个视频，点了 10 个。
- 用户小红看了 1 个视频，点了 0 个。

小明的这 100 次 Views，是高度自相关的。小明的个人喜好决定了他这 100 次大概率行为一致。

如果你把小明的 100 次 Views 拆散，当成 100 个独立的陌生人来算 Variance，你就人为地增加了样本量 (N)。

- 统计学常识：样本量 N 越大，方差 (Variance) 越小，标准误 (SE) 越小。
- SE 越小，t 统计量 $(\text{Mean_diff} / \text{SE})$ 就越大。
- t 越大，p 值就越小。

所以，忽略用户层面的相关性，会导致你严重低估方差，算出一个虚假偏小的 p 值。

这就叫 **False Positive (第一类错误) 膨胀**。你以为你发现了宝藏，其实只是噪音。

第三部分：正确的打开方式——Delta Method

CTR 本质上是两个随机变量的比值：

$$\text{CTR} = \text{mean}(\text{Clicks}) / \text{mean}(\text{Views}) = \bar{X} / \bar{Y}$$

注意，这里的 X (点击) 和 Y (曝光) 都是变量，而且 X 和 Y 是相关的（看的多通常点得多）。

要正确计算 $\text{Var}(X/Y)$ ，我们需要用到 **Delta Method**（利用泰勒级数展开来近似）。

公式虽然看起来吓人，但逻辑很清晰：

$$\text{Var}(R) \approx (1/\bar{Y})^2 * \text{Var}(X) + (\bar{X}/\bar{Y}^2)^2 * \text{Var}(Y) - 2(\bar{X}/\bar{Y}^3) * \text{Cov}(X, Y)$$

翻译成人话：

比率的方差，不仅取决于分子（点击）的方差，分母（曝光）的方差，还取决于分子分母的协方差 (Covariance)。

在实际业务中（Python/SQL 实现时），我们通常做**线性化 (Linearization)** 处理：

构造一个新的变量 z_i (用户 i 的线性化残差)：

$$z_i = X_i - R_{\text{global}} * Y_i$$

其中 X_i 是用户 i 的总点击， Y_i 是用户 i 的总曝光， R_{global} 是整体 CTR。

然后对这个 z_i 做普通的 t 检验。这样就回归到了“用户层级”的计算，完美解决了独立性问题，同时也保留了 View 加权的特性。

第四部分：另一种武器——Bootstrap (自助法)

如果你觉得 Delta Method 的公式太难解释给业务方听，还有一个更直观的方法：**Bootstrap**。

它的逻辑是“大力出奇迹”：

1. 假设你有 1 万个用户。
2. **Resample**：随机从这 1 万人里，有放回地抽取 1 万人（有的人会被抽中多次，有的 0 次）。
3. **Calculate**：用这抽出来的 1 万人，算出他们的总 Clicks / 总 Views，得到一个新的 CTR'。
4. **Repeat**：重复搞 1000 次，你就得到了 1000 个 CTR'。
5. **Distribution**：直接看这 1000 个值的分布，掐头去尾（比如取 2.5% 和 97.5% 分位点），就是 95% 置信区间。

如果 0 不在这个区间里，那就是真的显著。

Bootstrap 的好处是**不依赖正态分布假设**，对各种奇形怪状的指标都适用（比如中位数、99 分位数）。缺点是**计算成本高**，数据量几亿行的时候跑不动。

第五部分：总结与建议

作为分析师，下次看到 CTR、CVR、人均时长 (Total Time / Total Users) 这类**比率型指标 (Ratio Metrics)** 的 p 值时，请务必多问一句：

“这个 p 值是怎么算的？是把曝光当分母直接算的，还是用了 Delta Method？”

如果是前者，请毫不留情地打回重算。
因为宁可错过一个平庸的策略 (Type II Error)，也不能全量一个实际上无效甚至有害的策略 (Type I Error)。前者只是少赚，后者是白忙活甚至亏钱。

总结知识点

1. 独立性假设 (Independence Assumption): t 检验要求样本独立，用户内的多次行为不独立。
2. 比率型指标 (Ratio Metric): 分母也是随机变量的指标，方差计算需特殊处理。
3. Delta Method: 利用泰勒展开近似计算比率方差，工业界最常用。
4. Bootstrap: 重抽样模拟分布，计算量大但稳健。
5. 第一类错误 (Type I Error): 假阳性，低估方差会导致误报显著。

追问

既然 Global CTR (总点击/总曝光) 算起来这么麻烦，我能不能直接算“用户平均 CTR”？也就是把每个人的 CTR 算出来，然后求平均值。这样单位就是“人”了，能不能直接用 t 检验？

追问解答

这是一个非常经典且极具迷惑性的替代方案。
答案是：技术上可以（满足 t 检验假设），但业务上通常不建议（指标含义变了）。
我们来拆解一下这两个指标的区别：

1. 定义区别

- **Global CTR (聚合 CTR):**
$$\text{Sum(所有人的点击)} / \text{Sum(所有人的曝光)}$$

这是大盘视角的 CTR。它等价于“每一次曝光的平均点击概率”。
- **User Average CTR (人均 CTR):**
$$\text{Mean}(\text{User A CTR}, \text{User B CTR}, \dots)$$

这是用户视角的 CTR。它等价于“每一个用户的平均点击意愿”。

2. 为什么它们不相等？（辛普森悖论的影子）

Global CTR 会天然地对“活跃用户”加权。
举个极端的例子：

- 活跃用户大明：看了 100 个视频，点了 10 个。CTR = 10%。
- 不活跃用户小红：看了 1 个视频，点了 1 个。CTR = 100%。

计算 Global CTR:

$$(10 + 1) / (100 + 1) = 11 / 101 \approx 10.9\%$$

(接近大明的水平，因为大明贡献了绝大多数曝光)。

计算 User Average CTR:

$$(10\% + 100\%) / 2 = 55\%$$

(被小红的 100% 严重拉高)。

3. 业务影响：你到底想要什么？

如果你的老板看重的是“整体流量的变现效率”（比如广告收入，只要有点击就有钱），那么 **Global CTR** 才是对的。

因为大明贡献了 101 次机会中的 100 次，他的表现理应主导大盘。如果你用 User Average CTR，你会错误地以为系统 CTR 高达 55%，实际上大盘只有 10.9%。

如果你的老板看重的是“普惠 / 用户体验”（比如希望每个用户都能看到感兴趣的），那么 **User Average CTR** 也有道理。

因为它赋予了每个用户（无论活跃与否）平等的权重。

4. 统计学上的坑：User CTR 的噪声极大

选用 User Average CTR 还有一个巨大的实操坑：分母为 1 或极小的用户方差极大。

- 看 1 个点 1 个 -> CTR 100%
- 看 1 个点 0 个 -> CTR 0%

大部分长尾用户的 CTR 要么是 0 要么是 1。这会导致数据的分布呈现极端的双峰 (Bimodal) 或 零膨胀 (Zero-inflated) 形态，虽然 t 检验对正态性不敏感（大数定律），但极端的方差会降低实验的灵敏度 (Power)。通常处理这种 User CTR 时，需要加平滑 (Smoothing) 或者剔除低活跃用户，这又引入了新的人为偏差。

结论

不要为了“好算 p 值”而篡改指标定义。

如果是为了衡量系统效率（推荐流、广告），**必须用 Global CTR**，并乖乖使用 Delta Method 或 Bootstrap 算显著性。

如果是为了衡量人均满意度，可以用 User Average CTR，但要小心低活用户的噪音干扰。

题目 70

欧莱雅在2025年双11投放了5000万预算。

复盘时，如何区分哪些用户是"不投也会买"的自然转化，哪些是"投了才买"的营销增量？如何找到真正的"说服型"用户？

解答

第一部分：不仅是“浪费”，更是“亏损”

2025 年双 11，欧莱雅投放了 5000 万预算。复盘时发现 ROI 还可以。
但是，CFO 挑战了一个灵魂问题：
“在这个 ROI 里，有多少人是**本来就要买的**？我们是不是花钱买了本来就属于我们的业绩？”

这是一个极其普遍的营销误区。
传统的 Look-alike 或 CTR/CVR 模型，预测目标是 $P(Y=1 | X)$ —— **谁最爱买**？
算法当然会告诉你：“那些昨天刚搜过、购物车里放了 3 件商品、过去一年买了 10 次的忠诚用户，最爱买。”
于是，你把最贵的广告、最大力度的 8 折券，推给了这群“铁粉”。
结果呢？

- 铁粉本来准备原价买，看到 8 折券，高兴地省了 20% 的钱。
- 对公司来说，这 20% 是纯纯的利润损失。

我们真正想找的，不是“最爱买的人”，而是“**会被广告改变的人**”。
这就是 **Uplift Modeling (营销增效模型)** 的战场。

第二部分：营销四象限策略

Uplift Model 的核心公式极其简单，却直击灵魂：
 $Lift(x) = P(Buy | 有广告, x) - P(Buy | 无广告, x)$

根据这个 Lift 值，我们把 5000 万预算的目标人群切分为著名的**四象限**：

1、Persuadables (摇摆党 / 说服型)

- 特征： $Lift > 0$ (显著正值)。
- 行为：没广告不买，有广告才买。
- 策略： **All-in!** 这是预算的唯一归宿。他们是真正的 ROI 贡献者。

2、Sure Things (铁粉 / 必买型)

- 特征： $Lift \approx 0$ ，但 $P(Buy)$ 极高。
- 行为：不管有没有广告，大概率都会买。
- 策略： **停止投放!** 或者只做最低成本的触达。把发给他们的优惠券省下来，利润率瞬间提升。

3、Lost Causes (路人 / 无感型)

- 特征： $Lift \approx 0$ ，且 $P(Buy)$ 极低。

- 行为：怎么撩都不买。
- 策略：放弃。别浪费钱。

4、Sleeping Dogs (反感者 / 沉睡狗)

- 特征： $Lift < 0$ (负值!)。
- 行为：本来可能想买，看了烦人的广告反而想退订/拉黑。
- 策略：绝对隔离！千万别去唤醒他们。

第三部分：如何训练这个“读心术”模型？

普通的机器学习模型 (GBDT/LR) 只能预测结果 Y ，不能预测“增量”。
要训练 Uplift Model，你必须拥有“反事实” (Counterfactual) 的数据能力。

这意味着，在双 11 预热期，你必须进行一场严谨的 RCT (随机对照实验)：

- 实验组 (Treatment)：随机抽取 100 万人，正常投放广告。
- 对照组 (Control)：随机抽取 100 万人，完全不投广告（或者投无关的公益广告 PSA，以保持曝光环境一致）。

收集好数据后，我们有几种建模流派：

1. Meta-Learners (T-Learner / S-Learner)：

简单粗暴。训练两个模型。

- 模型 A：只用实验组数据，学 $P(Y|T=1)$ 。
- 模型 B：只用对照组数据，学 $P(Y|T=0)$ 。
- 预测时： $Uplift = \text{模型A预测值} - \text{模型B预测值}$ 。

2. Uplift Trees / Causal Forests (树模型改进)：

这是进阶玩法。在构建决策树时，分裂节点的标准不再是“信息增益 (Information Gain)”，而是“组间差异最大化 (Maximize Difference in Lift)”。

比如，按照“年龄 < 25”切一刀，如果左边叶子节点 T 组和 C 组差异巨大，右边没差异，那这就是一个好的特征。

第四部分：评估与实战坑点

训练好了，怎么证明模型好？看 AUC 吗？

错！AUC 只能评估“预测买不买”准不准，评估不了增量。

我们需要看 Qini Curve 或 AUUC (Area Under Uplift Curve)。

简单说，就是把用户按预测的 Uplift 分数从高到低排序，看看如果我们只投 Top 10%、Top 20%... 的用户，累计带来的纯增量订单是多少。

一条优秀的 Uplift 曲线，应该像弓背一样高高隆起，意味着模型精准地把 Persuadables 抓到了最前面。

实战中的坑：

- **对照组污染**：如果你想保留 10% 的人完全不看欧莱雅广告，这在全渠道环境下很难。用户可能在朋友圈没看到，但在小红书看到了。这会稀释实验效果。
- **数据稀疏**：Conversion 通常是稀疏事件，Difference 更是稀疏中的稀疏。Uplift Model 需要极大的样本量才能收敛。

总结知识点

1. **Uplift vs Response**：Response 找高概率（含铁粉），Uplift 找高增量（摇摆党）。
2. **四象限策略**：重点投 Persuadables，放弃 Sure Things 和 Lost Causes，避开 Sleeping Dogs。
3. **Meta-Learners**：T-Learner (Two models), S-Learner (Single model with feature T)。
4. **AUUC / Qini**：评估增量模型好坏的专用指标。

追问

训练 Uplift 模型时，我们只有“用户 A 在实验组买了”或者“用户 B 在对照组没买”的数据。对于单独一个用户，我们无法同时观测到他“看广告”和“不看广告”的两个结果（反事实问题）。那模型怎么打标签（Label）呢？

追问解答

这是一个触及因果推断核心的问题：“因果推断的根本缺失问题”。

是的，我们永远无法知道：如果那个“看了广告买了”的用户 A，**当时没看广告**会不会买。上帝只给了我们一条时间线。

所以，Uplift Model **从根本上就不是在预测单个用户的标签**，而是在预测**一类相似人群的平均概率差**。

1. 既然没有个体 Label，Loss Function 怎么算？

在传统的监督学习中，我们有真实标签 Y_{true} ， $Loss = (Y_{pred} - Y_{true})^2$ 。

在 Uplift 中，我们没有 $Lift_{true}$ 。

所以，我们使用了一种转化的思路，叫 **Transformed Outcome (变换因变量)**，或者叫 **Class Transformation Method**。

构造一个新的变量 Z ：

- 如果用户在实验组 ($T=1$) 且买了 ($Y=1$)： $Z = 1$
- 如果用户在实验组 ($T=1$) 且没买 ($Y=0$)： $Z = 0$
- 如果用户在对照组 ($T=0$) 且买了 ($Y=1$)： $Z = -1$ (注意这里！)

- 如果用户在对照组 (T=0) 且没买 (Y=0): $Z = 0$

(注: 具体编码方式有多种, 比如 Layman 提出的 $Z = Y * (T - P(T)) / (P(T) * (1 - P(T)))$)

数学上可以证明, 预测这个变量 Z 的期望, 等价于预测 **Uplift**。

即 $E[Z | X] = P(Y|T=1) - P(Y|T=0)$ 。

这样, 我们就把一个“无标签的因果问题”转化为了一个“有标签的回归问题”。你可以直接用 XGBoost 去拟合这个 Z 。

2. 树模型 (Uplift Trees) 的处理方式

如果你用树模型 (如 Causal Forest), 逻辑更直观。

树模型不需要给单个样本打标签。它只需要把相似的人归到一个叶子节点里。

当决策树分出一个叶子节点 (比如: 25岁女性, 一线城市), 这个节点里可能有 1000 人:

- 500 人是实验组, 转化了 50 人 (10%)。
- 500 人是对照组, 转化了 20 人 (4%)。

那么, 这个叶子节点里所有人的 **Uplift 预测值**, 就是 $10\% - 4\% = 6\%$ 。

只要样本量够大, 群体层面的统计规律就是稳定的。

我们不需要知道“具体某个用户”的反事实, 我们只需要知道“这类用户”作为一个群体的反事实差异。

3. 怎么验证模型准不准?

既然没有真实标签, 做测试集验证的时候也很痛苦。我们不能算 MSE (均方误差)。

我们只能算“排序能力”。

也就是前面提到的 Qini Coefficient。

- 按模型预测的 Uplift 分数把测试集用户从高到低排队。
- 把他们切成 10 份 (Deciles)。
- 计算每一份里真实的 $(Y_{exp} - Y_{con})$ 。
- 如果模型准, 那么第一份 (分数最高) 的真实增量应该最大, 最后一份应该最小 (甚至为负)。

结论

我们确实无法给单个数据点打上“增量标签”。

我们要么是通过 **Transformed Outcome** 做数学变换, 要么是通过 **Uplift Trees** 做群体切分。

因果推断的本质, 就是利用群体的统计规律去推测个体的潜在命运。

题目 71

米哈游《原神》近期发布大版本后, DAU创历史新高, 但人均日游戏时长却下降了10%, 策划怀疑是新版本内容太少, 作为数据分析师, 你觉得可能是什么原因?

解答

很多策划看到“人均时长下跌 10%”就慌了，觉得是“内容不够吃”或者“版本不好玩”。
但作为数据分析师，我们要做的第一件事，是先把数字算清楚，把“平均值”这个最大的骗子给拆穿。

第一步：回归指标定义，寻找数学上的“稀释效应”

我们先看核心公式：
$$\text{人均日游戏时长} = \text{当日全服总游戏时长} / \text{当日 DAU}$$

题目给了两个关键信号：

1. DAU 创历史新高（分母激增）。
2. 人均时长下降 10%（比值下降）。

这在数学上只有一种解释：分子的增长速度，慢于分母的增长速度。
但这并不意味着分子（总时长）没有涨，也不意味着核心体验出了问题。最常见的情况是：分母里混入了大量“低时长”的人群，把平均值给拖累了。

这在统计学里叫做“辛普森悖论”（Simpson's Paradox）：即在各个分组中趋势都是向好的，但合并在一起看，趋势却是向坏的。

第二步：用户分层拆解，还原真实业务场景

为了验证这个假设，我们必须把 DAU 这块大饼切开。在这样的大版本更新节点，DAU 的构成通常会发生剧烈变化。我们要把用户拆解为三类：

- 1、核心老玩家（Active Users）：
这批人一直在玩，新版本开了新地图（须弥），他们通常会进入“肝帝”模式，疯狂跑图、做任务。
他们的预期时长：应该是暴涨的（比如从日常 15 分钟 -> 120 分钟）。
- 2、回流用户（Resurrected Users）：
被新版本铺天盖地的广告喊回来的退坑玩家。
他们的特征是：上来领个回归奖励，抽两发卡，或者跑两步发现地图太复杂这就下线了。
他们的预期时长：极短（可能只有 10-20 分钟）。
- 3、新增用户（New Users）：
刚注册的小萌新。
他们的特征：还在过新手教程，或者因为手机配置不够、更新包太大等原因，体验受阻。
他们的预期时长：波动极大，整体偏低。

推理时刻：
假设老玩家有 1000 万，今天人均玩 2 小时（极高）。
假设回流玩家来了 500 万（宣发太成功了！），但人均只玩 0.5 小时。
当你把这两拨人混在一起算“人均”时，这 500 万“低时长”用户会瞬间把大盘的平均值拉下来。

所以，时长下降，恰恰可能证明了——你们的市场宣发太成功了，拉来了海量的回流和新用户！

第三步：结合新版本须弥版本的特殊性进行“归因排查”

除了用户结构，我们还要结合《原神》新版本的实际落地情况，排查一些非业务因素：

1、更新耗时问题：

新版本是个巨型版本，手机端更新包动辄几个 G。

如果数据口径是“进入游戏世界才开始计时”，那么大量用户可能卡在了“下载资源”界面。如果有 10% 的用户因为更新太慢直接放弃了，这部分 0 时长用户会极大地拉低平均值。

2、体验门槛问题（须弥的森林书）：

新版本的主线任务（森林书）以“又长又难”著称。

我们要看“任务放弃率”。是不是有一部分轻度玩家，因为任务引导太繁琐，玩了 30 分钟产生挫败感下线了？如果是这种情况，那就是设计问题了。

第四步：给出结论与建议

基于以上分析，我会给策划这样的反馈：

1、别看大盘平均值：

立刻把“人均时长”按用户分层拆开看。

只要“核心老玩家”和“高等级回流用户”的人均时长是上涨的（比如环比上周涨了 50%），那说明新版本内容质量没问题，非常硬核。

2、定性大盘下跌：

大盘下跌大概率是“结构性稀释”造成的。这说明 UA（获客）团队立功了，而不是策划背锅。

3、关注转化漏斗：

重点去盯那批“时长很短”的回流用户。他们为什么只玩了 20 分钟就走了？是卡池不吸引人？还是手机太卡？还是更新太慢？这才是接下来的优化重点。

好了，分析到这里，相信你已经帮策划解开了心结。

这时候，作为面试官，我会接着追问你一个问题：

“既然人均时长这个指标被新用户稀释了，失效了，那在新版本上线头三天，你建议我看哪个指标，来最准确地判断‘新版本内容好不好玩’？”

追问解答

标题：指标失效后，如何精准衡量“好不好玩”？

你好，我是你的数据分析陪练。上一篇我们聊了为什么“人均时长”在 3.0 版本上线初期会失真（辛普森悖论）。既然这个万能指标失效了，老板和策划又急着要结论：这版本到底成没成？内容到底够不够？

这时候，你不仅要能指出旧指标的问题，更要能提出新指标来救场。这就是面试官追问你的核心意图——考察你的指标体系搭建能力。

回答这个问题的思路，要从“内容的消耗深度”和“用户的沉浸意愿”两个维度出发。

一、替代“时长”的黄金指标：分层后的“内容消耗率”

既然“时长”会被挂机、发呆、聊天等行为注水，那我们直接看“干货”的消耗情况。

1. 核心任务完成率（Quest Completion Rate）

针对 3.0 版本的主线任务（比如森林书第一章）。

我们看核心玩家（比如等级>55级）在首日的“任务通关率”。

如果 80% 的核心玩家都在首日一口气肝完了主线，说明剧情紧凑、吸引力强。

反之，如果很多人接了任务，做到第二步就停在野外了，那说明任务引导或者剧情吸引力出了大问题。

2. 核心资源解锁率（Teleport Waypoint Unlock Rate）

在开放世界游戏里，“开了多少个传送锚点”或者“开了多少个七天神像”，是衡量玩家探索欲望的最直观指标。

我们可以定义一个指标：首日解锁 50% 以上新地图锚点的用户占比。

这个指标越高，说明地图设计的探索感越强，玩家越“停不下来”。

二、衡量“粘性”的进阶指标：DAU/MAU 并不够

通常大家会说看留存，但留存是滞后指标（要等明天、后天）。当天就要结论，怎么办？

1. 此时段在线率（Intraday Stickiness）

看同一个用户，在一天内上线了多少次。

或者看“单次游戏时长”的分布。

如果一个版本不好玩，玩家可能上线一次，领完原石就下线了。

如果版本好玩，玩家可能会：早上上班路上玩半小时，中午吃饭玩半小时，晚上回家肝 3 小时。

所以，“日均登入次数”变多，且“晚间黄金时段在线时长占比”提升，是内容优质的强信号。

2. 甚至可以看“溢出时长”

对于《原神》这种有体力限制（树脂）的游戏。

如果玩家在“体力耗尽”之后，依然在线超过 1 小时。

这说明什么？说明他在锄大地、在看风景、在过剧情，而不是纯粹为了“打工”刷材料。

这部分“无收益游戏时长”，才是衡量内容质量的试金石。

三、总结

所以，如果我是分析师，我会建议看这就看这三个数：

1. 核心老玩家的主线任务推进进度（判断剧情吸不吸引人）。
2. 新地图锚点的点亮比例（判断地图设计好不好）。
3. 体力耗尽后的额外在线时长（判断是单纯刷刷刷，还是真的在享受内容）。

用这三个维度，足以在“人均时长”失效的情况下，给老板一个精准的定性结论。

题目 72

为什么在跑A/B实验之前，必须先跑一周A/A测试？如果A/A测试的p值小于0.05，说明了什么问题？

解答

我们先把大方向捋一下。

业务方通常会挑战你：“时间就是金钱，为什么要浪费一周流量去做无用功？”

你的回答必须一针见血：A/A 测试不是为了测策略，而是为了测“尺子”。如果尺子是弯的，量出来的所有数据都是垃圾。

第一步：什么是 A/A 测试？它在测什么？

A/A 测试，俗称“空跑”或“白测”。

也就是把流量随机分成两组（Control A 和 Control B），但对这两组用户 **不施加任何策略变动**。他们看到的产品界面、算法推荐、优惠力度完全一样。

我们在测什么？我们在测三样东西：

1. 随机分流系统的均匀性（Sanity Check）：系统是不是真的做到了“随机”。
2. 基础指标的天然波动（Variance）：现在的用户大盘，天然的转化率波动大概是多少。
3. 第一类错误率（Type I Error Rate）：验证统计检验工具本身是否准。

第二步：深度解析 $P < 0.05$ 的灾难性含义

题目问：如果 A/A 测试跑出来 P 值小于 0.05，说明了什么？

这在统计学上是一个非常危险的信号。

我们要回到 P 值的定义：

P 值 = 在两组完全没区别的前提下，单纯靠运气跑出这么大差异的概率。

在 A/A 测试中，两组确实是完全没区别的（因为我们啥也没干）。

如果你算出来 $P < 0.05$ ，只有两种解释：

解释一：你的分流系统有严重的 Bug（Systematic Bias）

这是最常见的情况（90% 的可能性）。

- 哈希算法冲突：比如你的分流算法导致 A 组全是 iPhone 用户，B 组全是安卓用户。
- 缓存污染：A 组用户可能命中了旧版本的缓存，B 组没有。

- 样本比率失衡（SRM）：你设定 50% vs 50% 分流，结果实际跑出来是 48% vs 52%。
这种情况下的 $P < 0.05$ ，意味着“起跑线不一样”。A 组可能天生就比 B 组转化率高 10%。如果你这时候上策略，你根本不知道提升是策略带来的，还是 A 组“自带”的。
结论：严禁开启正式实验，必须找工程团队修 Bug。

解释二：你撞上了那 5% 的“倒霉运”（Random Chance）

这是统计学的本质——第一类错误（Type I Error，假阳性）。

即使系统完美无缺，做 100 次 A/A 测试，理论上也会有 5 次（当置信水平为 95% 时）跑出显著差异。

这就是概率的玩笑。

结论：如果你确信系统没问题，可以重新洗牌（Re-hash / Re-randomize）用户 ID，再跑一次。如果还是 $P < 0.05$ ，请回到解释一。

第三步：业务场景推演（带数字）

假设你在测一个“购买按钮变色”的实验。

在没变色之前（A/A 阶段）：

- A 组转化率：2.0%
- B 组转化率：2.5%
- P 值：0.03（显著！）

这时候如果你不看 A/A 数据，直接把 B 组按钮改成红色。

结果 B 组转化率变成了 2.6%。

你会高高兴兴地汇报：“红色按钮提升了 30% 的转化率（2.0% -> 2.6%）！”

但实际上，红色按钮可能只有 0.1% 的微弱提升（2.5% -> 2.6%），甚至可能是负向的。

那个 0.5% 的巨大差距，是分组不均带来的“噪音”，而不是策略带来的“信号”。

这就是不做 A/A 测试最大的风险：你会把“系统误差”当成“业务收益”，导致错误的决策满天飞。

第四步：怎么救？

如果 $P < 0.05$ ，作为分析师，你的标准动作流程是：

1. 检查 SRM（Sample Ratio Mismatch）：先看样本量比例是不是严格的 50:50。如果样本量都对不上，肯定是分流服务挂了。
2. 切割维度查看（Slicing）：把数据按 平台（iOS/Android）、城市、新老用户 切开。看看是不是某个特定维度出现了偏差。
3. 重新分流（Re-randomization）：换一个随机种子，重跑。

好了，讲到这里，你应该明白了 A/A 测试就是实验系统的“校准器”。

这时候，作为面试官，我会追问你一个更刁钻的实战问题：

“刚才你提到了 SRM（样本比率失衡），如果我在跑 A/B 实验（不是 A/A）的时候，发现 A 组有 100 万人，B 组只有 98 万人，样本量明显不对等（ $P < 0.001$ ），但我算出来的转化率差异又是显著的。这实验结果能用吗？为什么？”

追问解答

现在面试官把你推到了一个更尴尬的境地：实验已经跑完了，或者跑了一半，发现出现了 SRM（Sample Ratio Mismatch，样本比率失衡）。

这是一个极高频的“实验事故”。很多新手分析师会说：“100万 和 98万，差得也不多嘛，才 2%，应该不影响转化率的计算吧？既然转化率显著，那就采信呗。”

这是大错特错的。

一旦出现 SRM，实验结果通常直接判死刑。

一、什么是 SRM？为什么它比你想象的严重？

假设你配置的流量分配是 50% vs 50%。

理论上，当样本量达到百万级时，A 组和 B 组的人数应该极度接近，差异通常在 0.1% 以内。

如果出现了 100万 vs 98万（差了 2%），在统计学上，这绝对不是随机波动，而是系统性丢失。

那 2万个 B 组用户去哪了？

这才是问题的核心。这 2万个消失的用户，绝不是随机消失的，而是被“过滤”掉的。

二、消失的用户通常是谁？（业务侦探环节）

我们要推演一下，什么原因会导致用户在 B 组“消失”（即没有被埋点记录到，或者没进入实验桶）。

场景假设：

B 组是“新功能组”（加载了一个复杂的 3D 模型），A 组是“对照组”（无模型）。

只有当页面完全加载成功，才会上报“进入实验”。

可能性：

B 组的那 2 万个用户，可能是用低端机（性能差）的用户，或者是弱网环境的用户。

因为加载 B 组的 3D 模型太卡了，导致 App 崩溃了，或者加载超时了。

这些用户还没来得及上报“进入实验”，就已经退出了，或者根本没加载出来。

三、为什么这会导致结果不可信？

现在来看看剩下的用户：

- A 组（100万）：包含了 高端机 + 低端机 用户。
- B 组（98万）：只剩下了 高端机 用户（因为低端机用户崩了，没计入分母）。

这时候你算转化率：

B 组全是高端机用户，购买力本来就强。A 组被低端机用户拉低了平均值。

就算 B 组的 3D 模型做得像坨屎，B 组的转化率可能依然高于 A 组。

这叫“幸存者偏差”（Survivorship Bias）。

你比较的不再是“有策略 vs 无策略”，而是“高端用户 vs 全量用户”。

这完全破坏了 A/B 实验的“唯一变量原则”。

四、总结与补救

所以，回答面试官：

不能用！绝对不能用！

一旦出现统计显著的 SRM（比如卡方检验 $P < 0.001$ ），无论实验组的转化率涨了多少，都必须视为无效数据。

补救措施：

1. 必须查明那 2% 的人为什么丢了。是 Crash 了？是过滤逻辑写错了？还是日志上报延迟？
2. 如果能精准找到 A 组中对应的“低端机用户”，把他们剔除掉，强行配平（但这很难做到完美）。
3. 最稳妥的办法：修复 Bug，重开实验。

记住：SRM 是实验分析的第一道“死刑判决书”，看到它，直接拒收报告。